

基于融合聚类和 RBF-SVM 的固体氧化物燃料电池系统故障识别

蔡仕云¹, 吴肖龙^{1†}, 李 豫¹, 李 曦²

1. 南昌大学 信息工程学院, 江西 南昌 330031;
2. 华中科技大学 人工智能与自动化学院, 湖北 武汉 430074

收稿日期: 2025-04-11 † 通信联系人 E-mail: xiaolongwu@ncu.edu.cn

基金项目: 国家自然科学基金(62203204); 江西省自然科学基金(20212BAB212013)

第一作者: 蔡仕云, 男, 硕士生, 现从事固体氧化物燃料电池健康管控研究。E-mail: 416100220204@email.ncu.edu.cn

摘 要: 为了准确识别固体氧化物燃料电池(SOFC)系统故障, 克服传统方法参数难以确定、结果偶然性大和难以运用复杂数据处理的问题, 提出了一种基于融合聚类和径向基核函数支持向量机(RBF-SVM)的故障识别方法。该方法使用基于融合机制的聚类算法对 SOFC 系统重整器催化剂性能衰退故障数据进行处理, 得到不同故障等级下的聚类标签, 再使用 RBF-SVM 算法对划分后的故障数据进行训练, 得到故障识别模型。该模型能够将故障特征信息映射到更高维空间以提升故障识别能力, 并进一步用于空气和燃料泄露故障识别。实验结果表明, 所提融合聚类算法能很好地划分故障, RBF-SVM 故障识别模型对重整器催化剂退化故障的识别准确率达到 99.3%, 对空气泄漏和燃料泄漏故障的识别率分别达到 99.9% 和 99.4%。

关 键 词: 固体氧化物燃料电池(SOFC); 故障识别; 融合聚类; 径向基函数支持向量机(RBF-SVM)

中图分类号: TM911.4

文献标志码: A

文章编号: 1671-8836(2025)06-0841-10

Fault Identification of Solid Oxide Fuel Cell System Based on Fusion Clustering and RBF-SVM

CAI Shiyun¹, WU Xiaolong^{1†}, LI Yu¹, LI Xi²

1. School of Information Engineering, Nanchang University, Nanchang 330031, Jiangxi, China;
2. School of Artificial Intelligence and Automation, Huazhong University of Science and Technology, Wuhan 430074, Hubei, China

Abstract: To accurately identify faults in Solid Oxide Fuel Cell (SOFC) systems and overcome the challenges of traditional methods such as difficulties in parameter determination, high result randomness, and limitations in complex data processing, a fault identification method based on fusion clustering and Radial Basis Function Support Vector Machine (RBF-SVM) is proposed. This method employs a clustering algorithm based on a fusion mechanism to process the performance degradation fault data of the SOFC system reformer catalyst, obtaining clustering labels under different fault levels, and then uses the RBF-SVM algorithm to train the classified fault data to develop a fault identification model. This model can map fault feature information to higher-dimensional spaces to enhance fault identification capabilities and is further applied to identify air and fuel leakage faults. Experimental results demonstrate that the proposed fusion clustering algorithm effectively classifies faults, and the RBF-SVM fault identification model achieves 99.3% accuracy in identifying reformer catalyst degradation faults, 99.9% accuracy for air leakage faults, and 99.4% accuracy for fuel leakage faults.

Key words: Solid Oxide Fuel Cell (SOFC); faults identification; fusion clustering; Radial Basis Function Support Vector Machine (RBF-SVM)

引用格式: 蔡仕云, 吴肖龙, 李豫, 等. 基于融合聚类和 RBF-SVM 的固体氧化物燃料电池系统故障识别[J]. 武汉大学学报(理学版), 2025, 71(6): 841-850. DOI: 10.14188/j.1671-8836.2025.0094.
CAI Shiyun, WU Xiaolong, LI Yu, et al. Fault Identification of Solid Oxide Fuel Cell System Based on Fusion Clustering and RBF-SVM [J]. J. Wuhan Univ. (Nat Sci Ed), 2025, 71(6): 841-850. DOI: 10.14188/j.1671-8836.2025.0094 (Ch).

0 引言

自《氢能产业发展中长期规划(2021—2035年)》出台以来,氢能的发展备受重视。固体氧化物燃料电池(Solid Oxide Fuel Cell, SOFC)系统是氢能应用的重要方向之一,具有高效率、高能量密度、低排放、长寿命和燃料选择广泛等特点^[1]。设计SOFC系统故障识别方法,对及早发现和识别故障并保证其稳定和高效运行具有非常重要的意义。

SOFC系统是一种将化学能直接转化为电能的发电装置,燃料和空气经过管道输送至电堆发生电化学反应,并通过电解质来传导氧离子,同时根据外部负载需求进行发电^[2-3]。与质子交换膜燃料电池(Proton Exchange Membrane Fuel Cell, PEMFC)一样,它的发电过程是一个复杂的多变量、强耦合的非线性过程^[4]。它可使用氢气、天然气等多种燃料,在反应过程中主要副产物是水蒸气,几乎没有污染物排放,对环境极其友好^[5]。因此,SOFC系统在分布式能源系统、电动汽车、船舶和航空航天领域都有着广泛的应用前景^[6]。随着SOFC发电技术的不断发展,其稳定性得到了显著提高,但重整器催化剂性能退化、空气和燃料管道破裂等都是系统运行过程中无法避免的问题。如果没有及时识别故障,不仅会影响SOFC系统发电质量,还会导致故障进一步蔓延,造成设备损坏。现有主流的故障识别方法主要有基于模型和基于数据两种:基于模型的故障识别方法利用所建立模型与实际系统之间互相作用产生的残差信号检测和定位故障;基于数据的故障识别方法通过对历史故障数据进行训练,挖掘不同故障特征信息,进而识别故障。目前,识别SOFC系统故障遇到以下难题:1)难以建立准确的机理模型,且传感器采集的未标记数据无法满足数据驱动方法对大量已标记历史故障数据的需求;2)传统的K-means聚类算法^[7]初始质心位置对分类结果具有很大的影响,结果有较大偶然性,且对数据分布特点要求苛刻;3)基于数据的方法训练效果不佳,对隐蔽特征信息学习效果不理想,导致故障识别率不够高。

本文提出一种基于融合聚类和径向基核函数支持向量机(Radial Basis Function Support Vector Machine, RBF-SVM)的故障识别方法,主要贡献如下:1)基于数据对SOFC系统进行故障识别,同时对SOFC系统进行全工况实验并采集大量跨工况数据,确保故障识别算法能够充分训练并挖掘故障信息;2)提出一种融合聚类算法用于SOFC系统故

障分类,对未标记故障数据进行划分和标记,得到标签数据,克服传统聚类方法的不足;3)基于支持向量机(Support Vector Machine, SVM)算法,为SOFC系统设计了融合聚类和RBF-SVM算法对故障数据进行训练并用于故障识别,通过径向基核函数将故障特征信息映射到更高维空间,使故障信息能更容易区分。

1 相关研究

1.1 基于模型的故障诊断与分析方法

SOFC系统结构复杂,故障类型多样且隐蔽,一旦发生故障,不仅会造成系统损坏,甚至还会危害负载设备安全。此外,故障发生时不仅造成单一参数改变,还可能导致故障扩大到其他发电辅助部件。文献[8]研究了SOFC电堆的外部温度场特征及其在泄漏故障诊断中的应用,分析了不同泄漏工况下温度场的时空演变规律,为构建泄漏故障的机理模型提供了参考。文献[9]提出的基于运行机理的燃料电池系统可行操作区域模型,同时考虑了燃料电池效率的下降和辅助系统的动态功耗,有助于实现不同工况下的电力调度。文献[10]针对PEMFC催化剂充水问题,构建了氧传递过程模型,有助于发现PEMFC中催化剂层的故障。文献[11]考虑到PEMFC中螺栓振动松动和橡胶振动松弛的机理,提出振动条件下密封结构的泄漏机理模型,揭示了结构参数和材料参数对泄漏率的定量影响。文献[12]提出一种用于蒸汽重整SOFC系统多故障退化融合评估的新型混合建模方法,结合机理模型与数据驱动,构建了能够量化多故障耦合效应的评估框架。文献[13]提出一种基于机理退化模型与粒子滤波的SOFC故障预测方法,通过改进粒子滤波算法并引入自适应重采样策略预测系统故障。

上述方法所依赖的机理模型是在理想条件和环境恒定情况下构建的,而真实的SOFC系统发电过程是非线性的过程,变量多且与环境耦合性强,导致模型与实际系统之间的存在残差信号,且该信号稳定性较差,导致故障诊断效果较差。

1.2 基于数据的故障识别方法

基于数据的方法能够简化诊断过程,处理复杂的SOFC系统有着独特优势。文献[14]提出一种基于变分模态分解(Variational Mode Decomposition, VMD)和希尔伯特变换(Hilbert Transform, HT)的方法,通过分析SOFC电堆的温度和电压信号,成功检测了密封失效导致的泄漏故障,比传统经验模

态分解方法提前 100 s 检测到故障。文献[15]通过实验研究了基于电压信号的 SOFC 燃料泄漏检测方法。该研究通过控制不同泄漏率,系统分析了电压纹波系数与泄漏程度的关联性,提出一种基于实时电压波动的诊断算法,可在 10 s 内完成故障诊断。文献[16]提出一种基于单电池电压分析的故障诊断算法,通过对傅里叶变换后的时间域和频域信号进行特征提取,并利用分类器训练和识别,成功实现了单一故障和复合故障的诊断。文献[17]提出一种基于主成分分析(Principal Component Analysis, PCA)和 SVM 的数据驱动在线故障诊断方法,能有效识别漏气和燃料泄漏故障。文献[18]提出一种基于贝叶斯人工神经网络与特征选择的 SOFC 系统性能分类与故障诊断优化方法,结合 Relief-F 算法进行特征选择,从温度、电压、阻抗等多种特征中筛选出关键特征,采用贝叶斯优化调整人工神经网络(Artificial Neural Network, ANN)超参数,将故障识别率提升了 12%。文献[19]提出一种特征放大变压器故障诊断方法。该模型保留了自校正模型的自相关机制层来提取全局特征,并用性能增强的时变形态滤波器替换了在自校正分解过程中模糊局部特征的移动平均值滤波器,在诊断 PEMFC 早期水淹故障方面达到了 99.62% 的准确率。

上述方法需要大量已知数据和故障信息,此外有关重整器催化剂性能衰退、空气泄漏和燃料泄漏等故障,目前并没有明确的等级划分标准。若采用人工进行划分,不仅效率低下,而且传统的聚类方法在 SOFC 领域准确性表现欠佳。本文提出一种基于融合聚类和 RBF-SVM 的 SOFC 系统故障识别方法,能更为准确地划分系统的故障数据,解决重整器、空气和燃料泄露的故障识别问题。

2 算法设计

本文基于融合聚类方法,实现对 SOFC 系统故障数据的划分;基于 RBF-SVM 的故障识别算法^[20],使故障信息更容易被区分和训练,增强其对故障的识别能力。

2.1 基于融合聚类的故障划分算法

为了实现 SOFC 系统故障等级的划分,作如下定义。

1) 设经过预处理后的 SOFC 故障数据集为 $T(t_1, t_2, \dots, t_n)$, t_i 为第 i 组 SOFC 系统故障样本数据, n 为总故障数据组数; E 为全部故障数据集 T 的集合。

2) 定义融合聚类数据点的邻域为 ϵ : 对于 $\forall t_i \in E$, 若该故障数据点 t_i 到 t_j 的距离小于等于 ϵ , 则归为 t_j 的邻域; 每个故障数据点邻域内的数据点子集定义为 $F_\epsilon(t_j)$:

$$F_\epsilon(t_j) = \{t_j \in E | \text{dist}(t_i, t_j) \leq \epsilon\} \quad (1)$$

3) 定义核心故障数据点: 将 $F_\epsilon(t_j)$ 子集的数据点数目定义为 $N_\epsilon(t_j)$, 定义 NUM 为核心点所需的最小邻居数量。若 $\forall t_j \in E$, 且 $N_\epsilon(t_j) \geq \text{NUM}$, 则 t_j 为核心故障数据点, 构成核心故障数据点集合 H , 即满足:

$$N_\epsilon(t_j) \geq \text{NUM} \quad (2)$$

基于以上定义,设计融合聚类算法,具体步骤如下:

Step 1 聚类簇划分和集合初始化。设 SOFC 系统核心故障数据点集合 $H = \emptyset$, 初始化聚类数 $k = 0$, 未遍历的 SOFC 系统故障数据点集合 $W = D$ (W : 未遍历的故障数据点集合; D : 原始故障数据点集合), 故障划分 $C = \emptyset$ (C : 聚类簇划分集合)。

Step 2 判定故障数据点。对所有故障数据点进行遍历,即考查集合 E 内,对于任意 t_j ,若同时满足公式(1)和(2),则被归为核心故障数据点,更新核心故障数据点集合 $H = H \cup \{t_j\}$;若不满足,则跳转至第 4 步。

Step 3 终止条件判断。若核心故障数据点集合 $H = \emptyset$,则融合聚类算法结束,否则进行第 4 步。

Step 4 新聚类簇初始化。在 H 中随机确定一个核心故障数据点 o ,并归入当前聚类簇核心故障数据点队列 $H_{\text{cur}} = \{o\}$,更新聚类序号 $k = k + 1$,设当前聚类簇故障数据点集合 $C_k = \{o\}$,更新未遍历故障数据点集合 $W_k = E - o$ 。

Step 5 当前聚类簇终止判断。若当前聚类簇核心故障数据点队列 $H_{\text{cur}} = \emptyset$,则当前聚类簇 C_k 生成完毕,更新聚类簇划分 $C = \{C_1, C_2, \dots, C_k\}$,更新核心故障数据点集合 $H = H - C_k$,并执行第 7 步,否则继续执行第 6 步。

Step 6 聚类簇扩展。从当前聚类簇的核心故障数据点队列 H_{cur} 中取 1 个核心故障数据点 o' ,通过(1)式找到故障数据点 $F_\epsilon(o')$,令 $\Delta = F_\epsilon(o') \cap W_k$,更新当前聚类簇故障数据点集合 $C_k = C_k \cup \Delta$,更新未遍历故障数据点集合 $W_k = W_k - \Delta$,更新当前聚类簇核心故障数据点队列 $H_{\text{cur}} = H_{\text{cur}} \cup (\Delta \cap H) - o'$,并执行第 3 步。

Step 7 结果优化与簇划分完成。取 $C = \{C_1, C_2, \dots, C_k\}$ 聚类簇划分集合中的故障数据点,将其按照第 3 步至第 6 步的过程,划分至 $L =$

$\{L_1, L_2, \dots, L_k\}$ 中, 被定义为典型工况数据; 主体聚类完成后, 存在部分未融合散点, 取未融合样本集合 W_k 划分到聚类簇 L_{k+1} , 被定义为非典型工况。得到最终的簇划分 $L' = \{L_1, L_2, \dots, L_{k+1}\}$, 则聚类结束。至此, 通过融合聚类算法完成故障划分, 标签 $L_1, L_2, \dots, L_{k+1}$ 对应 SOFC 系统故障等级。

整个融合聚类过程如图 1 所示。




图1 融合聚类过程

Fig. 1 Fusion clustering process

2.2 基于RBF-SVM的故障识别算法

1) SVM算法

设划分好的 SOFC 系统故障数据集为 $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$, x 为 SOFC 系统的一组故障数据, y 为二元输出(值为 1 或 -1)^[20]。

超平面模型为:

$$f(x) = \omega^T x + b \quad (3)$$

SOFC 系统故障数据点到超平面的距离为:

$$\gamma = \frac{|\omega^T x + b|}{\omega} \quad (4)$$

其中: ω 为权重向量; b 为截距; x 为输入。超平面上方和下方的 SOFC 系统故障数据点分别满足:

$$\begin{cases} \omega^T x_i + b \geq +1, y_i = +1 \\ \omega^T x_i + b \leq -1, y_i = -1 \end{cases} \quad (5)$$

满足公式(5), 且使等号成立的 x_i 为支持向量, 从而可以简化原本距离为 2 个支持向量之间的距离:

$$\gamma = \frac{2}{\|\omega\|} \quad (6)$$

引入正则化参数 $C \geq 0$ 和松弛变量 $\xi_i \geq 0$ 。松

弛变量满足:

$$y_i(\omega^T x_i + b) \geq 1 - \xi_i \quad (7)$$

其中, $i = 1, 2, \dots, m$ 。引入正则化参数的模型优化目标为式(8), 约束条件为式(9):

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i \quad (8)$$

$$\text{s.t. } y_i(\omega^T x_i + b) \geq 1 - \xi_i \quad (9)$$

其中, $i = 1, 2, \dots, m$ 。引入拉格朗日乘子 $\alpha_i \geq 0$, $\mu_i \geq 0$, 将模型本身的有约束问题转化为无约束问题。拉格朗日函数为:

$$L(\omega, b, \xi, \alpha, \mu) = \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y_i(\omega^T x_i + b) - 1 + \xi_i] - \sum_{i=1}^m \mu_i \xi_i \quad (10)$$

将拉格朗日函数对偶化, 分别对 ω, b, ξ 求偏导, 将结果代入式(10), 得到简化后的拉格朗日函数:

$$L(\omega, b, \xi, \alpha, \beta) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad (11)$$

2) RBF 核函数

为解决 SOFC 系统的故障识别中的非线性分类问题, 引入 RBF 核函数, 在高维空间完成分类任务。核函数为:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad (12)$$

引入核函数后, 模型的优化目标变为式(13), 约束条件为式(14):

$$\min_{\alpha} \frac{1}{2} \sum_{i=1, j=1}^m \alpha_i \alpha_j y_i y_j k(x_i, x_j) - \sum_{i=1}^m \alpha_i \quad (13)$$

$$\text{s.t. } \sum_{i=1}^m \alpha_i \gamma_i = 0 \quad (0 \leq \alpha_i \leq C) \quad (14)$$

如此, 就完成了 RBF-SVM 故障识别算法的设计, 可用于 SOFC 系统重整器催化剂性能退化等故障的识别。

3 仿真实验

3.1 实验数据采集

本实验从一套以天然气为燃料的 SOFC 系统中采集运行数据。一个完整的 SOFC 系统由多个辅助发电设备(Balance of Plant, BOP)构成, 能够完成独立发电。该系统由 4 个子系统构成: 电堆子系统、气体供应子系统、尾气回收子系统和电控子系统, 结构如图 2 所示。其构成部件包括电堆、重整器、空气热交换器、空气-燃料热交换器、尾气燃烧室、水蒸发器、除硫器等。




图2 SOFC系统结构

Fig. 2 The structure of SOFC system

1) 电堆子系统。选用平板式 SOFC 单电池串联组成的电堆,采用交叉流和外气道结构,当燃气和空气到达电堆后发生氧化还原反应,产生二氧化碳和水,并实现发电功能。

2) 气体供应子系统。该子系统由燃气、水蒸气和空气供应模块组成,主要负责燃气、去离子水和空气的输送和供给,并根据质量流量控制器实时调整输气量的大小,以满足 SOFC 电化学反应的需要。其中,燃气供应模块包括燃气输送管道、重整器和空气-燃料热交换器。燃气输送至重整器,与高温水蒸气发生重整反应生成氢气和一氧化碳混合气体,作为 SOFC 电堆的阳极气体来源。

3) 尾气回收子系统。尾气燃烧室主要功能是将电堆内未反应完的废气和产生的尾气充分燃烧生成高温烟气,再将高温烟气通入空气热交换器中预热空气。

4) 电控子系统。该子系统主要包括各质量流量控制器、电子负载,负责接收传感器数据、监测系统运行状态以及调控电堆温度梯度,目的是保证电堆最大温度在安全范围内,这是保证系统能正常发电的前提。此外,就电子负载而言,电控子系统还要促使 SOFC 电堆有足够的输出功率,以满足自身和负载端用电需求。

对 SOFC 系统进行全工况实验并采集实验数据,经历以下 4 个阶段:

1) 准备阶段。准备足量的天然气、氢氮气(5% 氢气+95% 氮气)、去离子水和冷却水,分别在阳极、阴极通入少量的天然气和空气。

2) 放电阶段。系统启动缓慢升温,达到放电温度,启动电子负载,进行电流的逐步拉升。

3) 热待机阶段。当关闭负载时,系统停止供电,电流降为 0,此时系统仍处于高温状态,以便随时重新开机满足外部负载的需求。

4) 结束阶段。实验结束后,先关闭电子负载,通入氢氮气保护电堆,同时减少通入的空气量,使 SOFC 系统逐步降温,关闭系统。

在系统开启阶段采集系统状态参数,每 1 s 采样 1 次。

3.2 重整器催化剂退化故障的划分与识别

3.2.1 基于融合聚类算法的划分效果

将初始化后的 SOFC 系统重整器催化剂退化故障数据输入融合聚类模型中进行聚类。鉴于数据维度高,用主成分分析法(Principal Component Analysis, PCA)将 21 维的原数据降至 3 维,得到 3 种主成分(X_1 、 X_2 、 X_3)。如图 3 所示,融合聚类所得结果为 5 类,其中典型工况 4 类(轻微退化、轻度退化、中度退化和严重退化),非典型工况 1 类。

根据所得聚类结果和各类样本参数的特性,将典型工况聚类结果视为 4 种故障等级。同时,统计各故障等级的样本数量,结果如表 1 所示。由图 3 和表 1 可知,系统轻微退化过程较漫长,样本数目最多,占比达 85% 以上,而每组系统参数的采集时间间隔大致相等,因此,轻微退化过程是整个退化过程的主体。此外,3 个更严重等级的退化数据量占比均远远小于轻微退化。最后一类数据是非典型工况数据,是因 SOFC 系统环境波动或测量误差导




图 3 重整器催化剂退化故障数据融合聚类结果

Fig. 3 Fusion clustering results of reformer catalyst degradation fault

表 1 重整器催化剂性能退化等级划分及样本分布

Table 1 Reformer catalyst performance degradation grade classification and sample distribution

故障等级	对应状态	样本数量
轻微退化	空气和燃料进出口温度较高	2 166
轻度退化	空气和燃料进出口温度最高	74
中度退化	空气和燃料进出口温度较低	80
严重退化	空气和燃料进出口温度最低	139
非典型工况		54
总计		2 513

致的少部分样本点游离,将其定义为非典型工况。

基于以上结果可知,融合聚类的方法可以很好地区分开具有不同特性的样本点,具有相似特征的样本点被聚到一类。此外融合聚类模型还能识别出少量离群值,可剔除这些数据或者重新测量。


为了考察融合聚类方式的分类效果,对比了其于 K -means 聚类对故障数据划分的效果。如图 4 所

示,本文所设计的融合聚类算法用于 SOFC 系统故障多维数据处理,能够精准地完成对重整器催化剂性能退化故障的划分;而由于初始质心位置的影响, K -means 聚类算法对故障数据的划分效果较差,出现了“将相同特性的数据点分成了两类”和“将不同特性数据点归为一类”的现象。

3.2.2 基于 RBF-SVM 的识别效果

使用融合聚类算法对 SOFC 系统重整器催化剂退化故障数据进行聚类并标记后,得到标签数据。取总标签数据的 70% 作为训练集,30% 作为测试集。在训练集中,利用原始数据作为模型输入,与之对应的聚类标签作为模型输出,并将输入和输出代入模型中进行训练。然后,利用测试集对所设计算法进行测试,以观察其故障识别率。

为了考察模型的故障识别效果,将 RBF-SVM 与 SVM、高斯贝叶斯网络 (Gaussian Bayesian Network, GBN)、决策树 (Decision Tree, DT)、 K 邻近

图 4 融合聚类与 K -means 聚类效果比对Fig. 4 Comparison of fusion clustering and K -means clustering effects

(K-Nearest Neighbor, KNN)、线性判别(Linear Discriminant, LD)模型进行对比,结果如图5所示。图5中的纵轴为真实类,即 SOFC 系统实际故障等级,其中1~5类分别对应轻微退化、轻度退化、中度退化、严重退化和非典型工况;横轴为预测类,即分类模型判定的故障等级。处于混淆矩阵对角线上的数值为判定正确的样本个数,其他为判定错误的个数。从整体性能来看,6种分类模型均实现了95%以上的故障识别准确率。然而,详细分析图5的混淆矩阵可知,由于典型工况(真实类1~4)在样本集中占比较大,导致模型产生显著的学习偏向。具体

表现为:SVM、GBN、KNN 和 LD 模型虽然在典型工况识别中表现出色,但在非典型工况(真实类5)的识别中仅能识别出少量样本(1~5个)。相比之下,RBF-SVM 和 DT 在非典型工况识别方面均表现出较好的性能,分别实现了11/12和12/18的识别准确率,但DT在典型工况识别中的表现显著低于RBF-SVM模型,特别是在真实类1、类4和类5中出现明显误判。

综上所述,RBF-SVM模型在典型工况和非典型工况的识别中均表现出较强的鲁棒性,展现出最优的综合性能。




图5 5种分类模型故障等级识别结果

Fig. 5 Results of fault level identification of five classification models

选用5个性能指标(曲线下面积(Area Under Curve, AUC)值^[21]、准确率、精确率、召回率和训练时长)的平均值,详细对比各模型对故障等级的识别效果,如表2所示。结合表2的数据,从分类准确性角度看,所有模型都展现出较好的性能,平均准确率普遍维持在97.0%以上,其中RBF-SVM模型达到99.3%的最高准确率。在平均精确率和平均召回率方面,RBF-SVM分别达到97.3%和92.5%,均位居前列,表现出较强的泛化能力。虽然在计算效率上,RBF-SVM的训练时间(1.23 s)相对于GBN(0.60 s)和LD(0.71 s)略长,但考虑到其AUC值达到1.00的理想水平,以及在准确率和精确率等关键指标上的优势,这种程度的训练时长是

可以接受的。综合来看,RBF-SVM模型对SOFC系统重整器催化剂退化故障识别的效果最好。

3.3 空气泄漏和燃料泄漏故障划分与识别

进一步将RBF-SVM模型用于SOFC系统的空气泄漏和燃料泄漏故障测试。按照重整器故障相同的方法进行融合聚类,结果见图6。空气泄漏的融合聚类结果为4类,3类典型工况(轻度、中度、严重泄漏)和1类非典型工况。利用同样方式处理燃料泄漏故障数据,融合聚类结果为6类,5类典型工况(轻微、轻度、中度、严重、非常严重泄漏)和1类非典型工况。由图6可知,该算法对两种故障的划分效果均十分显著,能够顺利地地区分具有不同特征的数据,将具有相同特征的数据聚为一类,得到聚

表 2 5 种模型性能指标的平均值

Table 2 The average values of five model performance indicators

模型	准确率/%	精确率/%	召回率/%	训练时长/s	AUC
RBF-SVM	99.3	97.3	92.5	1.23	1.00
SVM	98.2	93.3	83.5	1.05	1.00
GBN	97.9	95.3	84.7	0.60	0.99
DT	98.1	89.0	91.4	0.74	0.99
KNN	98.3	94.0	84.7	0.97	1.00
LD	97.9	93.4	81.2	0.71	0.98




图 6 空气泄漏和燃料泄漏融合聚类结果

Fig. 6 Fusion clustering results of air leakage and fuel leakage

类标签。

为空气和燃料泄漏两种故障的原始数据样本标记标签,得到故障标签数据,按 7:3 的比例划分成训练集和测试集。将原始数据作为训练集的输入,聚类标签作为训练集的输出,测试集只保留原始数据。使用 RBF-SVM 模型对训练集进行训练,对测试集进行测试,以考察模型对空气泄漏和燃料泄漏两类故障的识别效果。在图 7(a)中,典型工况为真实类 1~3,分别对应空气轻度、中度和严重泄漏,非典型工况为真实类 4。在图 7(b)中,典型工况为真

实类 1~5,分别对应燃料轻度、轻度、中度、严重和非常严重泄漏,非典型工况为真实类 6。由图 7 可知,RBF-SVM 模型对 SOFC 系统的空气泄漏和燃料泄漏故障均具有较高的识别准确率,分别可达 99.9% 和 99.4%。可见,RBF-SVM 模型不仅可以精确地划分和识别重整器催化剂退化故障,还能拓展到空气泄漏和燃料泄漏的故障。

RBF-SVM 模型的 5 种性能指标如表 3 所示。该模型对空气泄漏故障和燃料泄漏故障均具有极高的识别准确率和 AUC 值,同时,其平均识别准确




图 7 RBF-SVM 模型对空气泄漏和燃料泄漏识别结果

Fig. 7 RBF-SVM model identification results of air leakage and fuel leakage

表 3 RBF-SVM 模型性能指标的平均值

Table 3 The average values of RBF-SVM model performance indicators

故障类型	准确率/%	精确率/%	召回率/%	训练时长/s	AUC
空气泄漏	99.9	99.8	75.0	6.49	1.00
燃料泄漏	99.4	99.0	79.2	6.78	1.00

率分别达到 99.9% 和 99.4%, 平均识别精确率分别达到 99.8% 和 99.0%。由于对空气泄漏和燃料泄漏故障数据进行融合聚类所得典型工况样本多, 非典型工况样本少, 模型对非典型工况的训练和识别能力不足, 使得平均召回率较低。

综合来看, 该模型对两种故障的表现出良好的识别能力, 证明了该模型对 SOFC 系统故障识别的广泛性。

4 结 语

本文提出一种基于融合聚类和 RBF-SVM 算法的故障识别模型, 并将其用于 SOFC 系统重整器催化剂性能退化、空气泄漏和燃料泄漏等故障的识别。其中, 融合聚类方法能够克服传统聚类方法的不足, 完成对维度大、复杂性高的故障数据的划分; RBF-SVM 算法通过引入径向基核函数将故障特征信息映射到更高维空间, 提升了对故障的识别能力。该方法对 SOFC 系统中重整器催化剂性能退化、空气泄漏和燃料泄漏等故障的识别准确率分别达到 99.3%、99.9% 和 99.4%, 明显优于其他模型。本文所设计的故障识别方法有望为其他领域复杂系统的故障划分和识别提供参考。

参考文献:

[1] SINGLA M K, NIJHAWAN P, OBEROI A S. Correction to: Hydrogen fuel and fuel cell technology for cleaner future: A review [J]. *Environmental Science and Pollution Research*, 2021, **28**(15): 19536. DOI: 10.1007/s11356-021-13191-3.

[2] XU K, SHEN C C, XU C, *et al.* Modeling and control-oriented thermal characteristics under variable load of the solid oxide fuel cell [J]. *Journal of Solid State Electrochemistry*, 2023, **27**(8): 2083-2099. DOI: 10.1007/s10008-023-05477-y.

[3] CHEN J W, HU Z C, ZHANG H S. A novel control scheme to mitigate temperature profile variation in a SOFC System [J]. *Energy Reports*, 2022, **8**: 10604-10613. DOI: 10.1016/j.egyrs.2022.08.185.

[4] YAN J, CHEN H L. Power generation *via* solid oxide fuel cell using ex-reformed oxygen-containing low-concentration

methane[J]. *Materials Chemistry and Physics*, 2024, **313**: 128736. DOI: 10.1016/j.matchemphys.2023.128736.

[5] ZHANG L, LI X, JIANG J H, *et al.* Dynamic modeling and analysis of a 5-kW solid oxide fuel cell system from the perspectives of cooperative control of thermal safety and high efficiency[J]. *International Journal of Hydrogen Energy*, 2015, **40**(1): 456-476. DOI: 10.1016/j.ijhydene.2014.10.149.

[6] 杜柯, 林凯生, 宋琛, 等. 固体氧化物燃料电池电堆及相关系统发展现状与展望[J]. *中国电机工程学报*, 2025, **45**(10): 3877-3892. DOI: 10.13334/j.0258-8013.pcsee.232375.

DU K, LIN K S, SONG C, *et al.* Current status and prospects of solid oxide fuel cell stacks and related systems [J]. *Proceedings of the CSEE*, 2025, **45**(10): 3877-3892. DOI: 10.13334/j.0258-8013.pcsee.232375(Ch).

[7] 聂雷, 杨拓, 张俊杰, 等. 基于多属性决策和 *k*-means 聚类的车载安全消息中继选择方法[J]. *武汉大学学报(理学版)*, 2023, **69**(5): 609-616. DOI: 10.14188/j.1671-8836.2022.0198.

NIE L, YANG T, ZHANG J J, *et al.* Multi-attribute decision-making and *k*-means clustering based relay selection method for vehicular safety messages dissemination [J]. *Journal of Wuhan University (Natural Science Edition)*, 2023, **69**(5): 609-616. DOI: 10.14188/j.1671-8836.2022.0198(Ch).

[8] XIONG X Y, YANG L, WU Y F, *et al.* External temperature field test and leakage fault diagnosis for SOFC stacks [J]. *International Journal of Hydrogen Energy*, 2023, **48**(7): 2788-2800. DOI: 10.1016/j.ijhydene.2022.10.175.

[9] DING H H, HU Q R, WANG Y Z, *et al.* A mechanism-based convex model of fuel cell systems considering the effect of auxiliary system[J]. *IEEE Transactions on Sustainable Energy*, 2025, **16**(4): 3124-3127. DOI: 10.1109/TSTE.2025.3564106.

[10] DU Y, LI Y H, REN P, *et al.* Oxygen transfer at mesoscale catalyst layer in proton exchange membrane fuel cell: Mechanism, model and resistance characterization [J]. *Chemical Engineering Journal*, 2024, **494**: 153021. DOI: 10.1016/j.ccej.2024.153021.

[11] GUO S, ZHAO Y Q, WANG X Y, *et al.* Leakage mechanism model of proton exchange membrane fuel cell sealing structures under vibration conditions[J]. *International*

- Journal of Green Energy*, 2024, **21**(12): 2912–2922. DOI: 10.1080/15435075.2024.2338386.
- [12] WU X L, XU Y W, PENG J X, *et al.* Novel hybrid modeling and analysis method for steam reforming solid oxide fuel cell system multifault degradation fusion assessment[J]. *ACS Omega*, 2023, **8**(40): 36876–36892. DOI: 10.1021/acsomega.3c03928.
- [13] XU Y W, JIANG C, PENG J X, *et al.* Fault prognosis method for solid oxide fuel cells based on mechanism degradation process model and particle filtering[J]. *IEEE Transactions on Power Electronics*, 2023, **38**(6): 6831–6840. DOI: 10.1109/TPEL.2023.3246068.
- [14] 武鑫, 胡超, 王祺, 等. 基于 VMD 的 SOFC 电堆密封失效泄漏故障诊断[J]. 中国电力, 2024, **57**(12): 139–147. WU X, HU C, WANG Q, *et al.* VMD based fault diagnosis method for SOFC stack seal failure and leakage[J]. *Electric Power*, 2024, **57**(12): 139–147(Ch).
- [15] ZHANG J H, YU S, LEI L B, *et al.* Experimental detection of fuel leakage in solid oxide fuel cells based on voltage signals[J]. *International Journal of Hydrogen Energy*, 2024, **77**: 575–581. DOI: 10.1016/j.ijhydene.2024.06.144.
- [16] YANG J, LI Z J, BIAN R L, *et al.* Fault diagnosis of SOFC system based on single cell voltage analysis[J]. *International Journal of Hydrogen Energy*, 2021, **46**(48): 24531–24545. DOI: 10.1016/j.ijhydene.2021.04.114.
- [17] ZHENG Y, WU X L, ZHAO D Q, *et al.* Data-driven fault diagnosis method for the safe and stable operation of solid oxide fuel cells system[J]. *Journal of Power Sources*, 2021, **490**: 229561. DOI: 10.1016/j.jpowsour.2021.229561.
- [18] WU X L, MEI J, XU Y W, *et al.* Stack performance classification and fault diagnosis optimization of solid oxide fuel cell system based on Bayesian artificial neural network and feature selection[J]. *Journal of Power Sources*, 2024, **620**: 235198. DOI: 10.1016/j.jpowsour.2024.235198.
- [19] YI F Y, SUN Y, ZHANG J M, *et al.* Early flooding fault diagnosis method of fuel cell based on feature amplification transformer[J]. *International Journal of Hydrogen Energy*, 2025, **119**: 13–24. DOI: 10.1016/j.ijhydene.2025.03.241.
- [20] 陈梅, 陈熙鹏, 陈薇, 等. 基于融合聚类的篦冷机工况划分与识别研究[J]. 控制工程, 2023, **30**(2): 361–367. DOI: 10.14107/j.cnki.kzgc.20200861. CHEN M, CHEN X P, CHEN W, *et al.* Research on division and recognition of grate cooler operating conditions based on fusion clustering[J]. *Control Engineering of China*, 2023, **30**(2): 361–367. DOI: 10.14107/j.cnki.kzgc.20200861(Ch).
- [21] 胡涛, 武梦婷, 胡巍, 等. 基于机器学习的粉煤灰活性分类预测[J]. 中南大学学报(自然科学版), 2023, **54**(10): 3829–3839. HU T, WU M T, HU W, *et al.* Reactivity classification prediction of coal fly ash based on machine learning[J]. *Journal of Central South University (Science and Technology)*, 2023, **54**(10): 3829–3839(Ch).

□