

doi: 10.3969/j.issn.1003-3106.2021.07.021

引用格式: 曹孟达,张涛,王羽,等.基于深度学习的锂离子电池剩余寿命估计[J].无线电工程,2021,51(7):641-648. [CAO Mengda,ZHANG Tao,WANG Yu,et al.Remaining Useful Life Estimation for Lithium-ion Battery Using Deep Learning Method[J].Radio Engineering,2021,51(7):641-648.]

基于深度学习的锂离子电池剩余寿命估计

曹孟达,张涛,王羽,张亚军,刘亚杰*
(国防科技大学 系统工程学院,湖南 长沙 410073)

摘要: 锂离子电池剩余使用寿命 (Remaining Useful Life, RUL) 的准确预测能够帮助更好地了解锂离子电池的工作状态,人工智能和深度学习的发展为锂离子电池 RUL 预测提供了新的数据驱动方法。基于自动编码器和深度神经网络,提出了一种深度学习框架的锂离子电池 RUL 预测方法。通过自动编码器对锂离子电池进行退化特征的提取和融合,以融合特征作为输入、电池容量作为输出,训练深度神经网络用于多电池 RUL 预测。将该方法应用于 NASA 的锂离子电池的真实数据集。实验结果表明,该深度学习预测框架中自动编码器提取融合特征后能够提高 RUL 预测精度,预测方法具有很好的可靠性和准确性。

关键词: 锂离子电池; 剩余寿命估计; 深度学习; 自动编码器; 深度神经网络

中图分类号: TM911

文献标志码: A

开放科学(资源服务)标识码(OSID):

文章编号: 1003-3106(2021)07-0641-08



Remaining Useful Life Estimation for Lithium-ion Battery Using Deep Learning Method

CAO Mengda, ZHANG Tao, WANG Yu, ZHANG Yajun, LIU Yajie*

(College of Systems Engineering, National University of Defense Technology, Changsha 410073, China)

Abstract: The accurate prediction of the remaining useful life (RUL) of lithium-ion batteries can help to better understand the working state of lithium-ion batteries. With the development of artificial intelligence and deep learning, new data-driven methods are provided for lithium-ion battery RUL prediction. An automatic encoder and deep neural network are combined to propose a deep learning framework for lithium ion battery RUL prediction. First, the automatic encoder is used to extract and fuse the degraded features of lithium-ion batteries. Then, the deep neural network is trained with fusion features as input and capacity as output for multi-cell RUL prediction. This method is applied to NASA's real data set of lithium ion battery cycle life. The experimental results show that the automatic encoder in the deep learning prediction framework can improve the RUL prediction accuracy after extracting the fusion features. The prediction method has good reliability and accuracy.

Keywords: lithium-ion battery; remaining useful life estimation; deep learning; autoencoder; deep neural network

0 引言

随着我国工业的蓬勃发展,锂离子电池技术已广泛应用于车辆、航空航天、便携式电子设备等领域。与传统电池相比,锂离子电池具有许多优势,如高能量密度、循环寿命长、自放电率低且与其他电池化学物质相比没有记忆效应^[1-3]。这些优势使得锂离子电池被应用在更广泛的领域,如新一代丰田普锐斯、比亚迪 E6、K9 和本田思域等电动汽车都采用锂离子电池作为动力来源。尤其是在航空航天领域,锂离子电池取代传统镍氢、镍镉电池,成为第三

代卫星储能电池,并已经投入实际生产和应用,例如美国国家航空航天局(NASA)的火星探测漫游者项目(Mars Exploration Rover, MER)、欧洲航天局(ESA)的火星快车号(Mars Express)和日本的猎鹰(Falcon Bird)小行星都已经选择锂离子电池作为能量储备^[4-5]。同时,锂离子电池使用期间的安全性、可靠性和稳定性是应用中关注的重点,通常需要安

收稿日期: 2021-01-05

基金项目: 面向应急任务的 XXX 电源系统保障能力评估

Foundation Item: Supported by the Project of Evaluation of XXX Power System Support Capability for Emergency Tasks

装电池管理系统(BMS)来确保电池系统的安全、高效运行^[6-7]。

作为工业系统中的主要储能设备,锂离子电池故障常常会导致系统性能降低、失效,增加维修、维护成本^[8]。1999年,美国太空试验空军研究实验室因电池内部阻抗异常而故障失效^[9]。2013年,机载锂离子电池故障引起多架波音787失火,并导致所有同类型客机无限期停飞^[10]。而卫星电源系统的锂离子电池由于工作环境特殊,维修困难,一旦出现故障,将导致卫星整体失效,无法运转。NASA发射的火星探测器电池存在过充问题,但操作者未及时发现其状态仍然将探测器的太阳能电池板朝太阳方向旋转,使电池温度过高而失效,最终导致探测器丢失。因此,准确地评估、预测锂离子电池的剩余使用寿命(Remaining Useful Life, RUL),在锂离子电池状态估计和健康管理中起着越来越重要的作用^[11],能够在电池出现失效前及时调整工作状态,避免出现更严重的故障。

1 锂离子电池 RUL 研究

锂离子电池 RUL 估计的典型方法通常可以分为基于模型的方法^[12]、基于数据驱动的方法^[13]和二者组合的混合方法^[14]。现在较普遍的粒子滤波方法^[15]、艾林(Eyring)模型^[16]、威布尔分布模型^[17]等均属于基于模型的方法。OSSAI等人^[18]采用随机效应模型和威布尔分布函数对锂离子电池 RUL 进行评估,选择最大似然估计(MLE)算法和随机近似期望最大化(SEM)算法对随机效应参数进行优化,对锂离子电池 RUL 预测精度达到98%以上。XU等人^[19]通过建立状态空间模型预测锂离子电池 RUL,该模型中参数和状态的更新是通过期望最大化(EM)和扩展卡尔曼滤波器(EKF)算法的组合来实现。这些研究虽然能够对复杂系统退化进行精确建模从而获取较准确的预测结果,但其建模过程往往需要大量有关物理系统的先验知识^[20]。由于锂离子电池内部复杂的化学反应,通常很难检测和收集用于电池退化模型的综合内部状态参数,因此在实际情况中很难建立准确的预测模型。数据驱动方法能够基于传感器收集的历史数据对退化特性建模,通过揭示传感器数据中的潜在相关性和因果关系推断出相应的系统信息^[21](如RUL)。基于数据驱动的方法通常需要足够的历史数据来训练模型,在预测上不过多依赖先验知识。近年来提出了许多数据驱动算法,并且取得了良好的预测结果,包括人

工神经网络(Neural Network, NN)、支持向量机(SVM)^[22]、隐马尔可夫模型^[23]、相关向量机(RVM)^[24]等。将基于数据驱动的方法和基于模型的方法相结合的混合方法旨在利用2种方法的优点,避免其缺点^[25]。锂离子电池的混合方法主要与粒子滤波和卡尔曼滤波等方法相关。Dong等人^[26]提出了一种基于短期浮动的锂离子电池 RUL 预测框架,该框架通过应用基于布朗运动的退化模型来实现电池容量评估,将容量变化视为布朗粒子在一定时间内间隔的移动距离,粒子滤波用于估计布朗运动的漂移参数。尽管在混合方法上已经有了一些研究,但是开发有效的混合方法应用于实际退化仍然是非常困难的,特别是对于物理模型和数据驱动技术的结合。

在过去的几年中,基于数据驱动的方法在锂离子电池 RUL 预测领域得到了许多关注。但是,基于数据驱动的方法常常需要复杂的信号处理技术从传感器数据中提取特征。这种信号处理需要人工提取、处理并分析信号数据,但人为因素的加入也导致模型的精确度和可靠性受到影响。随着人工智能和生物技术的发展,深度学习在处理信号数据时具有良好的自动挖掘和提取信息的能力^[27],能够避免人为提取特征的不确定性。谷歌的Deepmind在AlphaGo上取得的成功证明了深度学习对大数据处理和功能学习的强大作用^[28]。而深度神经网络结构也在图像识别、自然语言处理、语音识别等许多领域获得了巨大的成功,并在提取原始振动信号和时频特征方面进行故障诊断有很好的应用潜力^[29-31]。

基于深度学习在信号处理和提取特征中的优势,提出了一种集成的深度学习方法用于锂离子电池 RUL 预测。将深度学习中的自动编码器和深度神经网络集成在一起,构建一种基于自动编码器模型的20维特征提取方法来表征锂离子电池的退化状况,训练基于深度神经网络的多电池 RUL 预测模型。将该方法应用于NASA的锂离子电池循环寿命的真实数据集进行实例验证,实验结果表明了该方法的有效性和优越性。

2 锂离子电池 RUL 预测的深度学习框架

基于深度学习的锂离子电池 RUL 预测模型框架如图1所示。首先从原始数据中提取特征后采用自动编码器对特征进行融合,然后将融合后的特征输入深度神经网络中,以预测锂离子电池的 RUL,输出预测结果。




图1 基于深度学习的锂离子电池 RUL 预测模型

Fig.1 RUL prediction model of lithium-ion battery based on deep learning

2.1 提取特征

2.1.1 原始信号数据

通过对传感器收集的锂离子蓄电池充放电过程时的数据进行分析,得出充放电过程,如图2所示。




图2 一次循环充放电过程


Fig.2 One cycle charging and discharging process

充电阶段首先以恒定电流对锂离子电池进行充电,待电压升至固定值后,保持恒定电压进行充电,直到充电电流降至固定值。放电阶段同样以恒定电流进行放电,直至电压降至固定值后,停止放电。


在锂离子电池循环充放电的全寿命周期内,获得的充电数据包括充电温度、充电测量电流、充电端电流、充电测量电压。电池充电期间电荷参数变化如图3所示。

放电数据包括放电温度、放电负载电流、放电负载电压、放电测量电流。电池放电期间电荷参数变化如图4所示。


随着电池充放电循环次数的增加,电池寿命逐渐退化,在每一次循环中电池充放电时间不完全一致,因此采样数据点也参差不齐,无法直接将原始采样数据输入特征融合模型,需要对原始数据进行预处理,以提取所有电量参数的典型特征。




(a) 端电压变化



(b) 测量电压变化



(c) 端电流/测量电流变化



(d) 测量温度变化

图3 电池充电期间电荷参数变化

Fig.3 Change of charge parameters during battery charging




图4 电池放电期间电荷参数变化

Fig.4 Change of charge parameters during battery discharging

2.1.2 提取特征

在对原始数据进行特征提取时,需要考虑提取得到的数据是否能够有效表征锂离子电池的退化和实际性能,而锂离子电池的每个测试参数的曲线都有明显的几何特征,并随电池寿命退化而发生偏移^[3]。因此,根据锂离子电池每个循环中的每个维

度,提取各个维度中的典型几何特征信息,并利用这些几何特征来表示锂离子电池当前的状态。

① 电池充电期间端电压特征提取如下:

$$(t_{\max(i)}, v_i), \text{ s.t. } v_i \leq 4.2 \text{ V}, i = 1, 2, 3, \dots, n, \quad (1)$$

式中, $t_{\max(i)}$ 为电池端电压达到峰值,即将下降时的充电时间; v_i 为电池端电压即将下降前的电压值; n 为当次循环样本数。

② 电池充电期间端电流、测量电流特征提取如下:

$$(t_{\max(i)}, I_i), \text{ s.t. } I_i \leq 1.5 \text{ A}, i = 1, 2, 3, \dots, n, \quad (2)$$

式中, $t_{\max(i)}$ 为电池端电流、测量电流保持恒定不变的最长时间; I_i 为电池端电流、测量电流即将下降前的电流值; n 为当次循环样本数。

③ 电池充电期间测量电压特征提取如下:

$$(t_{\text{cmv}}, v_{\text{cm}}) = \{t_i, v_i \mid \max(v_i)\}, i = 1, 2, 3, \dots, n, \quad (3)$$

式中, t_{cmv} 为电池测量电压达到峰值,开始恒压充电时的时间; v_{cm} 为此时的电压值; n 为当次循环样本数。

④ 电池充电、放电期间温度特征提取如下:

$$(t_{\text{cT}}, T_c) = \{t_i, T_i \mid \max(T_i)\}, i = 1, 2, 3, \dots, n, \quad (4)$$

式中, t_{cT} 为电池测量温度达到峰值的时间; T_c 为电池温度峰值; n 为当次循环样本数。

⑤ 电池放电期间测量电压、负载电压特征提取如下:

$$(t_d, v_d) = \{t_i, v_i \mid \max(v_i)\}, i = 1, 2, 3, \dots, n, \quad (5)$$

式中, t_d 为电池测量电压、负载电压达到峰值时的时间; v_d 为此时电压值; n 为当次循环样本数。

⑥ 电池放电期间测量电流、负载电流特征提取如下:

$$(t_{\max(i)}, I_i), \text{ s.t. } |I_i| \leq 2 \text{ A}, i = 1, 2, 3, \dots, n, \quad (6)$$

式中, $t_{\max(i)}$ 为电池结束恒定电流放电、电流的绝对值将低于 2 A 的时间; I_i 为此时的电流值; n 为当次循环样本数。

2.2 锂离子 RUL 预测的深度学习框架

2.2.1 自动编码器

采用神经网络模型进行预测时,通常输入特征信息越多,信息的表达能力越强。但随着提取特征维度的增加,容易导致模型信息冗余和计算效率低下。同时,电池充电时恒流放电结束和电压达到峰值的时间、放电时恒流放电结束和电压达到最低值的时间常常是高度相关甚至互补的,应当在不降低预测精度的情况下减少冗余数据,多传感器收集的信息进行融合产生更准确、更可靠的信息表示。因此在进行深度神经网络训练前,需要对提取特征进

行数据融合。经典的信息融合降维方法包括主成分分析(Principal Component Analysis, PCA)^[3]、近邻保持嵌入(Neighborhood Preserving Embedding, NPE)^[3]和自动编码器(Auto Encoder, AE)等。但PCA法存在局限性,在线性投影上效果较好且要求数据服从高斯分布,近邻保持嵌入等方法无法学习高维抽象^[3],因此采用AE对锂离子电池的时域特征数据进行融合。

AE是一种3层的无监督神经网络,具有完全对称的网络结构,采用输入向量通过非线性映射在下一层形成一个高层次的概念。AE尝试近似一个相同的函数,将输入的 x 进行编码,得到新的特征 y ,并且希望原始的 x 能够从新的特征 y 中解码出来,其结构如图5所示。




图5 自动编码器的编码和解码

Fig.5 Encoding and decoding of the autoencoder

AE分为编码和解码2个阶段。编码是一个前向传播过程,通过Sigmoid激活函数 $f(z)$ 训练数据集 $\{x^1, x^2, \dots, x^i\}$, $x^i \in Z^n$ 进行非线性映射到隐含层:

$$y_i = f\left(\sum_{j=1}^m W_{ij}x_j + b_i^{(1)}\right), \quad (7)$$

$$f(z) = \frac{1}{1 + \exp(-z)}, \quad (8)$$

得到隐含层 $\{y^1, y^2, \dots, y^i\}$ 后,对隐含层进行解码:

$$x'_i = f\left(\sum_{j=1}^n W_{ij}^T y_j + b_i^{(2)}\right), \quad (9)$$

式中, W 为不同层之间的权值向量; b 为偏差。

自动编码器解码时的损失函数为:

$$Loss_{\text{AE}}(W, b) = \frac{1}{m} \sum_{i=1}^m \frac{\|x' - x\|^2}{2}, \quad (10)$$

式中, m, n 分别为原始数据维度和隐含层维度,锂离子电池特征数据维度 m 为20,隐含层维度 n 为16; x', x 分别是解码后输出数据和原始数据。

2.2.2 深度神经网络

深度学习技术已经被广泛应用于各行各业中,通过组合多种类型的网络层,形成深度神经网络模

型,逐层对原始数据计算,利用反向传播算法学习对数据越来越抽象的表示形式,从而提高对目标预测、图像分类等任务的精确度^[3]。由于深度神经网络中每个隐含层都可以是非线性变换的输出层,因此深度神经网络比浅层神经网络具有更强的表达能力。

在锂离子电池RUL预测框架中使用深度神经网络模型,它是一种有监督的学习模型,在前向传播过程接收原始数据(即经过自动编码器融合后的特征数据)将其映射为固定数据量的输出数据,从前一层到下一层的计算过程中,融合特征被加权求和,经过激励函数,得到输出结果。

加权求和过程为:

$$h_{w,b}(x) = f(w^T x) = f\left(\sum_{i=1}^m w_i x_i + b\right). \quad (11)$$

激励函数一般有Sigmoid函数、tanh函数和Relu函数,Sigmoid函数如式(8),tanh函数和Relu函数如式(12)和式(13)所示:

$$f(x) = \tanh(x), \quad (12)$$

$$f(x) = \max(x, 0). \quad (13)$$

训练深度神经网络时,设置预测结果和实际结果的均方误差(Mean Square Error, MSE)作为损失函数:

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2. \quad (14)$$

3 实验分析

3.1 实验数据

实验数据来自于NASA埃姆斯卓越故障预测研究中心(Prognostic Center of Excellence, PCoE)的锂离子电池数据集。本文利用了数据集中的B5、B6、B7三种锂离子电池数据开展验证实验,该系列电池均为市场销售的18650锂离子电池,在25℃下进行了3种不同工作模式下的加速退化实验,并记录了实验数据,步骤如下:

① 充电过程:以1.5 A的恒流充电模式对锂离子电池进行充电,电压不断升高至4.2 V后开始恒压充电,直至充电电流降低至0.02 A。


② 放电过程:以2 A的恒流放电模式对锂离子电池进行放电,直至B5、B6、B7三组锂离子电池的电压降至2.7、2.5、2.2 V。

③ 不断进行充放电循环,加速电池退化过程,当检测到电池容量衰减到70%时,判定电池失效,实验结束。


3.2 模型训练结果及分析

锂离子电池 RUL 预测模型分为 AE 和深度神经网络两部分,选择 B5、B6 电池数据作为训练集, B7 电池作为测试集对预测模型进行实验验证,并将混合模型(ADNN)预测结果和深度神经网络模型、SVM 模型和采用 AE 融合特征的 AE-SVM 模型预测结果进行对比。

在 AE 模型中,传感器收集的原始数据特征经预处理后得到 20 维的特征数据。编码过程采用 Sigmoid 函数作为激励函数,设置中间层为 16 维,解码过程的激励函数采用 Relu 函数,得到中间层输出结果即为深度神经网络预测模型的输入数据。在深度神经网络部分,设置隐含层数分别为 12,7,4,输出层为 1,即锂离子电池容量。中间层激活函数均采用 Relu 函数,模型参数更新采用 Adam 优化算法,两部分训练过程损失函数如图 6 所示。



(a) 自动编码器训练损失



(b) 深度神经网络训练损失


图 6 模型训练损失

Fig.6 The training loss of the model


深度神经网络训练结束后,采用 B7 电池进行锂离子电池 RUL 预测,未采用 AE 对特征数据进行融合处理得到预测结果如图 7(a) 所示,采用自动编码器处理后的 ADNN 预测结果如图 7(b)。

预测结果中横轴为 B7 电池充放电循环次数,纵轴为电池容量归一化后结果。蓝色的点为真实值,红色的线为预测值,能够观察到图 7(a) 中 RUL 预测曲线与实际值趋势相近,但预测误差较大。而

图 7(b) 中 RUL 预测曲线与实际值基本吻合。



(a) DNN




(b) ADNN


图 7 DNN 和 ADNN 方法的预测结果

Fig.7 Prediction results of DNN and ADNN

使用 SVM 模型对 B7 电池进行 RUL 预测的结果如图 8 所示,能够发现采用自动编码器对特征数据进行融合处理后的 SVM 模型预测效果更好。



(a) SVM



(b) AE-SVM

图 8 SVM 和 AE-SVM 方法的预测结果

Fig.8 Prediction results of SVM and AE-SVM

除损失函数均方误差 (Mean Square Error, MSE) 外, 进一步采用均方根误差 (Root Mean Square Error, RMSE) 和平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE) 对模型预测精度进行验证:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2}, \quad (15)$$

$$MAPE = \frac{100\%}{m} \sum_{i=1}^m \left| \frac{\hat{y}_i - y_i}{y_i} \right|, \quad (16)$$

式中, y_i 为真实值; $\hat{y}_i$ 为预测值; m 为预测样本数量。

模型预测误差对比结果如表 1 所示。

表 1 预测误差

Tab.1 Prediction error

模型类型	MSE	RMSE	MAPE/%
DNN	0.003 679	0.060 654	11.91
ADNN	0.000 473	0.021 770	4.09
SVM	0.006 167	0.078 533	14.78
AE-SVM	0.001 689	0.041 105	7.59

由表 1 可以看出, 采用深度神经网络对锂离子电池 RUL 预测具有很好的效果, 而采用自动编码器对锂离子电池数据进行融合处理后, 预测精度都有了一定的提升。因此本文提出的基于自动编码器的 ADNN 模型能够准确、可靠地预测锂离子电池的 RUL。当卫星发射到太空后, 由于无法直接获取容量数据, 通过地面同类型电池循环实验构造锂离子电池容量评估模型, 根据卫星传回地面的相关数据得到卫星锂离子电池的实时容量, 使地面操作人员更直观清晰地了解卫星电池的工作状况。

4 结束语

锂离子电池的 RUL 预测对锂离子电池状态估计和健康管理很重要, 因此本文提出了一种深度学习框架的锂离子电池 RUL 预测方法。这种深度学习框架采用自动编码器对锂离子电池数据进行特征提取和数据融合, 深度神经网络对锂离子电池 RUL 进行预测。基于 NASA 的电池测试数据, 与支持向量机方法相比, 验证了自动编码器在特征提取融合上的优势和本混合方法在锂离子电池 RUL 预测上具有更好的准确性和有效性。

根据这种方法, 在卫星在轨运行期间, 通过地面同步实验构建锂离子电池 RUL 预测模型, 结合卫星传输到地面的遥测数据实时了解锂离子电池容量, 为地面操作人员判断卫星电池健康状态提供参考。下一步计划研究在不同充放电环境下锂离子电池的 RUL 预测方法。

参考文献

- ZHAO C, YIN H, MA C B. Quantitative Efficiency and Temperature Analysis of Battery - Ultracapacitor Hybrid Energy Storage Systems [J]. IEEE Transactions on Sustainable Energy, 2016, 7(4): 1791-1802.
- HU X S, ZOU C F, ZHANG C P, et al. Technological Developments in Batteries: a Survey of Principal Roles, Types, and Management Needs [J]. IEEE Power and Energy Magazine, 2017, 15(5): 20-31.
- ZOU C F, MANZIE C, NESIC D. A Framework for Simplification of PDE-based Lithium-ion Battery Models [J]. IEEE Transactions on Control Systems Technology, 2016, 24(5): 1594-1609.
- CAO M D, ZHANG T, YU B, et al. A Method for Interval Prediction of Satellite Battery State of Health Based on Sample Entropy [J]. IEEE Access, 2019, 7: 141549-141561.
- LIU D T, ZHOU J B, PENG Y. Data-driven Prognostics and Remaining Useful Life Estimation for Lithium-ion Battery: a Review [J]. Instrumentation, 2014, 1(1): 59-70.
- HU X S, CAO D P, EGARDT B. Condition Monitoring in Advanced Battery Management Systems: Moving Horizon Estimation Using a Reduced Electrochemical Model [J]. IEEE/ASME Transactions on Mechatronics, 2017, 23(1): 167-178.
- HU X S, LI S B, JIA Z Z, et al. Enhanced Sample Entropy-based Health Management of Li-ion Battery for Electrified Vehicles [J]. Energy, 2014, 64: 953-960.
- 时玮. 动力锂离子电池组寿命影响因素及测试方法研究 [D]. 北京: 北京交通大学, 2014. pp22-23.
- KAI G, SAHA B, SAXENA A, et al. Prognostics in Battery Health Management [J]. IEEE Instrumentation & Measurement Magazine, 2008, 11(4): 33-40.
- POZZI J, 李璇. 关于锂电池作为民航飞机主要动力来源的争议 [J]. 航空维修与工程, 2015(10): 27-28.
- 李练兵, 祝亚尊, 田永嘉, 等. 基于 Elman 神经网络的锂离子电池 RUL 间接预测研究 [J]. 电源技术, 2019, 43(6): 1027-1031.
- VIRKAR A V. A Model for Degradation of Electrochemical Devices Based on Linear Non-equilibrium Thermodynamics and Its Application to Lithium-ion Batteries [J]. Journal of Power Sources, 2011, 196(14): 5970-5984.
- WANG Z P, MA J, ZHANG L. State-of-health Estimation for Lithium-ion Batteries Based on the Multi-island Genetic Algorithm and the Gaussian Process Regression [J]. IEEE Access, 2017, 5: 21286-21295.
- SONG Y C, LIU D T, YANG C, et al. Data-driven Hybrid

- Remaining Useful Life Estimation Approach for Spacecraft Lithium-ion Battery [J]. Microelectronics Reliability, 2017, 75: 142-153.
- [15] JOUIN M, GOURIVEAU R, HISSEL D, et al. Particle Filter-based Prognostics: Review, Discussion and Perspectives [J]. Mechanical Systems and Signal Processing, 2016, 72: 2-31.
- [16] JOUIN M, GOURIVEAU R, HISSEL D, et al. Degradations Analysis and Aging Modeling for Health Assessment and Prognostics of PEMFC [J]. Reliability Engineering and System Safety, 2016, 148: 78-95.
- [17] FENG L Y, YA S W, CHUN H Z, et al. An Improved Parameter Estimation Method for Three-Parameter Weibull Distribution in the Life Analysis of Rolling Bearing [J]. Advanced Materials Research, 2012, 1950: 442-446.
- [18] OSSAI C I, RAGHAVAN N. Statistical Characterization of the State-of-Health of Lithium-ion Batteries with Weibull Distribution Function-A Consideration of Random Effect Model in Charge Capacity Decay Estimation [J]. Batteries, 2017, 3(4): 32.
- [19] XU X, CHEN N. A State-space-based Prognostics Model for Lithium-ion Battery Degradation [J]. Reliability Engineering and System Safety, 2017, 159: 47-57.
- [20] LI X, DING Q, SUN J Q. Remaining Useful Life Estimation in Prognostics Using Deep Convolution Neural Networks [J]. Reliability Engineering and System Safety, 2018, 172: 1-11.
- [21] 杜许龙. 基于信息融合方法的卫星部件可靠性预测 [J]. 西安: 西安理工大学, 2018.
- [22] 王一宣, 李泽滔. 基于改进支持向量回归机的锂离子电池剩余寿命预测 [J]. 汽车技术, 2020(2): 28-32.
- [23] 王飞. 改进初值 II 隐马尔可夫模型预测电池剩余寿命研究 [J]. 哈尔滨: 哈尔滨理工大学, 2018.
- [24] 张洋. 基于相关向量机的锂离子电池在线剩余寿命预测方法研究 [J]. 长沙: 国防科学技术大学, 2016.
- [25] BARALDI P, COMPARE M, SAUCO S, et al. Ensemble Neural Network-based Particle Filtering for Prognostics [J]. Mechanical Systems and Signal Processing, 2013, 41(1-2): 288-300.
- [26] DONG G Z, CHEN Z H, WEI J W, et al. Battery Health Prognosis Using Brownian Motion Modeling and Particle Filtering [J]. IEEE Transactions on Industrial Electronics, 2018, 65(11): 8646-8655.
- [27] LECUN Y, BENGIO Y, HINTON G. Deep Learning [J]. Nature, 2015, 521(7553): 436-444.
- [28] SILVER D, HUANG A, MADDISON C J, et al. Mastering the Game of Go with Deep Neural Networks and Tree Search [J]. Nature, 2016, 529(7587): 484-489.
- [29] CHEN Z Y, ZENG X Q, LI W H, et al. Machine Fault Classification Using Deep Belief Network [J]. // 2016 IEEE International Instrumentation and Measurement Technology Conference Proceedings. Taipei: IEEE, 2016: 1-6.
- [30] SHAO H, JIANG H, ZHANG X, et al. Rolling Bearing Fault Diagnosis Using an Optimization Deep Belief Network [J]. Measurement Science & Technology, 2015, 26(11): 115002.
- [31] LU C, TAO L F, FAN H Z. Li-ion Battery Capacity Estimation: A Geometrical Approach [J]. Journal of Power Sources, 2014, 261: 141-147.
- [32] ZHAO R, XIE J Y, ZHANG L B, et al. Multisensory Fusion Based Virtual Tool Wear Sensing for Ubiquitous Manufacturing [J]. Robotics and Computer-Integrated Manufacturing, 2017, 45: 47-58.
- [33] 刘敏, 陆宁云, 肇刚, 等. 基于近邻保持嵌入的卫星姿态控制系统微小故障检测 [J]. 空间控制技术与应用, 2018, 44(2): 42-48.
- [34] BENGIO Y. Learning Deep Architectures for AI [J]. Foundations & Trends in Machine Learning, 2009, 2(1): 1-27.
- [35] 吕燕彬. 深度神经网络架构改进和训练性能提升的研究 [J]. 太原: 中北大学, 2016.

作者简介



曹孟达 男, (1995—), 就读于国防科技大学管理科学与工程专业, 博士研究生。主要研究方向: 卫星遥测数据分析。



张涛 男, (1976—), 博士, 教授。主要研究方向: 能源互联网。



王羽 男, (1997—), 硕士研究生。主要研究方向: 航天器的故障诊断与健康管理。



张亚军 男, (1997—), 硕士研究生。主要研究方向: 锂离子电池健康管理。



(* 通信作者) 刘亚杰 男, (1975—), 博士, 副教授。主要研究方向: 数据驱动的复杂系统演化规律。