

文章编号: 1007-5429(2024)01-0142-09

DOI: 10.19495/j.cnki.1007-5429.2024.01.014

基于深度强化学习的混合能源系统多目标优化研究

吕永敬¹, 张涛², 李凯文^{2*}, 赵红¹

(1. 中国科学院大学 经济与管理学院, 北京 100049;

2. 国防科技大学 系统工程学院, 湖南 长沙 410073)

摘要: 在新能源技术高速发展的背景下, 本文提出了一种基于深度强化学习的多目标优化方法, 对混合能源系统进行配置和设计。首先, 设计了一种基于循环神经网络的深度强化学习方法, 对系统配置方案优化过程中计算耗时的目标值进行近似估计, 以在线优化的方式实现能源系统运行控制策略的快速求解; 其次, 以经济性、可靠性、环境效益作为优化指标, 采用多目标进化算法对混合能源系统进行优化配置, 计算得到满足用户不同偏好的帕累托解集; 最后, 以离网型混合能源系统作为研究对象验证了该方法的有效性, 所提方法明显优于多种传统优化设计方法。

关键词: 深度强化学习; 多目标优化; 混合能源系统规划

中图分类号: O 221

文献标识码: A

Research on Multi-objective Optimization of Hybrid Energy System Based on Deep Reinforcement Learning

LYU Yongjing¹, ZHANG Tao², LI Kaiwen^{2*}, ZHAO Hong¹

(1. School of Economics and Management, University of Chinese Academy of Sciences,

Beijing 100049, China; 2. College of System Engineering, National University of

Defense Technology, Changsha, Hunan 410073, China)

Abstract: With the rapid development of new energy technologies, a multi-objective optimization method based on deep reinforcement learning was proposed for the configuration and design of hybrid energy systems. Firstly, a deep reinforcement learning method based on recurrent neural networks was designed to approximate the time-consuming process of objective calculation in the optimization of system configuration schemes. The energy system operation control strategy could be optimized in a fast manner by means of online optimization. Secondly, taking economy, reliability and environmental benefits as optimization objectives, a multi-objective evolutionary algorithm was used to optimize the configuration of hybrid energy system, and Pareto solution set satisfying different user preferences was calculated. Finally, an off grid hybrid energy system was taken as an example to verify the effectiveness of this method. The proposed method was obviously superior to various traditional optimization methods.

收稿日期: 2022-11-10

基金项目: 国家自然科学基金面上项目(71972175); 国家社会科学基金重大项目(208-ZD075)

作者简介: 吕永敬(1973—), 江苏徐州人, 博士, 主要研究方向为能源互联网技术、人工智能技术以及运筹优化方法。E-mail: 15616269417@163.com。

*通信作者: 李凯文, 讲师, 博士, 主要研究方向为强化学习、智能优化。E-mail: 1176414603@qq.com。

— 142 —

Key words: deep reinforcement learning; multi-objective optimization; hybrid energy system planning

1 引言

近年来,随着化石能源的过度开发和全球环境问题的日益加剧,风力发电、光伏发电等可再生能源技术得到了大力发展,集成可再生能源发电、储能系统以及传统化石能源发电的混合能源系统是当前能源技术发展阶段下促进能源利用转型的重要方式^[1],是实现“碳达峰、碳中和”目标的重要途径。

混合能源系统是集成太阳能、风能、柴油/市电能源、储能系统以及其他可再生能源的系统。由于可再生能源和负载的间歇性和波动性,需要对混合能源系统的配置进行合理优化才能保证对负载可靠供电、降低系统成本,即对太阳能、风能、储能等元件的数量进行优化,从而提高经济效益、环境效益以及供电可靠性。混合能源系统的优化配置需要考虑可再生能源资源禀赋、建设预算以及负荷需求,相对于传统能源系统,混合能源系统涉及的设备种类繁多,需要考虑经济性、可靠性、环境效益等指标^[2],优化配置也往往更加复杂。混合能源系统从运行方式上分为并网型和离网型。并网型可接入大电网进行能源交易。离网型能源系统多建设于海岛、偏远山区、军事营区等与大电网分离的地区。从系统构成上,混合能源系统分为光伏、光伏-风力、光伏-储能、光伏-储能-柴油发电机等具有不同结构构成的类型^[3]。

作为近年来的研究热点,混合能源系统优化配置的研究已相对成熟。DEETJEN等^[4]对美国德州电力可靠性委员会的一处光伏-风力混合能源系统进行了优化配置,只考虑了经济性目标,得到了光伏 26.6 GW、风力 11.1 GW 的最优配置。JACOB等^[5]、HUA等^[6]向系统中引入了储能单元,白天光伏发电所储存的电力用于满足夜晚的负荷用电,或者向大电网进行卖电。BERRUETA等^[7]对西班牙纳瓦拉地区的屋顶光伏系统进行了优化配置,通过引入储能系统提高整体经济效益。PANAYIOTOU等^[8]综合考虑了风力发电、光伏发电以及储能系统,为法国南部尼斯的混合能源系统

进行优化配置,考虑了其夏天干热、冬季温和的气候特点,所设计的规划算法能够在 100% 满足负荷需求的前提下最小化系统成本。

针对离网型混合能源系统,除了上述文献主要优化的经济性指标之外,可靠性是系统优化需要考虑的重要指标。MALEKI和ASKARZADEH^[9]对伊朗南部的一处离网型混合能源系统进行了优化配置,综合考虑风力发电、光伏发电以及储能,以可靠性和经济性为优化目标,结论证明综合考虑风力和光伏在可靠性和经济性上优于仅考虑风力发电或光伏发电,综合使用风力和光伏发电能够使得可再生能源在不同时段均满足负荷的需求。KUMAR等^[10]进一步将柴油发电机集成至离网混合能源系统当中,以满足重要负载的需求,在中等风力资源和充足阳光资源的印度某地区进行了案例研究,证明了其优化配置方法能够有效提高供电可靠性。BILAL等^[11-12]额外将二氧化碳排放量作为环境效益指标对混合能源系统进行了规划配置,采用多目标进化算法对模型进行优化,得到多个具有不同经济性、环境效益偏好的帕累托非支配解集供用户选择。针对其他类型的混合能源系统,LIAN等^[3]、AL-FALAH等^[13]进行了详细的综述研究,并对不同优化配置方法进行了分析比较。在优化算法方面,进化算法^[14-16]、粒子群算法^[17-19]、模拟退火算法^[20-21]、蚁群优化算法^[22]以及各种混合类算法被广泛应用于混合能源系统的优化配置当中。

为了对系统配置方案进行优化,需要计算优化过程中每个方案的适应度值/目标值,例如在该规划方案下系统运行一年的成本。然而能源系统不同的运行控制策略会导致不同的运行成本,存在一个最优的运行控制策略可以使系统成本最小,理论上可以通过优化算法对该运行控制策略进行寻优,但是对一年的运行控制策略进行优化通常需要很长的运算时间。在系统配置方案优化的过程中,通常需要上万次的适应度值/目标值计算,如果每次目标值计算时均进行运行控制策略的寻优会导致算法耗时严重,无法运行。因此,当前大多数文献在进行规划配置方案的优化时,都通过人工设计的

“规则”对能源系统的运行进行控制,从而计算每个方案的目标值。然而人工设计的运行控制规则无法达到系统最优的运行状态,从而导致对方案目标值的估计存在一定误差,得到的优化方案也无法反映其真实的经济性或可靠性指标。

鉴于此,本文提出一种新的基于深度强化学习的方法对方案的目标值进行估计,能够以在线优化的方式对能源系统的运行控制策略进行快速求解,得到近似最优的系统运行控制策略,克服计算个体目标值费时这一困难。相对于传统的规则式方法,本文所设计方法能够有效提高能源系统运行控制策略的质量,从而能够在系统配置方案的优化过程中,对每个方案的目标值进行更加准确的估计,以提高混合能源系统优化设计的合理性。本文以离网型风-光-储能-柴油发电机混合能源系统为研究对象,以年化成本、可靠性、二氧化碳排放为规划目标,采用多目标进化算法结合深度强化学习方法对混合能源系统进行优化配置,验证了该方法在混合能源系统优化上的有效性。

2 系统建模

本文所研究的离网型混合能源系统由光伏电池阵列、风力发电机、柴油发电机、蓄电池组构成,决策变量为光伏电池阵列、风力发电机、蓄电池、柴油发电机的数量,通过对该混合能源系统进行优化配置,以系统成本最小化、环境效益和供电可靠性最大化为优化目标。

计算优化目标需要对光伏、风电、柴油发电机的发电能力以及储能系统的能量交互进行计算,因此首先需要对光伏、风电、储能以及柴油发电机的发电进行建模。

2.1 光伏发电模型

考虑太阳辐照度、温度以及太阳高度角等因素,对光伏发电进行建模。太阳辐照度由太阳能直射、反射以及散射三个部分构成,本文只考虑辐照度中占比最大的直射部分。

因为太阳的位置不同,不同时刻光伏板实际接收的辐照度也存在差别。根据太阳高度角 h 、光伏板的安装倾角 β ,给定辐照度水平分量 S ,光伏板接收到的有效太阳辐照度 S_p 可通过以下公式计算^[2]:

$$S_i = \frac{S}{\sin h}$$

$$S_p = S_i \sin(h + \beta)$$

太阳高度角 h 由以下公式计算:

$$\delta = \theta \times \sin\left(360^\circ \times \frac{284 + n}{365}\right)$$

$$\sinh = \sin \varphi \sin \delta + \cos \varphi \cos \delta \cos \tau$$

$$\tau = \frac{360}{24} (12 - lt)$$

其中: δ 是太阳赤纬角, θ 是地球公转方向与地轴之间的倾角, n 代表天数序数, τ 为时角, φ 是纬度, lt 代表本地时间。根据有效太阳辐照度 S_p ,给定在 t 时刻的环境温度 $T_A(t)$,光伏发电的输出功率为^[2]:

$$T_c(t) = T_A(t) + \frac{N_{COT} - 20}{800} S_p(t, \beta)$$

$$I_{sc}(t) = [I_{sc,STC} + K_I(T_c(t) - 25)] \frac{S_p(t, \beta)}{1000}$$

$$V_{oc}(t) = V_{oc,STC} - K_V \times T_c(t)$$

$$P_M(t, \beta) = N_s \times N_p \times V_{oc}(t) \times I_{sc}(t, \beta) \times FF(t)$$

其中: N_{COT} 为光伏电池的额定工作温度; I_{sc} 和 V_{oc} 为光伏电池的短路电流和开路电压; $I_{sc,STC}$ 和 $V_{oc,STC}$ 为标称条件下光伏电池的短路电流和开路电压; K_I 和 K_V 代表温度系数; $FF(t)$ 是填充因子,为光伏电池的物理参数; N_s 为串联的光伏板个数, N_p 为并联的光伏板个数。

2.2 风力发电模型

风力发电量由风机叶片的物理性质、风速、空气密度等因素决定,风机发电模型为:

$$P_{WG}(v, t) = \begin{cases} 0, & v < V_c \\ \frac{1}{2} C_p \rho A_{WG} v^3, & V_c \leq v < V_r \\ P_{WGR}, & V_r \leq v < V_f \\ 0, & v \geq V_f \end{cases}$$

其中: V_c 是风机的切入风速,当风速小于 V_c 时,风机无法达到启动速度; V_f 是切出风速,当风速大于 V_f 时,风机会过载损耗,因此发电功率为0; V_r 是额定风速,当风速达到 V_r 时以额定功率 P_{WGR} 发电;当风速小于 V_r 时发电功率取决于风速 v 、风机的性能系数 C_p 、空气密度 ρ 和转子叶片面积 A_{WG} 。

2.3 储能单元模型

本文仅考虑蓄电池储能,储能系统电池组的荷电状态(state of charge, SOC)为:

$$SOC(t+1) = SOC(t) + \frac{(P_{bat}(t)/V_{bus}) \Delta t \eta}{C_n}$$

其中: η 是充放电效率, P_{bat} 为充放电功率(充电时为正值), Δt 是充电时长, V_{bus} 是直流母线电压。

储能电池组的总容量 C_n 由电池数量决定, 具体为:

$$C_n = \frac{N_{\text{bat}}}{n_{\text{bs}}} C_{\text{bat}}, \quad n_{\text{bs}} = \frac{V_{\text{bus}}}{V_{\text{bat}}}$$

其中: C_{bat} 是单个电池容量, N_{bat} 是电池总数量, V_{bat} 是额定电压, n_{bs} 代表电池串联个数。

2.4 柴油发电机模型

给定柴油发电机的输出功率 P_{dg} , 柴油发电机消耗的燃料量为:

$$F_{\text{cons}} = B_{\text{dg}} P_{\text{dg}} + A_{\text{dg}} P_{\text{r,dg}}$$

其中: $P_{\text{r,dg}}$ 是发电机的额定功率, 即每次开机运行, 无论发电机的实际输出功率为多少, 均需要耗费一定的燃料; A_{dg} 为开机燃料消耗系数; B_{dg} 为输出功率燃料系数。

2.5 多目标优化建模

对能源系统的优化模型, 考虑系统运行的经济性、可靠性和环境效益三个目标, 优化的决策变量为混合能源系统内光伏电池阵列、风力发电机、柴油发电机等各个组件的数量。优化目标基于第2.1~2.4中的元件模型公式进行计算。

针对经济性目标, 本文采用系统年化成本作为优化指标, 包括系统的初始投资成本 C_{ainv} 、年化元器件替换成本 C_{arep} 以及年化运行和维修成本 C_{aom} 。系统年化成本为^[2]:

$$\begin{aligned} \text{ACS} = & C_{\text{ainv}} (PV + WG + TOWER + BAT + DG) \\ & + C_{\text{aom}} (PV + WG + TOWER + BAT + DG) \\ & + C_{\text{arep}} (BAT) \end{aligned}$$

其中: $TOWER$ 表示风机塔的建设成本, PV 、 WG 、 BAT 和 DG 分别代表光伏、风机、电池、柴油发电机的成本, 仅考虑蓄电池的更换成本。

初始投资成本 C_{ainv} 是考虑资本利率和通胀率之后的“年化”初始投资成本, 具体为^[2]:

$$\begin{aligned} C_{\text{ainv}} = & \sum C_{\text{inv}} \text{CRF}(i, L_{\text{com}}) \\ \text{CRF}(i, L_{\text{com}}) = & \frac{i(1+i)^{L_{\text{com}}}}{(1+i)^{L_{\text{com}}} - 1} \\ i = & \frac{i_{\text{nom}} - f}{1+f} \end{aligned}$$

其中: 资本回收因子 (capital recovery factor, CRF) 用于计算在特定期限和利率下, 需要的等额年度付款金额以回收初始资本投资; i 是实际利率, 由利率 i_{nom} 和通胀率 f 计算得到; L_{com} 为元件寿命, 以年计;

C_{inv} 是元件的初始投资成本。

年化元器件替换成本 C_{arep} 为^[2]:

$$\begin{aligned} C_{\text{arep}} = & C_{\text{rep}} \text{SFF}(i, L_{\text{rep}}) \\ \text{SFF}(i, L_{\text{rep}}) = & \frac{i}{(1+i)^{L_{\text{rep}}} - 1} \end{aligned}$$

其中: C_{rep} 是总更换成本, SFF 为偿债基金系数, L_{rep} 代表元件替换之前的寿命。

年化运行和维修成本 C_{aom} 包括各元件的维修成本和运行中燃料消耗的总成本, 不同能源系统设备的运行时长、运行模式也会影响维修成本, 本文为简化计算, 将维修成本设置为固定值 C_{repair} , 运维成本为^[2]:

$$C_{\text{aom}} = \sum C_{\text{repair}} + \sum_{t=1}^T F_{\text{cons}}(t) F_{\text{price}}$$

通过上述公式, 可根据系统的固定投入和年化消耗, 折算得到系统运行的年化成本。

在离网型混合能源系统中, 由于未接入大电网, 存在一定程度上无法满足负载需求的情况, 因此可靠性目标计算为功率供应缺失比例 (loss of power supply probability, LPSP):

$$LPSP = \frac{\sum_{t=0}^T T(P_{\text{avail}}(t) < P_{\text{load}}(t))}{T}$$

其中: $LPSP$ 代表一年运行期间未满足负荷功率需求的小时数比例; $P_{\text{avail}}(t)$ 为光伏、风力、柴油发电机在 t 时刻的发电总功率, 由上述模型计算得到。

环境效益目标由二氧化碳排放量计算:

$$F_{\text{emission}} = \sum_{t=1}^T F_{\text{cons}}(t) E_f \quad (13)$$

其中: E_f 为单位燃料燃烧所排放的二氧化碳量。因此, 该多目标优化问题可建模为:

$$\begin{aligned} \text{Min } F_{\text{obj}} = & (ACS, LPSP, F_{\text{emission}}) \\ \text{s.t. } & 0 \leq N_{\text{pv}} \leq N_{\text{pv}}^{\text{max}} \\ & 0 \leq N_{\text{wg}} \leq N_{\text{wg}}^{\text{max}} \\ & 0 \leq N_{\text{bat}} \leq N_{\text{bat}}^{\text{max}} \\ & 0 \leq N_{\text{dg}} \leq N_{\text{dg}}^{\text{max}} \end{aligned}$$

3 模型求解

本文采用进化算法对该多目标优化模型进行求解, 即首先初始化为多个个体构成的种群, 在进化的每一代, 计算种群中每个个体的三个目标值, 根据个体的目标值更新种群, 从而得到最终的帕累

托解集。

模型求解的核心问题是如何计算个体的目标值,每个个体代表一种该能源系统的规划设计方案。因此,需要计算采用该系统配置方案的情况下,系统运行一年的燃料消耗、功率供应缺失比例。采用不同的运行控制方法(储能系统、发电机在不同时刻的充放电以及开关机)会产生不同的燃料消耗和功率缺失比例,理想情况是采用优化算法计算得到能源系统在该配置方案下最优的控制策略(一年中每个小时的开关机和充放电)。但是如果采用这种方式计算目标值,每进化一代都需要对种群中的每个个体进行一次控制策略优化,耗时极其严重,无法实际使用。因此,目前常用的方法是设定简单的运行规则,对开关机和充放电进行规则式控制,但是该方法明显无法得到最优的控制策略,会造成额外的燃料消耗或者过大的功率缺失,从而导致目标值估计不准。

基于此,本文采用深度强化学习方法,得到给定能源系统配置方案下的系统运行控制策略,以远低于传统优化算法的计算耗时得到近似最优的系统运行控制策略,从而对个体的目标值进行准确估计。

3.1 深度强化学习运行控制建模

本文设计基于循环神经网络的PPO(proximal policy optimization)强化学习方法^[23]对能源系统的运行控制策略进行优化,从而为多目标优化算法提供个体目标值的有效估计。

3.1.1 强化学习建模

强化学习由智能体、环境、状态 s_t 、动作 a_t 、奖励 r_t 组成,智能体在环境中根据当前状态 s_t 执行动作 a_t ,获得反馈奖励 r_t ,根据动作和环境转移到了新的系统状态 a_{t+1} ,智能体不断地进行上述过程,以最大化奖励为目的对自身选择动作的策略进行更新。

在本文中,能源系统的状态定义为五元组 $(P_{pv}, P_{wg}, P_{load}, SOC, T_{hour})$,代表当前的光伏发电量、风力发电量、负荷、储能电池的荷电状态以及所在的时刻,并根据最大配置数量所对应的数值进行归一化。

动作为柴油发电机的开启和关闭,如果风力、光伏以及柴油发电功率超过了负荷,则给蓄电池充

电,少于负荷则蓄电池放电,因此只对柴油发电机的启停进行决策。

反馈奖励设置为最小化燃油消耗和功率缺失比例,为了使得两者具有相同量纲,使用柴油发电机总发电功率代表燃油消耗,使用负荷未被满足的总功率代表功率缺失比例,两者之和的负数作为奖励。

3.1.2 策略建模

给定当前状态,智能体根据策略进行动作的选择,本文采用基于长短期记忆(long short-term memory, LSTM)的深度神经网络模型对策略进行建模。

由于光伏、风电、负荷具有不确定性,模型需要根据可再生能源以及负荷的历史规律对未来的发电量和负荷进行预测估计,这样才可以实现对能源系统的有效运行控制,仅仅根据当前时刻 t 的状态信息 $(P_{pv}, P_{wg}, P_{load}, SOC, T_{hour})$ 很难进行正确的决策。因此,本文采用LSTM将历史状态信息融入策略决策当中,策略神经网络具体结构为:

$$y = Relu(LSTM(s_t))$$

$$y = Relu(FF(y))$$

$$P_{a_t} = Softmax(FF(y))$$

其中: $Relu$ 为激活函数; FF 为全连接神经网络; $Softmax$ 为归一化函数,用于将多个标量映射为动作选择的概率分布。其计算公式为:

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}, \quad j = 1, \dots, K$$

其中: z_j 代表第 j 个神经元的输出, K 表输出神经元的个数。

3.1.3 模型训练

采用PPO算法对该基于深度神经网络的模型进行训练。PPO是近年来新提出的一种策略梯度方法,在多种强化学习任务中超越了传统强化学习方法。作为一种策略梯度方法,需要设计一个值网络(Critic神经网络)对值函数进行估计。本文中值网络采用和上述策略网络相同的神经网络结构,把最后一层替换为单输出的全连接层,从而输出值函数的估计 V_{ϕ_s} 。PPO算法流程如下:

Step 1 给定策略网络的初始参数 θ_0 和值网络

的初始参数 ϕ_0 。

Step 2 在第 k 次训练过程中,执行策略 $\pi(\theta_k)$ 得到累计奖励 $\hat{R}_t$,并根据 V_{ϕ_k} 计算得到优势函数估计 $\hat{A}_t$ 。

Step 3 根据以下公式更新策略网络参数,详见论文[23]。

$$\theta_{k+1} = \arg \max_{\theta} \sum \min \left(\frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_k}(a_t | s_t)} A^{\pi_{\theta_k}}(s_t, a_t), g(\epsilon, A^{\pi_{\theta_k}}(s_t, a_t)) \right)$$

Step 4 以最小化 $(V_{\phi}(s_t) - \hat{R}_t)^2$ 为目标更新值网络。

模型离线训练完成之后,给定一个能源系统的配置方案,可采用该模型快速计算得到该方案下系统的最优运行策略,计算得到功率缺失比例以及燃油消耗量,并据此对本文提出的三个目标值进行计算,从而作为种群中个体的目标值进行配置方案的多目标优化。

3.2 多目标优化模型求解

基于上述对于个体目标值的计算方法,采用多目标进化算法对混合能源系统的配置方案进行多目标优化,步骤如下:

Step 1 随机初始化规模为 N 的种群,每个个体编码为 $[N_{pv}|N_{wgl}|N_{bat}|N_{dg}]$ 。

Step 2 在每一代进化过程中,首先对种群以 p 的概率进行模拟二进制交叉操作,以 q 的概率进行变异操作,得到子代种群。

Step 3 基于深度强化学习方法计算种群内每个个体的 M 个目标值($M=3$)。

Step 4 采用NSGA-II算法的非支配排序算子,将父代和子代种群合并,得到所有个体的非支配排序等级,优先保留排序靠前的个体,直至个体总数超过了 N 。

Step 5 如果多于 N 个个体被保留,计算个体间的拥挤度距离,并以0.2的概率将最拥挤的个体删除,以保持种群的多样性。

Step 6 删除重复解,并进行下一轮迭代。

进化完成之后,对 N 个个体筛选得到非支配解,每个解代表一个配置方案,通过该多目标优化过程,可以一次运行得到具有不同偏好的多个配置方案供用户选择。

4 实验

4.1 实验设置

采用文献[2]中西班牙某地的数据进行案例研究,时间步长为1小时,采用文献[2]提供的风速、太阳辐射等气象数据以及负荷数据,混合能源系统各元件的参数设置如表1~4所示。

表1 光伏板参数

参数名	值	参数名	值
开路电压 V_{OC}/V	21	额定电池工作温度 $NCOT/^{\circ}C$	43
短路电流 I_{SC}/A	7.22	初始投资成本 $C_{ainv}/\$$	3 000
最大电压 V_{max}/V	17	运行维修成本 $C_{aom}/\$$	30
最大电流 I_{max}/A	6.47	寿命 $L_{com}/年$	25

表2 风机参数

参数名	值	参数名	值
额定功率/W	10 000	寿命 $L_{com}/年$	25
风机初始投资成本 $C_{ainv}/\$$	3 013	风机塔初始投资成本 $C_{ainv}/\$$	250
风机运行维修成本 $C_{aom}/\$$	50	风机塔运行维修成本 $C_{aom}/\$$	2.5

表3 蓄电池参数

参数名	值	参数名	值
额定容量/Ah	100	运行维修成本 $C_{aom}/\$$	1.26
电压/V	12	元器件替换成本 $C_{arep}/\$$	126
最低SOC/%	20	寿命 $L_{com}/年$	5
初始投资成本 $C_{ainv}/\$$	126	充放电效率 η	0.8

表4 柴油发电机参数

参数名	值	参数名	值
额定功率/W	2 000	运行维修成本 $C_{aom}/\$$	0.17
初始投资成本 $C_{ainv}/\$$	1 514	寿命 $L_{com}/年$	25

计算目标函数时,利率和通胀率设置为3.75%和1.50%,二氧化碳排放 E_f 设置为2.5 kg/lit。神经网络模型的隐含层维度为50,策略网络和价值网络的学习率设置为0.001,PPO算法的裁剪参数 ϵ 设置为0.2,经验池规模设置为1 024,折扣因子为1,设置训练1 000代。多目标优化算法的交叉概率为0.8,变异概率为0.2,种群大小为100,进化代数为50。

4.2 实验结果

为验证本文所提深度强化学习(deep reinforcement learning,DRL)方法的有效性,选择经典多目标优化算

法 MOEA/D (multi-objective evolutionary algorithm based on decomposition)、NSGA- II (non-dominated sorting genetic algorithm II)、IBEA (indicator-based evolutionary algorithm)、SPEA2 (strength pareto evolutionary algorithm 2)、PICEA-g (pareto incremental cooperative coevolutionary algorithm) 作为对比算法,采用文献[2]所设计的能源系统运行控制规则进行种群个体目标值的计算。采用 HyperVolume (HV) 指标评估解的质量。本文所提算法 DRL 和其他算法在规划方案求解质量上的对比结果如表 5 所示,每个算法的结果为 11 次运行的平均值。

表 5 算法对比结果

算法	指标(HV)
DRL	2.491 3 $\times 10^{10}$
NSGA-II	2.420 5 $\times 10^{10}$
SPEA2	2.425 8 $\times 10^{10}$
IBEA	2.410 4 $\times 10^{10}$
MOEA/D	1.101 8 $\times 10^{10}$
PICEA-g	2.423 4 $\times 10^{10}$

由表 5 可见,本文所提方法明显超越了传统的混合能源系统多目标优化方法,在 HV 指标上超越了所有的对比方法。相对于基于规则的运行控制策略,所设计的深度强化学习方法能够有效实现控制策略的优化,解决了个体目标值计算费时的问题。

图 1 给出了 PPO 算法训练 1 000 次的奖励值变化曲线,可见平均奖励值基本收敛,验证了强化学习算法的有效性。图 2 展示了本文所提方法得到的帕累托前沿,可见帕累托前沿分布均匀,系统配置成本和功率缺失比例两个目标互相冲突,低系统成本会导致高功率缺失比例,符合问题特征。帕累托前沿由一系列帕累托最优解构成。因此,算法一次运行可以得到具有不同目标值偏好的多个规划设计方案,用户可根据经济性、可靠性、环境效益不同目标的偏好进行方案的选择。

进一步对采用深度强化学习方法得到的单个配置方案的系统运行结果进行分析,并与基于规则的运行控制策略进行对比分析,结果如表 6 所示。随机选取具有不同配置的多个规划方案,由于三个目标均可以根据燃料消耗量和功率缺失比例计算,




图 1 PPO 训练奖励值曲线




图 2 帕累托解集

因此对该两个指标进行对比。

表 6 规划方案运行结果对比

规划方案	算法	燃料消耗	功率缺失率
[10, 10, 15, 2]	DRL	3 335	0
	规则	4 150	4.02%
[13, 12, 18, 1]	DRL	2 940	1.58%
	规则	2 445	19.2%
[4, 5, 8, 3]	DRL	5 130	0
	规则	6 673	0
[30, 20, 30, 5]	DRL	2 301	0
	规则	4 169	0
[5, 15, 5, 1]	DRL	2 558	2.44%
	规则	2 358	18.7%

由表 6 结果可见:在 [10, 10, 15, 2]、[4, 5, 8, 3]、[30, 20, 30, 5] 的系统配置方案下,采用深度强化学习方法得到的运行结果具有更少的燃料消耗和功率缺失率,明显超过了传统规则式方法;在其余配置方案下,深度强化学习方法和规则式方法各有优劣。规则式方法虽然具有较低的燃料消耗,但是功率缺失比例达到了 20% 左右;而强化学习得到的运行结果只是稍微增加了燃料消耗,却极大降低了功

率缺失比例。

图3展示了当风机数量为0时,随机选取的时间段内光伏发电曲线和柴油发电机的启停状况。在光伏发电充足时,发电机仅偶尔开启;在光伏发电量为0时,发电机处于常开启状态以满足负荷需求。在光伏发电能够满足负载需求时,发电机仍然偶尔开启,从而为储能系统充电作为备用,以供总发电功率不足时负载的用电。然而文献[2]所采用规则只有当可再生能源功率不足以满足负荷功率时才开启柴油发电机,这导致储能系统没有足够的电量储备,在发电功率不足时无法进行电池供电,从而产生较大的功率供应缺失率,因此会产生表6所示的结果。




图3 光伏发电和柴油发电机运行状态

综上所述,本文所提方法能够有效提高混合能源系统规划的可靠性,得到的帕累托解集质量超越了多个传统方法,单个配置方案的质量得到了有效提升,方法具有合理性。

5 结论

本文提出了一种基于深度强化学习的混合能源系统多目标优化方法,设计了一种深度强化学习方法对优化过程中目标值计算这一费时过程进行近似估计,以在线优化的方式实现能源系统运行控制策略的快速求解。基于对目标值的准确计算,采用多目标进化算法对混合能源系统的配置方案进行优化,从而得到满足用户不同偏好的帕累托解集。实验证明该方法能够有效提升解的质量,超越了多个传统的多目标优化方法,并且单个配置方案的质量得到了有效提高,明显超越了传统基于规则的方法。该方法为求解该类混合能源系统优化配

置问题提供了一种新的更加有效的思路,并可以推广到不同类型能源系统的优化配置过程当中,具有广泛的理论创新和应用意义。

近年来,人工智能技术的飞速发展,为能源系统规划建设这一经典的管理学科问题带来了新的启示。传统依靠专家经验的人工设计手段很难适应愈发复杂的系统结构和新时代对于多样性优化目标的需求,本文证明了深度强化学习等人工智能技术能够有效提高系统规划建设的效率和可靠性,能够对系统的特性进行自适应地学习和调整,从而对系统成本、可靠性、环境效益等多目标进行综合考虑,为系统优化设计等管理学经典问题提供了新的思路。

未来的研究需要考虑更加复杂的混合能源系统结构,考虑不同能源系统运维方式对系统配置的影响,进一步针对并网型微电网进行研究。考虑燃料电池、飞轮储能、生物质能发电、潮汐能发电等不同储能和发电形式,并针对超大规模的混合能源系统优化方法进行研究,考虑算法在大规模优化问题上的性能,提高混合能源系统的优化效率。

参考文献:

- [1] WU W, CHRISTIANA V I, CHEN S A, et al. Design and techno-economic optimization of a stand-alone PV (photovoltaic)/FC (fuel cell)/battery hybrid power system connected to a wastewater-to-hydrogen processor[J]. Energy, 2015, 84: 462-472.
- [2] SHI Z, WANG R, ZHANG T. Multi-objective optimal design of hybrid renewable energy systems using preference-inspired coevolutionary approach[J]. Solar Energy, 2015, 118(8): 96-106.
- [3] LIAN J, ZHANG Y, MA C, et al. A review on recent sizing methodologies of hybrid renewable energy systems[J]. Energy Conversion and Management, 2019, 199: 112027.
- [4] DEETJEN T A, MARTIN H, RHODES J D, et al. Modeling the optimal mix and location of wind and solar with transmission and carbon pricing considerations[J]. Renewable Energy, 2018, 120: 35-50.
- [5] JACOB A S, BANERJEE R, GHOSH P C. Sizing of hybrid energy storage system for a PV based microgrid through design space approach[J]. Applied Energy, 2018, 212: 640-653.
- [6] HUA Z, MA C, LIAN J, et al. Optimal capacity allocation of multiple solar trackers and storage capacity for utility-scale photovoltaic plants considering output characteristics and complementary demand[J]. Applied Energy, 2019, 238: 721-733.

- [7] BERRUETA A, HECK M, JANTSCH M, et al. Combined dynamic programming and region-elimination technique algorithm for optimal sizing and management of lithium-ion batteries for photovoltaic plants[J]. *Applied Energy*, 2018, 228: 1-11.
- [8] PANAYIOTOU G, KALOGIROU S, TASSOU S. Design and simulation of a PV and a PV-Wind standalone energy system to power a household application[J]. *Renewable Energy*, 2012, 37(1): 355-363.
- [9] MALEKI A, ASKARZADEH A. Artificial bee swarm optimization for optimum sizing of a stand-alone PV/WT/FC hybrid system considering LPSP concept[J]. *Solar Energy*, 2014, 107: 227-235.
- [10] KUMAR R, GUPTA R A, BANSAL A K. Economic analysis and power management of a stand-alone wind/photovoltaic hybrid energy system using biogeography based optimization algorithm[J]. *Swarm and Evolutionary Computation*, 2013, 8: 33-43.
- [11] BILAL B O, SAMBOU V, KÉBÉ C M F, et al. Methodology to size an optimal stand-alone PV/wind/diesel/battery system minimizing the levelized cost of energy and the CO₂ emissions[J]. *Energy Procedia*, 2012, 14: 1636-1647.
- [12] BILAL B O, SAMBOU V, NDIAYE P A, et al. Study of the influence of load profile variation on the optimal sizing of a standalone hybrid PV/wind/battery/diesel system[J]. *Energy Procedia*, 2013, 36: 1265-1275.
- [13] AL-FALAH M D A, JAYASINGHE S D G, ENSHAEI H. A review on recent size optimization methodologies for standalone solar and wind hybrid renewable energy system[J]. *Energy Conversion and Management*, 2017, 143: 252-274.
- [14] GONZÁLEZ A, RIBA J R, RIUS A, et al. Optimal sizing of a hybrid grid-connected photovoltaic and wind power system[J]. *Applied Energy*, 2015, 154: 752-762.
- [15] ZHANG Y, MA C, LIAN J, et al. Optimal photovoltaic capacity of large-scale hydro-photovoltaic complementary systems considering electricity delivery demand and reservoir characteristics[J]. *Energy Conversion and Management*, 2019, 195: 597-608.
- [16] MAHMOUDIMEHR J, SHABANI M. Optimal design of hybrid photovoltaic-hydroelectric standalone energy system for north and south of Iran[J]. *Renewable Energy*, 2018, 115: 238-251.
- [17] KORNELAKIS A, MARINAKIS Y. Contribution for optimal sizing of grid-connected PV-systems using PSO[J]. *Renewable Energy*, 2010, 35(6): 1333-1341.
- [18] MALEKI A, AMERI M, KEYNIA F. Scrutiny of multifarious particle swarm optimization for finding the optimal size of a PV/wind/battery hybrid system[J]. *Renewable Energy*, 2015, 80: 552-563.
- [19] MALEKI A, KHAJEH M G, AMERI M. Optimal sizing of a grid independent hybrid renewable energy system incorporating resource uncertainty, and load uncertainty[J]. *International Journal of Electrical Power & Energy Systems*, 2016, 83: 514-524.
- [20] XIE K, DONG J, TAI H M, et al. Optimal planning of HVDC-based bundled wind-thermal generation and transmission system[J]. *Energy Conversion and Management*, 2016, 115: 71-79.
- [21] EKREN O, EKREN B Y. Size optimization of a PV/wind hybrid energy conversion system with battery storage using simulated annealing[J]. *Applied Energy*, 2010, 87(2): 592-598.
- [22] MENSHSARI A, GHIAMY M, MOHAMMAD M, et al. Optimal design of hybrid water-wind-solar system based on hydrogen storage and evaluation of reliability index of system using ant colony algorithm[J]. *International Journal of Sciences: Basic and Applied Research (IJSBAR)*, 2013, 4(11): 3582-3600.
- [23] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[EB/OL]. <https://arxiv.org/abs/1707.06347>, 2017-07-20.