

doi: 103969/j.issn.1003-3106.2020.04.006

引用格式: 曹孟达,张涛,李文桦,等.基于粒子群算法的卫星蓄电池区间预测方法[J].无线电工程,2020,50(4):285-293.[CAO Mengda,ZHANG Tao,LI Wenhua,et al.A Method for Interval Prediction of Satellite Battery Health State Based on Particle Swarm Optimization Algorithm[J].Radio Engineering,2020,50(4):285-293.]

基于粒子群算法的卫星蓄电池区间预测方法

曹孟达,张涛,李文桦,王羽,刘亚杰*

(国防科技大学 系统工程学院,湖南长沙 410073)

摘要: 卫星在阴影区运行时需要蓄电池提供能源,而锂离子电池由于能量密度大、自放电率低、循环寿命长的优点逐渐成为多数卫星的选择。卫星蓄电池在外太空工作时,容量会随着循环次数的增多而逐渐下降。针对这种健康状态(State of Health, SOH)退化的问题,提出一种基于粒子群算法(Particle Swarm Optimization, PSO)的上下边界估计(Lower Upper Bound Estimation, LUBE)神经网络建立预测模型,将放电过程中的截止电压、样本熵和工作温度作为神经网络模型输入,电池SOH作为神经网络模型输出。在提高预测区间覆盖率(Prediction Intervals Coverage Probability, PICP)的同时减少预测区间宽度(Normalized Mean Prediction Intervals Width, NMPIW),构建了集成指标(Coverage Width-based Criterion, CWC)。基于该指标函数的不可微性,采用PSO优化神经网络模型使CWC尽可能地降低以兼顾PICP和NMPIW指标的最优。采用NASA的18号电池测试数据,对所提区间预测算法的有效性进行了分析验证。

关键词: 电池健康状态; 粒子群算法; 上下边界估计法; 区间预测

中图分类号: TM912

文献标志码: A

开放科学标识码(OSID):



文章编号: 1003-3109(2020)04-0285-09

A Method for Interval Prediction of Satellite Battery Health State Based on Particle Swarm Optimization Algorithm

CAO Mengda, ZHANG Tao, LI Wenhua, WANG Yu, LIU Yajie*

(College of Systems and Engineering, National University of Defense Technology, Changsha 410073, China)

Abstract: Satellites need batteries to provide energy when operating in shadow regions, and lithium-ion batteries have become the choice of most satellites due to their high energy density, low self-discharge rate and long cycle life. When a satellite battery is working in outer space, its capacity will gradually decrease as the number of cycles increases. For the problem of the state of health (SOH) degradation, a neural network model based on lower upper bound estimation and particle swarm optimization (PSO-LUBE) is proposed. The prediction model is constructed using LUBE neural network, and the method used the discharge cutoff voltage, the discharge voltage sample entropy and the operating temperature as the inputs for the neural network model and the battery state of health (SOH) as the output for the neural network model. To improve the prediction interval coverage and reduce the prediction interval width, an integrated index CWC is constructed. Additionally, based on the nondifferentiability of this index function, a particle swarm algorithm is used to optimize the neural network to make the CWC as low as possible and the optimal values of PICP and NMPIW are taken into account. Finally, the test data of NASA battery No.18 is used to analyze and verify the validity of the proposed interval prediction algorithm.

Key words: battery state of health; particle swarm optimization; lower upper bound estimation (LUBE); interval prediction

0 引言

随着在轨工作卫星数量的逐渐增多,其安全性和稳定性逐渐成为人们关注的问题。电源系统作为卫星在太空中稳定运行的关键保障,一旦损坏或者发生故障,卫星将会因为失去动力而完全失效。电源系统通常将蓄电池、太阳能电池等多种储能技术

耦合使用,为卫星提供安全可靠的电力供应^[1-2]。在光照区,太阳能电池阵供给负载并为蓄电池组充电^[3];在阴影区,蓄电池为卫星运行提供动力。蓄电池作为卫星在阴影区运行时的唯一能量来源,一

收稿日期: 2019-11-15

基金项目: 装备技术基础项目(181GF35003)

Foundation Item: Funded by Basic Project of Equipment Technology (181GF35003)

2020年 无线电工程 第50卷 第4期 285

旦出现异常状况,卫星将无法在阴影区工作^[4-5]。由于锂离子电池具有能量密度高、循环寿命长、自放电率低等优点,已经作为第三代储能电池被广泛应用于航天航空领域^[6]。然而,随着锂离子电池使用时间的增加,固体电解质界面(Solid Electrolyte Interface, SEI)膜的形成、电池内部电解液分解以及电极材料分解、剥落或腐蚀等都会造成电池性能退化^[7-8]。因此需要研究电池的健康状态(State of Health, SOH),实时监测电池的老化情况,有效地保障卫星安全稳定运行^[9]。

本文主要以 NASA 公开的 PCOE 锂离子蓄电池地面实验数据为基础,选择锂离子电池的放电截止电压、放电温度及放电电压样本熵作为输入,锂离子电池 SOH 作为输出^[10-12],构建了上下边界估计(Lower Upper Bound Estimation, LUBE)神经网络,采用粒子群算法(Particle Swarm Optimization, PSO)对神经网络预测效果进行优化^[13],得到了良好的预测结果。该方法能够以少量参数,通过训练好的神经网络模型对卫星锂离子蓄电池的 SOH 提供一个有效合理的区间预测,既能够提供锂离子电池的实时剩余容量,也能为锂离子电池的输出功率状态提供可靠的波动范围。同时还能够随着新数据的增加,不断更新迭代模型,一旦输出波动达到警戒阈值,地面操作人员能够及时调整卫星工作状态。

1 国内外研究现状分析

随着航天航空事业的飞速发展,蓄电池组作为卫星电源分系统中的重要组件,其 SOH 的评估和预测成为了人们关注的重点^[14]。SOH 表征电池相对于新电池存储电能和能量的能力,随着充放电循环的增加,电池的 SOH 会逐渐下降。目前针对蓄电池 SOH 的评估方法主要有基于模型和基于数据驱动的 2 种方法。基于模型的方法包含基于电池退化机理模型、等效电路模型和经验退化模型^[15]。基于退化机理的模型主要通过分析影响电池的内外因素如 SEI 膜厚度、电解液浓度、温度等构建起退化模型,但所需参数大多无法直接获得,且建模过程复杂^[16]。等效电路法^[17]则更多依据电池元件中各部件的电路特性构造退化模型,但需要阻抗谱等对参数进行识别。而经验退化模型相较于前二者所需参数较少,但需要大量实验数据拟合构建^[18]。

因此,对于锂离子电池这种典型的动态、非线性的电化学系统^[19],在线应用时内部参数难以直接测量等问题导致模型法常常难以实现。近年来,随着人工智能、机器学习的快速发展,基于数据驱动的方法可以采用历史数据挖掘电池内部的有用信息,依托各种映射和回归工具来建立退化模型,一定程度上能够克服模型法对于不同电池要建立不同模型的弱点。吴婧睿等^[20]提出了基于萤火虫优化算法的极限学习机锂离子剩余使用寿命(RUL)预测模型。罗悦等人开展基于粒子滤波的锂离子电池 RUL 的研究,构建粒子滤波与自回归模型相融合的混合型 RUL 预测方法^[21]。SAHA 等人^[22]采用电池电化学阻抗谱(Electrochemical Impedance Spectroscopy, EIS)测试数据建立电池模型,将电池离线模型参数和在线状态过程相结合,构建了基于 RVM 算法获取指数模型相关参数并给出 SOH 预测结果。

然而上述针对锂离子电池 SOH 与 RUL 的数据驱动方法,大多只能得到确定性的点预测,研究者的重点集中在如何提高点预测的准确率。但在实际工程应用中,卫星受轨道、环境变化的影响,数据经常存在较大的不确定性,点预测仅仅给出一个确切的数值,但无法估计该数值出现的概率也无法确定预测结果可能波动的范围,具有很大的局限性和不稳定性。因此本文拟采用了一种基于 LUBE 神经网络的区间预测方法,采用 PSO 优化模型结构,提高模型运算速度,并采用 NASA 公开的 PCOE 锂离子电池数据集验证了方法的可靠性和准确性。

2 基于 PSO 的卫星蓄电池健康状态区间预测方法

2.1 卫星蓄电池健康状态区间预测方法

本文所提出卫星蓄电池区间预测方法的流程如图 1 所示。首先收集蓄电池放电过程中的电压、温度和容量数据,在此基础上从放电电压数据序列提取样本熵和放电截止电压。之后选择放电截止电压、样本熵及温度作为输入,蓄电池容量作为输出,构建和训练 LUBE 的神经网络模型。在此过程中采用 PSO 优化模型参数。最后基于 NASA 公开的相关锂离子实验数据,对本文所提预测方法的有效性进行验证。




图1 健康状态区间预测方法流程

Fig.1 Flowchart of the method for interval prediction of health state

22 健康状态与退化特征

本文选择锂离子蓄电池的 SOH 作为区间预测模型的输出,一般将满电状态下蓄电池放电到截止电压过程释放的电量和新电池额定容量的比值作为蓄电池的 SOH^[23]:

$$SOH = \frac{C_i}{C} \times 100\% (i = 1, 2, 3, \dots),$$

式中, C_i 为蓄电池第 i 次放电的电池容量 (Ah); C 为蓄电池出厂时的额定容量,一般 $C = \text{Max}(C_i)$ 。

从遥测数据中提取与 SOH 相关的退化特征参数。蓄电池放电过程中,放电电压随着放电过程逐渐下降,放电结束时所对应的最低电压即为放电截止电压,如图 2 所示。




图2 锂离子电池放电过程电压变化

Fig2 Voltage changes during discharge of lithium ion batteries

随着蓄电池循环放电次数的增多,蓄电池性能下降,电池自满电状态开始放出同一电量后的放电截止电压会逐渐下降,能够很好地表征蓄电池 SOH 的退化过程,因此本文采用放电截止电压作为分析电池性能的特征量之一。但仅仅采用放电截止电压作为神经网络模型输入,对锂离子蓄电池退化过程中的容量恢复效应等局部波动不敏感,因此在从放电电压数据中进一步提取样本熵。由于样本熵是一种量化时间序列波动的规律性和不可预测性的非线性

性动力学参数,能够很好地捕捉锂离子蓄电池 SOH 的局部变化^[24-25]:对于有 N 个数据组成的时间序列 $\{x(n)\} = x(1), x(2), \dots, x(N)$, 计算步骤如下^[26]:

① 按时间序列的序号选取一组维数为 m 的向量序列,其中 $X_m(i) = \{x(i), x(i+1), \dots, x(i+m-1)\}$, $1 \leq i \leq N-m+1$ 。这组向量表示在 N 个数据中从第 i 点开始的 m 个连续值;

② 对向量 $X_m(i)$ 和 $X_m(j)$ 之间的距离 $d[X_m(i), X_m(j)]$, 定义为 2 组向量对应元素中最大差值的绝对值,即 $d[X_m(i), X_m(j)] = \max_{k=0, \dots, m-1} (|x(i+k) - x(j+k)|)$;

③ 对于给定的 $X_m(i)$, 计算 $X_m(i)$ 和 $X_m(j)$ 之间距离小于等于 r 的 j ($1 \leq j \leq N-m, j \neq i$) 的数量,记为 B_i , 即: $B_i^m(r) = \frac{1}{N-m-1} B_i$;

④ 定义 $B^{(m)}(r)$ 为:

$$B^{(m)}(r) = \frac{1}{N-m} \sum_{i=1}^{N-m} B_i^m(r);$$

⑤ 增加维数到 $m+1$, 计算 $X_{m+1}(i)$ 和 $X_{m+1}(j)$ ($1 \leq j \leq N-m, j \neq i$) 距离小于等于 r 的个数, 记为 A_i :

$$A_i : A_i^m(r) = \frac{1}{N-m-1} A_i;$$

⑥ 定义 $A^{(m)}(r)$ 为:

$$A^{(m)}(r) = \frac{1}{N-m} \sum_{i=1}^{N-m} A_i^m(r)。$$

这样, $B^m(r)$ 是 2 个序列在相似容限 r 下匹配 m 个点的概率,而 $A^m(r)$ 是 2 个序列匹配 $m+1$ 个点的概率,样本熵的定义为:

$$\text{SampEn}(m, r) = \lim_{N \rightarrow \infty} \left\{ -\ln \left[\frac{A^{(m)}(r)}{B^{(m)}(r)} \right] \right\}。$$

由于样本熵具有很好的一致性, m 和 r 的值对样本熵的影响是相通的,一般 m 取 1 或 2, r 取 0.1。

当 N 为有限值时,上式可以表达为:

$$\text{SampEn}(m, r, N) = -\ln \left[\frac{A^{(m)}(r)}{B^{(m)}(r)} \right]。$$

23 LUBE 神经网络与 PSO

23.1 LUBE 神经网络

现有的直接区间预测方法中, LUBE 神经网络是较为经典和常用的, 其结构如图 3 所示, 是对变量在未来一段时间的波动范围进行预测, 在本文中即对锂离子蓄电池 SOH 一个上下界范围的估计。这个上下界的估计范围组成的预测区间由下限 L_i 和上限 U_i 组成, 其中预测结果 y_i 以一定概率存在于预测区间, 在这个区间的可能性称为置信水平。通常采用区间覆盖率 (Prediction Intervals Coverage Probability, PICP) 和区间宽度 (Normalized Mean Prediction Intervals Width, NMPIW) 来衡量预测区间的质量^[27]。




图3 LUBE神经网络结构

Fig3 LUBE neural network structure

区间覆盖率 PICP 是通过计算有多少个真实值位于预测区间内来衡量的, 其定义如下: $PICP = \frac{1}{N} \sum_{i=1}^N C_i$, 当真实值落在预测区间内时, C_i 为 1, 否则 C_i 为 0。

理想情况下, PICP 应该非常接近或大于预测区间的置信水平, PICP 接近 0, 说明落在区间内的实际值很少, PICP 接近 1, 说明大多数实际值落在区间内, PICP 值越大则区间质量越好。但是仅考虑 PICP 常常会导致预测区间过宽, 这样得到预测区间是没有意义的。因此, 在考虑 PICP 的同时, 还应该考虑预测区间的宽度。预测区间的平均宽度 (MPIW) 定义:

$$MPIW = \frac{1}{N} \sum_{i=1}^N (U_i - L_i)。$$

在实际应用中, 习惯采用标准化的 MPIW (NMPIW) 来度量, 定义如下:

$NMPIW = MPIW/R$, R 为待测目标的取值范围, NMPIW 越小则预测区间质量越好。

PICP 和 NMPIW 的变化范围均为 $[0, 1]$ 。要构造高质量的预测区间既需要较高的区间覆盖率, 又需要 NMPIW 不能过大。但 NMPIW 越小, PICP 也会随之下降。因此这 2 个指标是互斥的。针对二者的互斥特性, 构造了集成指标 CWC 来综合表示这 2 个指标对区间质量的贡献:

$$CWC = NMPIW \cdot (1 + \gamma(PICP) e^{-\eta(PICP - \mu)})，$$

式中, $\gamma(PICP)$ 定义为:

$$\gamma = \begin{cases} 1, & \text{if } PICP < \mu \\ 0, & \text{if } PICP \geq \mu \end{cases}$$

通常可以将 μ 设置为置信水平 $1 - \alpha$ 。如果区间覆盖率高于 $1 - \alpha$, 则区间的质量仅通过其宽度 NMPIW 来测量。同时, 如果 PICP 无法达到 $1 - \alpha$, 则会受到惩罚。 η 通常被设置为一个较大的惩罚系数, 如 50^[27]; CWC 越小, 则区间质量越好。但由于该指标是不可微的, 因此利用 PSO 对网络结构进行优化, 通过调整 CWC, 生成同时兼顾 PICP、NMPIW 的高质量 SOH 预测区间。基本算法流程如图 4 所示。




图4 基于 PSO 优化 LUBE 神经网络的流程

Fig4 Flowchart of lower upper bound estimation neural network based on particle swarm optimization

(1) 数据准备: 将原始数据分为训练集和测试集两部分。训练集用于模型训练, 测试集用于测试算法效果, 并对数据进行相应的归一化处理。

(2) 参数初始化: 采用随机梯度下降产生初始参数 w_{opt} , 将参数迁移到 PSO 中, 作为 PSO 优化的初始参数。

(3) 通过在学习得到的参数加入随机扰动, 产生 N_{pop} (种群大小) 个粒子个体;

(4) 计算每个粒子的 CWC 后, 更新粒子群的全局最优解和个体历史最优解;

(5) 粒子群更新后对神经网络进行寻优操作, 直到满足终止条件或达到迭代次数;

(6) 根据评价指标评测模型的性能利用得到的神经网络对测试集进行区间预测。

2.3.2 粒子群算法

PSO 作为一类经典的优化算法, 在 1995 年 Eberhart 和 Kennedy 的人工生命和演化计算理论中被首次提出^[28]。在 PSO 算法中, 可以将每个优化问题的解视作搜索空间中的一只鸟, 称之为“粒子”。每个粒子都被赋予了一个初始化的位置和速度以及一个由适应度函数决定的适应值。每个粒子都被赋予记忆功能, 能记住搜索过程中的最佳位置^[30]。在每一次迭代训优的过程中, 粒子通过跟踪 2 个“极值”来更新自身的速度和位置, 分别为粒子本身找到的最优解——个体极值点 (p_{best}) 和整个种群目前找到的最优解——全局极值点 (g_{best})。粒子的速度和位置的迭代更新如下:

$$v_i(t+1) = \omega v_i(t) + c_1 R_1 [R_i^b(t) - x_i(t)] + c_2 R_2 [R_g^b(t) - x_i(t)],$$

$$x_i(t+1) = x_i(t) + \phi v_i(t+1),$$

式中, t 为迭代次数; v_i 为第 i 个粒子在 t 次迭代的速度; ω 为惯性权重; c_1, c_2 为认知系数, 合适的 c_1, c_2 可以加快收敛且不易陷入局部最优, 通常设置 $c_1 = c_2 = 2$; R_1, R_2 为 $[0, 1]$ 的随机数; $R_i^b(t)$ 为粒子 i 个体历史最优位置; $R_g^b(t)$ 为群体历史最优位置; $x_i(t)$ 为粒子在 t 次迭代的位置; ϕ 是收缩因子, 用来保持速度在一定范围内。

与其他智能算法相比, PSO 的优势在于简单、鲁棒性好、易于实现和收敛速度快, 能以较大概率找到问题的全局最优解^[31]。因此本文采用 PSO 算法对 LUBE 模型的集成参数 CWC 进行寻优, 建立满足目标函数的锂离子蓄电池 SOH 区间预测模型。

3 算例分析

3.1 实验数据

为验证本文描述的 PSO-LUBE 神经网络区间预测模型的有效性, 使用来源于 NASA 埃姆斯卓越故

障预测研究中心公布的用于实验验证的锂离子电池退化状态监测数据集进行实验验证。该锂离子电池数据在爱达荷国家实验室使用市场销售的 18650 锂离子电池进行测试, 额定容量为 2 Ah。该实验在 24℃ 条件下通过 3 种不同的工作特性 (充电、放电、阻抗) 以 15 A 的恒定电流对蓄电池进行充电, 至电压达到 4.2 V 后, 再以 2 A 的恒定电流进行放电, 直至电压降低到截止电压时结束。每次循环过程中, 电池具有相同的放电深度, 在连续充电和放电循环期间, 收集电池的实际容量并通过 EIS 以 0.1~5 kHz 的频率进行阻抗测量。

本文选择数据集中 18 号电池数据对模型效果进行检验。图 5、图 6 和图 7 分别给出了本文提取自 18 号电池的每一个放电周期中放电截止电压、放电电压的样本熵与温度: 在提取样本熵时, m, r 分别设置为 1, 0.1。从图中能够看出, 样本熵随着循环次数的增加而不断增大, 而放电截止电压随循环次数的增加而逐渐减小。而电池工作温度没有明显的随时间变化的规律, 在 37.5℃ 上下波动, 波动变化不超过 1℃。




图 5 18 号电池放电截止电压变化

Fig5 Cut-off voltage changes of battery No.18 discharge




图 6 18 号电池放电电压样本熵变化

Fig6 Sample entropy changes of battery No.18 discharge




图7 18号电池温度变化

Fig7 Temperature changes of battery No.18




图8 18号电池容量变化

Fig8 Capacity changes of battery No.18

18号电池归一化后的容量变化曲线如图8所示。可以看出,随着循环次数的增加,容量逐渐降低至失效阈值。

32 模型参数设置

模型参数设置如表1所示。

表1 参数设置


Tab.1 Parameter settings

μ	γ	c_1	c_2	进化次数	N_{pop} (种群大小/个)	V_{max}	V_{min}	Pop_{max}	Pop_{min}
0.9	50	1499.5	1499.5	50	50	0.5	-0.5	2	-2


初始化 LUBE 神经网络模型时,通常将置信水平设置为 0.9 以满足实际预测需求,惩罚系数则设为 50。为提升 PSO 算法在该问题上的计算性能,将 c_1, c_2 都设置为 1499.5,该参数值被证明在许多问题上具有较好的性能。利用 PSO 算法对神经网络预测进行寻优,决策变量为神经网络的权重 w 和阈值 b ,因此,将算法的速度最大、最小值分别设置为 0.5, -0.5。PSO 种群大小的个数设为 50,进化次数设为 50,每次迭代中粒子的更新方式按照 2.3.2 介绍的进行计算。

3.3 实验结果和分析

将放电截止电压、样本熵及放电温度作为输入变量,代入已经设置好参数的 PSO-LUBE 神经网络模型中,SOH 预测区间(由上、下边界构成)作为输出变量,结果如图9所示。给出了初始化神经网络参数后不采用 PSO 对模型参数进行优化的结果,其中图9(a)为神经网络模型训练效果,图9(b)为神经网络模型效果。可以看出,未采用 PSO 优化的神经网络模型能够对蓄电池 SOH 的退化趋势拟合的很好,但无法得到有效的预测区间。



(a) 神经网络模型拟合效果



(b) 神经网络模型预测效果

图9 未采用 PSO 优化的神经网络模型

Fig9 Neural network model without particle swarm optimization

图 10 为经过 PSO 优化神经网络模型后得到的拟合情况和预测效果。在粒子群寻优过程中,初始平均 NMPIW 较窄,PICP 接近于 0,CWC 初始较大。随着迭代过程的进行,PICP 逐渐收敛至稍高于 0.9,而 NMPIW 在不影响区间覆盖率的情况下慢慢变窄,在这一过程中 CWC 一直在不断减小,最终迭代得到了有效的预测区间。图 10(a) 结果表明以放电截止电压、样本熵和温度作为输入的 PSO-LUBE 神经网络模型能够模拟出电池的退化情况,而图 10(b) 则表示预测区间能将实际值包含在内,但整体预测 NMPIW 较大。蓄电池实际 SOH 在第 132 个周期达到失效阈值,预测的 SOH 分别在第 93 周期后就多次达到了失效阈值,影响了地面操作人员对蓄电池性能的准确判断。因此过宽的 NMPIW 虽然保证了区间覆盖率,但也降低了预测区间的可靠性与实用性,因此在初始化 PSO-LUBE 神经网络时,如果将 μ, γ 设置得过高,将会存在过拟合问题。




图 10 未对 μ 和 γ 调优的神经网络模型
Fig10 Neural network model without optimizing μ and γ

为尽可能提高区间覆盖率的同时将覆盖宽度也尽可能的减小,进一步对 $\mu = \{0.8, 0.82, \dots, 0.96\}$

和 $\gamma = \{10, 15, \dots, 50\}$ 的组合进行了遍历试验,发现将 μ, γ 分别取值为 0.86, 40 时,能够在对区间覆盖率影响不大的情况下减少区间覆盖宽度,使 CWC 最小。图 11 给出了将置信水平 μ 和惩罚系数 γ 调整后所得到的拟合情况和预测效果。从图 11(a) 可以看到,通过上述优化调整,在不降低区间覆盖率的情况下,得到了较窄的 NMPIW,而图 11(b) 的结果表明,经过优化后的区间预测下边界更接近真实值,仅有 3 个点掉出区间边界,体现出了良好的预测效果。




图 11 对 μ 和 γ 调优后的神经网络模型
Fig11 Neural network model after optimizing μ and γ

最终经过训练好的神经网络模型预测效果通过预测区间平均 NMPIW、PICP 和 CWC 三个指标来度量,其结果如表 2 所示。可以看出,调整模型初始化参数后虽然区间覆盖率有所下降,但 NMPIW 更窄,CWC 更低,预测区间的质量更好,对地面操作人员具有更好的警示作用。

表 2 预测效果对比

电池类型	NMPIW	PICP/%	CWC
18 号电池调优前	0.391 3	0.941 7	0.391 3
18 号电池调优后	0.153 2	0.893 9	0.176 6

4 结束语

区间预测不仅能描述未来一段时间内蓄电池 SOH 的波动范围,同时能有效评估预测区间的可靠性,给出 SOH 在不同置信水平下可能的波动区间与失效阈值,更好地为地面操作人员提供参考。本文针对卫星锂电池 SOH 评估和预测需求,提出了一种 PSO-LUBE 神经网络区间预测模型,选择蓄电池放电过程中放电截止电压、样本熵和工作温度作为输入,对蓄电池的健康状况进行预测,通过 PSO 优化神经网络模型参数,使 CWC 尽可能降低从而得到高质量预测区间。基于 NASA 的 18 号电池测试数据的实验结果表明,本文所提的锂电池 SOH 区间预测方法能够较好地预计锂电池 SOH 的退化趋势和局部波动,并能同时确保区间覆盖率和区间覆盖宽度,有着较为满意的表现。当卫星锂电池 SOH 发生突变时,通过对 SOH 预测结果和实际结果进行对比,可为地面操作人员提供相关的预警,具有良好的实用性。

考虑到部分在轨卫星向地面站所发回的遥测数据中并不包含电池容量参数,因此,下一步可以基于该情况继续开展在轨卫星锂电池 SOH 预测研究,比如在地面选择同种电池进行同工作状态实验,并把地面实验数据与在轨遥测参数进行有效融合。此外,对 LUBE 神经网络中 CWC 还可以进一步优化完善,以进一步提高预测性能。



参考文献

- [1] PENG X Y, PANG J Y, PENG Y, et al. Review on Anomaly Detection of Spacecraft Telemetry Data [J]. Chinese Journal of Scientific Instrument, 2016, 37(9): 1929-1945.
- [2] 曹孟达, 张涛, 李训嘉, 等. 一种基于聚类的卫星太阳能电池衰减估计方法 [J]. 无线电工程, 2019, 49(5): 397-403.
- [3] TAGUCHI M. 24.7% Record Efficiency Hit Solar Cell on Thin Silicon Wafer [J]. Photovoltaics, IEEE Journal of, 2014, 4(1): 96-99.
- [4] ZHANG B Z. Evolution and Application of PHM Technologies [J]. Measurement and Control Technology, 2008, 27(2): 5-7.
- [5] 吴建若. 太阳同步轨道卫星电源系统的研究与发展 [J]. 世界导弹与航天, 1990(8): 37-38.
- [6] AN X Y, TAN L S. Development of Lithium-ion Batteries as New Power Sources for Space Application [J]. Power technology, 2006(1): 70-73.
- [7] 吴赞, 蒋新华, 解晶莹. 锂离子电池循环寿命快速衰减的原因 [J]. 电池, 2009, 39(4): 206-207.
- [8] ZHANG Q, WHITE R E. Capacity Fade Analysis of a Lithium Ion Cell [J]. Journal of Power Sources, 2008, 179(2): 793-798.
- [9] 申江卫, 苏晓波, 王泽林, 等. 基于混合算法的电池健康状态估计 [J]. 电源技术, 2018, 42(6): 874-876.
- [10] WIDODO A, SHIM M C, CAESARENDRA W, et al. Intelligent Prognostics for Battery Health Monitoring Based on Sample Entropy [J]. Expert Systems with Applications, 2011, 38(9): 11763-11769.
- [11] CUI H J, MIAO Q, LIANG W, et al. Application of Unscented Particle Filter in Remaining Useful Life Prediction of Lithium-ion Batteries [C] // Prognostics and System Health Management Conference, 2012.
- [12] 袁晓辉, 王乘, 张勇传, 等. 粒子群优化算法在电力系统中的应用 [J]. 电网技术, 2004, 28(19): 14-19.
- [13] 郑贵文, 蒋奎. 基于粒子群算法的雷达网优化部署方法研究 [J]. 无线电工程, 2016, 46(1): 42-45.
- [14] CHENG L, TANG A, WANG W. A Review of SOH Estimation Methods in Lithium-ion Batteries for Electric Vehicle Applications [J]. Energy Procedia, 2015, 75: 1920-1925.
- [15] 张凝, 徐皓冬, 王锴, 等. 基于粒子滤波算法的锂离子电池剩余寿命预测方法研究 [J]. 高技术通讯, 2017, 27(8): 699-707.
- [16] 闫晓华. 空间电源系统仿真及锂离子电池剩余寿命预测研究 [D]. 哈尔滨: 哈尔滨工业大学, 2015.
- [17] 韩丽, 戴广剑, 李宁, 等. 基于 GA-Elman 神经网络的电池劣化程度预测研究 [J]. 电源技术, 2013, 37(2): 249-250.
- [18] 徐崇彦, 何川东, 邹冬冬. 基于贪婪策略的灵巧卫星启发式任务规划算法 [J]. 无线电工程, 2018, 48(10): 908-912.
- [19] 刘大同. 锂离子电池健康评估和寿命预测综述 [J]. 仪器仪表学报, 2015, 36(1): 1-16.
- [20] 吴婧睿. 基于 GSO-ELM 的锂离子电池剩余寿命间接预测方法研究 [D]. 大连: 大连海事大学, 2017.
- [21] 罗悦. 基于粒子滤波的锂离子电池剩余寿命预测方法研究 [D]. 哈尔滨: 哈尔滨工业大学, 2012.
- [22] SAHA B, KAI G, POLL S, et al. Prognostics Methods for Battery Health Monitoring Using a Bayesian Framework [J]. IEEE Transactions on Instrumentation & Measurement, 2009, 58(2): 291-296.
- [23] 邓伟锋, 李振璧. 基于 GA 优化 BP 神经网络的微电网蓄电池健康状态评估 [J]. 电测与仪表, 2018, 55(21): 56-60.
- [24] RICHMAN J S, RANDALL J R. Physiological Time-series Analysis, Using Approximate Entropy and Sample Entropy [J]. American Journal of Physiology - Heart and Circulatory Physiology (Print), 2000, 278(6): H2039

-H2049.

- [25] ALCARAZ R, RIETA J J. A Review on Sample Entropy Applications for the Non-invasive Analysis of Atrial Fibrillation Electrocardiograms [J]. Biomedical Signal Processing & Control, 2010, 5(1) : 1-14.
- [26] GRASSBERGER P, PROCACCIA I. Measuring the Strangeness of Strange Attractors [M]. New York: The Theory of Chaotic attractors, Springer, 2004.
- [27] KHOSRAVI A, NAHAVANDI S, CREIGHTON D, et al. Comprehensive Review of Neural Network - based Prediction Intervals and Nw Avances [J]. IEEE Transactions on Neural Networks, 2011, 22 (9) : 1341-1356.
- [28] KENNEDY J, EBERHART R. Particle Swarm Optimization [C] // Proc. of 1995 IEEE Int. Conf. Neural Networks, 1995.
- [29] 杨维, 李歧强. 粒子群优化算法综述 [J]. 中国工程科学, 2004, 6(5) : 87-94.
- [30] 杨锡运, 关文渊, 刘玉奇, 等. 基于粒子群优化的核极限学习机模型的风电功率区间预测方法 [J]. 中国电机工程学报, 2015, 35(S1) : 146-153.
- [31] 王业琴, 刘一星. 粒子群优化神经网络电动汽车 SOC 估算方法 [J]. 电源技术, 2013, 37(5) : 800-803.

作者简介



曹孟达 男, (1995—), 就读于国防科技大学管理科学与工程专业, 博士研究生。主要研究方向: 卫星遥测数据分析。



张涛 男, (1976—), 教授。主要研究方向: 能源互联网的多目标优化策略、优化调度与决策。



李文桦 男, (1995—), 硕士研究生。主要研究方向: 进化算法、微电网。



王羽 男, (1997—), 硕士研究生。主要研究方向: 数据驱动的航天器健康管理。



(* 通信作者) **刘亚杰** 男, (1975—), 博士, 研究员, 副教授。主要研究方向: 数据驱动的复杂系统演化规律。