

并行智能优化算法研究进展

张 国^{1,2}, 王 锐^{1,2†}, 雷洪涛^{1,2}, 张 涛^{1,2}, 王 凌³

(1. 国防科技大学 系统工程学院, 湖南 长沙 410073;

2. 多能源系统智慧互联技术湖南省重点实验室, 湖南 长沙 410073; 3. 清华大学 自动化系, 北京 100084)

摘要: 基于种群迭代搜索的智能优化算法在农业、交通、工业等很多领域都取得了广泛的应用. 但是该类算法迭代寻优的特点使其求解效率通常较低, 很难应用到大规模、高维或实时性要求较高的复杂优化问题中. 随并行分布式技术的发展, 国内外很多学者开始着手研究智能优化算法的并行化. 本文首要介绍了并行智能优化算法的基本概念; 其次从协同机制、并行模型以及硬件结构3个维度综述了几类常见的并行智能优化算法, 详细分析阐述了它们优点及不足; 最后对并行智能优化算法的未来研究进行了展望.

关键词: 大规模优化; 智能优化算法; 并行计算; 并行优化算法

引用格式: 张国, 王锐, 雷洪涛, 等. 并行智能优化算法研究进展. 控制理论与应用, 2023, 40(1): 1–11

DOI: 10.7641/CTA.2021.10084

Survey on parallel intelligent optimization algorithms

ZHANG Guo^{1,2}, WANG Rui^{1,2†}, LEI Hong-tao^{1,2}, ZHANG Tao^{1,2}, WANG Ling³

(1. College of Systems Engineering, National University of Defense Technology, Changsha Hunan 410073, China;

2. Hunan Key Laboratory of Multi-Energy System Intelligent Interconnection Technology (HKL-MESI²T),
Changsha Hunan 410073, China;

3. Department of Automation, Tsinghua University, Beijing 100084, China)

Abstract: Population based intelligent optimization algorithms have been widely used in a variety of fields such as agriculture, transportation and industry. However, their iterative search based behavior makes them inefficient in addressing large-scale, high-dimensional and complex optimization problems, especially with high real-time requirements. With the development of parallel and distributed technology, many scholars in lots of countries began to study the parallel of intelligent optimization algorithm. In this survey, we first introduce the basic concepts of parallel intelligent optimization algorithms. Second, several types of common parallel intelligent optimization algorithms are summarized from the perspectives of coordination mechanism, parallel models and hardware structure. Also, their advantages and disadvantages are discussed in detail. Finally, some future research on the parallelization of intelligent optimization algorithms is prospected.

Key words: large-scale optimization; intelligent optimization algorithms; parallel computing; parallel optimization algorithms

Citation: ZHANG Guo, WANG Rui, LEI Hongtao, et al. Survey on parallel intelligent optimization algorithms. *Control Theory & Applications*, 2023, 40(1): 1–11

1 引言

国家大型工程设计、军事复杂系统决策、大规模交通网络优化以及工厂设备作业的调度中都存在各式各样的复杂优化问题, 这些问题给基于梯度下降法这类传统数学优化方法带来了极大的挑战, 特别是很多优化问题的目标函数不可导, 甚至无法解析表达. 智能优化算法是基于计算智能的机制求解复杂优化问题最优解或满意解的方法. 它通过对生物、物理、化

学、社会、艺术等系统或领域中的相关行为、功能、经验、规则、作用机理的认知, 揭示优化算法的设计原理, 在特定问题特征的导引下提炼相应的特征模型, 设计智能化的迭代搜索型优化算法. 简言之, 基于种群的智能优化算法, 如遗传算法 (genetic algorithm, GA)^[1]、蚁群算法 (ant colony optimization, ACO)^[2]、粒子群算法 (particle swarm optimization, PSO)^[3]等, 采用个体表达待求解优化问题的候选解, 随机生成初

收稿日期: 2021–01–23; 录用日期: 2021–09–23.

†通信作者. E-mail: ruiwangnudet@gmail.com; Tel.: +86 18874962006.

本文责任编辑: 陈增强.

国家优秀青年科学基金(62122093), 国家自然科学基金项目(61973310), 国防科技大学自主科研计划项目(ZZKY-ZX-11-04)资助.

Supported by the National Science Fund for Outstanding Young Scholars (62122093), the National Natural Science Foundation of China (61973310) and the Scientific Key Research Project of National University of Defense Technology (ZZKY-ZX-11-04).

始化种群,然后执行交叉、变异、评估、选择等操作,经过多次迭代搜索获得问题的最优解。相比于传统梯度下降优化方法,智能优化算法不需要问题目标函数的具体数学表达式,鲁棒性高,且全局搜索能力强,因而成为当前解决复杂优化问题的有效方法。

同时,很多实际工程问题需要同时优化两个或两个以上的目标函数,统称为多目标优化问题。因为目标函数之间通常具有一定的冲突,即提升一个目标函数性能的同时会降低另一个目标函数的性能,即不存在一个解使得所有目标函数都达到最优,而是存在一组互有利弊的解集,称为Pareto最优前沿。传统数学优化方法因其一次运行只能找到一个解,因此在求解多目标优化问题时效率较低。基于种群思想的多目标优化算法,在一次寻优迭代的过程中可以找到多个Pareto解,逐渐成为解决多目标优化问题的主流方法。

尽管上述智能优化算法在标准测试集或实际工程问题中都得到了良好的应用,但是随着大数据时代的到来,现实优化问题的规模和复杂性不断增加,对智能优化算法提出了新的挑战。例如面对大规模复杂优化问题时,尤其是搜索空间涉及大量局部最优点和个体解适应度计算成本较高的情况,仅在一个处理器上运行这类迭代搜索型优化算法时,常常会发生内存溢出问题,或者无法在可接受的时间成本内获得近似最优解。

随着多核处理器(central processing unit, CPU)、图形处理器(graphics processing unit, GPU)、分布式计算机集群等物理硬件的更新,计算能力有了很大提升^[4]。与此同时分布式并行技术也在不断发展,出现了很多先进的计算平台与框架,如: OpenCL, CUDA, Spark, Hadoop等。

并行智能优化算法就是利用基于种群的智能优化算法具有天然的并行性特点和分布式并行技术,将智能优化算法部署在分布式系统上可以提高种群的多样性进而增强算法跳出局部最优的能力;另一方面结合分而治之的协同机制有望提高解决大规模复杂优化问题的能力。鉴于此,近年来国内外学者对智能优化算法的并行化开展了大量研究,如图1所示。

本文对智能优化算法的并行化相关研究进行综述,以便更好地梳理该领域取得的成绩和总结该领域未来发展的趋势。文章简单介绍了并行智能优化算法中的并行协同机制以及几类常见迁移拓扑结构。从4类主要并行模型(主从模型、细胞模型、岛屿模型、混合模型)以及硬件结构出发对智能优化算法并行化现有进展进行了讨论和总结。最后对未来研究进行了展望。

2 并行协同机制和迁移拓扑

智能优化算法中的协同机制是将多个对象通过一定的策略展开协同搜索,以达到提升算法性能的目的,

蕴含并行的思想在内^[5]。下面将从种群协同、个体协同、算法协同、操作协同4个角度对并行智能优化算法中的协同机制进行简单介绍。




图1 并行智能优化算法相关研究发展趋势图(数据来源于Google学术搜索)

Fig. 1 The development trend diagram of parallel intelligent optimization algorithms (Data from Google Scholar search)

2.1 种群协同

种群协同机制主要借鉴同物种多子种群协同进化的原理,通过划分子种群与迁移精英个体实现协同搜索,通常基于岛屿模型,各岛屿(子种群)各自独立进化,岛屿间通过定期迁移精英个体共享搜索信息,协同进化,相关研究在本文第3.1节中再行阐述。

2.2 个体协同

个体协同机制基于细胞模型选择不同的个体进行协作,个体被固定在物理拓扑结构下的网格内,通过邻域内的个体相互协作实现种群的进化,相关研究在本文第3.2节中再行阐述。

2.3 算法协同

并行智能优化算法中的算法协同机制通过利用各种算法各自的优势协同搜索改善算法的性能,以解决日益复杂的问题。例如Risco等^[6]异构并行执行SPEA-II和NSGA-II,要比其串行版本得到解质量更高且速度更快。刘福英等^[7]结合SPEA-II和NSGA-II的优点,提出新的并行多目标进化算法并证明了其有效性。Wiak等^[8]在主节点上利用棕鸟群优化算法(flock-of-starlings optimization, FSO)探索整个解空间,从节点执行PSO搜索解空间局部有效区域,并利用细菌趋化性算法(bacterial chemotaxis algorithm, BCA)改进PSO得到的解。Xing等^[9]提出了集成GA与蚂蚁算法(ACO)的分布式协同进化算法。Deng等^[10]提出集成GA和PSO并行协同算法优化模糊神经网络参数(fuzzy neural network)。Li等^[11]融合了人工鱼群和人工蜂群两种算法的优势,提出了并行混合人工鱼群蜂群算法(parallel hybrid artificial fish and bee swarm algorithm,

PHAFB), 在复杂多峰优化问题上具有全局寻优和收敛速度快的优点。

2.4 操作协同

种群通过单一或多类操作实现进化, 如交叉、变异等, 同类操作也可以有不同的实现方式, 如变邻域搜索算子通过不同的邻域结构改变解。采用多算子协同搜索, 既丰富了搜索模式, 又在一定程度上避免陷入单一算子陷入局部最优。Cao等^[12]提出并行合作协同粒子群(parallel cooperative coevolution particle swarm optimization, PCCPSO)算法, 结合全局粒子群算法(global particle swarm optimization, GPSO)针对单峰问题快速收敛和局部粒子群算法(local particle swarm optimization, LPSO)针对多峰问题全局探索的优势协同搜索。Talbi等^[13]提出并行混合元启发式算法, 其中禁忌搜索为主搜索算法, GA保持种群多样性。Wang等^[14]提出了双种群协同进化算法, 两个种群分别采用侧重全局探索与局部开发的两套操作。Cadenas等^[15]构建了一种集中式并行元启发式协作多智能体系统, 其中协作智能体通过引导控制各元启发式算子搜索协同求解优化问题。James等^[16]设计了协同并行禁忌搜索算法, 并行执行禁忌搜索算子并通过全局禁忌表协同求解二次指派问题。Arora等^[17]将进化算子如交叉变异等并行化, 分别实现了实数编码和二进制编码GA。

2.5 迁移拓扑结构

迁移拓扑结构描述了种群间个体交换的路径, 是影响并行智能优化算法性能的重要参数之一。下面首先阐述几类常见的迁移拓扑结构。

主从拓扑, 如图2(a)所示。从节点的操作包括执行进化算子和发送局部最优个体, 而主节点的操作包含接收从节点发送的局部最优个体, 并向所有从节点广播全局最优个体, 从而导致通信负载不均衡。环型拓扑易于实现, 有单环和双环两种迁移方式, 如图2(b)和(c)所示。单环拓扑中最优个体传播缓慢, 易于保持种群的多样性。双环拓扑虽然收敛速度更快, 但是通信负载更高且易于使算法早熟收敛。网格拓扑与环形拓扑相比, 它既包含左右邻居通信, 又包含上下邻居通信, 同时也包括单向和双向迁移, 如图2(d)和(e)所示。在全链接网状拓扑结构中, 每个节点都要向剩余所有节点发送该子种群中的最优个体, 同时接收部分或全部最优个体以替换子种群中一些不良个体, 如图2(f)所示。它具有较高的通信负载, 因此不适合应用于大规模的分分布式并行体系结构中。

在上述拓扑结构中, 无论紧密连接还是稀疏连接, 各有优缺点。文献[18]提出由二进制矩阵决定节点连接的随机拓扑结构, 在算法的收敛性和多样性之间达到平衡。




图2 并行迁移拓扑结构示意图

Fig. 2 Illustration of parallel migration topology

此外, 值得指出的是并行智能优化算法的性能还会受到迁移率和迁移周期参数的影响, 其中迁移率指种群之间一次迁移交换个体的数量; 迁移周期则指种群之间发生迁移的频率。

3 并行智能优化算法中的常见模型

自20世纪90年代以来, 根据上述智能优化算法的并行协同机制和特定的迁移拓扑结构, 学者们提出了一系列并行智能优化算法。这些算法多采用以下4种经典模型: 主从模型、岛屿模型、细胞模型, 以及由前面3种组成的混合模型^[19]。

3.1 主从模型

主从模型采用上述的主从拓扑结构, 如图3所示。精英个体迁移包括同步和异步两种方式。异步避免了同步迁移带来的通信等待问题和通信数据突增问题, 所以主流的主从并行智能优化算法多采用异步迁移。主从模型易于实现, 不同子节点可以设置不同的智能优化算法, 即异构主从模型。由于主从模型向所有节点发送精英个体, 虽然算法收敛速度较快, 但这导致种群多样性下降, 算法易于陷入局部最优。此外通信数据量大, 不适合用于低带宽的系统上。




图3 主从模型示意图

Fig. 3 Illustration of master-slave model

Li等^[20]提出并行基于分解的多目标粒子群算法(multi-objective particle swarm optimization based on decomposition, MOPSO/D)。主线程对种群初始化并

分组,副线程上执行PSO算子,定期迁移最优个体. Silva等人^[21-22]提出并行GA解决生物学领域中蛋白质序列比对问题. 各从节点并行执行GA,主节点定期异步迁移最优个体. Sato等人^[23]提出分布式改进非支配排序遗传算法(distributed NSGA-II, DNSGA-II),通过引入分层排序策略减少非支配排序计算时间,实现算法加速.

Kaur等人^[24]设计了并行SPEA-II算法求解高维图像加密算法中参数优化问题. Kannas等人^[25]提出了基于图进化算法(graph based evolutionary algorithm, gEA)并应用于药物化学结构设计优化问题. Zhan^[26]等人提出基于Spark分布式协同进化算法框架(spark distributed coevolutionary based evolutionary algorithm, SDCEA),并基于spark的量子粒子群优化算法(spark based quantum-behaved particle swarm optimization, SDQPSO),通过在分布式空间上进行并行搜索求解大型分布式优化问题时,不仅有效提升了计算效率,而且相同时间搜索得到解的质量更好.

Niu等^[27]设计了膜启发式多目标进化算法(membrane-inspired multi-objective algorithm, MIMOA)求解双目标随机需求车辆路径问题(BO-VRPSD). 在MIMOA中,由控制子系统通过通信迁移机制引导操作子系统并行执行进化算法的搜索方向. Kus等^[28]设计了AIA (artificial immune algorithm)的并行版本,并应用于机械结构优化问题中. Tsutsui等^[29]在多核CPU上对个体适应度异步多线程并行评估.

综上主从模型不仅实现算法显著加速,同时使得解的质量提升. 此外在小规模优化问题上加速不明显,说明主从并行智能优化算法更适用于解决大规模复杂优化问题^[20,24].

3.2 岛屿模型

岛屿模型,也叫粗粒度模型. 基本思想是将初始种群分成若干子种群并分配给若干子节点,独立执行进化算子搜索最优个体,如图4所示. 一定迭代次数后,各节点之间迁移精英个体提高算法收敛速度. 岛屿模型的可拓展性较强,在没有主节点全局管理的情况下,各节点处于同一级别,可以分别应用不同的智能优化算法. 个体迁移包括同步和异步两种方式. 由于精英个体仅在相邻节点间迁移,通信负载要比主从模式更加均匀. 与主从模型相比,岛屿模型不必向所有节点发送精英个体,虽然收敛速度有一定的下降,但是一定概率上阻止了算法陷入局部最优,同时通信开销小,适合在低带宽系统上运行,可以获得近似线性加速. 由于基于岛屿模型实现智能优化算法并行化,需要先确定迁移个体选择和替换策略、迁移拓扑、迁移周期以及迁移率,这使得算法设计实现较为复杂.

文献[30-32]等均提出了岛屿并行NSGA-II算法. 其中巩敦卫等^[30]基于目标函数分解策略将问题分解

成多个子问题,各子种群执行NSGA-II对子问题进行优化求解并将非支配解发送到外部存档集中组成原优化问题的完整Pareto解集. Wei等^[31]提出并行NSGA-II用于购物推荐系统,所有岛屿并行执行NSGA-II,所得非支配个体发送到本地池中,并迁移全局最优个体加快算法收敛. Rocha等^[32]在计算机集群上设计并行NSGA-II大大降低了外部照明方案设计的时间. 所有岛屿两两互相连接,每隔10代在相邻岛屿之间迁移1%种群数量的精英个体.




图4 岛屿模型示意图

Fig. 4 Illustration of island model

文献[33-34]将MOEA/D并行化,对子问题分区,每个分区的子种群并行执行进化算子逼近整个PF (pareto front). 迁移分区前10%的精英个体以共享信息跳出局部极值,增加算法收敛性和解多样性. Xie等^[35]提出精英个体和乌托邦点混合迁移的pMOEA/D. Ying等^[36]将适用于双目标优化问题的pMOEA/D拓展到高维多目标优化问题(peMOEA/D). 相比较于pMOEA/D的线性分区划分策略,基于最近邻关系划分的分区在高维决策空间上更加均匀,减少了精英个体跨分区迁移的通信负载. 同时自适应迁移拓扑使算法在收敛速度和迁移通信负载两者之间实现平衡.

Liao等^[37]分别设计了主从模型和岛屿模型的并行MOEA/D-STAT^[38]用于特征选取. 岛屿模型中,动态调整岛屿大小的策略使各岛屿的计算时间达到良好的平衡. Dulebenets^[39]提出自适应岛屿进化算法(adaptive island evolutionary algorithm, AIEA)用于求解港口船只泊位调度问题,自适应个体迁移策略可以更有效地探索问题决策空间. Jamshidi等^[40]在控制器局域网(controller area network, CAN)上实现了异步PGA. 与主从模型相比,CAN下的通信数据量非常低,同时具有较强的鲁棒性.

Abd-alsabour^[41]用并行GA求解高维背包问题,验证了并行GA可以解决高维优化问题. Atashapendar等^[42]将加速限制多目标粒子群优化(speed-constrained multi-objective particle swarm optimization, SMPSO)算法与合作协同多目标进化算法框架(cooperative coevolutionary based MOEA, CC-MOEA)结合并进行并行化,各子种群独立进化,定期交换最优个体. Cao等^[43]针对大规模多目标优化问题提出DPCCMOEA (distributed parallel cooperative coevolutionary MO-

EA), 将决策变量分组, 每组由一个子种群并行优化. 文献[44]将Tian等^[45]提出的 GFM-MOEA (general front model based MOEA)并行化以求解水电-光伏混合系统能源优化问题. 各线程独立执行GFM-MOEA 定期迁移精英个体, 得到一组收敛良好且分布均匀的pareto解.

文献[46-47]只从局部相邻岛屿接收信息实现全局多样化, 避免了岛屿模型通信和计算成本过高的问题. 其中各岛屿并行搜索不同决策空间, 可以使算法收敛到全局最优和局部最优在内的多个最优值.

综上, 岛屿模型并行智能优化算法可以大大提高算法求解大规模优化问题的计算速度, 同时所获得解的收敛性和多样性均有良好的效果. 此外引入自适应策略, 可以更有效地探索决策空间, 同时减少迁移通信负载, 使算法在收敛性和计算效率之间达到平衡. 另外岛屿并行搜索不同决策空间, 增加了种群多样性, 可以有效求解多模态优化问题. 最后算法并行所得解的质量是决策者的首要偏好, 计算加速反而次之^[37].

3.3 细胞模型

细胞模型, 也叫细粒度模型. 细胞模型中各节点组成二维晶格或环面网格, 理想情况下, 每个节点仅包含一个个体, 进化操作仅在相邻个体之间执行, 如图5所示. 通信负载要比主从和岛屿模型高得多.




图5 细胞模型示意图

Fig. 5 Illustration of cell model

文献[48-51]均提出了基于细胞模型的并行遗传算法. 其中Sekaj等^[48]描述了在二维环面网格拓扑下实现GA, 且发现“选择所有邻居个体”的邻居选择策略是最优的. Llorca等^[49]基于并行遗传算法设计了遗传与人工生命环境(genetic and artificial life environment, GALE), 在二维网格拓扑的空间邻域上定义了局部遗传算子和个体适应度并行计算. Nayak等^[50]将细粒度并行GA用于求解多模态全局优化问题. 黄樟灿等^[51]将基于空间划分的选择策略引入细胞并行GA中, 实现局部演化. Soca等^[52]提出了一种基于GPU的并行细胞进化算法框架(parallel cellular evolutionary algorithm framework implemented on GPU, PUGACE)求解二次分配组合优化问题. Gupta等^[53]提出并行量

子启发进化算法(quantum-inspired evolutionary algorithm, QIEA), 求解社区检测优化问题.

综上, 细粒度并行算法具有最大并行度和保持种群多样性的优点, 因此在算法加速和防止早熟收敛两个方面有良好的效果, 多用于求解高维决策变量优化问题和多模态全局优化问题.

3.4 混合模型

混合模型也称为分层模型, 即将两种(或多种)并行模型混合组合, 以利用多种模型的优势来提高求解多类优化问题的能力, 如图6所示. 常见的分层模型有岛屿-主从混合、岛屿-细胞混合、岛屿-岛屿混合、主从-细胞混合等.




图6 混合模型示意图

Fig. 6 Illustration of hybrid model

文献[54-57]均采用了岛屿-细胞混合模型, 如图6(a)所示. 其中Folino等^[54]设计了一种分布式GP (genetic program)算法, 上层为环状岛屿模型, 每个岛屿内执行基于细胞模型的GP, 相邻岛屿之间迁移最优个体. Lee等^[55]设计了混合并行进化算法求解带约束实

值优化问题. 上层岛屿中精英个体的迁移频率较低, 下层细胞结构中迁移频率较高, 使算法在探索和搜索两方面达到适当平衡. Federici等^[56]提出并行多种群的罗马大学的进化优化算法(evolutionary optimization at Sapienza, EOS)求解空间轨道设计优化问题. EOS采用并行同步异构岛屿混合模型, 即各岛屿并行进化, 岛屿内子种群细粒度并行化. Dorronsoro等^[57]将并行细胞遗传算法(parallel cellular genetic algorithm, PEGA)应用于求解大规模容量车辆路径问题(capacity vehicle routing problem, CVRP), 上层为单环岛屿拓扑, 下层为细胞模型.

Herrera等^[58]建立了上下层都采用孤岛模型的分层模型, 如图6(b)所示. 个体迁移由节点间全局迁移和节点内局部迁移组成. 该异构分层模型提高了每个节点的效率以及实现岛屿之间多样化的协作.

在文献[59–62]中, 初始种群被分为几个子种群基于岛屿模型并行进化. 对于每个子种群, 采用主从模型并行评估个体适应度以进一步提高计算效率, 如图6(c)所示. 其中Huo等^[59]设计了分层并行人工蜂群算法优化水文模型的参数, 上层为岛屿模型, 下层为主从模型. Artina等^[60]提出分层并行化的NSGA-II算法以优化供水网络, 在计算机集群中的不同计算节点上并行独立执行NSGA-II算法, 对每个计算节点内的子种群采用主从并行评估个体适应度. Ng等^[61]用多种群并行GA设计气动翼型, 采用分层多级并行化策略, 子种群与计算机集群一一映射, 多个计算机集群之间迁移个体并行进化, 集群内各计算节点并行评估气动翼型昂贵优化问题. Zhao等^[62]提出分层差分进化算法求解卫星资源调度优化问题.

综上, 岛屿-主从混合模型的加速效果呈近似线性加速, 可以最大限度地利用计算集群强大计算能力实现算法加速, 多适用于求解昂贵评价大规模优化问题. 岛屿-细胞模型与经典分布式模型性能基本一致, 同时在保持种群多样性方面具有优势, 可以防止算法早熟收敛, 多适用高维多模态优化问题. 岛屿-岛屿模型可以在各岛屿之间开展多样化协作, 协同利用多种智能优化算法的优势. 此外多种并行模型混合组合虽然具有良好的分散性、高可拓展性以及算法加速等优点, 但结构过度耦合可能会导致分层模型的鲁棒性较差.

3.5 并行智能优化算法总结和对比

综上所述, 岛屿模型为多种群模型, 而细胞及主从模型均为单种群. 岛屿及细胞模型两者之间差别在于并行化的程度不同, 相比于主从模型考虑了拓扑中所有节点, 岛屿和细胞模型仅在拓扑中相邻节点之间执行进化和迁移操作. 基于4类模型的并行智能优化算法已广泛应用于工业固件结构设计、车辆路径问题、混合能源系统优化、资源分配调度、模型参数优化、数据分类等领域. 算法通过决策变量分组、目标函数

分组、目标函数分解等策略求解大规模复杂优化问题, 并将初始种群分成多个较小的子种群(个体)并行协同搜索, 扩大了搜索范围, 充分利用了并行计算可以提高算法效率的优势, 同时保证解的质量. 相比较于传统串行智能优化算法, 并行智能优化算法求解大规模复杂优化问题, 在减少计算时间和避免系统内存不足等方面具有出色的性能, 同时多种群分离的特点也在一定程度上增加了了解的多样性, 防止早熟收敛. 此外精英个体迁移的通信数据负载是影响并行算法计算效率的重要因素之一, 通过引入自适应策略可以在算法加速和解多样性之间达到平衡. 表1具体对比分析了本节所述并行模型的优缺点.

4 实现并行智能优化算法的硬件结构

4.1 基于多核处理器实现

多核处理器(multi-core processor)是单核处理器在面对物理极限和功耗等无法跨越的障碍而进行技术变革的产物, 简单来说, 就是将多个处理核心集成到一个芯片中, 并通过任务划分使其并行工作来提高系统性能, 多个核心之间通过片上网络或共享缓存紧密耦合, 通信速度较快. Li等^[20]在双核处理器上提出并行MO-MOPSO/D算法, 实现了两倍加速效果. Kanas等^[25]提出并行多目标进化图算法(parallel multi-objective evolutionary graph algorithm, PMEGA)优化药物化学结构, 在双核处理器上速度提升了约1.6倍. Tsutsui等^[29]在多核处理器上分别对个体适应度实施同步和异步多线程并行评估, 算法加速与核心数成近似线性. Wei等^[31]在多核处理器上基于并行协同多目标算法框架CC-MOEA以NSGA-II为具体实现, 达到了良好的加速效果. Hong等^[63]在双核处理器上并行实现人工蜂群算法, 展现了并行算法求解高维决策变量优化问题的优越性. 此外, 张峰^[64]在多核处理器上实验并行协同差分进化算法发现随着处理器核心数增加, 算法呈近似线性加速, 然而其得到的解的质量要比串行差分进化算法差, 这说明算法线性加速与解的质量之间存在着冲突, 需要引入精英个体迁移机制交换有利信息协同进化. 例如Sato等在DNSGA-II中交换非支配排序个体来提升Pareto解的收敛性^[23, 65–66].

总之, 借助于现有的OpenMP, MPI等规范编程接口, 智能优化算法在多核处理器上的并行实现较为简单, 相关研究已经相当成熟, 如PSO, GA, 蜂群算法(bee colony optimization, BCO)及MOEAs等等.

4.2 基于计算机集群实现

计算机集群(computer cluster)是由运行多个处理器的计算机或多台多处理器的计算机组加上通信网络等其他辅助系统构成, 协同高效完成计算任务. 单一处理器或单台计算机通常被视为一个计算节点, 节点之间通过高速网络链接进行数据通信. 相比于多核

处理器, 计算机集群在计算速度和可靠性方面具有优势. Rocha等^[32]在40个节点的计算机集群上运行NSGA-II算法, 实现超线性加速且种群数量越大, 加速效果越好. Jameshidi等^[40]在多节点CAN总线上实现异步分布式GA, CAN的低通信成本特点使算法可以实现超线性加速. Parsopoulos等^[67]在高性能计算机集群上实现了cooperative micro particle swarm optimization (COMPSO), 在1200维决策变量的标准测试

问题上实验表明, 16个节点的计算效率是最高的. Burczynski等^[68]在Alchemi集群框架下实现人工免疫算法, 分布式计算个体的适应度, 达到近似线性加速. Chen等^[69]给出了云计算环境下粗粒度GA的并行设计思想. 综上, 利用现有的一些分布式并行技术和平台, 如Hadoop和Spark等, 研究者可以较为轻松地利用计算机集群强大的计算能力, 对大规模复杂优化问题和昂贵评价优化问题进行求解.

表 1 本节所述的并行智能优化算法对比分析

Table 1 Analysis of parallel intelligent optimization algorithms described in this section

模型	优点	缺点	具体算法实现	优化问题	文献
主从模型	易于实现; 各节点可以执行不同进化算子, 拓展性高; 算法收敛速度快; 加速效果明显, 适用于解决大规模复杂优化问题	节点之间通信负载不均衡且开销较大, 不适用于低带宽系统; 算法易早熟收敛, 陷入局部最优	MOPSO/D	标准测试函数	[20]
			AlineaGA	蛋白质多序列比对问题	[21–22]
			DNSGA-II	标准测试函数	[23]
			SPEA-II	图像加密算法参数设置优化问题	[24]
			PMEGA	药物化学结构设计优化问题	[25]
			SDQPSO	标准测试函数	[26]
			MIMOA	双目标随机需求车辆路径优化问题	[27]
			AIA	机械结构优化设计优化	[28]
岛屿模型	通信负载均衡且开销较小; 不依赖于主节点的工作, 拓展性较好; 保持种群多样性, 全局搜索能力较强	算法收敛速度较慢; 需要优化问题的先验知识或凭借决策者的经验设置岛屿数量、迁移拓扑、迁移周期等参数	NSGA-II	标准测试函数	[30]
				外部照明设计双目标优化问题	[31]
				购物推荐系统	[32]
			MOEA/D	标准测试函数	[33–36]
			MOEA/D-STAT	数据分析特征选取问题	[37]
			AIEA	港口船只泊位调度优化问题	[39]
			GA	标准测试函数	[40]
				高维0–1背包问题	[41]
			SMPSO	标准测试函数	[42]
			DPCCMOEA	标准测试函数	[43]
细胞模型	并行化程度高; 种群多样性良好, 不易陷入局部最优	算法收敛速度较慢; 通信开销很大, 不适用于低带宽系统	GFM-MOEA	水电-光伏混合系统优化问题	[44]
			GA	多模态优化问题	[46–47]
			GA	标准测试函数	[48–50]
				数据分类器	[51]
			PUGACE	二次分配组合优化问题	[52]
			QIEA	社区检测优化问题	[53]
			GP	标准测试函数	[54]
分层模型	分散性、可拓展性、以及算法加速; 联合了其 他3种模型的优点, 算法设计较为灵活, 各节点可以异构设置不同算法和参数	结构过度耦合, 模型和算法鲁棒性差	EA	带约束实值优化问题	[55]
			EOS	空间轨道设计优化问题	[56]
				载荷约束车辆路径问题	[57]
			GA	标准测试函数	[58]
				机械结构优化设计问题	[59]
				气动翼型设计优化问题	[60]
			NSGA-II	供水网络优化问题	[61]
			DE	卫星资源分配调度优化问题	[62]

4.3 基于GPU实现

GPU (graphics processing unit)最开始是为了提高3D图像处理速度. 随着通用计算技术的快速发展, GPU不再局限于图像领域, 更多用于解决复杂且计算

量大的实际问题. 在GPU中执行的程序称为内核, 它使用多达数千个线程并行执行. 换句话说, 多个线程执行相同的指令, 但是对不同的数据元素进行操作. 全局内存、共享内存和寄存器构成了GPU的内存架

构. 每个线程都有专用寄存器和本地存储器. 每个线程块都有对该块的所有线程可见的共享内存. 所有线程都可以访问同一个全局内存^[70], 如图7所示. Soca等人^[52]提出了基于GPU的细粒度并行进化算法框架(PUGACE). Gupta等^[53]基于CUDA实现量子启发式进化算法(QIEA). Ding等^[70]根据GPU结构重新设计了烟花算法, 每个烟花的位置和适应度值存储在全局内存中, 而火花的数据存储在快速共享内存中. Gao等^[71]在GPU集群上并行实现ACO, 通过局部信息素更新策略避免不同GPU之间过多的数据同步, 从而提高计算速度. Kumar等^[72]在GPU上用CUDA并行实现协同粒子群算法(cooperative particle swarm optimization, CPSO), 与顺序CPSO对比发现执行时间不仅有效减少了且解的收敛性也更好. Liu等^[73]将人工免疫机制引入到协同进化粒子群算法框架中, 开发了基于CUDA的优化并行基于GPU的并行协同粒子群优化算法(GPU based parallel cooperative particle swarm optimization, G-PCPSO), 利用高速共享内存交互优秀解在广泛搜索和精确搜索之间取得平衡. Li等在GPU上实现了GA^[74]、ACO^[75]、人工免疫优化算法^[76], 以及Hung等^[77]实现PSO算法, Huang等^[78]实现蜂群算法等.

综上, GPU中拥有大量的线程块, 因此对于具有大量计算的问题的加速是显而易见的. GPU的成本较低和高性能浮点计算, 吸引越来越多的学者在GPU上并行实现智能优化算法. 另外CUDA和OpenCL等工具使开发人员更容易充分利用GPU的并行特性, 而不需要明确熟悉GPU架构. 此外CURAND库^[70]用于GPU上生成高质量的随机数, 有助于保持种群多样性, 从而获得更好的解. 最后GPU架构的最大并行性特点提高了算法全局搜索的能力.




图7 GPU架构示意图

Fig. 7 Illustration of GPU architecture

5 未来研究展望

尽管现有针对智能优化算法并行化的研究已不少, 但现有研究还存在如下问题.

1) 并行智能优化算法中的精英个体迁移机制虽然有助于算法的快速收敛, 但是如果迁移频率过高的话, 每次最优个体从某一子种群迁移到另一子种群, 最终一定会有一个超级最优的个体捕获所有的子种群, 从而陷入局部最优. 设计新的策略在收敛性和多样性之间实现平衡会是下一步的研究重点.

2) 智能优化算法通过并行化来使算法加速, 提升效率, 但这会导致算法所获得解的收敛性能下降, 即算法效率和解的收敛性能两者之间存在冲突关系. 如何设计高效的协同机制或分解策略或信息交流机制使算法加速的同时, 保持解的质量与原来一致或有所提升是下一步的重要研究方向.

3) 现有基于GPU实现的并行智能优化算法仍存在一些限制, 如GPU全局内存与系统内存之间传输数据传输会消耗大量时间, 导致算法效率降低^[70]; 由于线程之间的通信负载, 线程块的过度增加反而会不利于算法加速^[72]. 设计合理的通信机制使数据尽可能地在片内内存之间传输是以后研究的重点. 此外GPU数量的增加可以使算法进一步加速. 如何在GPU集群上并行实现是重要的研究方向.

4) 在主从模型中, 随着从节点数量的增加, 主节点处理达到饱和时, 加速效果会变得很差; 在岛屿和细胞模型中, 预定义的拓扑和刚性连接限制了要使用的节点数量以及节点之间的自发协作. 网格计算共享平台是松散低耦合的结构, 计算节点在共享资源池中工作, 它们不知道彼此的存在, 只与资源池交互^[79]. 因此利用网格计算平台设计实现并行智能优化算法, 根据问题规模充分地利用闲置计算资源也是开展下一步研究的重点方向.

5) 将种群或者个体分配到不同的资源并行计算加速是较为普遍的做法, 然而Li等^[80]在世代并行的层面实现了局部粒子群优化算法, 极大地提高了算法的运行速度且求解能力未受到影响. 这为智能优化算法并行化提供了新的思路.

6 总结

综合而言, 随着计算机计算能力的提升以及分布式并行技术的发展, 智能优化算法的并行化有望应对越来越复杂的大规模优化问题. 本文介绍了并行智能优化算法中一些并行协同机制、拓扑结构以及底层的硬件设施, 重点分析了基于主从模型、岛屿模型、细胞模型以及混合模型4种范式下的并行智能优化算法, 并指出了各种范式的优缺点. 最后对梳理了智能优化算法并行化的未来研究方向, 希望为开展相关研究的学者提供有益的参考和借鉴.

参考文献:

- [1] HOLLAND J H. Genetic algorithms. *Scientific American*, 1992, 267(1): 66 - 73.

- [2] DORIGO M, BIRATTARI M, STUTZLE T. Ant colony optimization. *IEEE Computational Intelligence Magazine*, 2006, 1(4): 28 – 39.
- [3] KENNEDY J, EBERHART R. Particle swarm optimization. *Proceedings of ICNN'95-International Conference on Neural Networks*. Perth, Australia: IEEE, 1995, 4: 1942 – 1948.
- [4] BAO Te, SUN Xiaowei. Analysis on the development of computer hardware performance. *Digital Communication World*, 2018, (6): 120.
(鲍特, 孙笑微. 关于计算机硬件性能发展的分析. 数字通信世界, 2018, (6): 120.)
- [5] WANG Ling, SHEN Jingnan, WANG Shengyao, et al. Research progress of co-evolutionary algorithms. *Control and Decision*, 2015, 30(2): 193 – 202.
(王凌, 沈婧楠, 王圣尧, 等. 协同进化算法研究进展. 控制与决策, 2015, 30(2): 193 – 202.)
- [6] RISCO-MARTÍN J L, ATIENZA D, HIDALGO J I, et al. A parallel evolutionary algorithm to optimize dynamic data types in embedded systems. *Soft Computing*, 2008, 12(12): 1157 – 1167.
- [7] LIU Fuying, WANG Xiaoshen. Parallel multi-objective optimization algorithm based on SPEA2 and NSGA-II algorithm. *Information and Communication*, 2016, (11): 28 – 30.
(刘福英, 王晓升. 基于SPEA2和NSGA-II算法的并行多目标优化算法. 信息通信, 2016, (11): 28 – 30.)
- [8] WIAK S, COCO S, LAUDANI A, et al. TWT magnetic focusing structure optimization by parallel evolutionary algorithm. *COMPEL-The International Journal for Computation and Mathematics in Electrical and Electronic Engineering*, 2012, 31(5): 1338 – 1346.
- [9] XING L N, CHEN Y W, YANG K W. Multi-population interactive coevolutionary algorithm for flexible job shop scheduling problems. *Computational Optimization and Applications*, 2011, 48(1): 139 – 155.
- [10] DENG W, CHEN R, GAO J, et al. A novel parallel hybrid intelligence optimization algorithm for a function approximation problem. *Computers & Mathematics with Applications*, 2012, 63(1): 325 – 336.
- [11] LI W, BI Y, ZHU X, et al. Hybrid swarm intelligent parallel algorithm research based on multi-core clusters. *Microprocessors and Microsystems*, 2016, 47(1): 151 – 160.
- [12] CAO B, LI W, ZHAO J, et al. Spark-based parallel cooperative co-evolution particle swarm optimization algorithm. *2016 IEEE International Conference on Web Services (ICWS)*. San Francisco, USA: IEEE, 2016: 570 – 577.
- [13] TALBI E G, BACHELET V. Cosearch: A parallel cooperative metaheuristic. *Journal of Mathematical Modelling and Algorithms*, 2006, 5(1): 5 – 22.
- [14] WANG H F, CHEN Y Y. A coevolutionary algorithm for the flexible delivery and pickup problem with time windows. *International Journal of Production Economics*, 2013, 141(1): 4 – 13.
- [15] CADENAS J M, GARRIDO M C, MUNOZ E. Using machine learning in a cooperative hybrid parallel strategy of metaheuristics. *Information Sciences*, 2009, 179(19): 3255 – 3267.
- [16] JAMES T, REGO C, GLOVER F. A cooperative parallel tabu search algorithm for the quadratic assignment problem. *European Journal of Operational Research*, 2009, 195(3): 810 – 826.
- [17] ARORA R, TULSHYAN R, DEB K. Parallelization of binary and real-coded genetic algorithms on GPU using CUDA. *IEEE Congress on Evolutionary Computation*. Barcelona, Spain: IEEE, 2010: 1 – 8.
- [18] DEFERSHA F M, CHEN M. A parallel genetic algorithm for a flexible job-shop scheduling problem with sequence dependent setups. *The International Journal of Advanced Manufacturing Technology*, 2010, 49(1): 263 – 279.
- [19] VAN VELDHUIZEN D A, ZYDALLIS J B, LAMONT G B. Considerations in engineering parallel multiobjective evolutionary algorithms. *IEEE Transactions on Evolutionary Computation*, 2003, 7(2): 144 – 173.
- [20] LI J Z, CHEN W N, ZHANG J, et al. A parallel implementation of multiobjective particle swarm optimization algorithm based on decomposition. *2015 IEEE Symposium Series on Computational Intelligence*. Cape Town, South Africa: IEEE, 2015: 1310 – 1317.
- [21] DA SILVA F J M, PÉREZ J M S, PULIDO J A G, et al. Parallel AlineaGA: an island parallel evolutionary algorithm for multiple sequence alignment. *The International Conference of Soft Computing and Pattern Recognition*. Cergy-Pontoise, France: IEEE, 2010: 279 – 284.
- [22] DA SILVA F J M, PÉREZ J M S, PULIDO J A G, et al. A parallel niched pareto evolutionary algorithm for multiple sequence alignment. *The 5th International Conference on Practical Applications of Computational Biology & Bioinformatics*. Berlin, Heidelberg: Springer, 2011: 157 – 165.
- [23] SATO Y, SATO M, MIYAKAWA M. Distributed NSGA-II sharing extreme non-dominated solutions for improving accuracy and achieving speed-up. *2019 IEEE Congress on Evolutionary Computation (CEC)*. Wellington, New Zealand: IEEE, 2019: 3086 – 3093.
- [24] KAUR M, SINGH D, SINGH UPPAL R. Parallel strength Pareto evolutionary algorithm-II based image encryption. *IET Image Processing*, 2020, 14(6): 1015 – 1026.
- [25] KANNAS C C, NICOLAOU C A, PATTICHIS C S. A parallel implementation of a multi-objective evolutionary algorithm. *The 9th International Conference on Information Technology and Applications in Biomedicine*. Larnaca, Cyprus: IEEE, 2009: 1 – 6.
- [26] ZHANG Z, WANG W, PAN G. A distributed quantum-behaved particle swarm optimization using opposition-based learning on spark for large-scale optimization problem. *Mathematics*, 2020, 8(11): 1860.
- [27] NIU Y, ZHANG Y, CAO Z, et al. MIMOA: A membrane-inspired multi-objective algorithm for green vehicle routing problem with stochastic demands. *Swarm and Evolutionary Computation*, 2021, 60: 100767.
- [28] KUS W, BURCZYŃSKI T. Parallel bioinspired algorithms in optimization of structures. *International Conference on Parallel Processing and Applied Mathematics*. Berlin: Springer, 2007: 1285 – 1292.
- [29] TSUTSUI S. Parallelization of an evolutionary algorithm on a platform with multi-core processors. *International Conference on Artificial Evolution (Evolution Artificielle)*. Berlin: Springer, 2009: 61 – 73.
- [30] GONG Dunwei, LIU Yiping, SUN Xiaoyan, et al. High-dimensional multi-objective parallel evolutionary optimization method based on objective decomposition. *Acta Automatica Sinica*, 2015, 41(8): 1438 – 1451.
(巩敦卫, 刘益萍, 孙晓燕, 等. 基于目标分解的高维多目标并行进化优化方法. 自动化学报, 2015, 41(8): 1438 – 1451.)
- [31] WEI G, WU Q. CC-MOEA: A parallel multi-objective evolutionary algorithm for recommendation systems. *International Conference on Algorithms and Architectures for Parallel Processing*. Cham: Springer, 2020: 662 – 676.
- [32] ROCHA H, PERETTA I S, LIMA G F M, et al. Exterior lighting computer-automated design based on multi-criteria parallel evolutionary algorithm: optimized designs for illumination quality and energy efficiency. *Expert Systems with Applications*, 2016, 45: 208 – 222.
- [33] DURILLO J J, ZHANG Q, NEBRO A J, et al. Distribution of computational effort in parallel MOEA/D. *International Conference on Learning and Intelligent Optimization*. Berlin: Springer, 2011: 488 – 502.
- [34] NEBRO A J, DURILLO J J. A study of the parallelization of the multi-objective metaheuristic MOEA/D. *International Conference on*

- Learning and Intelligent Optimization*. Berlin: Springer, 2010: 303 – 317.
- [35] XIE Y, YING W, WU Y, et al. Partitioned parallelization of MOEA/D for bi-objective optimization on clusters. *International Symposium on Computational Intelligence and Intelligent Systems*. Singapore: Springer, 2015: 373 – 381.
- [36] YING W, XIE Y, WU Y, et al. Universal partially evolved parallelization of MOEA/D for multi-objective optimization on message-passing clusters. *Soft Computing*, 2016, 21(18): 5399 – 5412.
- [37] LIAO W, ISHIBUCHI H, PANG L M, et al. Parallel implementation of MOEA/D with parallel weight vectors for feature selection. *2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*. Toronto, Canada: IEEE, 2020: 1524 – 1531.
- [38] NGUYEN B H, XUE B, ANDREAE P, et al. Multiple reference points-based decomposition for multiobjective feature selection in classification: static and dynamic mechanisms. *IEEE Transactions on Evolutionary Computation*, 2019, 24(1): 170 – 184.
- [39] DULEBENETS M A. An adaptive island evolutionary algorithm for the berth scheduling problem. *Memetic Computing*, 2019, 12(1): 51 – 72.
- [40] JAMSHIDI V, NEKOUKAR V, REFAN M H. Analysis of asynchronous distributed multi-master parallel genetic algorithm optimization on CAN bus. *Evolving Systems*, 2020, 11(4): 1 – 10.
- [41] ABD-ALSABOUR N. Parallel evolutionary algorithms and high dimensional optimization problems. *Journal of Computers*, 2018, 13(11): 1265 – 1271.
- [42] ATASHPENDAR A, DORRONSORO B, DANOY G, et al. A scalable parallel cooperative coevolutionary PSO algorithm for multi-objective optimization. *Journal of Parallel and Distributed Computing*, 2018, 11(2): 111 – 125.
- [43] CAO B, ZHAO J, LV Z, et al. A distributed parallel cooperative coevolutionary multiobjective evolutionary algorithm for large-scale optimization. *IEEE Transactions on Industrial Informatics*, 2017, 13(4): 2030 – 2038.
- [44] ZHU F, ZHONG P, SUN Y, et al. A coordinated optimization framework for long-term complementary operation of a large-scale hydro-photovoltaic hybrid system: Nonlinear modeling, multi-objective optimization and robust decision-making. *Energy Conversion and Management*, 2020, 226: 113543.
- [45] TIAN Y, ZHANG X, CHENG R, et al. Guiding evolutionary multiobjective optimization with generic front modeling. *IEEE Transactions on Cybernetics*, 2020, 50(3): 1106 – 1119.
- [46] ZHANG L F, ZHOU C X. Self organized parallel genetic algorithm to automatically realize diversified convergence. *2012 IEEE Congress on Evolutionary Computation*. Brisbane, Australia: IEEE, 2012: 1 – 9.
- [47] ZHANG L F, HE R. A globally diversified island model PGA for multimodal optimization. *2014 IEEE Congress on Evolutionary Computation (CEC)*. Beijing, China: IEEE, 2014: 2553 – 2561.
- [48] SEKAJ I, ORAVEC M. Selected population characteristics of fine-grained parallel genetic algorithms with re-initialization. *Proceedings of the First ACM/SIGEVO Summit on Genetic and Evolutionary Computation*. Shanghai: ACM, 2009: 945 – 948.
- [49] LLORA X, GARRELL J M. Knowledge-independent data mining with fine-grained parallel evolutionary algorithms. *Proceedings of the Third Genetic and Evolutionary Computation Conference*. San Francisco, Morgan Kaufmann: IEEE, 2001: 461 – 468.
- [50] NAYAK R K, MISHRA B S P. Implementation of gpu using fine-grained parallel genetic algorithm. *International Journal of Computer Applications*, 2015, 120(19): 1 – 4.
- [51] HUANG Zhangan, CHEN Siduo. Fine-grained parallel evolutionary algorithm based on space partition. *Application Research of Computers*, 2000, 17(8): 4 – 5.
- (黄樟灿, 陈思多. 基于空间划分的细粒度并行演化算法. 计算机应用研究, 2000, 17(8): 4 – 5.)
- [52] SOCA N, BLENGIO J L, PEDEMONTE M, et al. PUGACE, a cellular evolutionary algorithm framework on GPUs. *IEEE Congress on Evolutionary Computation*. Barcelona, Spain: IEEE, 2010: 1 – 8.
- [53] GUPTA S, MITTAL S, GUPTA T, et al. Parallel quantum-inspired evolutionary algorithms for community detection in social networks. *Applied Soft Computing*, 2017, 61(1): 331 – 353.
- [54] FOLINO G, SPEZZANO G. P-cage: an environment for evolutionary computation in peer-to-peer systems. *European Conference on Genetic Programming*. Berlin: Springer, 2006: 341 – 350.
- [55] LEE C H, PARK K H, KIM J H. Hybrid parallel, evolutionary algorithms for constrained optimization utilizing PC clustering. *Proceedings of the 2001 Congress on Evolutionary Computation (IEEE Cat. No. 01TH8546)*. Seoul, Korea: IEEE, 2001, 2: 1436 – 1441.
- [56] FEDERICI L, BENEDIKTER B, ZAVOLI A. EOS: a parallel, self-adaptive, multi-population evolutionary algorithm for constrained global optimization. *2020 IEEE Congress on Evolutionary Computation (CEC)*. Glasgow, United Kingdom: IEEE, 2020: 1 – 10.
- [57] DORRONSORO B, ARIAS D, LUNA F, et al. A grid-based hybrid cellular genetic algorithm for very large scale instances of the CVRP. *2007 High Performance Computing & Simulation Conference (HPCS 2007)*. Prague, Czech Republic: IEEE, 2007: 759 – 765.
- [58] HERRERA F, LOZANO M, MORAGA C. Hierarchical distributed genetic algorithms. *International Journal of Intelligent Systems*, 1999, 14(11): 1099 – 1121.
- [59] HUO J, LIU L, ZHANG Y. An improved multi-cores parallel artificial Bee colony optimization algorithm for parameters calibration of hydrological model. *Future Generation Computer Systems*, 2018, 81(1): 492 – 504.
- [60] ARTINA S, BRAGALLI C, ERBACCI G, et al. Contribution of parallel NSGA-II in optimal design of water distribution networks. *Journal of Hydroinformatics*, 2012, 14(2): 310 – 323.
- [61] NG H K, LIM D, ONG Y S, et al. A multi-cluster grid enabled evolution framework for aerodynamic airfoil design optimization. *International Conference on Natural Computation*. Berlin: Springer, 2005: 1112 – 1121.
- [62] ZHAO M, LI D. A hierarchical parallel evolutionary algorithm of distributed and multi-threaded two-level structure for multi-satellite task planning. *International Journal of Automation and Control*, 2020, 14(5/6): 612 – 633.
- [63] HONG Y S, JI Z Z, LIU C L. Research of parallel artificial bee colony algorithm based on mpi. *Applied Mechanics and Materials*, 2013, 380: 1430 – 1433.
- [64] ZHANG Feng. A parallel collaborative large-scale differential evolution algorithm for solving NP-hard problems. *Journal of Suzhou University*, 2018, 33(11): 101 – 107.
- (张峰. 一种求解NP-难问题的并行协同大规模差分进化算法. 宿州学院学报, 2018, 33(11): 101 – 107.)
- [65] SATO Y, SATO M, MIYAKAWA M. Distributed NSGA-II with migration using compensation on many-core processors for improving performance and accuracy. *Proceedings of the Genetic and Evolutionary Computation Conference Companion*. Berlin, Germany: ACM, 2017: 161 – 162.
- [66] SATO Y, SATO M, MIYAKAWA M. Distributed NSGA-II using the divide-and-conquer method and migration for compensation on many-core processors. *The 21st Asia Pacific Symposium on Intelligent and Evolutionary Systems (IES)*. Hanoi, Vietnam: IEEE, 2017: 83 – 88.
- [67] PARSOPOULOS K E. Parallel cooperative micro-particle swarm optimization: A master-slave model. *Applied Soft Computing*, 2012, 12(11): 3552 – 3579.

- [68] BURCZYNSKI T, KUS W. Optimization of structures using distributed and parallel evolutionary algorithms. *International Conference on Parallel Processing and Applied Mathematics*. Berlin: Springer, 2003: 572 – 579.
- [69] CHEN Y. Intelligent algorithms for cold chain logistics distribution optimization based on big data cloud computing analysis. *Journal of Cloud Computing*, 2020, 9(1): 1 – 12.
- [70] DING K, ZHENG S, TAN Y. A gpu-based parallel fireworks algorithm for optimization. *Proceedings of the 15th Annual Conference on Genetic and Evolutionary Computation*. Amsterdam, Netherlands: ACM SIGEVO, 2013: 9 – 16.
- [71] GAO J, SUN Y, ZHANG B, et al. Multi-GPU based parallel design of the ant colony optimization algorithm for endmember extraction from hyperspectral images. *Sensors*, 2019, 19(3): 598.
- [72] KUMAR J, SINGH L, PAUL S. GPU based parallel cooperative particle swarm optimization using C-CUDA: a case study. *2013 IEEE International Conference on Fuzzy Systems (FUZZ-IEEE)*. Hyderabad, India: IEEE, 2013: 1 – 8.
- [73] LIU Z H, LI X H, WU L H, et al. GPU-accelerated parallel coevolutionary algorithm for parameters identification and temperature monitoring in permanent magnet synchronous machines. *IEEE Transactions on Industrial Informatics*, 2015, 11(5): 1220 – 1230.
- [74] LI J M, WANG X J, HE R S, et al. An efficient fine-grained parallel genetic algorithm based on gpu-accelerated. *2007 IFIP International Conference on Network and Parallel Computing Workshops (NPC 2007)*. Dalian, China: IEEE, 2007: 855 – 862.
- [75] LI Jianming, HU Xiangpei, PANG Zhanlong, et al. A fine-grained parallel ant colony algorithm based on GPU acceleration. *Control and Decision*, 2009, 24(8): 1132 – 1136.
(李建明, 胡祥培, 庞占龙, 等. 一种基于GPU加速的细粒度并行蚁群算法. *控制与决策*, 2009, 24(8): 1132 – 1136.)
- [76] LI J, ZHANG L, LIU L. A parallel immune algorithm based on fine-grained model with GPU-acceleration. *The 4th International Conference on Innovative Computing, Information and Control (ICICIC)*. Kaohsiung, Taiwan, China: IEEE, 2009: 683 – 686.
- [77] HUNG Y, WANG W. Accelerating parallel particle swarm optimization via GPU. *Optimization Methods and Software*, 2012, 27(1): 33 – 51.
- [78] LUO G H, HUANG S K, CHANG Y S, et al. A parallel Bees Algorithm implementation on GPU. *Journal of Systems Architecture*, 2014, 60(3): 271 – 279.
- [79] GONG Y J, CHEN W N, ZHAN Z H, et al. Distributed evolutionary algorithms and their models: a survey of the state-of-the-art. *Applied Soft Computing*, 2015, 34(11): 286 – 300.
- [80] LI J Y, ZHAN Z H, LIU R D, et al. Generation-level parallelism for evolutionary computation: a pipeline-based parallel particle swarm optimization. *IEEE Transactions on Cybernetics*, 2020, 51(10): 4848 – 4859.

作者简介:

张 国 硕士研究生, 研究方向为智能优化算法、进化多目标优化、车辆路径规划问题, E-mail: zhangguo@nudt.edu.cn;

王 锐 副研究员, 目前研究方向为复杂系统智能优化、进化计算, E-mail: ruiwangnudt@gmail.com;

雷洪涛 副教授, 目前研究方向为韧性能源系统规划、微电网鲁棒设计与优化, E-mail: hongtaolei@aliyun.com;

张 涛 教授, 目前研究方向为复杂系统智能优化、微电网规划设计及能量管理, E-mail: zhangtao@nudt.edu.cn;

王 凌 教授, 目前研究方向为智能优化理论方法与应用、复杂生产过程建模优化与调度, E-mail: wangling@tsinghua.edu.cn.