
上海交通大学博士学位论文

基于张量标签学习的多故障识别与定位
及容错控制

博士研究生：李双宏

学号：015032910027

导师：杨煜普教授

申请学位：工学博士

学科：控制科学与工程

所在单位：电子信息与电气工程学院

答辩日期：2018年6月

授予学位单位：上海交通大学

Dissertation Submitted to Shanghai Jiao Tong University
for the Degree of Philosophy Doctor

**FAULT IDENTIFICATION LOCATION
AND FAULT TOLORANT CONTROL
FOR INDUSTRY SYSTEM USING
TENSOR LABEL LEARNING**

Candidate:	Shuanghong Li
Student ID:	015032910027
Supervisor:	Prof. Yupu Yang
Academic Degree Applied for:	Ph.D
Speciality:	Control Science and Engineering
Affiliation:	School of Electronic Information and Electrical Engineering
Date of Defence:	Jun, 2018
Degree-Conferring-Institution:	Shanghai Jiao Tong University

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文《基于张量标签学习的多故障识别与定位及容错控制》，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海交通大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密 ☐，在___年解密后适用本授权书。

本学位论文属于

不保密 ☐。

（请在以上方框内打“√”）

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

工业系统在运行过程中会产生大量的高维高阶的过程数据和系统状态信息。这些高维的信息可以用张量的数学形式来表示。张量是一种高维的数据结构，能够保持复杂类型数据的内在结构，是矩阵的一种扩展形式。在数据处理的过程中，合适的数据结构可以提高数据挖掘的效率并且挖掘到更多的信息。

本文在深入了解生产过程中的过程特性、数据特性以及基于机器学习故障诊断方法的基础上，提出了一种张量标签学习的机器学习框架，来研究海量、多源、异构的工业故障数据和信息。研究了工业故障的识别、定位与控制问题，并将这三个故障诊断的主要环节输出的异构信息数据统一到张量学习的框架中，将异构的故障信息融合到故障张量中，综合评价故障诊断系统对故障的认知与处理能力。利用张量标签学习实现了工业故障信息的融合，对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，从而对工业系统安全的故障威胁进行完整、高效、精确的处理。

本文的研究内容主要有：

(1) 本文首次提出了一种张量标签学习的机器学习框架。本文将分类中的标签拓展为高维的张量表示形式，并给出了高维标签流的评价标准。本研究将监督学习、多标签问题统一到张量标签学习的框架中，作为 0-阶张量、1-阶张量学习的特殊情况。然后，将故障的识别、定位及容错控制统一到张量维度的标签学习中，给高阶的张量标签赋予了实际的含义，从更高的信息维度对故障进行了认知。利用张量标签学习，故障的信息可以进行张量形式的表示，在同一种张量标签的维度下可以同时表示故障的类别、位置以及对控制器的影响，最后通过高维信息的评价标准对识别、定位与容错控制进行定量化评价。张量信息化表示，可以定量化的评价故障诊断系统的故障的认知能力和处理能力，实现海量、多源、异构信息的统一整合、信息融合与统一评价。

(2) 针对并发故障组合模式众多难以训练完整的难点，本文利用 1-阶张量标签学习来解决并发故障的识别问题，首先针对的是训练数据具有丰富的标签样本的情况，并发故障由于是单故障模式的混合会造成模式识别困难、模式组合众多难点，传统的学习标签方法很难解决并发故障的识别问题。本章利用提出的 1-阶张量标签学习的方法，将并发故障利用 1-阶张量标签进行描述，然后，根据标签的格式改进学习器的标签维度构成了一种 1-阶张量标签学习模式识别方法。通过对二分类器的并行化处理，每个并行化的子分类器输出一位向量化标签的方式，实现并行化 SVM 算法。本方法的优势在于，采用 n 维二进制向量编码标签就可以表示 2^n 类的并发故障类型，极大的缓解了并发故障类型数量灾难的问题，仅采用独立的 n 类单故障的训练数据就可以预测 2^n 类并发故障的类型。

(3) 针对并发故障带标签的样本数据量稀少的情况，本文提出了一种向量化标签-迁移学习的策略，用于解决并发故障识别带标签的训练数据稀少无法学习得到学习器预测函数的难题。本文提出的并发故障识别系统包括两个部分：向量标签-迁移学习框架和并行随机森林机器学习算法。本方法采用 1-阶张量标签的形式建立起不同数据域之间的联系，通过数据量大的单独故障学习足够的数据分布信息，然后将学习器参数迁移到并发故障学习器上，这样

学习器的训练阶段分为两个部分：初始训练阶段和迁移学习阶段。根据标签的格式改进了基于决策树方法的并行随机森林算法。实验结果表明，本方法可以采用非常少的目标域数据就能快速的得到并发故障识别的模型。

(4) 为了解决基于数据模式的故障定位问题，本研究提出了基于特征选择可以进行故障定位的条件。然后，针对于基于相似性度量的故障定位系统进行了研究，采用了一种新的特征选择算法，基于不同类型故障样本之间的相似性度量，同时去除特征之间的相关性来挑选出与故障类型最为相关的特征，实现故障定位。本研究采用优化的 ReliefF 特征选择算法挑选与故障类别最为相关的特征，结合模型特征采集的位置进行故障定位，并通过在 SOFC 系统上的实验仿真验证该方法的可行性。为采用同一套算法同时解决故障的识别与定位，本章采用随机森林的特征性度量来选择合适个子集，从而确定故障发生的位置。通过张量标签学习的定量化评价，定量化评价了故障定位的精度。最后给出了故障识别与定位的张量化标签处理算法框架。

(5) 老化故障下的工业系统是一种高复杂度、非线性的连续时变系统，传统的辨识方法无法得到高精度的模型，也就难以精确的控制。本文利用故障识别与定位算法得到的结果，利用 0-阶张量标签学习结合离线的控制参数整定方法，设计了一种基于故障识别结果的控制律重新调度型主动容错控制器，来应对工业系统老化的故障。为了设计在线的辨识与控制，解决工业系统老化故障系统系统参数时变而且无法用准确的数学方程来表达的难点，本章提出了一种基于 TS 型的贝叶斯学习机与 GPC 相结合的方式，在一定的时间窗内在线辨识缓慢变化故障下的系统参数，并将输入输出关系映射输入到 GPC 控制器中，实现了控制律在线重组型主动容错控制。

关键词：张量标签学习，并发故障识别，迁移学习，故障定位，主动容错控制

FAULT IDENTIFICATION LOCATION AND FAULT TOLERANT CONTROL BASED ON TENSOR LABEL LEARNING

ABSTRACT

Industrial system will produce a lot of high-dimensional and high-order process data and system state information when operation at different condition. The data structure is a kind of high-dimensional data structure, it can maintain the inner structure of complex data type which is an extended form of matrix. In the process of data processing, a suitable data structure can improve the efficiency of operation and save storage space. Based on the the industrial process characteristics, data characteristics and machine learning fault diagnosis methods in the production process, the fault identification, location and control of faults are studied in this thesis by tensor label learning strategy. Heterogeneous information output from the three fault diagnosis parts are unified into the framework of the tensor learning.

This thesis studies the problems of identification, location and fault tolerant control, and realizes the unified representation of heterogeneous information data in the problems of identification, location and fault - tolerant control. The unified representation and learning performance evaluation of heterogeneous information data is realized by means of the method of unified representation of the information data of the high - dimension information data in the process of industrial fault diagnosis. The identification, location and control of faults are studied by using the method of tensor label learning. The different information is fused into the framework of tensor learning, and different information is fused into the fault diagnosis tensor, and the fault processing capability of the fault diagnosis system is comprehensively evaluated. The main contents of this thesis are as follows:

Firstly, the framework of tensor label learning is established. In this section, the concept of tensor label learning is proposed, and the supervised learning is extended to high dimensional tensor form. This study integrates supervised learning and multi-label problems into the framework of tensor label learning as a special case of 0-order tensor and 1-order tensor learning. In order to realize the uniform representation of the heterogeneous information data existing in the problems of identification, location and control, the 0-order tensor label learning (scalar label learning), 1-order tensor learning (vector label learning) introduced in the previous chapters is extended to the form of the matrix label learning and the third order label, and the evaluation index of the corresponding learning performance evaluation is derived.

Secondly, the problem of simultaneous fault identification is studied in this paper. Because of the combination of single failure modes, the problem of simultaneous faults is difficult to identify. A method of vector label learning is proposed to solve the problem of simultaneous faults. Only independent n -type single-fault training data can be used to predict the type of 2^n concurrent faults.

Thirdly, aiming at the problem of scarcity of simultaneous fault data, this section presents a vector label-transfer learning method for solving the problem of scarce training data of simultaneous faults in

industrial systems. The simultaneous fault recognition system includes two parts: vector label-transfer learning framework and random forest machine learning algorithm. The source domain (single fault data) and target domain (concurrent fault data) of this study are different distributions, and the source task and the target task are the same, and the strategy to encode the quantization label links the two data domains with different distribution. The experimental results show that the method can quickly obtain the model of simultaneous fault identification using very few target domain data.

Fourthly, in order to solve the problem of fault location based on data mode, the condition of fault location based on feature selection is proposed. Then, the fault location system based on similarity measure is studied, and a new feature selection algorithm is adopted, which is based on similarity measurement between different types of fault samples. At the same time, the correlation between the features is removed to select the features most relevant to the fault type to achieve fault location. In this study, the optimal ReliefF feature selection algorithm is used to select the most relevant features of the fault category, and the location of the model feature collection is used to locate the fault, and the feasibility of the method is verified by the experimental simulation on the SOFC system. In order to solve the problem of fault identification and location simultaneously by using a set of algorithms, this chapter adopts the method of random forest used in the previous chapter, and selects a suitable subset through the characteristic measure of random forest, so as to determine the location of fault. Qualitative analysis is used in fault location in this chapter.

Fifthly, in order to solve the problem of the aging failure, this chapter adopts the same type of fault and collects the data from different working conditions to identify the fault classes, and studies the invariant characteristics of the fault type by the method of supervised learning which is also regarded as 0-order tensor learning. Thus the fault information mining is realized. Based on the results of fault identification, an active fault tolerant controller with control law rescheduling based on the result of fault identification is designed in this section to realize the fault recovery of industrial system. Aiming at the shortage of control law rescheduling, a new method based on TS type Bayesian learning machine and GPC is proposed to identify the fault degree parameter online and assign it to the GPC controller. Finally, the online recombination active fault-tolerant control of control law is realized.

KEY WORDS: Tensor label learning, Fault identification, Feature selection, Fault tolerant control.

目 录

摘 要	I
ABSTRACT	III
第 1 章 绪论	1
1.1 论文研究背景及意义	1
1.2 故障识别的发展现状	2
1.2.1 基于机理模型的残差向量构造方法	3
1.2.2 基于统计学习的模式识别方法	4
1.3 故障定位的发展现状	5
1.3.1 定位拓扑矩阵方法	5
1.3.2 变量特征选择算法	5
1.4 主动容错控制研究现状	6
1.4.1 控制律重新调度	7
1.4.2 控制器在线重构设计	7
1.4.3 模型跟随重组控制	8
1.5 现阶段研究方法存在的问题	8
1.5.1 数据分布假设	8
1.5.2 单一工况假设问题	8
1.5.3 监督学习的两大假设	9
1.5.4 定量化定位的问题	9
1.5.5 故障识别、定位、容错控制的异构信息融合的问题	10
1.6 本文的主要研究内容和论文结构	10
第 2 章 预备知识	14
2.1 张量及相关运算	14
2.1.1 张量的基本概念	14
2.1.2 张量的数据表示	15

2.1.3 张量的运算	16
2.1.4 张量的范数	17
2.2 监督学习	17
2.2.1 输入输出空间	17
2.2.2 假设空间与决策函数	18
2.2.3 学习器性能评价	20
2.3 本文使用的实验验证系统	21
2.3.1 固体燃料电池系统 (SOFC) 工作原理	21
2.3.2 实际系统数据校正	23
2.3.3 系统故障与数据采集	24
第 3 章 张量标签学习	26
3.1 引言	26
3.2 张量标签学习总览	27
3.2.1 标量 (0-阶张量) 标签学习	27
3.2.2 向量 (1-阶张量) 标签学习	30
3.2.3 矩阵 (2-阶张量) 标签学习	33
3.2.4 高阶张量标签学习	35
3.3 基于张量标签的故障定位定量化评价	37
3.3.1 工业系统的拓扑结构	37
3.3.2 张量定位标签	38
3.3.3 一维空间定位评价	39
3.3.4 二维空间定位评价	40
3.4 基于张量标签的故障识别与定位信息融合	41
3.4.1 识别与定位关联矩阵	41
3.4.2 故障识别与定位张量融合与评价	42
3.5 基于张量标签的故障识别、定位与容错控制信息融合	44
3.5.1 容错控制定量评价	44
3.5.2 故障识别、定位与容错控制信息融合与评价	45
3.6 本章小结	47
第 4 章 基于张量标签学习的海量标签样本并发故障识别	48

4.1 引言	48
4.2 故障的模式化描述	49
4.3 向量标签与标量标签编码方式对比	50
4.4 并发故障的 1-阶张量标签描述	52
4.5 1-阶张量标签 PCA-SVM 算法	53
4.5.1 主元分析维数压缩	53
4.5.2 1-阶标签并行 SVM 分类算法	55
4.6 1-阶标签学习并发故障评价准则	59
4.7 实验结果与分析	60
4.7.1 实验参数	60
4.7.2 张量标签学习的并发故障识别精度	61
4.7.3 并发故障现象推理	62
4.7.4 故障树推理	65
4.8 本章小结	66
第 5 章 基于迁移学习的稀疏标签样本并发故障识别	68
5.1 引言	68
5.1.1 数据域与数据分布	70
5.1.2 学习任务	70
5.1.3 迁移学习研究的问题	71
5.2 数据域可迁移的条件证明	71
5.2.1 数据分布充分采样条件	72
5.2.2 源域可以预测目标域条件	73
5.3 1-阶张量标签-迁移学习策略设计	75
5.4 1-阶张量标签-迁移随机森林并行算法	78
5.4.1 决策树	78
5.4.2 迁移-随机森林并行算法	80
5.5 实验结果与分析	82
5.5.1 基于张量标签学习的并发故障识别精度	82
5.5.2 参数选择	84

5.5.3 并发故障可视化分析	84
5.6 本章小结	87
第 6 章 基于特征选择算法的故障定位.....	88
6.1 引言	88
6.2 故障定位的框架	89
6.2.1 能量耗散系统	89
6.2.2 基于特征选择算法的故障定位的流程	90
6.2.3 相似性度量	94
6.3 RELIEF 型过滤式特征选择故障定位算法	96
6.3.1 Relief 算法	96
6.3.2 最大相关-最小相容 Relief 算法	97
6.3.3 实验结果与分析	99
6.4 基于 1-阶张量标签随机森林算法的包裹式特征选择	102
6.4.1 Out-of-bag 随机特征挑选	102
6.4.2 重要性度量的特征选择算法	102
6.4.3 重要性度量实验结果	103
6.4.4 实时监控系统的	107
6.5 张量标签学习-随机森林算法的故障识别与定位	107
6.6 张量标签学习定量化定位结果	109
6.7 本章小结	111
第 7 章 基于张量标签学习的主动容错控制	112
7.1 引言	112
7.2 基于 0-阶张量标签学习的故障识别算法	113
7.2.1 决策树式多分类	114
7.2.2 基于 0-阶张量标签的多工况故障识别	115
7.2.3 实验结果	116
7.3 控制律重新调度的主动容错控制	120
7.3.1 燃料电池系统的控制系统	120

7.3.2 结构冗余装置	123
7.3.3 解析冗余控制系统与控制律重新调度	123
7.3.4 实验结果与分析	128
7.4 控制律在线重组的主动容错控制	137
7.4.1 TS 模型的特点与规则	138
7.4.2 TS 型贝叶斯学习(TS-BL)	139
7.4.3 广义预测控制 (GPC)	141
7.4.4 TS-BL-GPC 控制律在线重组	144
7.4.5 实验结果与分析	146
7.5 张量标签学习评价结果	151
7.6 本章小结	151
第 8 章 总结与展望	153
参 考 文 献	155
致 谢	165
附录 1 攻读博士学位期间已发表或录用的论文	166
附录 2 攻读博士学位期间参与的科研项目	168

第 1 章 绪论

1.1 论文研究背景及意义

工业生产线不可避免的会出现各种类型的故障，这些故障的发生会极大的影响生产的效率甚至导致非常严重的安全问题^[1-4]。当故障发生时，需要快速根据故障的类型、程度、位置采取相应的策略，从而将故障的危害降到最小。如果故障征兆出现却没有得到及时有效的处理，很有可能会造成生产性能失效，会造成生产线的停机，甚至会造成非常严重的生产事故。国内外都有因为故障没有处理完善造成的及其严重的后果的事件，例如，2003 年美国东北部和加拿大出现大面积停电的事故和 1986 年前苏联切尔诺贝利核电厂出现的严重核泄漏事故^[5-8]。

为了保证工业系统的安全稳定的运行，在生产过程系统里设计优良的过程监测系统和故障诊断系统就非常有必要。这些系统可以对过程中发生的故障进行准确及时的检测、辨识和消除，避免故障的进一步扩大。对于保障人员和财产安全，确保生产过程安全有效的运行，提升产品综合竞争力有着非常重要的意义。因此，研究高效、快速、准确的故障诊断系统，对于现代工业的发展有着非常重要的意义^[9-11]。

从系统的角度来看，故障是指在系统中至少有一个重要的系统变量或系统特性，超出了正常范围，同时系统逐步出现异常，从而导致了整个系统性能恶化的事件^[4]。通常情况下，故障的发生并不孤立，一个故障的发生会造成许多次生现象，多个故障也可能同时的发生，这就给故障的识别、定位以及故障恢复造成了极大的困难^[12-14]。

常规的故障诊断系统一般采用工业复杂非线性系统机理建模的方法，采用模型与现实工业系统的残差向量来判断工业系统的故障类型、位置等信息。近些年，随着集散控制系统（DCS）和智能仪表在工业系统中的广泛使用，记录保存了大量的工业过程数据，另外计算机控制技术以及数据库存储技术在工业系统中的广泛应用为分析大规模数据提供了基础和支持。基于数据驱动的故障诊断方法应运而生，并迅速成为故障诊断领域的热点研究方向，而基于统计理论的故障诊断方法作为数据驱动方法的一个分支，也得到了国内外学者的广泛关注。采用基于数据驱动的故障识别、定位等方法，主要是利用数据挖掘、机器学习的方法，挖掘工业过程数据背后的机理、模式，从而判断出当前的故障状态、故障位置等信息^[15]。

故障诊断过程包括故障检测、故障识别、故障定位、故障评价与决策以及容错控制五个部分^[16]。故障诊断是对系统异常状态的检测、识别、定位以及容错控制的过程的统称。各部分的详细介绍如下：

建立模型：按照工业系统的先验知识或系统工艺、物理化学原理以及过程的阶段特性与

运动规律对系统的正常过程和故障过程进行精确的数学或统计学建模。

故障检测：当系统输出或某些变量偏离了期望范围，或者是过程状态和某些特征突变变化超出预估，故障检测能及时检测到异常的发生，反馈异常警报。

故障的识别：故障识别是指识别故障的发生或者是识别故障的类型，故障的识别包含故障的检测与故障的类型判别两层含义。

故障的定位：故障定位是指判断出故障发生的根源变量，从而确定故障发生的位置。

故障的评价与决策：通过上一步得出的故障类型以及对故障等级的评价，对故障的发展趋势以及会对系统造成的影响进行分析，给出相应的决策和后序的处理方案。

容错控制：依据以上的综合分析，可以采取控制策略，来减小故障带来的损失，使系统保持安全稳定，甚至是恢复至正常状态。完整的诊断流程图如图 1-1 所示。




图 1-1 工业故障诊断流程

Fig 1-1 Industrial fault diagnosis process

1.2 故障识别的发展现状

故障识别是指系统发生了异常之后，根据当前的现象或是状态数判断出当前故障的类型^[17-22]。故障识别技术是工业过程监测技术的基础，工业系统被监控的目的是判断当前的故障是否发生以及发生的故障类型，例如常见的工业系统的温度、压力、流量等量是否正常以及识别发生了什么类型的异常。故障识别的结果用来指导控制系统控制律的设计、调整。随着自动化系统的发生，故障识别技术也用于对于控制系统装置的健康状态的识别，例如石油化工控制系统的故障识别、机械机床等设备的目标切割的控制精度等异常的识别^[23-26]。故障识别是整个故障诊断过程的核心，因为只有判断出故障的类型，才能够相应的采取措施消除或者降低故障的影响；故障检测本质上也是故障识别的一种特例，检测是做了正常与异常状态的识别。故障识别的研究主要分为两大类：一类是的基于机理模型的残差向量构造法，另一类是基于统计学习的模式识别方法。

1.2.1 基于机理模型的残差向量构造方法

基于定量模型的方法是最早发展起来的故障识别方法，该方法需要建立被识别系统的精确数学模型，然后利用残差向量为特征进行故障识别。残差向量是设备观测值与数学模型之间一致性检验的结果。在理想的情况下，当有故障存在时，残差或残差的变换取值相对较大；当仅存在干扰、噪声或模型误差时，取值较小，这就允许定义某一阈值以检测故障的存在，如图 1-2。




图 1-2 基于模型的故障识别流程图

Fig 1-2 Flow chat of fault diagnosis

基于模型的故障识别技术的基本思想是通过建立并了解对象系统的数学模型（数学解析模型、电路模型、信号流模型、网络模型等），将故障模拟设置为模型中参数的调整与改变，然后推导故障下模型可直接测量或可间接测量的状态、信号、变量的差值或特征量，鉴于系统的模型具有唯一性，因此，故障和表征故障的特征量之间的映射关键具有唯一性。基于模型的故障识别方法大多情况下，故障类型和表征故障特性的模型差值、特征量之间是一一对应了，避免了多种故障、相似性故障的区分难题。在工业应用中，很多对象和系统的数学模型是已知的，比如含电机的运动控制系统、含传感器的测量控制系统、以及网络控制系统等。在这些对象和系统中，基于模型的故障诊断技术被大量的研究，以解决系统故障检测、识别，设计配套的监控、预报、和维修决策系统。

基于解析模型的方法首先利用工业过程的内在机理建立精确的面向监测对象的数学模型，再通过冗余变量生成的残差序列进行统计分析，从而实现对工业过程的异常情况进行分析，同时增强残差序列隐含的故障信息，抑制因模型误差和扰动而导致的非故障信息，最后对残差序列做分析，得出结论^[27]。基于解析模型的方法主要包括：状态估计法^[28]，参数估计法^[29]、等价空间法^[30]等。

参数估计法结合参数辨识与理论建模，依据正常值和参数估计值的差值进行故障诊断，对于分离故障具有良好的效果。由于该方法要求物理参数与模型参数一一对应，所以将其与其他方法结合起来，更有利于提高检测精度。基于数学模型的方法能够更加精确的描述出系统的本质特征，对系统的动态波动进行量化分析。但是它必须对系统建立精确的数学模型，对于多变量耦合、高维非线性以及动态时变的复杂系统来说，这样的方法则很难实现。

状态估计法是根据工业系统的定量模型以及过程中的测量信号，对某一个可以测量的变

量进行重新测量，然后将重新测量出的估计值与实际测量值的差值用于故障的检测和分离。由于通常使用滤波器产生残差，故该方法也被称为滤波器法。该方法设计灵活、易获取、响应速度较快、算法简单且具有很强的鲁棒性，因而在故障诊断领域利用的较多。等价空间法需要做一个线性动态变换，变换后的残差则用于检测和分离故障。

基于模型的故障识别算法具备较高的识别效率，同时和故障类型的映射关系具备唯一性，受制于需要知道准确的系统模型和模型参数，在模型含不确定性动态过程或模型参数浮动较大的对象或系统中，基于模型的故障识别技术的应用有一定的限制。

1.2.2 基于统计学习的模式识别方法

基于数据的故障识别技术的基本思想是通过采集对象的历史数据，在一定约束条件下进行学习，获取对象的数学模型关系——模式识别，逼近对象数据中所隐含的映射机制以及隐含的信息，从而利用数据模型进行故障检测和识别。基于数据的故障识别技术不需要工业系统的详细的机理知识，以采集的对象历史数据及当前数据为基础，基于数据挖掘和机器学习的理论基础，利用历史数据集训练数据模型，建立数据和故障类别之间的映射关系。

在一些工业应用中，对象和系统的数学模型很难建立，比如医疗检测仪器、复杂非线性工业系统、社会系统或者金融系统等。这些系统的工作机理难以分析，但存在大量可测量的数据，如医学检测报告数值、影像，工业监控的温度、压力等，以及金融系统财务信息或者资金流的信息等。在这些领域基于机器学习的故障识别有非常广泛的应用，并在一定的置信区间中可以对故障进行有效的预报^[31-36]。

与基于模型的故障识别相比，基于数据的故障识别的方法不需要建立精确的数学机理模型。该类方法以采集的过程数据为基础，通过挖掘数据中能够反映过程运行状态的隐含信息来实施有效的过程监测。随着现代工业规模的不断扩大以及系统结构的日益复杂，获取精确机理模型和充足过程经验知识的难度越来越大，以致于基于数学模型和基于定性知识的过程监测方法很难在现代工业过程中得到广泛应用。另外，分布式控制系统（DCS）的广泛应用为过程监测提供了海量的分析数据。计算机科学技术的发展，尤其是机器学习与大数据技术的迅猛发展，也为工业数据的分析提供了强有力的技术支撑。

文献^[37-42]建立了基于数据模态分析及改进的算法、小波变换等信号处理技术对医学心脏病心电图进行了分析，并建立病程之间的逻辑映射关系。文献^[43-49]建立了基于数据，对复杂的工业过程控制系统，如石油、化工、冶炼等行业领域典型的故障识别算法。文献^[50]建立了基于统计学数据分析理论和技术，对澳洲城市汽车和季节性气候进行关联分析模型。文献^[51, 52]建立了基于数据的、对金融系统预测、风险规避、和投资组合的量化分析模型。文献^[53-57]建立了基于傅立叶分析、小波变换、经验模态分析和神经网络、支持向量及等机器学习理论对电机轴承、定子匝间短路、转子断条故障数据分析识别模型。

基于数据的故障识别技术需要大量有效的传感器测量数据，该故障诊断模型的优劣取决于对数据的处理整合能力、特征量的选择和组合、训练和测试所用的分类器选择、分类器参数的设置等，该类算法通常采用利用历史数据离线训练和测试模型，再将模型投入工程应用中，目前在投入工程应用中的模型通常还添加了根据当前数据自学习的算法。

1.3 故障定位的发展现状

故障定位是指，通过系统的故障现象和状态判断出系统故障的位置。但由于故障定位是一种由现象反推原因的过程，所以对系统自身的特性要求较高，并不是每一种系统都可以故障定位的。故障的定位需要满足许多条件，（1）系统的现象或者状态数据要包含系统的位置信息；（2）要对每一个变量在系统中的位置有充分的了解；（3）系统需要是能量耗散系统，才能够根据状态数据唯一的准确的定位到根源变量。现阶段故障定位问题主要应用的背景是电网领域，针对工业系统定位的文献较少。主要方法有：矩阵算法和数据挖掘型算法。

1.3.1 定位拓扑矩阵方法

定位拓扑矩阵主要是解决电网或者是互联网光纤网络的故障。故障定位的矩阵算法是基于故障电流判别故障区域，先根据配电网的网络结构构造网络描述矩阵，再由馈线开关的故障电流信息和网络描述矩阵生成故障判断矩阵，最后根据故障判断矩阵可以判断出发生故障的区段。矩阵算法编程简单，运算速度较快，但过多依赖于网络拓扑结构和故障信息，致使容错性差。矩阵算法从应用到配电网故障定位到现在，已经取得了很多研究成果，矩阵算法的速度和适用性都有所提升。

文献^[58]提出了能量耗散系统网络来描述电网系统，把故障定位问题转化寻找异常矩阵位置的异常值的问题，这样就可以通过矩阵对角线元素的异常以及异常元素在矩阵中的位置坐标来判断故障发生的拓扑节点。文献^[59]中，将整个配电网的电路联通情况用拓扑矩阵进行描述，仅选择有故障的线路参与矩阵计算，可以在一定程度上减少计算量，此算法非常适合判断故障在网络中的位置。文献^[60]根据有向拓扑矩阵来描述电网的网络拓扑结构，该算法适用于辐射状网、树状网和环网开环运行、环网闭环运行和多电源等多重并发故障的定位。文献^[61]将耦合点纳入网络描述矩阵，并将故障信息丢失节点进行区分分别判断，同时加入了节点矩阵，用以区分耦合点及自身故障点，适用于故障网络信息上传失败时的故障定位。

1.3.2 变量特征选择算法

基于数据特征选择的定位算法，主要是分析系统故障数据的模式，根据变量数据对系统正常状态（0）和故障状态（1）的贡献程度，找到一组最能够反映系统故障的变量子集，然

后根据这个子集变量在系统中的位置，判断出系统故障发生的根源位置。这种方法的本质就是系统特征集合的特征相似性度量，选择出对故障模式影响大的变量，其他变量都是这个或者这几个变量的随动情况，在某些条件下这些变量的位置也就是故障发生的位置。只有满足能量耗散系统条件才能做到唯一的、准确的定位，现实中满足以上条件的系统最常见的就是电网系统，因此这方面的研究主要集中在电网输配电系统中^[59, 62, 63]。

1.4 主动容错控制研究现状

当识别出故障时，为了保障系统的稳定性并维持高性能运行，就必须采用容错控制的方法将故障的影响减小到最低。容错控制分为主动容错控制和被动容错控制，本文研究的容错控制代指主动容错控制。主动容错控制是指故障发生后，根据故障识别与定位的结果，考虑所期望的特性重新设置一个控制系统，并至少能使系统达到稳定。新的控制系统的性能与原系统相比有可能会下降，但仍然能够在不停机的情况下安全的运行。主动容错控制需要根据现有的机理或者数据模式的知识，提前设计故障检测与诊断系统（Fault detection and diagnosis FDD）来识别故障。主动容错控制主要是主动对故障进行认知并主动的对故障进行控制方法的干预，减少故障对系统的危害^[64-66]。主动容错控制的基本概念有：

控制律：容错控制术语中控制系统及控制参数的统称。

控制律重组：对控制器参数进行调整。可以有在线和离线的情况。

控制律重构：同时对控制器的结构和参数进行调整，使控制系统最佳的适应当前的工况。可以有在线和离线的情况。




图 1-3 主动容错控制系统框图

Fig 1-3 Active fault tolerant control system

解析冗余：为了实现系统的容错控制，而在算法和软件上设计的冗余结构，正常情况下可能与没有冗余结构的控制系统没有什么区别，但故障发生时，可以通过调用和调整这些冗余实现系统的主动容错控制。

结构冗余：为了系统的容错控制，而设计的系统硬件结构。这些结构可能平时并不工作，

当系统发生故障的时候。可以通过系统的解析冗余来调用结构冗余实现系统的容错控制。主动容错控制都会有解析冗余，是否具有结构冗余则需要根据实际情况而定^[66]。

主动容错控制的框图如图 1-3 所示，主动容错控制的本质是主动的对故障进行识别，并进行干预。主动容错控制有三种类型：1) 控制律重新调度; 2) 控制器重构设计; 3) 模型跟随重组控制。

1.4.1 控制律重新调度

控制律重新调度提前已知常见的故障类型，针对每个故障的类型提前整定几套应对这些故障类型的控制参数，利用设计好的 FDD 单元在线的判断故障的类型，再从整定好的控制参数库中选择相应的控制器参数，从而实现容错控制的过程^[67-70]。采用这种容错控制方法可以应对大部分常见的故障，而且采用参数切换的方法一般不需要在线调整控制器结构。这类控制方法适合于具有多个稳定故障状态的工业系统，比较容易工程化实现。控制律重新调度是现阶段在实际中应用最广泛的容错控制方法是现阶段应用最多的一类主动容错控制方法，但是这种方法的应用范围仅限于能够处理有限的几个已知的故障类型，一旦故障超过了这些类型范围，或者控制参数切换过多，就会造成控制失效。

这种主动容错控制采用的最普遍，也最容易工程化，实际的容错控制效果最好。但基于控制律重新调度的主动容错控制方法只能有效的处理那种故障类型和认为可能发生的故障。对于那种故障类型完全未知，或者几种已知不同类型的故障同时发生的情况，该方法就具有一定的局限性。

1.4.2 控制器在线重构设计

控制器在线重构是指当故障发生了之后，通过 FDD 单元判断当前的故障类型，然后根据需要在在线的重新调整系统的结构或者在线的调整控制系统的控制参数。控制律重构设计方法需要 FDD 单元，通过 FDD 确定所发生的故障时间，发生的位置，和相应的故障严重程度或故障类型信息，利用这些信息对控制器进行重构或者重组。在主动容错控制领域，研究者和工程师通常利用观测器或者滤波器对故障进行检测与识别，然后再利用自适应、滑模技术设计相应的诊断观测器用于得到故障大小，利用位置观测器或者故障定位拓扑矩阵的方法确定故障发生的位置。综合利用这些故障信息，对故障下的被控对象设计一个控制律重构或者重组的方案。利用李亚普诺夫方法保证所设计的容错控制系统的具有一定的稳定性。也有部分研究成果，将 FDD 集成到控制器中，直接对控制器参数进行在线调节。

控制律在线重构的主动容错控制器的难点就是如何保证 FDD 单元的精度以及如何调整控制器的参数之后还能够使控制器保持稳定，以及具有足够的控制性能。现阶段 FDD 的设计

方法目前的研究都是基于模型设计的，但是要想得到系统精确的数学模型，是非常困难和具有挑战性的，所以如何设计不确定性的 FDD 单元用于故障诊断，也是当前研究的难点。

1.4.3 模型跟随重组控制

这类主动容错控制的基本原理是，采用模型参考自适应控制的思想，使得被控过程的输出始终自适应地跟踪参考模型的输出，而不管是否发生了故障。因此，这种容错控制不需要 FDD 单元。当发生故障后，实际被控过程会随之发生变动，控制律就会相应地自适应地进行重组，保持被控对象对参考模型输出的跟踪^[71, 72]。可以看出，这类容错控制是采用隐含的方法来处理故障的，实际的本质是基于机理模型的控制方法在故障控制下的特殊情况。

1.5 现阶段研究方法存在的问题

1.5.1 数据分布假设

工业系统的数据分布是一个客观存在的事实，数据的分布包括系统的正常状态和系统的故障状态都是可以估计和观测的。但是现阶段基于多变量统计的过程监测方法，往往假设数据的分布是高斯的。其中以基于 PCA 和 PLS 的方法为代表，通常假设过程数据服从多变量高斯分布，这是因为 T^2 和 SPE 统计量控制限通常都是在此假设下估计的得到的，基于高斯分布的假设可以计算得到故障的控制限，也就是故障发生的阈值^[73-80]。但是实际工业过程的观测数据往往都会表现出不同程度的非高斯性。当数据的实际分布情况背离高斯假设比较严重时，基于此假设的过程监测方法将会产生非常不理想的监测效果。

这些方法的问题在于，当工业系统的数据分布实际情况严重背离高斯假设的时候，基于次假设的过程监控方法将会失效，会有较高的误报和漏报。因此，在设计故障检测与诊断系统的时候，需要考虑更普遍的情况，减少与现实背离的假设。

1.5.2 单一工况假设问题

传统的多变量统计过程监测方法还对被监测过程做了静态假设。在这里静态假设主要指两方面，一是对过程数据的独立同分布假设，即不考虑数据样本间的自相关性，二是对工业过程的时不变假设，即认为过程运行在单一工况，正常工况不会随时间发生变化。虽然静态假设可以简化建模过程，但是却违背了实际工业过程的动态运行特点。在实际的工业过程中，生产系统往往都是动态系统，很多过程变量自身都是时序相关的。文献^[73-80]中研究的故障系统都是采集自单一工况，即认为系统工作在一个稳定的状态，系统的变量都在一个稳定值附近抖动，所以系统才会呈现高斯与非高斯的状态。

现实中的工业系统，不可能只工作中同一个工况下，比如发电站不可能按照一个功率进行发电。而且现实中完全保持恒定的系统往往是不存在的，正常工况的运行状态会因为各种不同的原因而发生缓慢地变化，比如设备老化、传感器漂移、催化剂逐渐失效等等。由于这些变化的存在，随着时间的推移，以前离线训练的统计监测模型已不能正确描述被监测过程当前的运行状态，因此需要不断更新监测模型以适应这种变化。基于这种假设得到的故障诊断系统，只能够应对单一工况，对于现实中工况反复变化的工业系统来说，实际意义有限。

1.5.3 监督学习的两大假设

现阶段故障识别在工业中的应用主要采用的是监督学习，主要有两方面的应用：利用监督学习方法将不同的故障数据作为不同的分类模式，然后利用监督分类来实现故障识别；第二种是软测量方法利用监督学习回归方法，学习数据间的映射关系，得到某些难测数据的计算。在深度学习、强大的算法和大量标记数据集的推动下，监督学习使得机器学习在工业系统的故障诊断中的应用越来越广泛。但是监督学习具有两大基本假设：

1. 训练数据与测试数据需要满足独立同分布的假设；
2. 需要有足够的训练数据，能够训练得到可以预测输入与输出的函数映射关系或者叫输入输出空间的条件分布。

然而，这两大基本假设在工业故障诊断过程中就会出现如下问题：

第一，在应用机器学习模型时，每个系统和每个状态都有自己的分布特点，利用机器学习模型的时候会有与训练的数据不同的测试数据；一个模型被要求执行许多没有被训练的任务，例如，工业系统的参数随着季节的不同，数据的分布会有差异。也就是实际应用的测试的过程，与训练过程的数据分布不同。

第二，一些系统的故障数据非常少，因为系统发生故障的时候大部分情况要采用停机处理，少量的情况下故障并不会使系统崩溃而是使系统的运行效率降低。这样的情形下，采集足够量的故障数据就非常困难。尤其是很多特殊的故障，例如并发的故障，就非常难以获得足够的数据训练得到。

1.5.4 量化定位的问题

文献^[58-61, 63, 81, 82]研究了工业系统的故障定位问题，为了将工业系统中的故障准确定位，就必须要有个定量的评级体系，从而可以判断定位算法的准确性，现阶段的研究基本都是定性的分析故障定位的合理与否，没有一个量化的指标来判断系统的定位精度。文献^[83]采用随机森林特征重要性度量的特征选择方法，但仅对根源变量进行了定位，并没有给出结果的评估和解释。文献^[62]采用随机森林的特征重要性度量的方法，定位 TE 系统的工业故障，

但并没有给出准确的定位精度度量，仅定性的对系统的定位给出了分析。

现阶段工业系统故障定位解决的问题是故障的位置度量，位置的度量主要是解决定位的位置与实际故障位置的关系。例如，要定位一个二维坐标空间中的点，可能不是每次都能完美的定位到这个点的坐标，但是一个效果良好的定位系统可以定位到这个点的附近或者最大程度的接近这个点。那么定位的位置 D ，与这个点的实际位置 H 之间就存在一个可度量的差异 $Diff(D, H)$ 。定性的分析这个 $Diff(D, H)$ 也就可以得到定位精度的度量。现阶段，还没有此类方面的研究。

1.5.5 故障识别、定位、容错控制的异构信息融合的问题

此前的故障诊断研究主要分为两大类：一类是工业系统的故障检测（Fault detection），主要采用 TE 模型来做工业模拟系统^[73-80]；另外一类是采用不同领域的工业系统研究工业系统的故障识别（Fault identification）^[31-35]。从前面几节的分析可以看出，在之前的研究工业故障诊断领域的文章中，研究故障识别与故障定位往往是两个独立并行的方向，二者并行研究而且没有统一到一起。而对于容错控制的研究，一般侧重控制率的重组和重构，对于主动容错控制的必要环节 FDD 一般采用理想化的处理方式，假设 FDD 子系统能够完整的识别出故障的类型，并没有与现实的故障识别系统的研究进行联合。故障诊断各环节不同类型信息数据编码后的特征空间互有差异，如识别的信息是故障类型（Fault class），定位的信息是故障源变量的空间位置（Fault root causes），容错控制的问题是控制回路的变化（Fault reconfiguration）。以往的研究中，这些信息都是孤立的、并行的研究，没有进行统一的整合、表示与融合。

信息融合可以理解为对来自多源的信息和数据进行检测、关联、相关、估计和综合等多级多方面的处理，以得到精确的状态和类别判定以及进行快速完整的态势和威胁估计。对于故障诊断系统信息融合，故障的识别、定位与容错控制就是来自于不同故障处理系统的多源信息，这些信息从不同的侧面都会反映故障对工业系统和控制系统的威胁程度，需要对这些信息进行关联、相关以及综合，从而对故障的进行全面及时的综合评价，进而完成所需的决策和容错任务。为实现故障的识别、定位、容错控制的异构信息统一表示与信息融合，需设计有效转换机制将不同特征空间的数据转换到统一表示空间中，这样才能将故障的源头、位置、类型以及对控制系统的影响统一量化度量，更完整的理解和处理故障的状态。现阶段没有这方面的研究，这也是本文研究最主要的出发点。

1.6 本文的主要研究内容和论文结构

为了解决故障信息表示不充分问题以及故障诊断各环节无法统一度量的问题，本研究提

出的张量标签学习，将数据的信息表示在高维的张量数据结构中，能够更本质的保持和反映数据信息的结构、数据的时序关系和不同数据模式之间的本质联系。为了实现对识别、定位与控制问题存在的异构信息数据的统一表示，本论文将研究基于工业故障诊断过程高维度信息数据的信息数据统一表示方法，在张量空间内实现对异构信息数据的统一表示与机器学习性能评价。利用张量标签学习的方法研究故障的识别、定位与控制问题，将这三个故障诊断的主要环节输出的异构信息数据统一到张量学习的框架中，将不同的信息融合到故障诊断张量中，综合评价故障诊断系统的故障处理能力。

本研究基于工业过程的数据资源，对不同特性数据利用相应的统计机器学习方法提取隐藏其内部的可用信息，对建立的有效机器学习模型将基于数据驱动的故障诊断问题转化为模式识别问题来进行分析从而实施故障类型的识别与定位，这具有一定的理论意义和实际应用价值。本研究提出了基于张量标签学习的故障识别方法处理的结果可应用于设备故障识别中，可以提高状态监测和故障识别智能化的程度。利用张量标签学习实现了工业故障信息的融合，对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，从而对工业系统安全的故障威胁进行完整、高效、精确的处理。

全文的组织结构如图 1-4，主要内容如下：




图 1-4 本文各章节之间的关系

Fig 1-4 Organization of the main contents

第二章首先介绍了本文研究的基础知识，主要包括：张量的定义与相关计算，监督学习的定义与基本要素，本文数据挖掘所用的固体氧化物燃料电池系统（SOFC）建模与故障数据的生成。

第三章，首先提出了张量标签学习的框架，介绍了各阶张量标签学习的基本内容。零阶张量标签学习（标量标签学习）、一阶张量学习（向量标签学习）拓展到矩阵标签学习和三阶以上的标签的形式，并推导出相应的学习性能评价的评价指标。利用张量标签表述故障的定位，将利用张量标签来描述一维和二维的故障定位，提出了一种定量化故障定位评价标准。利用张量标签将故障定位与故障识别统一到一个评价体系中，定位与识别的信息通过高维的张量形式进行表述，并利用推导的张量评价标准得到识别与定位的综合评价标准。利用工业系统控制系统的控制拓扑关系，建立起容错控制的评价标准，提出了控制系统维持率来评价故障状态下容错控制重构的程度。并利用四阶张量标签学习将故障识别、定位与容错控制统一到一个评价体系中。实现了识别、定位与容错控制的信息融合，从而利用综合评价指标来评价故障诊断系统对故障的认知和处理能力，并为故障的容错提供完整的信息。

第四章，针对并发故障组合模式众多难以完全训练的难点，本章提出了一种 1-阶张量标签学习算法，采用向量标签来向量化描述并发故障。提出了一种多标签并行化 SVM 的方法，只采用单故障训练学习器利用训练结果分析为解决上述问题，本章主要分析并发故障识别的难点，将并发故障利用向量化标签进行描述；提出向量标签学习方法。将向量化描述的并发故障利用向量标签学习进行识别；为单故障与并发故障之间的关系，建立了联系，仅采用 k 个类型的单故障就可以预测 2^k 种并发故障。

第五章，本章提出了一种向量标签迁移学习（ML-Transfer learning），用于解决工业系统并发故障识别训练数据稀少的情况。并发故障识别系统（Simultaneous fault identification system）包括两个部分：多标签迁移学习框架和随机森林机器学习算法。本章研究的源域（单故障数据）和目标域（并发故障数据）是不同的，而源任务和目标任务是相同的，并且源任务与目标任务的标签形式一致，都采用了向量化标签的形式，从张量学习的角度来讲，本章提出的向量标签迁移学习是向量化标签学习的迁移学习形式，也属于本文张量标签学习的框架内。

第六章，对于基于相似性度量的故障定位系统进行了研究，首先研究了特征选择进行故障定位的条件，然后采用了一种改进的过滤式特征选择算法，基于不同类型故障样本之间的相似性度量，同时去除特征之间的相关性来挑选出与故障类型最为相关的特征，实现故障定位。另外，为了在同一种算法中即实现故障识别又实现特征选择故障定位，从而节约计算代价，本章采用了上一章的随机森林算法中的特征重要性度量来进行特征选择，定量的恒定特征的重要性。最后，本章给出了张量标签学习在识别与定位的算法框架，采用同一套随机森林算法同时进行故障的识别和定位，也可以根据需求采用不同的识别与定位算法。

第七章，研究了老化故障下的主动容错控制，基于故障识别与定位的结果，采用 0-阶张量标签学习方法来学习变工况下老化故障的不变特征，从而可以利用多模式-监督分类的方法只采用系统采集的数据就可以判断当前的故障类型。然后，利用故障识别的结果采用不同的控制器参数，从而实现控制律重新调度的主动容错控制。为了在线辨识难以用数学表达式准

确描述的老化故障系统参数，本章提出了一种 TS-GPC 算法，本算法可以在一定时间窗周期内在线识别故障系统的时变参数，并根据故障参数在线调节控制参数从而实现系统的控制律在线重组的主动容错控制。

第八章总结全文，全文内容进行了总结，对后续的研究方向进行了展望。

第 2 章 预备知识

2.1 张量及相关运算

2.1.1 张量的基本概念




图 2-1 各阶次张量

Fig 2-1 Different order tensors




图 2-2 张量纤维

Fig 2-2 Tensor fiber




图 2-3 张量切片

Fig 2-3 Tensor slice

本节主要介绍张量的定义以及张量的基本计算。张量一种高维的数学模型，用来表示三阶以上的数组，如图 2-1。张量理论将一维、二维和 n 维数学模型统一起来。向量也就是 1-

阶张量，矩阵也就是 2-阶张量， n 阶张量则可以看做是 n 阶数组。习惯上，张量一般代指 3 阶以上的数组，对于低于 3-阶的数学模型，习惯上仍然使用向量、矩阵、标量的数学名称，但这几类数学模型都属于张量数学框架的低纬度的特例^[84, 85]。

张量的阶数和维数是不同的概念，要研究张量首先要确定其张量的阶数，阶数是张量坐标系的个数。3-阶张量是由 x 、 y 、 z 三个坐标轴的数据构成系的张量。而后确定张在各阶上的维数，也就是不同坐标轴离散化后分割成数据子块个数。张量各阶次的顺序可以事先定义，也可以使用右手定位来定义顺序。

张量的分量里，纤维（fiber）和切片（slice）是两个基本概念。其中张量的纤维是将张量按照一定规则顺序分割成条状物，是沿着不同的坐标轴进行的，如图 2-2，分别是将一个三阶张量按照 mode -1、mode -2 和 mode -3 切割的。张量的切片则是按一定规分割成切片状平面。如图 2-3，分别是将一个三阶张量按照水平、侧面和正面进行的切片。

2.1.2 张量的数据表示

在数值代数中把张量视为一个多维数组。形式上， m 阶张量是 m 个向量的张量积空间的一个元素。这个意义下的张量与物理学和工程学（如 stress tensor）中的含义不同，物理学和工程学中的“张量”有时对应数学中的“张量场”（tensor fields），这是物理学中场的一种。假如一个空间中的每一点的属性都可以以一个张量来代表的话，那么这个场就是一个张量场。最常见的张量场是广义相对论的应力能张量场（Stress-energy tensor field）^[86]。本文中的张量采用是的数值代数中的数据张量的概念，也就是高维数据信息在时间维度上的张量数据流（Tensor data flow）^[87, 88]。

本节介绍张量数据和信息的表示的信息处理系统，如图 2-4 所示。来自不同传感器和数据来源的数据信息，通过张量表示方法将各种类型的海量、多源、异构数据表示为不同阶数和维度的子张量模型，然后利用张量融合扩展技术构造高阶张量空间对大数据进行统一表示，最后进行大数据分析和挖掘，并组合成为大数据应用^[89, 90]。

张量信息的表示和挖掘框架包括五个环节：数据采集、信息的张量化表示、数据降维、数据分析与信息处理、高维张量数据和信息的应用。

张量化信息表示的优势：

1. 高维的数据表示能更本质的反映对象的本质信息，能够保存更多的系统本来的信息，从而可以挖掘出更有价值的信息。目前信息表示的方法相对简单，缺乏异构信息的表示与融合的数学模型。
2. 张量的信息表示，可以将海量、多源、异构信息进行有机的整合、统一的表示、信息的融合，融合在一个统一的表示框架内，方便统一的处理和统一的评价。
3. 张量化的信息表示，可以利用张量的数学运算，方便将张量化的信息进行切片或者纤

维处理，进行分布式或者并行式的信息处理，最后再根据张量的计算将切片或者纤维信息重新组合成张量的信息。并行的信息处理会极大的提高计算的效率，同时又不损失张量的结构化信息。




图 2-4 张量信息的表示与挖掘

Fig 2-4 Tensor data representation and mining

2.1.3 张量的运算

本节给出张量模型的相关背景知识，介绍张量模型及张量相关运算，阐述张量模展开运算、张量与矩阵的单模乘运算、张量与张量的多模乘运算。

采用 A 来表示张量，在本文中，采用张量符号来表示所有的标量、向量、矩阵，本文采用的张量计算方法主要有，张量的切片、张量的方向与计算、张量的范数。值得注意的是张量的切片是有方向的，方向的指定一般按照右手螺旋定律来进行，也可以根据需求，认为的定义张量的切片方向。张量计算的符号如下：

表 2-1 张量计算

Table 2-1 Tensor calculus

张量计算符号	计算含义
$A(n)$	按照模 n 展开
$\ A\ $	张量的范数
$A_j(i)$	张量沿着 j 方向的第 i 个切片矩阵
$\times_n$	按照模 n 的乘积
$\otimes$	Kronecker 积

2.1.4 张量的范数

张量作为一个向量空间也可以定义范数。如类似于矩阵的 Frobenius 范数，对于张量 $A \in R^{n \times n \times \dots \times n}$ 可以定义如下的张量 Frobenius 范数表示的是所有元素平方和再开方：

$$\|A\|_F = \sqrt{\sum_{i_1=1}^n \sum_{i_2=1}^n \dots \sum_{i_m=1}^n a_{i_1 i_2 \dots i_m}^2} \quad (2.1)$$

0 范数表示的是张量里非零元素的个数，表示的是张量的稀疏程度。

1 范数：

$$\|A\|_1 = \max_{i_1 \dots i_m} \sum_{i_1} |a_{i_1 i_2 \dots i_m}| \quad (2.2)$$

∞ 范数：

$$\|A\|_\infty = \max_{i_1} \sum_{i_2 \dots i_m} |a_{i_1 i_2 \dots i_m}| \quad (2.3)$$

2.2 监督学习

监督学习由三个要素组成：输入输出空间、假设空间与决策函数、学习性能评价^[91]。

2.2.1 输入输出空间

在监督学习中，讲输入输出所可能的取值集合分别称为输入空间（input space）和输出空间（output space）。输入输出空间可以是有限元素的集合，也可以是整个欧式空间，输入输出空间也可以是不同的空间。

工业系统的变量数据构成矩阵 $X_{n \times n \times nv}$ ，其中， ns 是样本数目（采样时间为 t_s ）， nv 是过程变量或特征的数目。过程数据矩阵的特征是根据过程的条件来描述的，表示为 X 。

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1nv} \\ \vdots & \ddots & \vdots \\ x_{ns1} & \cdots & x_{ns nv} \end{pmatrix} \quad (2.4)$$

另外，训练集 R 和测试集 E 将由划分所得。矩阵 R 和 E 各自是由完整数据 X 中的某几段连续样本构成，所以它们的交集为空集，即没有一个样本会同时属于训练集和数据集。为了包含更多关于流程动力学的信息，需要扩展特征并找出能够更好地描述每个过程状态的统计属性。这些扩展的特征将会被添加到每个过程样本的属性中。由此得到的新数据集的特征数目多于原始数据集 X ，但样本数不变。

标量标签：

$$y_{nc} = i, i \in N \quad (2.5)$$

标签的输出是时间序列的，因此，学习器的标签输出是标签维度加入时间 t 维度的输出：

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_{ns} \end{pmatrix} \quad (2.6)$$

2.2.2 假设空间与决策函数

联合概率分布与假设空间

监督学习假设输入与输出的随机变量 X 和 Y 遵循联合概率分布 $P(X,Y)$ 。 $P(X,Y)$ 表示分布函数或者分布密度函数。训练数据和测试数据被看作依联合概率分布 $P(X,Y)$ 独立同分布产生的。统计学习假设数据是存在一定的规律性， X 和 Y 具有联合概率分布的解释就是监督学习关于数据的基本假设。需要强调的是，在后面的章节中，这个假设不再成立。在实际的工业系统中，随着工况的改变训练集和测试集将不满足独立同分布假设，我们采用迁移学习的策略来解决分类问题。

监督学习的目的在于学习一个由输入到输出的映射，这一映射由模型来表示，学习的目的在于找到最好的模型。模型属于由输入空间的确定意味着学习的范围的确定。监督学习的模型可以是概率模型或者非概率模型，由条件概率分布：

$$P(Y | X) \quad (2.7)$$

或者决策函数（decision function）：

$$Y = f(X) \quad (2.8)$$

监督学习研究的形式化问题




图 2-5 监督学习

Fig 2-5 Supervised learning

首先给定一个训练集 R 输出为 Y 。在监督学习里训练数据 R 与测试数据 E 是依 $P(X, Y)$ 独立同分布产生的。在学习过程中，学习系统利用给定训练数据集 R ，通过学习（训练）得到一个模型，表示为条件概率分布：

$$\hat{P}(Y | R) \quad (2.9)$$

或者决策函数：

$$Y = \hat{f}(X) \quad (2.10)$$

条件概率分布或者决策函数描述输入与输出之间的映射关系。预测的过程中，预测系统给定测试样本输入 x_{N+1} ，由条件概率分布模型：

$$y_{N+1} = \arg \max_{y_{N+1}} \hat{P}(y_{N+1} | x_{N+1}) \quad (2.11)$$

或者决策函数模型：

$$y_{N+1} = \hat{f}(x_{N+1}) \quad (2.12)$$

学习过程中，学习算法学习数据集中样本带来的信息，学习算法通过不断的尝试，选取最好的模型，一遍对训练数据具有足够好的拟合能力，同时对未知的测试数据集的预测能力有足够好的推广。

2.2.3 学习器性能评价

对于学习器的泛化能力进行评价，需要有衡量学习模型泛化能力的标准，这就是性能评价（Performance measure）。性能度量反映了任务需要，在对比不同的能力时性能度量会导致不同的评价结果，所以性能评价取决于任务需求。

精度和错误率

错误率和精度是最常见的两种性能度量，这是分类任务中最常用的两种性能的度量，适用于单任务和多任务。错误率表示的是分类错误的样本数占样本总数的比例，精度是正确分类的样本数占样本总数的比例。对于输入 X ，错误率 E 和准确率 ACC 定于如下：

$$I(a=b)=\begin{cases} 1 & \text{if } a=b \\ 0 & \text{otherwise} \end{cases} \quad (2.13)$$

$$E(f, X) = \frac{1}{m} \sum_{i=1}^m I(f(x_i) \neq y_i) \quad (2.14)$$

$$ACC(f, X) = \frac{1}{m} \sum_{i=1}^m I(f(x_i) = y_i) \quad (2.15)$$

查准率、查全率与 F1 准则

准确率和精度不能满足所有的任务需求，例如二分类的问题，可以根据样本的真实标签与识别出的标签情况，可以分为：真正例（True positive）、假正例（False positive）、真反例（True negative）、假反例（False negative）。分类结果如表：

表 2-2 二分类预测与实际对比

Table 2-2 Comparison between two Classification Prediction and practice

		预测结果	
		1	0
实际情况	1	TP	FN
	0	FP	TN

查准率 Pre 与查全率 Rec 分别定义为：

$$Pre = \frac{TP}{TP + FP} \quad (2.16)$$

$$Rec = \frac{TP}{TP + FN} \quad (2.17)$$

查准率与查全率是一对矛盾的指标，F1 准则是取这两者的均值度量：

$$F1 = \frac{2 \cdot \text{Pre}}{\text{Pre} + \text{Rec}} \quad (2.18)$$

F1 表示的是，真实的事件发生了之后能否检测出的概率和检测出事件发生了而确实是真的发生的概率之间的平衡，因此，本文采用 F1 指标来表示模式识别精度的度量。

2.3 本文使用的实验验证系统

燃料电池是一种新型的发电装置，一般是利用氢气和氧气在电解质中发生电化学反应，直接产生电能的过程。这个过程与传统的发电原理不同，传统的发电方式一般是将化学能产生热能，然后利用热能推动机械设备再转化为电能。由化学能直接转化为电能的过程不存在燃烧过程也不会受到卡诺循环的束缚，能量转换效率会非常高，而且没有机械能的转化也就没有噪声。因此，燃料电池是一种高效、安静、能量密度高的发电方式。

固体氧化物燃料电池（Solid oxide fuel cell, SOFC）是燃料电池的一种类型，因为电解质的固体形态的因此叫做固体氧化物燃料电池^[92]。SOFC 系统有如下几个特点：第一，SOFC 的工作温度非常高，大约有 600-900K，在这么高的温度下氢气和氧气发电电化学反应；第二，SOFC 与其他燃料电池不同的是，不需要昂贵的铂铈合金的催化剂；第三，SOFC 需要外部辅助子系统来提供热能；第四，SOFC 对氢气的纯度要求低，不需要高纯度的氢气；第五，SOFC 的功率比一般的燃料电池高很多，可以做到几千瓦到几百兆瓦，一般作为电站来使用，而不仅仅是一般的发电电池级别。

2.3.1 固体燃料电池系统（SOFC）工作原理

氢气（Fuel, H₂）和空气（Air）中的氧气（O₂）在高温环境下，在电堆（Stack）中发生反应生成水（H₂O）并释放电能。SOFC 与其他燃料电池相比，最大的优点就是不需要昂贵的催化剂，但它的工作需要在高温环境下进行（960K~1160K）。为了使 SOFC 正常发电，SOFC 电堆必须配备相应的提供热量的外围辅助子系统（Balance of plant, BOP），才能构成一个完整的独立发电系统。被广泛采用的传统的纯氢 SOFC 独立发电系统的结构示意图主要由五个子系统构成：燃料供应管道以及阀门（Fuel），空气供应管道以及阀门（Air），电堆（Stack），尾气回收子系统（包括燃烧室（Burner）与热交换器（HEX1, HEX2））以及电控子系统。首先，氢气从储气罐或者重整器中流出进入换热器中进行加热，然后进入电堆中与高温的空气进行反应，换热器的热量来自于电堆里没有反应掉的氢气燃烧。鼓风机用来提供空气，通过控制鼓风机的功率来调节进入 SOFC 系统的空气流量，空气进入换热器中进行加热。在氢气与空气在换热器中流经的是不同的通路，二者不混合。电堆与 BOP 系统组成了完整的 SOFC 系统，SOFC 系统实现热量自循环。图 2-6 和图 2-7 表示了 SOFC 独立发电系统的实际系统的

图片和系统框图。该系统采用的是二级换热器加旁路冷空气控制的设计方式^[93-96]。



图 2-6 1kW 与 5kW 实际的 SOFC 系统

Fig 2-6 SOFC real system for 1kW and 5kW




图 2-7 SOFC 系统框图

Fig 2-7 Structure of SOFC system

与传统的 SOFC 独立发电系统相比，该系统系统主要有两大特点：

一是系统中有一条冷空气旁路 (Bypass, BP)，这种设计主要是防止换热器预热空气过量，加热后的热空气的温度超过了预设值，这时需要混合冷空气将温度降低。

二是二级换热器，也就是说在我们的换热器里，采用两个换热器来进行冷气体的预热，但是设计的时候，这两个换热器是集成到一起的，这样会更加紧凑，也会减少管路的长度，从而减少热量的散失。




图 2-8 Matlab/Simulink 平台下搭建的 5 kW SOFC 独立发电系统模型

Fig 2-8 5kW SOFC system in Matlab/Simulink platform

图 2-8 表示的是 Matlab/Simulink 平台下搭建的额定功率 5 kW SOFC 独立发电系统模型，本模型采用全工况的模拟仿真方式，并采用现实中的数据进行校正。

2.3.2 实际系统数据校正




图 2-9 实际系统数据验证

Fig 2-9 Real system data verification

本文的模型实验数据，来自 Global energy 公司的 SOFC 系统测试数据。模型的搭建是在两个实际基础上完成的：一是使用与实际设备一致的结构参数，从而保障了 SOFC 系统尺寸结构贴近实物装置，使其具备系统分析的实际可行性；二是 SOFC 系统的电堆，燃烧室，热交换器以及流体等的物性参数是采用权威化工手册得到的，从而保证了其可靠性；三是本文计算 SOFC 系统的电压时，与其相关的等效电阻就是根据实验数据进行拟合得到的。这样利用实物以及实验数据相结合建模，增加了其实际应用的有效性。但是，不可否认的是，由于实际系统中存在各种因素的影响以及扰动等因素，而本文的机理模型是以理想气体为基础搭建的，并且忽略了外界的影响，理论模型与系统模型之间存在误差是不可避免的。

为了对 SOFC 电堆的热电特性进行研究, 本文对单电池片的整体 U-I-P 曲线进行了分析。为了收集实验数据, 本文选择 $10 \times 10 \text{ cm}^2$ 的单电池片, 单电池片在恒温加热炉里通入足量的氢气与空气, 测试台的温度维持在 973 K 与 923 K 时采集实验数据, 记录单电池片的电输出特性, 包括: 输出电压, 电流密度以及功率密度特性。在 MATLAB 下, 本文在同等条件下, 对所搭建的单电池片模型进行了仿真, 将实验所获得的数据与仿真数据进行比较分析, 获得了如图 2-9 所示的 U-I-P 特性曲线。

综上所述, 当仿真条件与实验条件相吻合时, 实验测试获得的单电池片的输出电特性与仿真条件下获得的电特性是一致的。因此, 可以肯定的说, 本文所搭建的系统模型与实验设备特性是一致的, 从而 SOFC 系统模型是合理的。此模型为本文后续工作的展开提供了可靠的平台, 为本文后续动静态分析、优化以及控制器设计提供了良好的基础, 从而也证明了本文工作的有效性。

2.3.3 系统故障与数据采集

SOFC 系统可能发生许多类型的故障, SOFC 系统的变量分布如图 2-10。在研究中, 我们模拟了许多故障的条件, 以评估其对 SOFC 系统操作的影响, 在下文中的故障诊断中使用。




图 2-10 SOFC 系统变量分布

Fig 2-10 Variables in SOFC system

(1) 空气泄露

除了为电化学反应提供所需的氧化剂，阴极流允许控制电堆的温度。针对阴极空气流量对正确操作系统的重要性，第一类故障被认为是空气流量计（外部系统）和电堆之间的空气泄漏。

$$N_{air,stack,in} = \eta N_{air} \quad (2.19)$$

其中， η 是空气故障敏感因素，范围从 0 到 1。如果压缩机是正常的， η 为 0。如果压缩机发生故障， η 大于 0。当 η 为 1 时，SOFC 系统完全故障。

(2) 燃料泄漏

因为燃料流量的减少导致电堆故障（例如，缺少燃料会发生在电堆的某些部分，造成损害），实验模拟了裂化炉出口和 SOFC 电堆入口的燃料泄漏。由于氢分子的小体积和高扩散率，当高氢含量的混合物从燃料箱中流出时可能造成故障。

当燃料箱和电堆入口的连接处发生燃料泄漏，进入 SOFC 电堆的燃料流量减少。因此，燃料泄漏故障通过降低 SOFC 电堆阳极输入流量来模拟：

$$N_{fuel,stack,in} = \varepsilon N_{fuel} \quad (2.20)$$

其中， ε 是燃料故障敏感因素，范围为 0 到 1。如果没有发生燃料泄露的故障， ε 为 0，否则， ε 大于 0。

数据集说明

为了增加本文研究的可靠性和真实性，本文的模型采用现场的数据进行校准，得到的模型主要参数误差不超过 0.5%。本文的漏气单独故障数据以及电堆衰减的故障数据，全部采集来自 SOFC 实际系统，如图 2-6。模型用来仿真大量并发故障数据以及用来做为控制对象。

第3章 张量标签学习

3.1 引言

对工业大数据进行高效分析,挖掘其蕴含的内在规律的前提基础是海量、多源、异构数据的统一表示方法。故障的识别、定位、容错控制的信息在编码方法、存储格式、数据特征等方面不尽相同。基于数据挖掘的故障诊断的挖掘出的信息例如,故障位置、故障类型、故障程度等信息数据在形式、标识上都存在显著差异,这些输出的有效信息数据形成了一个信息孤岛,无法统一量化,也难以整体分析,这就需要一个简洁的模型将这些异构信息数据表示在统一的空间中[88-90, 97, 98]。

张量是一种高维的数组,能够保持复杂类型数据的内在结构,是矩阵的一种扩展形式。标量、向量、矩阵可以分别看作 0-阶张量、1-阶张量、2-阶张量。张量分析方法在计算机视觉、图像处理、模式识别、信号处理等领域已有广泛的应用。为了实现对异构信息数据的统一表示,本章将从三个方面入手进行研究。首先,分析结构化、半结构化和非结构化数据等不同类型数据的结构特征、量纲维度、组织方式,采用新的编码技术对异构数据进行统一。针对大数据异构、混杂、多维等特性,综合考虑数据的类型、结构及组织方式等因素,构建简洁的高阶张量统一表示模型是进行数据分析的前提基础[86, 88, 97]。

为了解决故障信息表示不充分问题,本研究提出的张量标签技术,将数据的信息表示在高维的张量数据结构中,能够更本质的保持和反映数据信息的结构、数据的时序关系和不同数据模式之间的本质联系。为了实现对识别、定位与控制问题存在的异构信息数据的统一表示,本论文将从三个方面入手进行研究。首先,分析结构化、半结构化和非结构化数据等不同类型数据的结构特征、量纲维度、组织方式,采用新的编码技术对异构数据进行统一量化处理。其次,不同类型数据编码后的特征空间互有差异,如识别的信息是故障类型,定位的信息是故障源变量的空间位置,容错控制的问题是控制回路的变化。为实现信息异构数据统一表示,需设计有效转换机制将不同特征空间的数据转换到同一表示空间中。最后,在故障信息数据的融合过程中,需要多维度地考虑数据的多源特征,探索新的融合扩展机制来重新组织所有数据,从而真实地描述现实工业系统中复杂关系中的多维信息。针对故障诊断信息数据异构、混杂、多维等特性,综合考虑数据的类型、结构及组织方式等因素,构建简洁的高阶张量标签的统一表示是进行故障数据模式信息全面、充分分析的前提基础。

总之,故障诊断问题存在大量的非结构化、半结构化、结构化信息数据,高效的信息数据表示方法是进行分析与挖掘的前提,然而目前尚缺乏适用于统一的故障诊断过程的评价标准[99-102]。

本章要解决的问题：将利用张量标签度量将故障识别、定位与控制融合到一个评价体系中。结构化数据的张量表示结构化数据在高阶张量空间中的统一表示模型，建立一套完整的故障诊断信息数据统一整合、表示、信息融合和评价体系，利用高维的张量信息数据对工业系统当前的模式状态进行充分、全面的描述。

本章的主要工作包括：

(1) 首先介绍了张量标签学习的框架。将 0-阶张量标签学习（监督学习）、0-阶张量学习（多标签学习）拓展到矩阵标签学习和三阶以上的标签的形式，并推导出相应的学习性能评价的评价指标。

(2) 利用张量标签表述故障的定位，将利用张量标签来描述一维和二维的故障定位，提出了一种量化故障定位评价标准。

(3) 利用张量标签将故障定位与故障识别统一到一个评价体系中，定位与识别的信息通过高维的张量形式进行表述，并利用推导的张量评价标准得到识别与定位的综合评价标准。

(4) 利用工业系统控制系统的控制拓扑关系，建立起容错控制的评价标准，提出了控制系统维持率来评价故障状态下容错控制重构的程度。并利用四阶张量标签学习将故障识别、定位与容错控制统一到一个评价体系中。利用综合评价指标来评价故障诊断系统对故障的处理能力。

从而对故障的识别、定位与容错控制的异构信息进行信息融合，对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，对工业系统安全的威胁进行高效、精确的进行处理。

3.2 张量标签学习总览

在监督学习的过程中，样本的标签是必不可少的，但是标签的类型，有时候用一个参数可能无法将当前样本的信息表达完整，因此需要采用多个标签来描述当前时刻的样本，这些标签的数据结构，可以是标量形式的，也可以是向量或者是矩阵，甚至是高维的张量形式。由于标量、向量、矩阵都是不同阶次的张量，因此本章从张量标签学习的角度，将监督学习的标签拓展为张量的形式，并给根据张量型标签判断学习器预测性能的量化指标。

3.2.1 标量（0-阶张量）标签学习

标量标签学习或者零阶张量标签学习，也就是传统的监督学习。本节从张量标签学习的角度对监督学习的各环节重新叙述，也为更高维度的张量标签学习建立统一的分析模式。在监督学习分类中，需要对训练数据 X 加入相应的标签 Y ，从而利用 X 和 Y 的关系来训练得到预测模型。在大部分研究中，每个采样周期的数据 x_i 对应的标签 y_i 对应的是 x_i 当前的类别，

采用自然数 n 来表示，也称作单标签。

从第二章基本知识中已知，监督学习都存在三个主要的要素：输入输出空间、预测函数、性能评价。本节从这三个角度来重新描述传统的监督学习以及多标签学习，并且将监督学习的标签拓展到高维的数组表示，也就是张量标签。本节中，将从标签、学习器输出、性能评价三个角度，将传统的单标签监督学习、多标签学习，以及拓展的张量标签学习重新描述。

首先定义输入空间：

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1nv} \\ \vdots & \ddots & \vdots \\ x_{ns1} & \cdots & x_{nsnv} \end{pmatrix} \quad (3.1)$$

定义矩阵比较函数函数：

$$comp(A, B) = \sum_{i=1}^m I(a_i = b_i \neq 0) \quad (3.2)$$

$comp(A, B)$ 表示的是 A 和 B 两个张量相同的非零元素的个数，在后面的张量计算中，用此计算符来评价两个张量信息的一致性。




图 3-1 标量标签学习的流程

Fig 3-1 The process of scalar label learning

本节从张量标签学习的角度来描述传统的监督学习。传统的监督学习，在第二章中有所叙述，现不赘述。从张量标签学习的角度，传统的监督学习都是 0 阶张量学习，也就是标量标签学习。

标量标签

对于标签问题的输入是一个可观测的序列，输出是一类标签序列或者称为状态序列。但对于每个周期，传统的监督学习的标签为自然数。这种标量标签可以表示为：

$$y_{nc} = i, i \in N \quad (3.3)$$

学习器的向量输出




图 3-2 标量标签在时间维度上的拓展

Fig 3-2 The extension of scalar label in time dimension

标签的输出，也就是训练得到的模型输出，每个计算周期都会输出一个模型预测类型或者状态值，也就是在标量标签维度上加入时间 t 维度，就得到了预测模型的标量标签输出：

$$Y_{\text{scalar}} = \begin{pmatrix} y_1 \\ \vdots \\ y_{ns} \end{pmatrix} \quad (3.4)$$

标签的输出总比标签的维度多一维，表示的是时间维度上的标量标签流。

学习器性能评价

为了对监督二分类学习器的能力进行评价，需要有衡量学习模型预测能力的标准，这就是学习器的性能评价（Performance measure）。性能度量反映了任务需要，在对比不同的能力时性能度量会导致不同的评价结果，所以性能评价取决于任务需求。对于带标签的监督分类学习来说，学习器的性能评价的本质：比较学习器预测的标签与实际数据的标签之间的吻合程度。如果不需要进行二进制编码标签的衡量，则仍然可以采用准确率 ACC 和错误率来衡量。

本研究定义两个变量：实际标签输出序列 H （Happen tensor）和预测标签输出序列 D （Diagnosis tensor）。 D 也就是学习器的预测输出 Y ，而 H 是实际样本的标签序列。在单标签监督学习中，因为标签的输出域标签的实际值非常容易比较，因此传统的机器学习研究中一般不引入这两个变量。但在高维度的标签数据评价中，对比这两个变量之间的关系，就是评价机器学习能力的关键。

样本实际标量标签流（Scalar label flow）：

$$H_s = \begin{pmatrix} h_1 \\ \vdots \\ h_{ns} \end{pmatrix} \quad (3.5)$$

$$h_i = \{0,1\}, \quad \forall i = 1, 2, \dots, ns$$

预测标签输出序列:

$$D_s = \begin{pmatrix} d_1 \\ \vdots \\ d_{ns} \end{pmatrix} \quad (3.6)$$

$$d_i = \{0,1\}, \quad \forall i = 1, 2, \dots, ns$$

标量标签学习的评价标准:

$$Pre_0 = \frac{comp(H_s, D_s)}{\|D_s\|_0} = \frac{\|(H_s \& D_s)\|_0}{\|D_s\|_0} = \frac{\sum_{i=1}^{ns} [1 - (h_i - d_i)^2] \cdot h_i}{\sum_{i=1}^{ns} (d_i)^2} \quad (3.7)$$

Pre 表示的是分类的精度, 一般情况下 Rec 可以反映的是所有检测为正类的样本里确实是真正正类样本的比例。但如果是二分类问题, 就需要考虑召回率 Rec。由于 0-阶张量标签学习, 也就是通常的监督学习, 没有进行二进制的编码方式, 标签都是采用自然数的形式, 公式如下:

$$Rec_0 = \frac{comp(H_s, D_s)}{\|H_s\|_0} = \frac{\|(H_s \& D_s)\|_0}{\|H_s\|_0} = \frac{\sum_{i=1}^{ns} [1 - (h_i - d_i)^2] \cdot h_i}{\sum_{i=1}^{ns} (h_i)^2} \quad (3.8)$$

$$F1_0 = \frac{2 \cdot Pre_0 \cdot Rec_0}{Pre_0 + Rec_0} \quad (3.9)$$

Rec 表示的是真正正类的样本里被真实检测出的比例。为了平衡采用比标量高一个维度的向量范数、向量计算得到的 F1 评价标准本评价准则在准确度和召回率之间取了一个平衡, 在标量学习的多分类问题中, F1 标准表示的是正确分类以及误分类的一个平衡, 在更高维度的标签学习中具有更普遍的意义, 因此本研究的准确率默认都采用 F1 准确率。

3.2.2 向量（1-阶张量）标签学习

传统的监督学习在单个标签下进行学习, 即每个示例只与单个标签相关联, 已提出多种算法并取得良好的效果。对于很多情况下, 每次学习器输出的都是一组标签来描述当前的状态, 这就是文献中叙述的多标签学习。多数文献中叙述的多标签学习, 从张量学习的角度来看, 是指向量标签也就是一阶张量标签。本节从张量标签监督学习的角度来描述多标签学习。

在标签分类领域的研究过程中, 由于标签数据集的类别数量过多而产生维数灾难的问题,

因此，标签分类中的特征降维是有必要的标签编码方法主要是将原始的标签空间投影二进制空间。这样做的好处是，利用较少的维度就能较多的表示不同的类别，这种监督学习的方法也叫作多标签学习。




图 3-3 单标签 (0 阶张量) 与多标签 (1 阶张量)

Fig 3-3 Single-label (0-order tensor) and multi-label

传统的监督学习是机器学习的主要研究模式之一，其中，每个真实世界的对象 (示例) 都由一个实例 (特征向量) 表示，并与单一标签相联系。形式上，设 X 表示实例空间， Y 表示实例空间的标签空间，传统监督学习的任务是学习函数 $f: X \rightarrow Y$ ，训练集 $\{(x_i, y_i) \mid 1 \leq i \leq m\}$ 。在这里， $x_i \in X$ 是一个描述对象的属性 (特征) 和 $y_i \in Y$ 是表示其特征的相应标签语义学。因此，传统的监督学习所采用的一个基本假设是：每个示例只属于一个概念，即具有独特的语义意义。传统的监督学习虽然盛行并取得了成功，但也有很多种学习方式。上述简化假设不适合的任务，因为现实中的对象可能是这样的。复杂而又具有多个语义的同时。举几个例子，在文本分类中，一份新闻报道可以报道体育、伦敦奥运会、门票等几个主题。销售和火炬传递；在音乐信息检索中，一首交响曲可以传达各种不同的信息。如钢琴、古典音乐、莫扎特和奥地利等信息；在自动视频注释中，一个视频片段可以与一些场景相关，如城市和建筑，等等。

传统监督分类里的二元分类是将特征空间 X 映射到只有两种标签的标签空间中 Y ，即寻找一个映射函数 $Y = f(X)$ 或者 $X \rightarrow Y$ 。多标签分类是将二元分类泛化而来，多标签数据是一种可以同时拥有多个标签的数据，而且标签之间具有一定关联性。给定标签空间中标签种类也要多于两种，多标签分类的目的是预测哪几种标签出现并将预测结果保存在标签空间中。因此，映射函数 $Y = f(X)$ 可表示为 $X \rightarrow 2^Y$ 。实际上，我们常常用固定长度的实数向量表示特征，故多标签分类映射 f 也可表示为 $R^D \rightarrow 2^Y$ ，其中 R^D 表示 D 维的特征空间。

事实上， 2^Y 可由二元向量表征。假设有三个标签，则任意一个多标签分类结果都可以用三维二元向量 $y = \{y^{(1)}, y^{(2)}, y^{(3)}, \dots, y^{(L)}\}^T \in \{0, 1\}^L$ ，其中， $y^{(i)}=1$ 表示第 i 个标签出现， $y^{(i)}=0$ 表示第 i 个标签不出现。因而，多标签分类映射函数也可表示为 $f: R^D \rightarrow \{0, 1\}^L$ 。给定包含 N

个实例的多标签训练集 $D=\{(x^i, y^i)\}^N$ ，其中，实例。该实例对应的标签 $y \in \{0, 1\}^L$ ，那么多标签分类的目的就是利用多标签映射函数预测未知实例的标签。与传统的二元分类不同，针对某具体实例，多标签分类同时输出多个标签。解释一个真实世界的对象可能具有的多个语义，直接解决方案是将一组适当的标签分配给对象，以显式地表示其语义。经过上述考虑，多标签学习的范式自然出现了。与传统的监督学习相比，在多标记学习中，每个对象也被表示。在与一组标签而不是单个标签相关联时，由单个实例执行。任务是学习一个函数，它可以预测未见实例的适当标签集。

向量标签

当一个标签的含义并不能反映当前样本 x_i 的信息的时候，就需要采用向量标签：

$$y_i = \{y_1 \cdots y_{nc}\} \quad (3.10)$$

学习器的矩阵输出




图 3-4 矩阵型输出

Fig 3-4 Matrix output

多标签输出，也就是矩阵输出或者二阶张量输出，也就是向量标签流（Vector label flow）：

$$Y_{\text{vector}} = \begin{pmatrix} y_{11} & \cdots & y_{1nc} \\ \vdots & \ddots & \vdots \\ y_{ns1} & \cdots & y_{nsnc} \end{pmatrix} \quad (3.11)$$

学习器性能评价

本研究定义两个变量：实际标签输出序列也就是向量标签流 H_v 和预测标签输出序列 D_v 。 D_v 也就是学习器的预测输出 Y_v ，而 H_v 是实际样本的标签序列。在单标签监督学习中，因为标签的输出域标签的实际值非常容易比较，因此传统的机器学习研究中一般不引入这两个变量。但在高维度的标签数据评价中，对比这两个变量之间的关系，就是评价机器学习能力的关键。

样本实际标签序列：

$$H_v = \begin{pmatrix} h_{11} & \cdots & h_{1nf} \\ \vdots & \ddots & \vdots \\ h_{ns1} & \cdots & h_{nsnf} \end{pmatrix} \quad (3.12)$$

$$h_{ij} = \{0,1\}, \quad \forall i=1,2,\dots,nf, \quad \forall j=1,2,\dots,ns$$

预测标签输出序列：

$$D_v = \begin{pmatrix} d_{11} & \cdots & d_{1nf} \\ \vdots & \ddots & \vdots \\ d_{ns1} & \cdots & d_{nsnf} \end{pmatrix} \quad (3.13)$$

$$d_{ij} = \{0,1\}, \quad \forall i=1,2,\dots,nf, \quad \forall j=1,2,\dots,ns$$

$$\text{Pre_1} = \frac{\text{comp}(D_v, H_v)}{\|D_v\|_0} = \frac{\|(H_v \& D_v)\|_0}{\|D_v\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{nf} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{nf} (d_{ij})^2} \quad (3.14)$$

$$\text{Rec_1} = \frac{\text{comp}(D_v, H_v)}{\|H_v\|_0} = \frac{\|(H_v \& D_v)\|_0}{\|H_v\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{nf} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{nf} (h_{ij})^2} \quad (3.15)$$

$$\text{F1_1} = \frac{2 \cdot \text{Pre_1} \cdot \text{Rec_1}}{\text{Pre_1} + \text{Rec_1}} \quad (3.16)$$

3.2.3 矩阵（2-阶张量）标签学习

在一些应用场景中，每个样本 x_i 包含的标签信息可能采用向量的形式并不能够完整的表现。比如，如果当前的样本表示的是一个二维空间中的位置信息，那么这个样本 x_i 的标签就需要采用一个二维的标签 (y_1, y_2) 来表示，如果 y 采用二进制编码的形式， x_i 的标签就是一个矩阵的形式。为了解决一些实际应用场景可能会面临的矩阵标签的形式，本节提出了一种矩阵标签的形式采用矩阵标签的方法对数据样本进行描述。

矩阵标签

$$y_i = \begin{pmatrix} y_{i1} & \cdots & y_{inc} \\ \vdots & \ddots & \vdots \\ y_{ns1} & \cdots & y_{ns\ nc} \end{pmatrix} \quad (3.17)$$

学习器的张量输出




图 3-5 2-阶张量标签的输出

Fig 3-5 Output for 2-order tensor label learning

矩阵型标签流（Matrix label flow）是一种 3-阶张量，这形式已经无法用公式表示出，如图 3-5 所示，定义两个张量（Tensor）：实际的矩阵型标签流 H_m 和预测出的矩阵标签流 D_m 。

学习器性能评价

$$\text{Pre_2} = \frac{\text{comp}(D_m, H_m)}{\|D_m\|_0} = \frac{\|(H_m \& D_m)\|_0}{\|D_m\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ijk})^2} \quad (3.18)$$

$$\text{Rec_2} = \frac{\text{comp}(D_m, H_m)}{\|H_m\|_0} = \frac{\|(H_m \& D_m)\|_0}{\|H_m\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ijk})^2} \quad (3.19)$$

$$\text{F1_2} = \frac{2 \cdot \text{Pre_2} \cdot \text{Rec_2}}{\text{Pre_2} + \text{Rec_2}} \quad (3.20)$$

3.2.4 高阶张量标签学习

将前面叙述的矩阵标签的基础上，在实际中有些数据样本 x_i 的模式标签信息需要用三阶张量甚至更高阶的张量来描述，比如，要定位样本 x_i 在空间中的位置，就需要采用 (y_1, y_2, y_3) 三个维度的坐标来表示，采用二进制的编码方式就需要采用张量标签的方式。张量标签不仅限于三阶，也可以采用四阶甚至更高阶的情况，但这些研究的情况与三阶张量标签形式并没有根本性的区别，因此本节的叙述中仅介绍三阶的张量学习，第七章第四节中叙述三阶张量学习在故障识别与定位中的应用。更高阶的张量标签学习在此就不叙述。

3-阶张量标签

张量是一种高维的数组，能够保持复杂类型数据的内在结构，是矩阵的一种扩展形式。标量、向量、矩阵可以分别看作零阶张量、一阶张量、二阶张量。三阶张量标签表示的是具有三个数据维度的数据结构，反映的是数据样本 x_i 的三维标签信息。本文中，张量标签的编码形式都采用二进制的方式。张量标签的结构如图：




图 3-6 3-阶张量标签

Fig 3-6 3-order tensor label

其中， y_1 、 y_2 、 y_3 表示的是从不同的维度来描述当前样本的标签信息，这种高维的标签结构可以保存更多的信息。

学习器的四阶张量输出

三阶张量标签学习的输出，也就是在标签的基础上加入了时间的维度 t ，标签加入时间维度之后，也就增加了一维的时间的信息，这样学习器每个时刻输出一个 3-阶张量，不同的时刻的标签流就构成了一个 4-阶的张量，如下图：




图 3-7 4-阶张量标签输出

Fig 3-7 4-order tensor label output

图 3-7 表示的是一个四阶的张量，每个样本对应一个三阶张量标签。高阶的张量型采用 tn 型下标，其中 t 代表张量（tensor）， n 表示标签的阶。

学习器性能评价

$$\text{Pre}_3 = \frac{\text{comp}(D_{t3}, H_{t3})}{\|D_{t3}\|_0} = \frac{\|(H_{t3} \& D_{t3})\|_0}{\|D_{t3}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} [1 - (h_{ijkp} - d_{ijkp})^2] \cdot h_{ijkp}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} (d_{ijkp})^2} \quad (3.21)$$

$$\text{Rec}_3 = \frac{\text{comp}(D_{t3}, H_{t3})}{\|H_{t3}\|_0} = \frac{\|(H_{t3} \& D_{t3})\|_0}{\|H_{t3}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} [1 - (h_{ijkp} - d_{ijkp})^2] \cdot h_{ijkp}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} (h_{ijkp})^2} \quad (3.22)$$

$$\text{F1}_3 = \frac{2 \cdot \text{Pre}_3 \cdot \text{Rec}_3}{\text{Pre}_3 + \text{Rec}_3} \quad (3.23)$$

更高阶的张量标签学习与上述叙述的三阶标签学习的格式与评价方式并无本质区别，只是维度的增加，并不改变标签与评价的基本格式。

高阶的张量学习评价是为了利用一个张量就评估多种信息，但也可以将张量评价恢复到低维的评价，利用是的张量计算：

$$F_j = A_j(1) \| A_j(2) \dots A_j(ns) \quad (3.24)$$

其中， F 表示标签张量流 A 的低 1 维度沿着 j 方向的降维，如果需要连续降维则重复公

式 3.24，只是降维的方向不同。

3.3 基于张量标签的故障定位量化评价

前面的叙述中介绍了各阶次的张量标签学习的基本要素，本节中就针对故障识别、定位与容错控制的环节，采用张量标签学习技术将故障诊断这三个重要的环节统一到一个评价体系中。本节要解决的问题是利用各阶次张量标签学习来实现故障的定位评价，利用张量分析来计算故障定位的精度。

3.3.1 工业系统的拓扑结构

工业系统故障定位首先要解决的问题是故障的位置度量，位置的度量主要是解决定位的位置与实际故障位置的关系。例如，要定位一个二维坐标空间中的点，可能不是每次都能完美的定位到这个点的坐标，但是一个效果良好的定位系统可以定位到这个点的附近或者最大程度的接近这个点。那么定位的位置预测张量 D ，与这个点的实际位置张量 H 之间就存在一个可度量的差异 $Diff(D, H)$ 。定性的分析这个 $Diff$ 也就可以得到定位精度的度量。




图 3-8 工业拓扑结构网络

Fig 3-8 Industrial topology network

工业系统一般都满足在子系统中呈现呈现对称或者局部对称的拓扑结构，在任意由相同或相似元器件构成的拓扑结构中存在对称的传感器，则该系统被称为网格系统，相同或相似元器件构成网格系统的节点。

假设 1：传感器能够充分采集系统的变化规律，充分反映系统内部信息。

假设 2：传感器的采样频率相同。

假设 3：传感器输出信号具有周期性。

假设 4: 传感器输出信号不存在相位差。

工业系统的数据采集就是采集自这些传感器系统。因此，为了将工业系统中的故障准确定位，就必须要有个定量的评级体系，从而可以判断定位算法的准确性，现阶段的研究中还没有这类的定量评价定位的指标。

以燃料电池系统为例：




图 3-9 SOFC 拓扑结构

Fig 3-9 Topological structure of SOFC system

燃料电池系统中，虽然整体并不是完全对称的，但是在某些模块系统呈现对称性。如图 3-9 所示，这样就可以利用上述的工业对称的拓扑结构进行分析。根据需求，可以分析故障的一维定位、二维定位，甚至是三维空间的故障定位。本节仅研究一维和二维定位的情况。

3.3.2 张量定位标签

为了量化的故障定位，需要解决定位的量化衡量问题，为了解决这个问题，需要提出一个概念：定位标签矩阵，如下：

$$L1 = (l_{11} \cdots l_{1nv}) \quad (3.25)$$

l_{11} 表示的是这个位置的变量是否发生故障，如果发生故障则 $l_{ij}=1$ ，如果没有发生故障则为零。L1 向量就表示出故障的位置，例如：

$$L1 = (0 \ 1 \ 0)$$

表示的是第二个位置的变量发生了故障，然后，采用第六章的故障定位方式可以得到故障的定位，评价预测输出 D 与实际故障位置 H 的关系，就可以量化的评价故障定位。故障定位矩阵可以是二维或者是高维的，从而可以表示空间中变量的位置。二维的故障定位矩阵

如下：

$$L2 = \begin{pmatrix} L_{11} & \cdots & L_{1nv} \\ \vdots & \ddots & \vdots \\ L_{nv1} & \cdots & L_{nvnv} \end{pmatrix} \quad (3.26)$$

如果要衡量变量在 3D 空间中的拓扑关系，就要采用三维的张量标签形式，具体的表现形式，在本文中就不进行研究。

3.3.3 一维空间定位评价

一阶张量标签是利用向量数据结构的形式表达数据样本当前的信息。在故障定位中，利用特征选择算法可以得到一个特征变量的子集，这个子集也就是最能反映故障位置的信息。由于工业系统具有非常多的样本，这就需要解决的问题是特征在特征空间里的排序，根据第六章的特征排序算法，将系统级变量排列在前面，这样可以得到的子集就会以系统级变量居多。




图 3-10 变量的一维排列

Fig 3-10 One dimensional arrangement of variables




图 3-11 一维空间定位的矩阵型输出

Fig 3-11 Matrix output for 1-D fault location

变量空间（图 3-10）在时间维度的扩张就得到了一维空间的矩阵型输出（图 3-11）一维

空间定位评价体系中， H_{l1} 矩阵是实际的故障发生位置矩阵，其中下标 l 表示定位 (location)，1 表示一维定位； D_{l1} 矩阵是定位系统判断的故障位置信息矩阵，也就是向量标签流，定量化的评价这两个矩阵得到一维变量定位评价体系的度量 $F1_{l1}$ 。

$$\text{Pre}_{l1} = \frac{\text{comp}(D_{l1}, H_{l1})}{\|D_{l1}\|_0} = \frac{\|(H_{l1} \& D_{l1})\|_0}{\|D_{l1}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ij})^2} \quad (3.27)$$

$$\text{Rec}_{l1} = \frac{\text{comp}(D_{l1}, H_{l1})}{\|H_{l1}\|_0} = \frac{\|(H_{l1} \& D_{l1})\|_0}{\|H_{l1}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ij})^2} \quad (3.28)$$

$$F1_{l1} = \frac{2 \cdot \text{Pre}_{l1} \cdot \text{Rec}_{l1}}{\text{Pre}_{l1} + \text{Rec}_{l1}} \quad (3.29)$$

3.3.4 二维空间定位评价

上节中按照一维的方式进行了变量的排列，但是变量在系统的分布本来就呈现一定的空间特性，本节解决的问题是：将系统的变量分布在 2-D 的空间中，这样变量的位置信息就得到了保持，然后根据特征选择算法找到最佳的特征子集，最后按照空间的位置来进行矩阵结构的排列。这种方式的好处就是，系统变量的空间位置信息可以保留，空间矩阵标签沿着时间维度的拓展，就形成了二维定位信息张量 H_{l2} 和检测位置张量 D_{l2} 。




图 3-12 二维空间定位与张量型输出

Fig 3-12 2-D fault location and tensor output

图 3-12 定位的向量标签，每一个变量都位于其中的一个点，但这个点的值为 0 表示这个

变量正常，1 表示这个变量发生了异常。向量标签在时间维度的拓展也就是向量标签流，得到定位信息三阶张量 H_{l2} 和检测位置三阶张量 D_{l2} ，定量的评价 H_{l2} 和 D_{l2} 就得到了二维空间定位的评价 $F1_{l2}$ 。

$$\text{Pre}_{l2} = \frac{\text{comp}(D_{l2}, H_{l2})}{\|D_{l2}\|_0} = \frac{\|(H_{l2} \& D_{l2})\|_0}{\|D_{l2}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ijk})^2} \quad (3.30)$$

$$\text{Rec}_{l2} = \frac{\text{comp}(D_{l2}, H_{l2})}{\|H_{l2}\|_0} = \frac{\|(H_{l2} \& D_{l2})\|_0}{\|H_{l2}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ijk})^2} \quad (3.31)$$

$$F1_{l2} = \frac{2 \cdot \text{Pre}_{l2} \cdot \text{Rec}_{l2}}{\text{Pre}_{l2} + \text{Rec}_{l2}} \quad (3.32)$$

3.4 基于张量标签的故障识别与定位信息融合

在传统的研究中，工业系统的故障识别与定位是两个独立的问题，二者并行的进行了处理。在本节中，我们采用张量标签学习的方式，将这两个独立的诊断信息统一到一个评价体系中。故障的识别、定位来自于不同故障处理系统的多源信息，这些信息从不同的侧面都会反映故障对工业系统的威胁程度，需要对这些信息进行关联、相关以及综合，从而对故障的进行全面及时的综合评价，进而完成所需的决策和容错任务。为实现故障的识别、定位异构信息统一表示与信息融合，本节采用张量化标签的方式，将故障类型与定位的异构信息表示在同一个高维标签里。

3.4.1 识别与定位关联矩阵

为了将识别与定位统一的度量，本研究定义识别与定位关联矩阵 DL ，如下：

$$DL = \begin{pmatrix} dl_{1nv} & \cdots & dl_{nv\ nc} \\ \vdots & \ddots & \vdots \\ dl_{11} & \cdots & dl_{1\ nc} \end{pmatrix} \quad (3.33)$$

在矩阵中 nc 表示的是并发故障类型的个数， nv 表示的是变量的数量，关联矩阵的元素为 $\{0,1\}$ ，在故障识别与定位的二维维度 $dl_{ij}=1$ 表示 j 类型的故障发生，发生在第 i 个变量的位置。这样，矩阵的坐标信息也就同时包含了故障的类型与位置信息。

例如：

$$DL = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

假设系统有 3 种故障类型，有 4 个系统变量。 DL 矩阵表示工业系统发生了第 2 故障和第 3 类故障的并发情况，其中第 2 类故障是有第 1 个和第 2 个变量的异常造成的，第 3 类故障是由第 2 个和第 3 个变量异常造成的。

3.4.2 故障识别与定位张量融合与评价

在故障识别与一维空间定位的评级体系中， DL 是矩阵的形式，也就是当前系统的状态标签。每个采样时刻，系统都会有故障类型信息和故障位置信息，如果这些信息不加以整理，就属于异构的信息。采用 DL 关联矩阵的方式可以将异构的信息统一到一个矩阵或者是高维的向量中。在一维的定位与识别关联的信息处理里，标签是 2-阶张量也就是矩阵，如图 3-13 坐标维度分别为故障类型（Fault class）与系统变量（Variables），每个采样时刻都会有一个矩阵标签的输出，那么沿时间维度的拓展就是一个 3-阶的张量，也就是矩阵标签流，如图 3-13。




图 3-13 2-阶张量标签与学习器输出时间序列

Fig 3-13 2-order tensor label and learner output

评价系统故障识别与一维定位的实际发生张量 H_{dl1} 与故障识别与一维定位的检测张量 D_{dl1} 的关系，就定性的评价了故障的类型与定位。利用如下公式：

$$\text{Pre}_{dl1} = \frac{\text{comp}(D_{dl1}, H_{dl1})}{\|D_{dl1}\|_0} = \frac{\|(H_{dl1} \& D_{dl1})\|_0}{\|D_{dl1}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ijk})^2} \quad (3.34)$$

$$\text{Rec}_{dl1} = \frac{\text{comp}(D_{dl1}, H_{dl1})}{\|H_{dl1}\|_0} = \frac{\|(H_{dl1} \& D_{dl1})\|_0}{\|H_{dl1}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} [1 - (h_{ijk} - d_{ijk})^2] \cdot h_{ijk}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ijk})^2} \quad (3.35)$$

$$\text{F1}_{dl1} = \frac{2 \cdot \text{Pre}_{dl1} \cdot \text{Rec}_{dl1}}{\text{Pre}_{dl1} + \text{Rec}_{dl1}} \quad (3.36)$$




图 3-14 3 阶张量标签与学习器输出时间序列

Fig 3-14 3-order tensor label and learner outputs

有些应用情况需要采用二维的定位与故障识别相结合，因此定义故障识别与二维定位现实张量 H_{dl2} ，以及检测张量 D_{dl2} ，这两个 4-阶张量都是 3-阶张量流，则故障识别与二维故障定位评级如下：

$$\text{Pre}_{dl2} = \frac{\text{comp}(D_{dl2}, H_{dl2})}{\|D_{dl2}\|_0} = \frac{\|(H_{dl2} \& D_{dl2})\|_0}{\|D_{dl2}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} [1 - (h_{ijkp} - d_{ijkp})^2] \cdot h_{ijkp}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} (d_{ijkp})^2} \quad (3.37)$$

$$\text{Rec}_{dl2} = \frac{\text{comp}(D_{dl2}, H_{dl2})}{\|H_{dl2}\|_0} = \frac{\|(H_{dl2} \& D_{dl2})\|_0}{\|H_{dl2}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} [1 - (h_{ijkp} - d_{ijkp})^2] \cdot h_{ijkp}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} (h_{ijkp})^2} \quad (3.38)$$

$$\text{F1}_{dl2} = \frac{2 \cdot \text{Pre}_{dl2} \cdot \text{Rec}_{dl2}}{\text{Pre}_{dl2} + \text{Rec}_{dl2}} \quad (3.39)$$

如果系统要退化到只分析系统的故障信息，则使用张量沿着某个方向的切片进行逻辑与计算，其中 j 是指切片的切线方向，具体的方向可以人为的指定：

$$F_j = A_j(1) \parallel A_j(2) \dots A_j(ns) \quad (3.40)$$

3.5 基于张量标签的故障识别、定位与容错控制信息融合

工业系统的控制系统一般采用解析冗余的方式进行设计，假设控制系统采用的都是传统型的 PID 控制网络，控制器中就分为两类控制环路：保证安全型和提高效率型。当系统发生故障时，往往会关闭一些提高效率型的控制环路，但要保证安全型控制回路正常工作，才能保证系统的安全运行。这时，控制系统会降低性能当安全的运行一段时间，直到生产间歇进行彻底的维修。如何评价系统控制网络的变化，就需要一个评价容错控制系统的指标。通过这个指标来定性的衡量系统控制回路的变化是本节需要解决的问题。

为了对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，对工业系统安全的威胁进行高效、精确的进行处理。对于故障诊断系统信息融合，故障的识别、定位与容错控制就是来自于不同故障处理系统的多源信息，这些信息从不同的侧面都会反映故障对工业系统和控制系统的威胁程度，需要对这些信息进行关联、相关以及综合，从而对故障的进行全面及时的综合评价，进而完成所需的决策和容错任务。采用高维张量标签来对故障的识别、定位、容错控制的异构信息统一表示与信息融合，将故障的源头、位置、类型以及对控制系统的影响统一量化度量，更完整的理解和处理故障的状态。

3.5.1 容错控制定量评价

工业系统的控制采用控制变量与操作变量的配对的形式，定义一个控制有向拓扑矩阵 C ：

$$C = \begin{pmatrix} c_{11} & \cdots & c_{1ncv} \\ \vdots & \ddots & \vdots \\ c_{ncv1} & \cdots & c_{ncvncv} \end{pmatrix} \quad (3.41)$$

变量 i 与变量 j 之间存在一个控制回路，则 $c_{ij}=1$ ，表示变量 i 作为操作变量来控制 j 。本式中的变量仅为参与控制的变量个数，也就是控制系统的输入输出变量的总和，不衡量全部的变量，而且，假设控制系统全部采用传统的 PID 控制器。主动容错控制的控制律在线重构会改变控制器的结构，关闭一些回路，仅保留系统安全回路。

$$C3 = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

例如，矩阵 $C3$ 表示，有三个变量，其中，第一个变量作为操作变量来控制第二个变量，也就是这两个变量构成一个控制闭环。

定义一个负荷矩阵：

$$S = \begin{pmatrix} S_{11} & \cdots & S_{1nv} \\ \vdots & \ddots & \vdots \\ S_{nv1} & \cdots & S_{nv nv} \end{pmatrix} \quad (3.42)$$

控制关联矩阵表现的是控制变量之间的控制关联，负荷矩阵表示的是控制器的参数矩阵，

其中， $S_{ij} = (s^{-1}, 1, s) \cdot x_i \cdot P_{ij}$ 表示的是一个 PID 型的控制变量，表示的是积分，比例和积分三个环节的系数对 x_j 的控制作用， P_{ij} 表示的是积分、比例、微分环节的系数。控制系统的参数矩阵 K ：

$$K = C \cdot S \quad (3.43)$$

S_{ij} 作为一个整体与 C 各元素相乘。根据容错控制的原理，控制系统不会发生本质的变换，当故障发生的时候，容错控制系统会关掉一部分非重要的回路，并适当的调整控制器的参数，从而使工业系统降低性能和效率但仍然能够安全的运行。定义 H_c 为正常系统的控制关联矩阵， D_c 为故障发生之后经过容错机制之后的控制关联矩阵，则可以定量的评价控制系统的变化程度。控制系统的改变程度，可以用实际控制有向拓扑矩阵流 H_c 和控制律重构后的有向拓扑矩阵流 D_c 的关系来计算。计算方式采用向量标签学习的计算方式：

$$\text{Pre}_c = \frac{\text{comp}(D_c, H_c)}{\|D_c\|_0} = \frac{\|(H_c \& D_c)\|_0}{\|D_c\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ij})^2} \quad (3.44)$$

$$\text{Rec}_c = \frac{\text{comp}(D_c, H_c)}{\|H_c\|_0} = \frac{\|(H_c \& D_c)\|_0}{\|H_c\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ij})^2} \quad (3.45)$$

$$\text{Fl}_c = \frac{2 \cdot \text{Pre}_c \cdot \text{Rec}_c}{\text{Pre}_c + \text{Rec}_c} \quad (3.46)$$

3.5.2 故障识别、定位与容错控制信息融合与评价

为了统一故障识别、定位与容错控制的度量，本节将上节所述的故障识别与定位，以及容错控制度量统一到一个张量标签学习的框架中，来统一定量化度量故障的识别、定位和容错控制的问题。

故障类型向量：

$$D = (d_{11} \cdots d_{1nc}) \quad (3.47)$$

为了简单起见，采用一维故障评价指标标签，故障位置向量：

$$L = (L_{11} \cdots L_{1nv}) \quad (3.48)$$

控制关联矩阵:

$$C = \begin{pmatrix} c_{11} & \cdots & c_{1nv} \\ \vdots & \ddots & \vdots \\ c_{nv1} & \cdots & c_{nv nv} \end{pmatrix} \quad (3.49)$$




图 3-15 四阶张量标签

Fig 3-15 4-order tensor label

将上述三类标签写入同一个四维张量中, 排列的顺序可以根据需求定义, 得到当前的故障信息标签如图 3-15。

四阶张量标签沿着时间维度拓展, 就得到了输出的五阶张量, 则故障识别、定位与容错控制的检测张量流定义为 D_{dlc} , 故障识别定位与容错控制实际标签张量流为 H_{dlc} 。




图 3-16 5 阶张量时间序列

Fig 3-16 5-order tensor outputs

$$\text{Pre}_{dlc} = \frac{\text{comp}(D_{dlc}, H_{dlc})}{\|D_{dlc}\|_0} = \frac{\|(H_{dlc} \& D_{dlc})\|_0}{\|D_{dlc}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} \sum_{q=1}^{nm} [1 - (h_{ijkpq} - d_{ijkpq})^2] \cdot h_{ijkpq}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} \sum_{q=1}^{nm} (d_{ijkpq})^2} \quad (3.50)$$

$$\text{Rec}_{dlc} = \frac{\text{comp}(D_{dlc}, H_{dlc})}{\|H_{dlc}\|_0} = \frac{\|(H_{dlc} \& D_{dlc})\|_0}{\|H_{dlc}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} \sum_{q=1}^{nm} [1 - (h_{ijkpq} - d_{ijkpq})^2] \cdot h_{ijkpq}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} \sum_{k=1}^{nv} \sum_{p=1}^{nw} \sum_{q=1}^{nm} (h_{ijkpq})^2} \quad (3.51)$$

$$\text{F1}_{dlc} = \frac{2 \cdot \text{Pre}_{dlc} \cdot \text{Rec}_{dlc}}{\text{Pre}_{dlc} + \text{Rec}_{dlc}} \quad (3.52)$$

本指标同时评价的是，故障的类型检测精度、故障的位置定位精度以及当前控制系统的变化程度，从而更全面的反映了工业系统故障诊断的精度。但很多时候，并不需要同时评价这三个指标，如果要减少结构化信息的维度，只需沿着要减少的维度方向，对张量的切片采用逻辑或计算。

如果系统要退化到只分析系统的故障信息，则使用张量的方向与计算：

$$F_j = A_j(1) \parallel A_j(2) \dots A_j(ns) \quad (3.53)$$

3.6 本章小结

本章提出了张量标签学习框架，本章要解决的问题：将利用张量标签度量将故障识别、定位与控制统一到一个评级体系中。为了实现对识别、定位与控制问题存在的异构信息数据的统一表示统一评价的问题，利用 1-阶和 2-阶张量标签表述工业系统的一维和二维空间故障定位，并提出了一种量化故障定位评价标准。利用 2-阶张量标签将故障定位与故障识别统一到一个评价体系中，定位与识别的信息通过高维的张量形式进行表述，并利用张量评价标准得到识别与定位的综合评价标准。利用工业系统控制系统的控制拓扑关系，建立起容错控制的评价标准，提出了控制系统维持率来评价故障状态下容错控制重构的程度。并利用 4-阶张量标签学习将故障识别、定位与容错控制统一到一个评价体系中。利用综合评价指标来评价本研究提出的故障诊断系统对故障的处理能力。本章建立一套完整的故障诊断信息数据统一表示和评价体系，利用高维的张量信息数据对工业系统当前的模式状态进行充分、全面的描述。将故障的识别、定位与容错控制的异构信息进行信息融合，对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，对工业系统安全的威胁进行高效、精确的进行处理。

第 4 章 基于张量标签学习的海量标签样本并发故障识别

4.1 引言

工业过程运行中，难免会出现多种类型的故障，当几个类型的故障同时发生的时候称为并发故障（Simultaneous fault）。并发故障是故障的通用形式，单故障是并发故障的一种特例。本章研究在一些工业系统中，并发故障带标签样本非常丰富的情况，也就是海量带标签样本的情况。

并发故障是多种独立故障（Independent fault）的集合，但与每个独立故障都不同，因为工业系统是一个整体，单故障模式会融合到一起，产生新的模式和新的现象，而且这些故障会相互作用、相互影响，这就给故障的识别造成了极大的难度。数据驱动的并发故障诊断是基于观察到的模式或数据，用于检测同时发生的多个独立故障^[103]。为了使机器学习算法能够处理工业系统的并发故障识别，需要克服两个挑战。第一，单故障的模式混合到一起组合出并发故障的模式，这些模式不仅是模式的加权而是会产生新的数据模型，从混合的模式里识别出模式的组合具有极高的难度。第二，由于单个故障的组合次数较多，因此获取大量并发故障的样本数据集成本很高，从而产生了许多可能的并发故障训练模式，并发故障的类型呈指数型增长。如果存在 10 个单一故障，则同步故障类将变为 1024 级，无法通过机器学习进行加标签训练。这种问题在本研究中被称作“并发故障类型灾难”^[104-107]。为目标域建立一个基于学习的模型几乎是不可能的，因为目标域的标记数据很少，难以用于监督学习。因此，将传统的机器学习方法应用于并发故障诊断是受到限制的。

传统的监督分类算法中，每个样本只拥有一个标签，并且不同的标签之间是相互排斥的，然而在实际应用中，每一个样本往往同时包含多个标签，且这多个不同标签之间是相互重叠相互关联的，多标签分类算法的研究过程中，通常遇到以下几种类型的挑战，包括：(1) 当标签空间稀疏时，如何利用标签之间的关联性提高分类算法的性能；(2) 当面临数据维度过高过大时，如何构建有效的学习算法；(3) 在学习的过程中，如何解决样本不平衡问题，即拥有不同标签类别的样本数量相差过大的问题^[108, 109]。为解决上述问题，本章主要完成以下工作：

（1）分析并发故障识别的难点，将并发故障利用向量化标签进行描述。

（2）利用 1-阶张量标签学习的方法，将向量化描述的并发故障利用向量标签学习进行识别。并通过 F1 准则，衡量并发故障识别的检测率和误报率。

（3）改进了 SVM 算法，将 SVM 算法变为并行分类算法，每个二分类的输出是向量化标签编码的一个数字位。

本方法的优势在于：

- (1) 采用 n 维二进制向量编码标签就可以表示 2^n 类的并发故障类型，极大的缓解了并发故障类型数量灾难的问题。
- (2) 仅采用独立的 n 类单故障的训练数据就可以预测 2^n 类并发故障的类型。
- (3) 并行的 SVM 算法可以极大的提高运行效率和速度，而且如果有新的独立故障加入到并发故障中，不需要重新训练之前的分类器，只需要增加一个新的独立故障的判别位就可以做到并发故障识别，提高并发故障识别算法的扩展性。

4.2 故障的模式化描述

在现代流程工业系统中，大都安装了许多性能优越的仪器仪表传感器，它们可以在线采集大量的系统状态数据并存储在计算机数据库中。如何从这些历史数据，构建系统运行状态的模型，以更好地服务系统的故障检测和诊断，是研究在线故障诊断系统的一个关键。在一些故障诊断方法中，我们可能需要对原始数据进行转换以得到比直接利用原始数据更好的结果。故障检测一直以来都是保证工业过程安全运行的重点，也是控制领域研究的热点问题。一个常规的检测过程通常包括三个阶段：数据的采集、信号的提取以及模式的识别。由于现代工业过程和控制结构的复杂性和多样性，过程干扰和环境因素的影响，可能导致工业生产过程中的大部分变量并不严格服从高斯分布；另外，工业过程的内部机理往往表现出很强的非线性特征，并且这种非线性关系很难使用线性方法处理。一些分类方法，特别是那些采用点间距离作为判决的方法，可能需要对数据进行标准化以获得最佳结果。所谓数据的标准化就是将测量值按比例对应到一个特定的范围，如 $[-1, 1]$ 或 $[0, 1]$ 。如果测量值没有标准化，距离测量将会超出平均起来数值更大的那些特征。

工业系统的变量数据构成矩阵 $X_{n \times nv}$ ，其中， ns 是样本数目（采样时间为 t_s ）， nv 是过程变量或特征的数目。过程数据矩阵的特征是根据过程的条件来描述的，表示为 X_f ，其中 f 待诊断的故障类型。 X_0 表示在正常情况下的过程数据。

$$X_f = \begin{pmatrix} x_{11} & \cdots & x_{1nv} \\ \vdots & \ddots & \vdots \\ x_{ns1} & \cdots & x_{ns\ nv} \end{pmatrix} \quad (4.1)$$

另外，训练集 R 和测试集 E 将由划分所得。矩阵 R 和 E 各自是由完整数据集 X_f 中的某几段连续样本构成，所以它们的交集为空集，即没有一个样本会同时属于训练集和数据集。为了包含更多关于流程动力学的信息，需要扩展特征并找出能够更好地描述每个过程状态的统计属性。这些扩展的特征将会被添加到每个过程样本的属性中。由此得到的新数据集的特征数目多于原始数据集 X_f ，但样本数不变。

输出：

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_{ns} \end{pmatrix} \quad (4.2)$$

对于工业系统的故障，我们采用监督学习的方法，对不同的故障加不同的标签。以燃料电池系统故障位置如图 2-7，故障编号如表 4-1。

表 4-1 SOFC 系统故障案例

Table 4-1 SOFC system fault cases

故障编号	故障描述
故障 0	正常状态
故障 1	风机与分离器之间的空气连接
故障 2	风机与分离器之间的空气连接
故障 3	分离器和混合器之间的空气连接
故障 4	热交换器和混合器之间的空气连接
故障 5	混合器电堆之间的空气连接
故障 6	电堆与燃烧器之间的空气连接
故障 7	燃烧器和热交换器之间的空气连接
故障 8	燃料供应系统与热交换器之间的燃料连接
故障 9	热交换器和电堆之间的燃料连接
故障 10	电堆与燃烧器之间的燃料连接

4.3 向量标签与标量标签编码方式对比

表 4-2 标量标签与向量标签对比

Table 4-2 Comparison between SL and ML

Framework	Training dataset	Strategy	Classification	Number of classifiers (k classes)	Training time
SL	Single and simultaneous	One-vs-all	Binary	2^k	Long
ML	Single	One-vs-all	Binary	k	Short




图 4-1 标量标签学习与向量标签学习比较

Fig 4-1 Comparison between scalar label learning and vector label learning

标量标签输出:

$$Y_{\text{scalar}} = \begin{pmatrix} y_1 \\ \vdots \\ y_{ns} \end{pmatrix} \quad (4.3)$$

向量标签输出:

$$Y_{\text{vector}} = \begin{pmatrix} y_{11} & \cdots & y_{1nc} \\ \vdots & \ddots & \vdots \\ y_{ns1} & \cdots & y_{nsnc} \end{pmatrix} \quad (4.4)$$

传统的监督学习是机器学习的主要研究模式之一，其中，每个真实世界的对象（示例）都由一个实例（特征向量）表示，并与单一标签相关联系。形式上，设 X 表示实例空间， Y 表示实例空间的标签空间，传统监督学习的任务是学习函数 $f: x \rightarrow Y$ ，训练集 $\{(x_i, y_i) \mid 1 \leq i \leq m\}$ 。在这里， $x_i \in X$ 是一个描述对象的属性（特征）和 $y_i \in Y$ 是表示其特征的相应标签语义学。因此，传统的监督学习所采用的一个基本假设是：每个示例只属于一个概念，即具有独特的语义意义。传统的监督学习虽然盛行并取得了成功，但也有很多种学习方式。上述简化假设不适合的任务，因为现实中的对象可能是这样的。复杂而又具有多个语义的同时。举几个例子，在文本分类中，一份新闻报道可以报道体育、伦敦奥运会、门票等几个主题。销售和火炬传递；在音乐信息检索中，一首交响曲可以传达各种不同的信息。如钢琴、古典音乐、莫扎特和奥地利等信息；在自动视频注释中，一个视频片段可以与一些场景相关，如城市和建筑，等等。如表 4-1 和图 4-1，采用标量标签（SL）与向量标签（ML）的分类模式，ML 分类可以极大的减少分类器的个数，因为 ML 的编码格式采用二进制的方式，仅采用 k 位二进制标签就可以表示 2^k 的类别信息。

传统监督分类里的二元分类是将特征空间 X 映射到只有两种标签的标签空间中 Y ，即寻找一个映射函数 $Y = f(X)$ 或者 $X \rightarrow Y$ 。多标签分类是将二元分类泛化而来，多标签数据是一种可以同时拥有多个标签的数据，而且标签之间具有一定关联性。给定标签空间中标签种类也要多于两种，多标签分类的目的是预测哪几种标签出现并将预测结果保存在标签空间中。因此，映射函数 $Y = f(X)$ 可表示为 $X \rightarrow 2^Y$ 。实际上，我们常常用固定长度的实数向量表示特征，故多标签分类映射 f 也可表示为 $R^D \rightarrow 2^Y$ ，其中 R^D 表示 D 维的特征空间。

事实上， 2^Y 可由二元向量表征。假设有三个标签，则任意一个多标签分类结果都可以用三维二元向量 $y = \{y^{(1)}, y^{(2)}, y^{(3)}, \dots, y^{(L)}\}^T \in \{0, 1\}^L$ ，其中， $y^{(i)}=1$ 表示第 i 个标签出现， $y^{(i)}=0$ 表示第 i 个标签不出现。因而，多标签分类映射函数也可表示为 $f: R^D \rightarrow \{0, 1\}^L$ 。给定包含 N 个实例的多标签训练集 $D = \{(x^i, y^i)\}^N$ ，其中，实例。该实例对应的标签 $y \in \{0, 1\}^L$ ，那么多标签分类的目的就是利用多标签映射函数预测未知实例的标签。与传统的二元分类不同，针对某具体实例，多标签分类同时输出多个标签。解释一个真实世界的对象可能具有的多个语义，直接解决方案是将一组适当的标签分配给对象，以显式地表示其语义。经过上述考虑，多标签学习的范式自然出现了。与传统的监督学习相比，在多标记学习中，每个对象也被表示。在与一组标签而不是单个标签相关联时，由单个实例执行。任务是学习一个函数，它可以预测未见实例的适当标签集。

4.4 并发故障的 1-阶张量标签描述

在工业过程中往往可能出现多种故障，但这些故障可能并发的出现。也就是同时出现多个故障。用 1 阶张量标签数学语言把并发故障进行完整的描述就是首先需要解决的问题。

首先，定义一个故障发生矩阵 H 来描述系统的故障发生情况。过程数据的特征在于可能正在发生（或未发生）并且可能正在被诊断（或未被发现）的给定的一组故障 f 。因此，可以使用二进制矩阵 H 来指示在每个采样时间发生哪个故障，并且可以使用另一个二进制故障识别矩阵 D 来指示每个采样时间的诊断。更具体地说，故障发生矩阵由下式给出：

$$H_{sd} = \begin{pmatrix} h_{11} & \cdots & h_{1nf} \\ \vdots & \ddots & \vdots \\ h_{ns1} & \cdots & h_{nsnf} \end{pmatrix} \quad (4.5)$$

$$h_{ij} = \{0, 1\}, \quad \forall i = 1, 2, \dots, nf, \quad \forall j = 1, 2, \dots, ns$$

故障识别矩阵：

$$D_{sd} = \begin{pmatrix} d_{11} & \cdots & d_{1nf} \\ \vdots & \ddots & \vdots \\ d_{ns1} & \cdots & d_{nsnf} \end{pmatrix} \quad (4.6)$$

$$d_{ij} = \{0,1\}, \quad \forall i=1,2,\dots,nf, \quad \forall j=1,2,\dots,ns$$

从上述公式可以得到, $\sum_{i=1}^{nf} h_{si} = 0$ 表示 s 采样时刻系统的状态为正常; 另一方面, $\sum_{i=1}^{nf} h_{si} = 1$ 表示在 s 采样时刻系统只发生一个故障; 当 $\sum_{i=1}^{nf} h_{si} > 1$ 时, 表示系统发生并发故障, 也就是同时发生多个故障。在参考文献^[104-109]中, 这种故障类型采用多标签的策略来进行处理。单故障的情况 ($\sum_{i=1}^{nf} h_{si} \leq 1$) 下, 检测矩阵的位置表示系统发生的故障类型, 多故障的情况下 ($\sum_{i=1}^{nf} h_{si} > 1$), 多标签技术不仅表现在故障的发生的类型, 也表示系统发生的组成信息。 $h_{ij}=1$ 表示故障发生在 j 位和 i 采样周期内。

4.5 1-阶张量标签 PCA- SVM 算法




图 4-2 向量标签多分类算法

Fig 4-2 ML learning classification

4.5.1 主元分析维数压缩

本节介绍主成分分析法 (Principal component analysis, PCA)。PCA 是特征提取的降维技术, 它可以通过奇异值分解或特征值分解方法使相关变量不相关, 并且沿着方差最大的方向进行投影。主成分分析可以从多变量向量中提取要的主因子, 从而实现采用主要的元素就能够重构整个数据集的目的。主成分分析的主要作用是降低了数据集的维数, 同时尽可能保留尽量多的数据集的成分。通过将高维数据转化为低维数据, 会极大的降低后续计算的负担。

图 4-2 所示为 PCA 主成分分析法的示意图。主要采用 PCA 将工业系统工作状态数据矩阵 X 进行降维处理, 具体算法为:

- 1) 数据标准化处理。多信息采集模块采集到本周期的工业系统工作状态:
将 m 个周期的状态写成状态矩阵形式 X_f 。将 X_f 进行归一化处理得到:

$$X = \frac{X_f - \bar{X}}{\sigma} \quad (4.7)$$

其中 $\bar{X}$ 代表 X_m 的均值均值, σ 代表 X_m 的标准差。




图 4-3 主元分析

Fig 4-3 Principle component analysis

2) 奇异值分解

利用数据的协方差矩阵进行奇异值分解:

$$S = \frac{1}{n-1} X^T X = U \Lambda U^T \quad (4.8)$$

其中,

$$\Lambda = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \quad (4.9)$$

3) 取主元元素。

取 Λ 的前 k 个主元作为分析元素。并取对应的前 k 个 U 矩阵的向量:

$$P = (u_1, u_2 \dots u_k) \quad (4.10)$$

4) 得到 X 的降维形式

$$\hat{X} = TP^T \quad (4.11)$$

其中

$$T = XP \quad (4.12)$$

在本研究中, 由于传感器和控制器的相关数据, 采用主成分分析 (PCA) 方法提取 SOFC

丰富的数据中的特征。它可以避免大的数值支配小的属性值，将属性值缩小到一个小的范围内，避免了维数的灾难，减少了计算的工作量。在生产线上，直接从传感器获取的数据特征会导致模式重叠。为了减少冗余信息，采用 PCA 进行在线的特征提取。它被用来降低数据维数，并将相关变量转化为独立变量。在线 PCA 算法如下：

表 4-3 主元分析降维算法

Table 4-3 Principle component analysis

Input: Train data set $R = \{x_1, x_2, \dots, x_m\}^T$
Low dimensional space dimension: N
Normalizing: For each variable $\bar{x}_i = x_i - \frac{1}{n} \sum_{i=1}^n x_i$
End for
$X = \{\bar{x}_1, \bar{x}_2, \dots, \bar{x}_m\}^T$
Covariance matrix: $C_x = XX^T$
Eigenvalue decomposition:
$C_x = W^T \Lambda W, \Lambda = \text{diag}[\lambda_1, \dots, \lambda_n]$
Principle analysis:
Selecting top N largest λ
and the corresponding eigenvector $w_1, w_2 \dots w_N$
Output: projection matrix: $W_p = (w_1, w_2 \dots w_N)$

4.5.2 1-阶标签并行 SVM 分类算法

支持向量机 (SVM) 是统计机器学习的一种分类方法。该方法建立在统计学习理论的 VC 维理论和结构风险最小化原则 (最小化实际风险) 的基础上。SVM 在处理小样本、非线性和高维问题方面有许多明显的优点，使其成为一种适合工业领域应用的机器学习算法。SVM 通常用于处理分类问题、回归问题和其他学习任务^[110-113]。

分类原理

考虑到训练样本的分类问题，假设训练集 $(x_1; y_1), \dots, (x_q; y_q)$ ， x_i 是输入的第 i 个样本， y_i 是对应第 i 个输入样本的输出标签。SVM 需要优化的函数：

$$\min_{w, d, \zeta} \frac{1}{2} w^T w + C \sum_{i=1}^q \zeta_i \quad (4.13)$$

$$\begin{aligned} \text{s.t. } & y_i(w^T \Phi(x_i) + d) \geq 1 - \zeta_i \\ & \zeta_i \geq 0, \quad i = 1, \dots, q \end{aligned} \quad (4.14)$$

其中, w 是 q 维向量, C 是惩罚参数, ζ_i 是对被分类点和超平面之间的距离度量, $\Phi(x_i)$ 将原始数据 x_i 投影到更高维空间, d 是一个标量。

核方法

SVM 最初用于处理线性分类的情况, 但是并非所有的分类问题都是线性可分。在遇到非线性情况, 这种线性分类器可能就表现很差。因此, 引入了一种核方法来使用线性分类器处理非线性问题。基于模式识别理论, 低维空间线性不可分的数据模式可通过非线性的核函数映射到高维特征空间可以线性可分。如果我们直接使用这种技术在高维空间进行分类或回归, 将很难确定非线性映射函数的形式、参数及高维特征维数。使用核方法就可以有效解决低维空间线性不可分的问题。以下是几种常用的核函数:

1) 线性核

$$k(x_i, x_j) = x_i^T x_j \quad (4.15)$$

2) 多项式核

$$k(x_i, x_j) = (x_i^T x_j)^d \quad (4.16)$$

3) 径向核函数(RBF)

$$k(x_i, x_j) = \exp(-\|x_i - x_j\|^2 / \delta^2) \quad (4.17)$$

其中, d 是多项式的阶数, δ 是 RBF 核窗口的宽度。

由于工业系统数据的非线性特点, 本文选择 RBF 核函数。大多数情况 RBF 都是一个具有非常好的预测效果, 理由如下:

(1) RBF 把样本用非线性的方式映射到高维, 因此它可以处理类标签与属性之间是非线性关系的情况;

(2) RBF 核影响模型复杂度的超参数个数较少。

本下节的 1-阶张量标签的并行分类方法采用多分类参数调整型支持向量机来实现并发故障的识别。本节提出了并发分类问题, 并介绍了评价并发故障识别性能的一般性指标 F1。工业系统的过程数据的特征是矩阵 X , n_f 是可能发生和诊断的故障类别数量。每个样本的故障发生和诊断可以用两个不同的矩阵 (分别为 H 和 D) 来描述, 其中包含列中的样本和列中可能发生的故障^[12, 114, 115]。

1-阶张量标签并行分类 SVM 算法

SVM 算法最初是用来解决模式的二分类问题, 在处理多分类问题时, 需要构造一个合适

的多分类器。目前，主要有两种构造多分类 SVM 的方法：一种是直接构造法（直接修改目标函数，将多个分类面的参数求解问题转化为一个优化问题，然后通过求解这个优化问题来实现多分类）；另一种是间接构造法（它主要是通过结合多个二元分类器来实现多分类）。采用间接构造法，方便多分类器的扩展而且计算代价远小于直接构造法。一对一法和一对多法是两种最常用的间接构造方法。下面对这两种间接构造方法进行简要介绍。

（1）一对多法 (1-v-r)：在训练时，我们将一个类别样本归为一类，其余样本归为另一类。因此对 k 类样本需要构造 k 个 SVM。在分类时，我将未知样本分类为具有最大分类函数值的类别。

（2）一对一法 (1-v-1)：该方法是在任意两类样本之间构造一个分类器。因此对 k 类样本需要构造 $k(k-1)/2$ 个 SVM。在对未知样本进行分类时，需要计算多个分类函数，最后把得票最多的类别作为未知样本的类别。

表 4-4 故障类型与标签编码

Table 4-4 Fault type and label encoding

Simultaneous fault	SL	Single fault	ML
Normal data	0	Normal	[0 0 0]
Single fault 1 data	1	Single fault 1 data	[1 0 0]
Single fault 2 data	2	Single fault 2 data	[0 1 0]
Single fault 3 data	3	Single fault 3 data	[0 0 1]
Simultaneous fault 1, 2 data	4	-	[1 1 0]
Simultaneous fault 2, 3 data	5	-	[0 1 1]
Simultaneous fault 1, 3 data	6	-	[1 0 1]
Simultaneous fault 1, 2, 3 data	7	-	[1 1 1]

SL 和 ML 标记的编码方式如表 4-4 所示。假设存在三个独立的故障及其对应的并发故障。对于 SL 方法，单个故障可以标记为 1、2、3。并发故障(1, 2), (1, 3), (2, 3), (1, 2, 3)可分别标记为 4, 5, 6, 7。这样，训练数据集的数目应该是 2^k ，如果 n 很大，就不可能进行完整的训练编码的。而对于 ML 方法，单个故障标签是[1 0 0], [0 1 0], [0 0 1]，而并发故障编码方式为同样位数的编码[1 1 0], [1 0 1], [0 1 1], [1 1 1]。由于采用了统一的标签编码格式，当训练集仅采用单故障类型，学习器可以学到单故障的本质特征，当这个类型的故障与其他故障类型并发出现时，学习器的泛化能力也能够从中识别出这个类型的故障，并在这个故障的位置编码处置 1。因此，训练数据集只要求单个故障条件，并发故障状态可以用独立故障组合来描述。如图 4-4 所示，按照上面的编码方式，将每一类都按照 1-v-r 进行独立的设计，然后按照二进制编码的方式输出。从而实现了并行的 1-阶张量标签并行 SVM 算法。




图 4-4 1-阶张量标签并行 SVM 算法

Fig 4-4 1-order tensor label parallel

并发故障识别的算法如表 4-5。

表 4-5 1-阶张量标签学习故障识别算法

Table 4-5 Fault identification algorithm

Algorithm 4.1	Inputs: Training data set: $R = \{x_1, x_2, \dots, x_m\}^T$,
	1-order Tensor Label $Y_R = \{y_1, y_2, \dots, y_m\}^T$
	Testing data set: $E = \{t_1, t_2, \dots, t_m\}^T$
	Low dimensional space dimension: N
	PCA Normalizing:
	For each variable $\bar{x}_i = x_i - \frac{1}{n} \sum_{i=1}^n x_i$
	End for
	$X = \{\bar{x}_1, \bar{x}_2, \dots, \bar{x}_m\}^T$
	Covariance matrix: $C_x = XX^T$
	Eigenvalue decomposition:
Training period	$C_x = W^T A W, A = \text{diag}[\lambda_1, \dots, \lambda_n]$
	Principle analysis:
	Selecting top N largest λ
	and the corresponding eigenvector
	$w_1, w_2, \dots, w_N$
	PCA Output:
	Projection matrix: $W_p = (w_1, w_2, \dots, w_N)$
	SVM training input: Low dimensional space:
	$R_L = W_p^T R$
	SVM Training:
Output:	Train the multi-class SVM by R_L and Y_R
	Trained multi-class SVM

Testing period	SVM testing input: Low dimensional space: $E_L = W_p^T E$
	Testing: T_L input the trained multi-class SVM
	Output: E_L corresponding classes Y_L E corresponding classes is also Y_L
	Outputs: E corresponding classes label tensor: Y_L

4.6 1-阶标签学习并发故障评价准则



图 4-5 向量标签学习流程

Fig 4-5 Process of vector label learning

本文采用机器学习领域中常用的 F1 性能指标，将诊断性能量化为单一评分。这一指数是对召回率 (Rec) 和精确度 (Prec) 的加权衡量；召回率 (也称为敏感性)反映了正确分类的正样本结果数量 (真实阳性) 与实际阳性案例总数之间的比率。准确率表示测量正确识别的正样本与预测正样本总数之间的比率^[107-109]。

当允许任何二进制值的编码时，一般的 ML 分类问题寻求匹配两个矩阵，包括正常情况下的空行 (无故障) 和包含多个非空值的行 (并发故障)。定义向量标签流 H_{sd} 和 D_{sd} 分别表示并发实际的标签流与故障识别系统预测的标签流。评价这两个矩阵的关系就得到了并发故障的识别评价表示：

$$\text{Pre}_{sd} = \frac{\text{comp}(D_{sd}, H_{sd})}{\|D_{sd}\|_0} = \frac{\|(H_{sd} \& D_{sd})\|_0}{\|D_{sd}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (d_{ij})^2} \quad (4.18)$$

$$\text{Rec}_{sd} = \frac{\text{comp}(D_{sd}, H_{sd})}{\|H_{sd}\|_0} = \frac{\|(H_{sd} \& D_{sd})\|_0}{\|H_{sd}\|_0} = \frac{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} [1 - (h_{ij} - d_{ij})^2] \cdot h_{ij}}{\sum_{i=1}^{ns} \sum_{j=1}^{n\theta} (h_{ij})^2} \quad (4.19)$$

$$\text{F1}_{sd} = \frac{2 \cdot \text{Pre}_{sd} \cdot \text{Rec}_{sd}}{\text{Pre}_{sd} + \text{Rec}_{sd}} \quad (4.20)$$

4.7 实验结果与分析

4.7.1 实验参数

本文采用的数据是基于现场采集的数据,包括正常数据(Fault 0)和部分单故障数据(Fault 1, 2, 8), 这对一个完整的并发故障识别来说并不够, 由于本文研究的 SOFC 模型具有极高的仿真精度, 因此可以利用 SOFC 模型运行一部分数据, 与真实的数据相混合, 增加数据集的科学性和合理性。数据驱动的并发故障诊断系统运行在 Python2.7 中。在数据驱动的故障分类过程中, 首先要准备两种数据集: 训练数据集和测试数据集。训练数据集要有标签, 这意味着要知道训练数据的故障类型, 然后用这些数据训练分类器。高维数据应降维为低维数据, 这对数据处理来说要快得多。由于数据是冗余的, 采用 PCA 提取的特征不会丢失其主要特征。采用低维训练方法训练多分类支持向量机(Multi-classification SVM), 然后利用训练后的 SVM 对测试数据进行故障类型分类。本章提出的多标签学习框架的参数见表 4-6。

表 4-6 实验参数

Table 4-6 The parameters of the proposed framework.

SOFC system		Parameters
Air leakage		η is 0.8
Fuel leakage		ε is 0.8
Normal Power		[0-5000] W
Normal Current		[60-75] A
Number of inputs		197 variables
Number of outputs		The fault vector of 10 dimensions
PCA		Parameters
The retained variance ratio		99.10%
Low dimensional space dimension		10
SVM		Parameters
Kernel function		RBF
Number of training data	30000*197 (10000 real data, 20000 simulation data)	
Number of testing data:	30000*197 (5000 real data, 15000 simulation data)	




图 4-6 数据样本

Fig 4-6 Data sample

为了收集足够的关于 SOFC 系统正常状态的数据，2.3.4 节进行了一些关于空气和燃料泄漏故障的说明，在这项工作中，为了覆盖所有可能的燃料和空气流量泄漏信息，随机选择故障位置并采用变工况的故障数据，也就是对于每一个漏气的位置在不同个工况下都进行数据的采集，避免了单一工况的弊端。空气和燃料入口流速分别在 $[0.05, 0.25]$ mol/s 和 $[0.02, 0.021]$ mol/s 之间随机变化。根据图 4-6，SOFC 系统的功率响应在 4000W 到 6000W 之间变化，采样时间 1s，采集得到 100000 组实验数据，这些数据后来用于数据驱动故障识别的训练和验证。其中，系统正常的数据采用现场采集的数据取代仿真数据，从 100000 个样本中选取训练集 30000 个样本，其余 70000 个样本中选取测试数据。

4.7.2 张量标签学习的并发故障识别精度

表 4-7 是 SL 和 ML 的结果对比，SL-SVM 和 ML-SVM 采用相同的训练数据集。表 4-8 显示测试数据集在不同分类器下的 F1 性能指标。在单故障诊断中，ML 和 SL 都获得了 95% 以上的高精度。结果表明，本节提出的 ML 模式识别方法在训练数据集上得到了很好地识别精度，虽然单故障识别 SL-SVM 也取得了较高的精度，但在并发故障识别时，SL 的识别泛化能力很差。SL-SVM 的训练时间和测试时间为 262s 和 180s，这样的计算速度和计算负担对实时的容错控制决策是很难满足要求的。ML-SVM 需要较少的训练数据，而且单故障识别率超过 95%，并发故障诊断准确率达 78%，平均性能 F1 指标为 85% 左右。为了增加实时决策的速率，采用 PCA 降维的方式对数据进行预处理，ML-PCA-SVM 平均性能指标 F1 精度达到 87%，降维后的数据比原始数据的识别精度更高了，这是因为 PCA 提取了 SOFC 中的数据特

征，减少了总体特征中的干扰量。综上所述，ML 分类器在并发故障识别中的泛化能力很高。

表 4-7 并发故障识别精度

Table 4-7 Accuracy for simultaneous fault identification

Classifier	Single-faults F1 (%)	Simultaneous-faults F1 (%)	Average performance F1 (%)
SL SVM	96.5	32.2	52.85
ML SVM	96.1	78.43	85.45
ML PCA+SVM	96.4	84.93	89.67

表 4-8 并发故障识别时间


Table 4-8 Processing time for for simultaneous fault identification

Classifier	Training data sets	Testing data sets	Training time (s)	Testing time (s)
SL SVM	30000*197	30000*197	262.1	189.2
ML SVM	30000*197	30000*197	111.1	140.1
ML PCA+SVM	30000*10	30000*10	0.18+19.3	26.1


对于数据的处理时间，ML-PCA-SVM 的训练和测试比 ML-SVM 更迅速，只用 19s 就能处理 80000 样本的训练数据。这非常适合用以监测 SOFC 系统在线故障识别，单个样本的识别平均时间为 0.0005s，完全可以满足实时容错控制的 FDD 的需求。

4.7.3 并发故障现象推理


本节分析漏气故障的故障现象与结果，在 SOFC 故障识别出故障类型之后，大约有 5 分钟左右的延迟故障现象才能表现出来，在这个时间差内，可以采用相应的措施减少故障危害，因此，可以根据基于数据驱动的故障识别结合现象推理提前预判故障的现象。




a. Air leakage 1, 2, 4, 5, system power and stack temperature




b. Air leakage 3, system power and stack temperature




c. Air leakage 6, 7, system power and stack temperature




d. Fuel leakage 8, 9, system power and stack temperature



e. Fuel leakage 10, system power and stack temperature



f. Fuel leakage 1 and 3, system power and stack temperature



g. Fuel leakage 2 and 3, system power and stack temperature

图 4-7 不同故障对系统功率和电堆温度的影响

Fig 4-7 Fault infections to system power and stack temperture

漏气故障是由于密封材料失效造成的，由于空气鼓风机不仅为发电提供氧气，在许多 SOFC 控制系统中，采用空气流量来控制系统的温度。因此，在发生空气漏气故障时，相当于发生了执行器故障，由于控制环路的存在，温度控制器可通过增加空气流量方式弥补这部分泄露的空气。因此，如果能提供足够的空气，空气泄露故障不会对 SOFC 系统造成太大的危害，但鼓风机的功率会增加，只会造成系统效率降低。如果空气泄漏发生在电堆前（漏气故障 1, 2, 4, 5），则系统功率将降低，而电堆温度将上升(图 4-7.a)。漏气故障 3 不同于其他故障，因为旁路管道（BP）在大多数情况下不工作，如果电堆温度不超过基准，BP 控制器是不会被触发的，所以当发生漏气故障时，系统功率和电堆温度不会发生变化(图 4-7.b)。图 4-5c 显示了漏气故障 6、7 时 SOFC 在功率和电堆温度方面的响应。空气泄漏 6 和 7 会导致进入换热器的高温废气减少。因此，电堆燃料和空气将获得足够的热量，然后进入电堆。虽然当电堆温度高于参考值时，电堆控制器可以处理干扰。电堆温度控制器无法处理预热不足的问题。因此，在一定程度上降低了系统的温度，同时也降低了系统的功率。

燃料泄漏可能导致燃料进入电堆减少，然后可能导致电堆燃料亏空和衰退。当发现燃料泄漏时，首先要估计泄漏的程度，然后再增加燃料，以避免燃料短缺造成的电堆氧化。在 SOFC 运行期间，通过提高密封能力，可以充分解决燃料泄漏故障。如果燃料泄漏达到危险临界点，则应关闭该系统，并采取一些安全措施。图 4-7.d-e 显示了燃料泄漏故障的系统响应。电堆之前的燃料泄漏（图 4-7.d）将导致系统功率下降，因为燃料供应不足。但是电堆温度可以由电堆控制器适当地处理。图 4-7.e 显示燃料泄漏 10 的响应。虽然电堆与燃烧器之间的燃料泄漏会导致燃烧器温度的一定程度的下降。如果燃烧器能提供足够的预热热量，则电堆温度仍可保持在参考值附近。

根据上述分析，可将漏气故障划分为 4 类，如表 4-9 所示。该表可用于分析单一故障和并发故障的 SOFC 故障现象预测将在下一节研究。

表 4-9 故障类型与影响分组

Table 4-9 Fault type and fault effects on power and stack temperature

Fault type	Fault classes	Stack temperature	System power
I	Air leakage 1, 2, 4, 5	↑	↓
II	Air leakage 6, 7	↓	↓
III	Fuel leakage 8, 9	→	↓
IV	Fuel leakage 10	→	→
V	Simultaneous fault 1 and 3, or Simultaneous fault 2 and 3	↑	↓ (but more than Air leakage 1, 2)

4.7.4 故障树推理




图 4-8 故障树推理

Fig 4-8 Fault diagnosis tree of the simultaneous fault

故障推理树分析法（Fault inference tree analysis, FITA）是一种推理工具，它允许通过“从下到顶”的方法将顶端的状态链接到低级别事件的组合。在故障诊断中，FITA 被广泛应用于排除故障事件的贡献程度或者故障触发的一系列现象。故障树表示顶层的事件与其所有潜在原因之间关系的图形表示。本文研究分析是以“自下而上”的方式进行，从基础的事件（故

障)开始,并研究这些底层的实际导致的故障现象。它决定了这些顶级事件是如何由单个或合并的较低级别的失败或事件引起的结果。

在这种情况下,FITA 被提出作为故障识别与现象预测的过程工具,并利用它获得的知识来理解整个 SOFC 系统中所有设备之间的相互作用。通过自下而上的方法,上述每个故障都与相应的症状相关联(总共建立了七个故障树),并定义了一个将系统级症状方便地链接到特定组件故障的故障特征。本研究的底层事件(故障类型)是由机器学习的方法获得的,然后,实时的故障识别系统判断当前的故障类型或者并发故障组合,再通过图 4-8 的故障树推理得到故障的现象,故障识别系统判断得到故障类型到这些故障症状表现出来之间,具有几分钟的时间差,在这个时间内,可以采用相应的措施减少故障症状对系统的损害。例如,检测出电堆的燃料气体泄漏,就说明系统的发电功率会下降,这时,可以提前减少功率负载,以免造成使用功率与发电功率不匹配造成的电池氧化。

FITA 在上述 SOFC 系统中的应用需要深入了解各主要部件之间的相互作用,其复杂性建议在组件级分析故障。上述与 SOFC 系统泄漏故障相关的故障及其相互作用在图 4-8 的故障树中进行了总结。在此图中,故障(顶级事件)可以由事件 I、事件 II、事件 III、事件 IV 或事件 V 引起。事件 I 是由基本事件 X1、X2、X4 或 X5 的当代发生引起的。事件 II 是由当前发生的基本事件 X6 或 X7 引起的。事件 III 是由当前发生的基本事件 X8 或 X9 引起的。事件 IV 只与一个症状 X10 相关。事件 V 不同于其他事件,它是由 X3 和 X1 或 X2 引起的,这意味着 X3 应该发生,而 X1 或 X2 应该发生。

同时出现的故障症状可以用图 4-8 所示的故障树来描述。此故障树支持从下到上的多输入推理。左边的优先级高于右边。例如,如果 X1 和 X7 同时发生,那么故障事件 I 和 II 都会被触发,但是,这两个事件中的电堆温度响应并不相同(在事件 I 时向上,在事件 II 时向下)。根据优先次序左大于右,最大的故障征兆是电堆温度降低,系统功率降低。基本故障的其他症状将通过故障树继承,并在顶层事件中运行。

4.8 本章小结

本章研究了并发故障的识别,并发故障由于是单故障模式的组合会造成模式识别困难、训练模式众多,传统的监督学习很难解决并发故障的问题。本章提出了一种 1-阶张量标签学习的并行 SVM 方法解决了并发故障的识别问题。首先分析并发故障识别的难点,将并发故障利用向量化标签进行描述,提出向量标签学习方法。将向量化描述的并发故障利用向量标签学习进行识别,为单故障与并发故障之间的关系,建立了联系。将 SVM 改进为并行是二分类 SVM 子系统的组合,每个子系统的输出是一位并发故障位,从而可以实现并发故障的识别。本方法的优势在于,采用 n 维二进制向量编码标签就可以表示 2^n 类的并发故障类型,极大的缓解了并发故障类型数量灾难的问题;仅采用独立的 n 类单故障的训练数据就可以预测 2^n 类

并发故障的类型。采用本方法，通过向量编码的方法不仅可以节约标签的标注量，而且将单故障与并发故障关系表示了出来。

第 5 章 基于迁移学习的稀疏标签样本并发故障识别

5.1 引言

本章研究并发故障缺少大量带标签训练样本的识别问题。在工业并发故障识别中，会有许多并发故障难以加入足够多的标签的情况，这样得到的训练数据集就只有少量的并发故障标签，但是单独的故障往往比较容易判断，因此会有许多带标签的单故障样本。这样的情况下，并发故障的识别会非常困难，首先，并发故障训练数据稀少，就很难通过带标签的训练集学习到并发故障的分布。第二，单故障训练集和并发故障的训练集来自不同的工况，二者的分布就不同，这也就不满足监督学习的独立同分布的基本假设^[103]。这就使采用传统的监督学习方法进行稀疏带标签样本的并发故障识别具有非常高的难度。




图 5-1 传统机器学习与迁移学习

Fig 5-1 Structure of the traditional learning and transfer learning

虽然单故障数据和并发故障数据的工况不同而且分布也不同，但并发故障与单故障之间存在相关联的关系：多个单故障的模式特征混合成一个并发故障的模式。因此，并发故障与相应的单故障之间存在一定的。受并发故障模式生成的启发，本章采用使用一种称为迁移学习（Transfer learning）的新型机器学习框架来解决上述问题。该框架的目的：是利用在海量相邻数据域中通过学习获得的知识，实现知识的迁移（Knowledge transfer），从而更快、更有效地解决新的数据域中的不同但类似的问题。监督学习中的两个基本假设可以放宽：(1)独立同分布的假设；(2) 训练样本足够的假设。目的是迁移已有的知识来解决目标领域中仅有少量有标签样本数据的学习问题^[116-120]。

传统的监督学习的训练是利用海量样本的数据域，这个具有大量数据样本的数据域被称作源域，学习机从源域中学到一定量的知识，然后，用来预测相同分布的目标域，如图 5-1，

源域和目标域本质上是同一个数据域的不同采样，所以监督学习要满足独立同分布假设。迁移学习方法用于在训练数据集（源域）上执行学习任务，然后在相关（而非相同）分布的测试数据集（目标域）上执行相同的任务。例如，当一个人学会了流利的英语时，他就能更快地说法语；或者，学会滑冰后，就能轻松地冲浪；或者，学了吉他之后，就能更好地学习物钢琴。传统的机器学习技术试图从一开始就学习每一项任务，而当目标任务拥有较少的高质量训练数据时，将学习技术从以前的一些任务迁移到目标任务。在这种情况下，迁移学习可以节省大量的目标域的有标签数据^[121-126]。

本章提出了一种向量标签-迁移学习（ML-Transfer learning），也可以叫做 1-阶张量标签-迁移学习，用于解决工业系统并发故障识别训练数据稀少的问题。特别说明，向量标签学习（1-阶张量标签学习）也就是现学术界普遍称为的多标签学习（Multi-label learning）本文为了与现阶段的研究统一，英文缩写仍然称为向量标签学习（1-阶张量学习）为 ML-learning。

1-阶张量标签-迁移学习（ML-Transfer learning）的流程：首先，源任务学习器通过大量的单故障数据进行训练，这些数据已经在单个故障条件下被收集到。然后，将源任务学习器的参数迁移到另一个领域的目标任务学习器（并发故障数据域）。在目标域中只需要少量的标记数据作为训练数据，才能获得目标任务学习器，并诱导目标预测函数。本文提出的向量标签-迁移学习是一种参数迁移方法，它假设源任务学习器和目标任务学习器在学习器模型中共享超参数，这两个领域是相互关联的。通过 ML 技术将迁移的知识编码到共享参数中。因此，知识可以通过发现共享参数来跨任务迁移。这种方法不重构学习器的结构，那么训练的速度和鲁棒性会非常高。

本章采用迁移学习策略，主要来解决目标域样本稀少，以及训练集与测试集不同分布的问题。传统的机器学习假设所有数据都必须具有相同的分布。这些算法不适用于许多实际工作条件。此外，由于基于学习的模型需要足够的标记数据来进行训练，因此不能为目标域建立一个基于学习的模型，因为该模型中可用于监督学习的标记数据非常少。本研究提出的一种多标签迁移学习框架，可以方便地利用一个领域中的可访问数据来预测模式和类，而这些模式和类是从另一个领域中不易获得的。该框架用于解决固体氧化物燃料电池系统的并发故障诊断问题。该框架主要包括：向量标签迁移学习框架和并行随机森林算法。迁移学习是利用大量的单一故障数据学习有用的特征，这些数据被充分收集，然后在同时的故障域中将参数传递给目标任务，其中只有很少的目标数据可供训练。实验结果表明，该框架能够诊断固体氧化物燃料电池系统的并发故障，具有较高的诊断精度，所需的训练数据少，计算量小。

该学习框架的主要创新之处在于：1) 本文首次提出了 ML-Transfer learning 的机器学习方法，张量标签的引入，将分布不同的两个数据域用统一的标签空间来描述，这样也就建立起这两个不同分布的联系；2) 是一种不改变机器学习器结构的参数传递方法，具有较高的学习速度和鲁棒性；3) 仅采用少量的目标域训练数据就可以达到很高的目标任务训练精度。特别适合处理很多训练数据极少的领域，只要能找到一个相邻近的数据充足的数据域；4) 不需要

数据分布假设。一个数据域的数据分布是可观存在的，所以假设这个域的分布是不合理的。本方法的训练数据和测试数据可以采集自不同分布，迁移学习是一个完全不同于监督学习的机器学习框架。

5.1.1 数据域与数据分布




图 5-2 输入与输出映射关系

Fig 5-2 Mapping relationship between input and output

定义 1: 域，表示为 $Do = \{\chi, P(X)\}$, 包括以下两个方面:

- (1) 特征空间 χ ,
- (2) 概率分布 $P(X)$, $X \in \chi$

其中，迁移学习中，从中学到知识的数据域叫源域（Source domain, Do_s ），用作预测输出的数据域叫做目标域（Target domain, Do_t ）。在监督学习中，本质上也存在源域和数据域的概念，训练集也就是源域，测试集是目标域。

5.1.2 学习任务

定义 2: 任务， $Ta = \{Y, f(\cdot)\}$, 包含以下两个要素:

- (1) 标签空间 $Y = \{y_1, \dots, y_m\}$,
- (2) 目标预测函数 $f(\cdot)$ ，无法直接观测，需要通过 $\{x_i, y_i\}$ 来学习。

预测函数 $f(\cdot)$ 根据当前的采样 x_i 来预测相应的输出标签 $f(x_i)$ 。从概率论的角度来看， $f(x_i)$ 可以写作条件分布函数 $P(y_i | x_i)$ 。特别的，源域可以写做:

$$Do_s = \{(x_{s1}, y_{s1}), \dots, (x_{sn}, y_{sn})\} \quad x_{si} \in \chi_s \quad (5.1)$$

在机器学习里表示训练数据所在的数据域， $y_{si} \in Y_s$ 是相应的类标签。同样的，目标域可以写做:

$$Do_t = \{(x_{t1}, y_{t1}), \dots, (x_{tm}, y_{tm})\} \quad x_{ti} \in \chi_t \quad (5.2)$$

表示测试集所在的数据域, $y_{ti} \in Y_t$ 是相应的标签输出, 在大部分情况下, 我们研究的是采用间隔相同的情况 $t_n = s_n$ 。

在源域中学习的任务称为源任务 (Source task, Ta_s), 在目标域中应用的任务称为目标任务 (Target task, Ta_t)。

5.1.3 迁移学习研究的问题

定义 3: 迁移学习, 源域 (Source domain) Do_s 和源学习任务 (Source task) Ta_s , 目标域 Do_t 和目标学习任务 Ta_t , 迁移学习的目的是利用在源域 Do_s 中学习的知识 Ta_s , 来提高目标预测函数 $f_t(\cdot)$ 的在目标域 Do_t 中的预测精度, 这时 $Do_s \neq Do_t$ 或者 $Ta_s \neq Ta_t$ 。

通过前面的定义 1, 条件 $Do_s \neq Do_t$ 表明 $\chi_s \neq \chi_t$ 或者 $P_s(X) \neq P_t(X)$ 。同样的, 条件 $T_s \neq T_t$ 表示 $Y_s \neq Y_t$ 或者 $f_s(\cdot) \neq f_t(\cdot)$ 。值得强调的是, 两个域的特征空间之间存在显式或隐式关系, 这意味着源域和目标域是相关的。当源域和目标域相同的时候 ($Do_s = Do_t$) 学习任务也相同 ($Ta_s = Ta_t$), 这时学习问题就回归到传统的监督学习问题。不同类型的迁移学习如表 5-1。

表 5-1 监督学习与迁移学习

Table 5-1 Supervised Learning and transfer Learning

机器学习类型		源域与目标域	源任务与目标任务
监督学习		相同	相同
迁移学习	诱导迁移学习	相同	不同但相似
	无监督迁移学习	不同但相似	不同但相似
	渐进直推式迁移学习	不同但相似	相同

根据表 5-1 的定义, 第四章中研究的向量标签学习本质上也是迁移学习, 因为, 但训练集与测试集的分布不同, 训练集采用的是单故障数据, 测试集采用的是并发故障数据, 但是训练中没有加入目标域的数据, 这种迁移学习属于渐进直推式迁移学习中的 self-taught learning 的情况。而本章中研究的迁移学习也属于渐进直推式迁移学习中的 Domain adaptation 情况。这两者之间的区别是训练的过程中有没有加入目标域的样本。

5.2 数据域可迁移的条件证明

在本部分, 研究数据域不同 $Do_s \neq Do_t$, 学习任务相同 $Ta_s = Ta_t$ 条件下, 数据域可以迁移的条件 (Dataset shift problem)。首先考虑一个分类问题, 学习的目标是学习一个分类器, x 和

y 分别表示输入和输出域。对于一个二分类问题 $y=\{-1,1\}$ 。假设存在一个函数 $f(\cdot)$ 能够将所有的样本分开。

5.2.1 数据分布充分采样条件

充分采样问题是研究机器学习的基础，研究的是采集的样本，能够真实的反映数据域的定义。随便采样变量 s ，当 $s=1$ 时表示样本充分采样，能够反映分布的特征； $s=0$ 表示样本没有充分采样，这时仅利用样本无法训练得到分布。

定义概率分布： P_{tr} 和 P_{te} 分别表示学习器训练过程得到的概率分布和测试集满足的概率分布。它们的概率密度分别为 p_{tr} 和 p_{te} 。在监督学习中 P_{tr} 和 P_{te} 是相同的，但在迁移学习中，这两个分布是不同的。在本文中，这两个分布的表达式分别为：

$$p_{tr}(y, x) = p(y, x | s = 1) \quad (5.3)$$

$$p_{te}(y, x) = p(y, x) \quad (5.4)$$

通过上式可以看出，训练集的样本必须是充分的采样 ($s=1$) 才能得到训练集的概率分布。

$$p(s = 1 | y, x) \quad (5.5)$$

$s=1$ 表示的是利用 (x, y) 的数据集，可以通过训练得到训练集的分布，也就是说训练集是充分采样的。

可以推导以下的结论：

$$p(y | x, s = 1) = \frac{p(y | x)p(s = 1 | x, y)}{p(s = 1 | +, x)p(+ | x) + p(s = 1 | -, x)p(- | x)} \quad (5.6)$$

$$p(x | s = 1) = \frac{p(s = 1 | x, +) + p(s = 1 | x, -)p(-, x)}{\int p(s = 1 | x, y)p(+ | x) + p(s = 1 | -, x)p(- | x)dx} \quad (5.7)$$

其中， $+$ 、 $-$ 分别表示 $y=1, y=-1$ ， $p(+, x)$ 表示的是 $p(y=1, x)$ ， $p(-, x)$ 表示的是 $p(y=-1, x)$ 。由于可以通过训练数据集 (x, y) 得到 $p(y|x, s=1)$ 和 $p(x, s=1)$ ，可以利用训练数据来推导测试集的分布：

$$\begin{aligned} p(y | x) &= \frac{p(y | x, s = 1)p(x | s = 1)p(s = 1) + p(y | x, s = 0)p(x | s = 0)p(s = 0)}{p(x | s = 1)p(s = 1) + p(x | s = 0)p(s = 0)} \\ &= \frac{p(s = 1 | x)}{p(s = 1 | y, x)} p(y | x, s = 1) \end{aligned} \quad (5.8)$$

$$\begin{aligned} p(x) &= p(x | s = 0)p(s = 0) + p(x | s = 1)p(s = 1) \\ &= \frac{p(s = 1)}{p(s = 1 | x)} p(x | s = 1) \end{aligned} \quad (5.9)$$

因此，得到了随机采样定理。

定理 5.1：随机采样定理

随机采样的样本 (x, y) 满足

条件 1:

$$p(s=1|y, x) = p(s=1) \quad (5.10)$$

条件 2:

$$p(y|x, s=1) = p(y|x) \quad (5.11)$$

条件 3:

$$p(x|s=1) = p(x) \quad (5.12)$$

满足上述三个条件，则训练集分布和测试集分布是相同的。

定理 5.2: 分类条件独立采样

当 y 的类别是相互独立的，或者，已知 x 以及 s 但未知 y ，这两种情况被称为采样不随机，采用下面的公式来描述：

$$p(s|x, y) = p(s|x) \Leftrightarrow p(y|x, s) = p(y|x) \quad (5.13)$$

训练集和测试集数据都需要满足上述条件，但是训练集概率分布的边界是不同的，满足：

$$p(x|s=1) = \frac{p(s=1|x)p(x)}{\int_x p(s=1|x)p(x)dx} \quad (5.14)$$

这个条件表明，测试集的条件需要也被训练集满足，在这种条件下标签可以被信任的，但是如果训练集和测试集的分布（ $p_{tr} \neq p_{te}$ ）不同需要给定一个限定。

5.2.2 源域可以预测目标域条件

通过上一节推导，我们得到了数据采样与分布预测的关系，本节提出训练集与测试集分布不同的情况下，利用训练集可以预测测试集分布的条件。

定理 5.3: （数据域可以迁移的条件，Dataset shift problem）如果有两个数据域分布不同：

$$P_{tr} \neq P_{te} \quad (5.15)$$

而且，训练集是充分采样($s=1$)，且：

$$P_{te}(A) = 0 \Rightarrow P_{tr}(A) = 0 \quad (5.16)$$

数据域可迁移条件，存在一个概率密度 f 满足

$$P_{tr}(A) = \int_A f dP_{te} \quad (5.17)$$

两个不同的数据域可以知识迁移的条件是：

$$\|f\|_{\infty} < \infty \quad (5.18)$$

下面对定理进行推导：

首先，迁移学习中，源域和数据域的分布是不同的（ $P_{tr} \neq P_{te}$ ），需要采用大量的训练数据来得到训练数据模型 P_{tr} ，然后通过 P_{tr} 来估算 P_{te} 。这也是数据域不同的迁移学习的本质。

现有源域和目标域的概率密度： p_{tr} 和 p_{te} 。由上节得到， $p_{tr}(y, x) = p(y, x|s=1)$ 和

$$p_{tr}(y, x) = p(y, x | s = 1)$$

$$p(y, x) = p(y, x | s = 0)p(s = 0) + p(y, x | s = 1)p(s = 1) \quad (5.19)$$

$p(y, x | s = 0)p(s = 0)$ 是可以建模的, 需要得到第二部分的解析解并满足 $p(s = 1) > 0$ 。对于 $(y, x) \in Y \times X$ 需要满足:

$$p(y, x) - p(s = 1)p(y, x | s = 1) \geq 0 \quad (5.20)$$

根据充分采样定理需要满足, p_{tr} 是 p_{te} 分布的一个采样, 可以描述为:

$$\sup_{(y, x) \in Y \times X} \frac{p_{tr}(y, x)}{p_{te}(y, x)} < \infty \quad (5.21)$$

满足上述条件, 说明 P_{tr} 是 P_{te} 的一个采样, 而充分采样可以表示为:

$$p(s = 1) \leq \inf_{y, x} \frac{p_{te}(y, x)}{p_{tr}(y, x)} \quad (5.22)$$




图 5-3 迁移学习中分布的关系

Fig 5-3 Distributions in transfer learning

下面来解释一下定理 5.3 的实际含义, 如图 5-3 所示, 我们采用训练数据集来学习一个分布 P_{tr} , 但这个分布是另外一个更大的分布 P_{te} 的不完全采样, 利用某些学习策略学到的 P_{tr} 知识可以来估计更大的采样 P_{te} , 学到的 P_{te} 可以用来预测另外一个不完全采样 P'_{te} 的输出。例如: 训练集是鸟, 测试集是飞机, 利用大量的鸟类的的数据学习到会飞的物体的特性, 然后用来预测飞机的输出。或者是, 训练集是吉他测试集是钢琴, 利用吉他来学习乐谱和琴类的演奏, 然后, 利用少量的样本或者完全不用目标域样本就可以快速学会如何演奏钢琴。

5.3 1-阶张量标签-迁移学习策略设计




图 5-4 1-阶张量标签在迁移学习中的应用

Fig 5-4 Vector label in transfer learning




图 5-5 多标签-迁移学习框架

Fig 5-5 Multi-label learning and ML-transfer learning machine learning framework

本节需要解决的问题是：当源域和目标域不相同的时候 ($Do_s \neq Do_t$) 但学习任务相同 ($Ta_s = Ta_t$)，要利用数据量充分的源域 (Do_s) 来训练，学习到的知识用于目标域 (Do_t) 的预测。首先要解决的问题是：建立源域和目标域之间的联系。这两个数据域虽然分布不同，但学习器的任务是相同的。采用上节提出的向量标签的方法建立二者之间的联系。

当一个标签的含义并不能反映当前样本 x_i 的信息的时候，就需要采用向量标签：

$$y_i = \{y_1 \cdots y_{nc}\} \quad (5.23)$$

这时，向量标签不仅表示了工业系统当前的状态，更重要的是通过相同的向量标签的形式，将单故障与并发故障建立起联系。如下表：

表 5-2 单故障与并发故障的向量标签编码形式

Table 5-2 Single fault and simultaneous fault in ML label structure

ML training data sets	ML testing data sets	ML classes	ML type
Normal	Normal data	[0 0 0]	
Single fault 1 data	Single fault 1 data	[1 0 0]	Single fault
Single fault 2 data	Single fault 2 data	[0 1 0]	label
Single fault 3 data	Single fault 3 data	[0 0 1]	
-	Simultaneous fault 1, 2 data	[1 1 0]	
-	Simultaneous fault 2, 3 data	[0 1 1]	Simultaneous
-	Simultaneous fault 1, 3 data	[1 0 1]	fault label
-	Simultaneous fault 1, 2, 3 data	[1 1 1]	

如果采用单标签的监督学习，训练数据集应涵盖所有的故障可能性，如果单个故障类型有 10 类，则并发故障的训练数据集由 2^{10} 类组成，那么 2^{10} 级的故障对于有监督的训练来说就太大而无法编码。采用了向量化的标签技术只需 10 种故障训练数据集就可以诊断工业系统的单故障和并发故障，可以节约大量的标签工作。实际上，从模式识别的角度来看，单个故障数据包含了一大部分并发故障的信息，并发故障的训练只需要学习多个故障相互作用产生的新模式即可。从这个角度来说，采用多标签-迁移学习的方式，更节省标签的开支，训练过程也更加智能。

多标签-迁移学习的训练过程如图 5-4 和图 5-5 所示。单个故障数据构成了训练的源域，并发故障数据构成了目标域，由表 5-2 分析可知，相同的标签格式为本来的异构的信息（源域和目标域）提供了桥梁。由第四章的研究可知，充分的源数据可以实现目标学习任务，然

而，要通过训练获得每一种故障类别的足够特征需要大量的单故障样本。本章的多标签-迁移学习为学习器的训练提供少量的并发故障（Simultaneous Fault）的数据，直接向学习器迁移并发故障的特征。如图 5-5 所示，1-阶张量标签学习中，在训练期间学习器学习了两种能力：

- (1) 学习单个故障的特征，用于单个故障的预测；
- (2) 从并发模式中识别单个故障组合。

从这个角度来看，第四章提出的多标签并发故障识别，实际上迁移学习中的自教学学习（Self-taught learning）。多标签-迁移学习具有两个训练阶段，即初始训练阶段和迁移训练阶段。在初始训练阶段，学习器只使用源域数据进行训练，通过不同工况下的单故障数据学习到足够的特征。然后，将初始阶段得到学习器的参数迁移给新的学习器，通过少量的目标数据（并发故障数据）来调整初始模型参数。这样，可以使学习器快速的利用单故障数据样本中学习到的知识通过少量的目标域数据就可以得到目标预测学习器。

向量标签迁移学习的算法如下：

表 5-3 向量标签-迁移学习算法

Table 5-3 ML-Transfer learning algorithm

Algorithm. 5.1 ML-Transfer learning	
Input: Train data set: Large number of Single faults data ($X_{\text{single}}, Y_{\text{single}}$) and a small amount of simultaneous data ($X_{\text{simultaneous}}, Y_{\text{simultaneous}}$)	
Testing data set: Simultaneous data ($X_{\text{simultaneous}_t}, Y_{\text{simultaneous}_t}$)	
Training Period	1. Training the RF classifier 1 with the single faults data ($X_{\text{single}}, Y_{\text{single}}$)
	2. Using the parameter of the RF classifier 1 as the initial parameter of the RF classifier 2.
	3. Training the RF classifier 2 with the simultaneous data ($X_{\text{simultaneous}}, Y_{\text{simultaneous}}$)
Testing Period	4. Testing the Simultaneous data $X_{\text{simultaneous}_t}$.
	Output: Simultaneous data prediction label $Y_{\text{simultaneous}_p}$

从迁移学习的观点来看，上面提出的学习方法。目标域是数据量稀少的并发故障数据，而源域是数据量多的单故障数据。通过这种方式，当面对数据域稀少的学习任务时，通过寻找一个相关的而且数据量大的数据域，就可以快速得到目标域预测函数。由于并发故障和单故障工作在不同的工况下，所以他们的分布是不同的 $Do_s \neq Do_t$ ，但是源任务和目标任务是相同的 $Ta_s = Ta_t$ ，从本文的观点来看都是一阶张量标签的分类问题。根据定义 2 所示，标签空间 Y 是相同的，而且源任务和目标任务都试图从训练数据 $\{x_i, y_i\}$ 中学习到一个最优的预测

函数 $f(\cdot)$ 。在目标域中需要少量的标记数据作为训练数据来诱导目标预测函数。这种类型的参数迁移方法假设源任务和目标任务共享模型的某些超参数。利用 ML 技术将传递的知识编码到共享参数中。因此，知识可以通过发现共享参数来跨任务域传递，采用这种方法学习器的训练速度就能大大提高。

算法 5.1 中表示是多标签-迁移学习的算法步骤。迁移学习的训练过程分两个步骤：初始训练阶段和迁移训练阶段。迁移学习训练步骤有两个训练周期，即训练和迁移学习阶段，借助于迁移学习。在初始训练期间，仅使用源域数据来训练学习器。然后，将学习器的参数传送到新的学习器，该新的学习器使用通过添加少量的目标数据来调整的初始模型参数来训练。对于同步 FDD，单一故障训练使用相当数量的单一故障源数据 (10000 组)，它们已经在单一故障条件下收集，然后在另一个工作条件 (并发故障) 下将参数传送到目标任务，其中仅有少量的目标数据可用。

5.4 1-阶张量标签-迁移随机森林并行算法

上节提出了 1-阶标签-迁移学习的框架，本节改进了随机森林 (Random Forests) 学习算法，将随机森林算法的输出拓展为向量的形式，可以有效的实现并行的算法设计。从而可以实现并发故障识别与迁移学习策略。随机森林作为一种分类算法，由于它是一种对输入变量较多的情况下的鲁棒方法，并且由于基于决策树的模型具有较高的可解释性，因此本文采用了随机森林分类算法。从技术效率的角度看，随机森林算法具有较快的训练和预测速度，它只依赖于一个或两个参数，对泛化误差有一个自适应的估计，可以直接用于高维数据的问题，而且具有很好的泛化能力。此外，该算法还提供了变量的重要度量 (Variable importance evaluation)，因此，随机森林算法不同于其他监督学习方法^[127-132]。数据驱动的故障诊断方法经常涉及到处理数据序列中的大量过程变量，随机森林变量重要性度量可以用于识别过程变量 (Variable) 对故障模式的贡献程度。通过分析变量重要性，仅基于数据模式就能发现故障的根源变量 (Fault source)，从而实现故障的定位，具有随机森林算法的故障的定位问题将在第 6 章中研究。

5.4.1 决策树

随机森林算法是一种基于决策树 (Decision Tree) 的集成算法，其中每棵决策树依赖于随机变量的集合。假设 p 维随机向量 X 表示实值输入或预测变量的未知联合分布 $p_{XY}(X, Y)$ 和表示实值响应的随机变量 Y ，求出预测 Y 的预测函数 $f(X)$ ，预测函数由损失函数 $L(Y, f(X))$ 确定，并定义为最小损失期望值。

$$E_{XY}(L(X, f(X))) \quad (5.24)$$

其中下标表示相对于 X 和 Y 的联合分布的期望。

$L(Y, f(X))$ 是 $f(X)$ 到 Y 距离的度量，是预测输出 $f(X)$ 与真实输出 Y 的损失函数。

$$L(X, f(X)) = I(Y \neq f(X)) = \begin{cases} 0 & \text{if } Y = f(X) \\ 1 & \text{otherwise} \end{cases} \quad (5.25)$$

对于平方误差 $E_{XY}(L(X, f(X)))$ ，损失会导致条件期望。

$$f(x) = E(Y | X = x) \quad (5.26)$$

在分类问题里，如果 y 表示 Y 集合中的一个元素，优化的目标是 $E_{XY}(L(X, f(X)))$

$$f(x) = \arg \max_{y \in Y} P(Y = y | X = x) \quad (5.27)$$




图 5-6 决策树分类原理

Fig 5-6 Decision tree classification

以一组基础学习器 $h_1(x), \dots, h_J(x)$ 的集合来构造 f ，这些基础学习器被组合起来形成集成的预测器 $f(x)$ 。在监督分类的训练中， $f(x)$ 大部分情况下是通过投票的方式进行组合的：

$$f(x) = \arg \max_{y \in Y} \sum_{j=1}^J I(y = h_j(x)) \quad (5.28)$$

在决策树中，第 j 个基础学习器也就是一棵决策树写作 $h_j(X, \Theta_j)$ ， Θ 是随机选择的变量子集，不同的 $\Theta_j, j=1, \dots, J$ 是相互独立的。这些树的预测空间是使用单个变量上的二进制分区序列来划分的，如图 5-6 所示。

5.4.2 迁移-随机森林并行算法




图 5-7 随机森林原理示意图

Fig 5-7 Diagram of random forests

随机森林利用决策树 $h_j(X, \theta_j)$ 作为基本的学习器，如图 5-7 所示。训练数据中 x_i 是预测器 p 的输入, y_i 表示预测器的输出。 θ_j 作为训练集的子集，每棵决策树都采用随机挑选的子集进行训练，得到预测器 $h_j(x, \theta_j, X)$ 。这种决策树的建立形式在实践中没有显式地考虑随机分量 θ_j ，而是以两种方式隐式地用于注入随机性。首先，每棵树都被安装在一个独立的自举样本中，类似于套袋中的原始数据。引导抽样涉及的随机化产生了 θ_j 的一部分。第二，当一个节点被分割时，最好的分割是在随机选择的 m 个预测变量的子集上，而不是在每个节点上，而不是所有的 p 预测器。用于对预测器进行抽样的随机化产生了 θ_j 的剩余部分。

加入了张量标签后，学习器算法就变为了并行式的决策树算法的集合，然后根据并发故障的特点，不进行结果的集成，而直接将预测的标签输出，这样就得到了张量标签型并行随机森林算法，如图 5-8 所示，算法如表 5-4。




图 5-8 随机森林与并行随机森林算法示意图

Fig 5-8 Random forests and parallel random forests

表 5-4 并行随机森林算法

Table 5-4 Random forests algorithm

Algorithm 5.2 Parallel random forests

Input: Train data set $R = \{x_1, x_2, \dots, x_{n_v}\}^T$

1-order tensor label $Y_R = \{y_1, y_2, \dots, y_m\}^T$

Number of tree: J

1. Take a bootstrap sample of C_j of size n from R
2. Using the bootstrap sample C_j as the training data, fit a tree using binary recursive partitioning.
 - a. Start with all observation in a single node.
 - b. Repeating the following steps recursively for each unsplit node until the stopping criterion is met.
- (i). Select m predictors at the random from the p available predictors.
- (ii). Find the best binary split among all binary splits on the m predictors from Step (i).

(iii). Split the node into two descendant nodes using the split from the Step (ii).

Output: Predictor $f(x) = \arg \max_y \sum_{j=1}^J I(h_j(x) = y)$

$h_j(x)$ is the prediction of the response variable at x using j th tree.

Label: $y = [f_1(x), f_2(x), \dots, f_J(x)]$

如算法 5.2 所述, 当决策结果输出时, 传统的决策树通过非加权投票进行组合。而本章提出的并行迁移学习, 将直接输出 k 维的向量标签, 如图 5-8。在分类方面, 从置换数据得到的预测与使用置换数据获得的预测的错误率之间的差异为观测提供了一种可变的重要程度。回归采用同样的方法, 但采用均方误差代替误码率。对于分类, 通过对来自同一类的观测值进行平均来计算类间变量的重要性。总的来说, 可变重要性是通过对所有观测值进行平均计算的。

并行随机森林算法在预测的环节, 可以实现并行的计算, 会极大的提高运行的速度。而且, 并行处理并发故障的识别可以有效的利用已知的少量标签, 极大程度的节约了计算代价。

5.5 实验结果与分析

5.5.1 基于张量标签学习的并发故障识别精度

实验的数据, 采用仿真数据与实际数据相混合的方法, 增加结果的科学性。其中, 系统正常的数据 (Fault 0), 以及故障 A 的数据采用真实的 SOFC 采集的数据。其他数据采用 SOFC 系统模型仿真数据。

使用相同的训练数据集对不同的学习环境进行训练, 将 ML-迁移学习与传统机器学习进行比较。表 5-5 显示了相同测试数据集中不同分类器的 F1 性能。对于单个故障的诊断, 所有学习器都获得了 95% 以上的高精度。然而, 对于并发故障诊断, SL-SVM 的泛化能力较差。ML-SVM 的并发故障诊断准确率达到 78%, 在 F1 指标中的平均性能约为 85%。ML-SVM 需要较少的训练数据, 计算量较小。ML-PCA-SVM 的处理时间比 ML-SVM 的处理时间快得多, 训练数据需要 19s, 测试数据需要处理 30000 个样本。ML-PCA-SVM 的并发故障诊断准确率达到 84%, 在 F1 指标中的平均性能约为 89%。在随机林中的帮助下, ML-随机森林 F1 指数的平均性能约为 94%, 并发故障诊断准确率为 89%, 比 ML-PCA-SVM 具有更好的性能。然而, 训练需要 30000 个数据集, 这就导致了 40 s 的训练时间的计算负担。由于数据维数没有降低, 随机森林的训练时间比 ML-PCA-SVM 长。在迁移学习的帮助下, 训练只需要 10000 个单一故障数据和 1000 个并发故障数据。此外, 借助同时的故障域数据, 目标预测函数可以

更好地逼近目标域。因此，ML-迁移学习的平均性能 F1 指数为 96.75%。训练速度明显提高。初始训练时间为 12.5s，迁移学习阶段训练时间为 0.78s。ML-迁移学习方法具有训练数据量小、计算负担小等优点，能够实现高精度的并发故障诊断。

表 5-5 不同机器学习方法结果对比

Table 5-5 Comparison of different classifier in testing data sets

Classifier	Single-faults F1 (%)	Simultaneous -faults F1 (%)	Average F1 (%)	Number of training data sets	Number of testing data sets	Training time (s)	Testing time (s)
SL SVM	96.5	32.2	52.85	30000*192	80000*192	262.1	189.2
ML SVM	96.1	78.43	85.45	30000*192	80000*192	111.1	140.1
ML PCA+SVM	96.4	84.93	89.67	30000*10	80000*10	0.18+19.3	26.1
ML RF	99.8	89.10	94.30	30000*192	80000*192	40.2	15.1
ML TF RF	99.8	94.23.	96.75	10000*192+ 1000*192	80000*192	12.5+0.78	15.1

实验的数据，采用仿真数据与实际数据相混合的方法，增加结果的科学性。其中，系统正常的数据 (Fault 0)，以及故障 A 的数据采用真实的 SOFC 采集的数据。其他数据采用 SOFC 系统模型仿真数据。

使用相同的训练数据集对不同的学习环境进行训练，将 ML-迁移学习与传统机器学习进行比较。表 5-5 显示了相同测试数据集中不同分类器的 F1 性能。对于单个故障的诊断，所有学习器都获得了 95%以上的高精度。然而，对于并发故障诊断，SL-SVM 的泛化能力较差。ML-SVM 的并发故障诊断准确率达到 78%，在 F1 指标中的平均性能约为 85%。ML-SVM 需要较少的训练数据，计算量较小。ML-PCA-SVM 的处理时间比 ML-SVM 的处理时间快得多，训练数据需要 19s，测试数据需要处理 30000 个样本。ML-PCA-SVM 的并发故障诊断准确率达到 84%，在 F1 指标中的平均性能约为 89%。在随机林中的帮助下，ML-随机森林 F1 指数的平均性能约为 94%，并发故障诊断准确率为 89%，比 ML-PCA-SVM 具有更好的性能。然而，训练需要 30000 个数据集，这就导致了 40 s 的训练时间的计算负担。由于数据维数没有降低，随机森林的训练时间比 ML-PCA-SVM 长。在迁移学习的帮助下，训练只需要 10000 个单一故障数据和 1000 个并发故障数据。此外，借助同时的故障域数据，目标预测函数可以更好地逼近目标域。因此，ML-迁移学习的平均性能 F1 指数为 96.75%。训练速度明显提高。初始训练时间为 12.5s，迁移学习阶段训练时间为 0.78s。ML-迁移学习具有训练数据量小、计算负担小等优点，能够实现高精度的并发故障诊断。

5.5.2 参数选择




图 5-9 随机森林的参数选择

Fig 5-9 Parameters tuning for random forests

参数调整过程如图 5-9 所示。根据学习精度和训练时间选择决策树的深度。应在这两个重要指标之间实现平衡。如图 5-9 所示合理树深数为 5。

5.5.3 并发故障可视化分析

从工业系统中采集的数据往往来自于众多传感器和控制器，数据具有高维的特性，为了对工业数据进行分析，就需要对数据进行压缩。常用的数据压缩方法为分为两类：特征选择与特征提取。

故障模式偏差与距离

正常和故障空间的低维特征空间将在三维图中呈现。该方法的目的是在低维空间(3D)上用点表示 SOFC 系统的故障状态，并观察正常故障、单故障和并发故障之间的关系。表 5-6 显示了故障聚类中心与变化任务中的最后一个正常状态之间的距离。故障 A 是非常接近正常状态，因为电堆温度控制器可以增加空气流量，以保持系统运行在接近正常状态，这一点在第 4.2.1 节中进行了分析。B 故障与正常状态的偏差最大。并发故障与 A 故障相结合，将与其

它独立故障极为接近。例如，故障 AF 与故障 F 非常接近，而故障 AB 非常接近 B，从而表明故障 A 的影响最小。故障 B 显示出最大的偏差，从而表明对 SOFC 系统的影响最大。并发故障继承了故障的特点，对系统的影响很大。故障簇向正常状态的中心偏差表示系统损伤水平的测量。

表 5-6 不同故障分布的聚类中心与正常样本的距离

Table 5-6 Fault cluster centers to the normal data

Fault	3D distance from normal
A	0.2
F	4.75
AF	4.92
FB	6.31
AFB	6.62
B	17.8
AB	16.5

故障模式可视化

在这一部分中，描述了一种多维可视化技术，用于通过数据模式的主成分分析(PCA)进行故障检测和多变量过程的诊断。高维数据可以转换为低维编码，利用主成分分析重构高维输入向量。本部分采用主成分分析方法将高维数据转换为三维低维数据，实现故障模式的可视化。表 5-5 中的变量表示特征空间。随机林算法所选择的特征空间可作为机器学习器学习的模式，并将其转换为三分量数据，并在三维空间中绘制，如图所示图 5-10。点的位置和形状指示正常和错误状态的分布。图 5-10.h 和图 5-10.i 显示了特性和原始数据空间的分布。特征空间具有原始数据的大部分特征，可以表示原始数据空间。

数据点的形状反映了故障在三维空间的分布。图 5-10 中显示了独立故障数据的分布情况。图 5-10.b-d 显示 F 故障和 AF 故障的分布，这种分布表明，AF 的形状与 F 的形状非常相似，但也可以识别 A 故障的特征（在红圈内）。在图 5-10.f 中也可以观察到 FB 和 AFB 同样的故障。图 5-10.g 对于 B 故障的分布，由于 B 故障的特征过于强烈，故障 A 的特征难以识别。然而，A 故障可以从其他角度在高维空间上识别。分析表明，特征空间能够有效地反映结构在多次变化下的状态。




图 5-10 故障模式可视化图

Fig 5-10 Fault pattern visualization

使用图 5-10 中所示的多维可视化技术可以得出几个结论。

(1) SOFC 系统故障的分布如图所示。图 5-10.a 是高度可分离的，所有正常和故障的状态都不能相互混合。因此，该分类器可以方便地对故障类别进行分类。

(2) SOFC 系统的同步 FDS 可以实现单类故障诊断系统的训练，并通过将多类病例分解成相应的单类组合，实现对单类和多类病例的分类能力。并发故障数据分布显示了独立故障和单故障的特点如图 5-10.e-f。此外，强特征故障可以影响同时发生的故障以显示它们的特征，而弱特征故障，例如 A 故障，可能被覆盖并且很难识别，如图 5-10.g 所示。

(3) SOFC 系统特征空间可以表示原始数据空间，因为随机森林算法提供的特征选择能够学习原始数据的大部分重要特征，如图 5-10.h-i 所示。

(4) 并发故障数据具有单故障的特点，但分布不同，同时分布继承了单故障的特征。这样，SOFC 系统的并发故障分布可以通过单一的故障分布来学习，并且由于单个故障分布和并发故障分布的相似性，知识被迁移到同步故障分布预测器中。

5.6 本章小结

本章提出了一种 1-阶张量标签迁移学习 (ML-Transfer learning)，用于解决工业系统并发故障识别带标签训练数据稀少的情况。并发故障识别系统 (Simultaneous fault identification system) 包括两个部分：1-阶张量标签迁移学习框架和随机森林并行算法。本章研究的源域 (单故障数据) 和目标域 (并发故障数据) 是不同的，而源任务和目标任务是相同的，并且源任务与目标任务的标签形式一致，采用了向量化标签的形式建立起两个数据域之间的联系。本章改进了随机森林 (Random Forests) 学习算法，将随机森林并行算法的输出拓展为向量的形式，可以有效的实现并行的算法设计，从而可以实现并发故障识别与迁移学习策略。

第6章 基于特征选择算法的故障定位

6.1 引言

本章要解决的问题：故障的定位与定位的量化度量。故障定位寻找故障设备的有故障部件，为确定故障根源，就必须找到系统中的故障源变量，从而可以针对故障的位置采取某些相应的措施。采用张量标签学习可以有效的量化衡量定位的精度，并且将故障的识别与定位统一度量，有效的提高对故障类型与位置的认知能力。

故障能够找到唯一的故障源头的条件是：系统是能量耗散系统网络。所谓耗散，是热力学第二定律的推广，是指能量从一个源头出发，流经整个系统网络，在网络中不存在新的能量源，这样系统网络的损坏，将在损坏点位置随着距离递减。只有这样的系统才能够进行唯一的精确的定位。如果网络中具有新的能量源，那么网络中节点的损坏将会造成链式的故障触发，从而加大故障的程度，这时系统的故障就会叠加、相互影响，故障因素就变的不唯一，这时利用故障信息进行定位就无法唯一的确定故障的位置。基于上述的分析，耗散型系统在现实中主要有：电网系统、具有唯一能量源的工业系统、或者具有唯一信号源的通信系统。本文采用的固体氧化物燃料电池系统（SOFC）具有唯一的能量源也就是燃烧室，整个系统的热量都来自于燃烧室，从燃烧室传递出来的能量加热整个系统，从而使系统工作在一个稳定的温度范围。而本文研究的故障类型为系统气体的泄露，这些故障都随着距离位置的增加呈递减的趋势，不会造成次生故障放大现象或者引发新的系统故障。因此可以根据当前的系统状态信息唯一的确定故障的位置^[63, 81, 82]。

本章采用特征选择的方法来解决故障定位的问题，特征选择可以研究故障定位的本质：利用特征选择的方法从原始特征空间选择一个合适的子集，这个子集能够最大程度的反映正常状态数据（0）和异常状态数据（1）的不同，也就是这些变量充分的反映了故障的状态特征。从贝叶斯推理的角度来看，如果某个位置发生故障，这个位置的某些变量会很大概率下发生异常变化。反之，当某些位置的变量发生异常，那么这个位置很有可能发生了故障。这些异常变量可能是故障的原因，也可能是故障的结果，但这些变量都从系统原理本质上反映了故障的位置信息。从系统原始特征空间中挑选出的特征子空间，能够最大程序的反映整个数据集的异常，这些变量在系统中的位置，也就极大概率的反映了故障的位置。把特征子集空间找到，相应的找到他们的在系统中的位置，也就很大程度的找到了故障的位置。

本章首先研究了基于特征选择可以进行故障定位的条件。然后，针对于基于相似性度量的故障定位系统进行了研究，采用了一种新的特征选择算法，基于不同类型故障样本之间的相似性度量，同时去除特征之间的相关性来挑选出与故障类型最为相关的特征，实现故障定

位。本章采用过滤式的特征选择算法 mRMR 的 ReliefF 特征选择算法挑选与故障类别最为相关的特征，结合模型特征采集的位置进行故障定位，并通过在 SOFC 系统上的实验仿真验证该方法的可行性。为进一步分析具体种类故障的定位，本章采用包裹式的随机森林的方法，通过随机森林的特征性度量来选择合适的子集，从而确定故障发生的位置。包裹式特征选择算法比过滤式的特征选择算法计算精度高但计算代价大，因此，实际的应用中两种方法可以根据需求进行选择，起到互补的作用。

6.2 故障定位的框架

6.2.1 能量耗散系统

热力学第一定律和热力学第二定律则在热力学领域中就分别被称为是能量守恒法则和能量耗散法则。要通过变量的数据定位到系统的故障位置，需要满足故障能够找到唯一的故障源头的条件是：系统是能量损耗系统网络。所谓耗散，是能量从一个源头出发，流经整个系统网络，在网络中不存在新的能量源，这样系统网络的损坏，将在损坏点位置随着距离递减。只有这样的系统才能够进行唯一的精确的定位。如果网络中具有新的能量源，那么网络中节点的损坏将会造成链式的故障触发，从而加大故障的程度，这时系统的故障就会叠加、相互影响，故障因素就变的不唯一，这时利用故障信息进行定位就无法唯一的确定出故障的位置。基于上述的分析，耗散型系统在现实中主要有：电网系统、具有唯一能量源的工业系统、或者具有唯一信号源的通信系统^[60, 61, 63, 81, 133-137]。




图 6-1 能量耗散系统网络结构图

Fig 6-1 Energy dissipation network

定理 6.1:（特征选择可以故障定位的条件）故障 x_f 是故障发生的根源变量，故障引起的变量

的范数 $\|\Delta x_i\|$ 要随变量距离 x_f 的空间距离 $d_i=|l(x_i)-l(x_f)|$ 递减，即如果 $d_j>d_i$ ，则 $\|\Delta x_j\|>\|\Delta x_i\|$ 。

满足这个定义的系统叫做能量耗散系统如图 6-1，只有能量耗散系统才能够通过分析变量数据唯一的定位到故障的源头。

本文采用的固体氧化物燃料电池系统（SOFC）具有唯一的热源也就是燃烧室，整个系统的热量都来自于燃烧室，从燃烧室传递出来的能量加热整个系统，从而使系统工作在一个稳定的温度范围。而本文研究的故障类型为系统气体的泄露，这些故障都随着距离位置的增加呈递减的趋势，不会造成次生故障放大现象或者引发新的系统故障。因此可以根据当前的系统状态信息唯一的确定故障的位置。

6.2.2 基于特征选择算法的故障定位的流程

工业系统在运行过程中会产生大量信息，能够由实时采集所得，同时能敏感地反应系统状态变化的信息被提取出来用于系统状态监测以及故障诊断，这些系统变量从数据挖掘的角度就称为特征。在工业系统的运行过程中，故障和特征之间不是一对一的关系，而很可能是发生一种故障会产生多种特征，或者是一个特征可能是由多种故障引起的。所以，在状态监测和故障诊断过程中，从原始信息中提取出能准确高效识别故障的特征子集是十分重要的。

故障的定位实际是对故障状态和正常状态的分类问题的延伸，找到对故障状态和正常状态影响最大的变量，在某些条件下，也就是故障的根源变量。其中，描述样本的特征向量包含了样本所述类型的所有信息，该信息的完整性以及与分类的相关性都直接决定了分类模型的准确度。这些特征向量中有几个关键性的特征引导着数据样本类别的差异，通过特征选择可以挑选出与样本类别相关度最高的特征，去掉冗余的和不相关的特征，简化数据集，增强可理解度，这些特征能够更加精确的描述系统状态，更好的满足需求。

特征选择定义为：在包含 D 个特征的特征集合中选取一个包含 d 个特征子集，其中 d 已知，并且 $d \leq D$ ，使得依据某种评价标准，这个子集是原集合所有包含元素个数为 d 的子集中的最优子集。特征选择是数据挖掘、模式识别、机器学习中的一重要技术，在数据准备和预处理中占据重要的位置，在故障诊断领域也得到了广泛的使用^[138, 139]。

特征选择主要分为两个环节，分别为“子集搜索”和“子集评价”^[140]。在子集搜索环节中，对于给定的特征集合 $\{a_1, a_2, \dots, a_n\}$ ，每个特征都被视为一个候选子集，并对这些子集都进行评价。假定 $\{a_2\}$ 最优，则第一轮选定集定为 $\{a_2\}$ ；然后向上一轮的选定集中添加一个特征，假设在这 $d-1$ 个候选子集中 $\{a_2, a_4\}$ 最优，而且优于 $\{a_2\}$ ，那么这一轮的选定子集就为 $\{a_2, a_4\}$ ；如此重复操作，在 $k+1$ 轮时，若上一轮的选定集优于这一轮的最优候选子集，则不产生候选集，并将上一轮即第 k 轮选定的 k 集合作为结果，这样逐渐增加相关特征的策略被称为“前向搜索”。相似的，每一轮逐渐删去无关特征的策略被称为“后向搜索”，若将二者结合起来，在每一轮中逐渐增加相关特征，删去无关特征的策略被称为“双向搜索”。在

子集评价环节，给定数据集 D ，假定 $p_i (i=1,2,\dots,|y|)$ 为数据集 D 中第 i 类样本所占比例。假设样本为离散型，根据属性子集 A 将 D 分成了 V 个子集 $\{D^1, D^2, \dots, D^V\}$ ，这样特征子集 A 就能对数据集 D 进行一个划分，每个划分出的区域在 A 有对应的取值，而样本的标记信息对应的是数据集 D 真实的划分，采用信息熵等标准来衡量这两个划分之间的差异，从而对属性子集 A 的优劣进行评价。特征选择过程如图 6-2 所示。




图 6-2 特征选择过程

Fig 6-2 Process of feature selection

特征选择方法有过滤式 (filter) [141]、包裹式 (wrapper) [142]、嵌入式 (embedding) [143] 三大类。过滤式 (filter) 特征选择通常选择和目标函数相关度大的特征子集，依赖于数据本身。过滤式特征选择算法运行高效，因而适用于规模较大的数据集，得到了广泛的应用。该算法的评估方法包括信息增益、关联度、Relief 系列算法等。过滤式特征选择方法的示意图如图 6-3 所示。





图 6-3 过滤式特征选择过程

Fig 6-3 Process of filter feature selection

包裹式 (wrapper) 方法将使得所选特征子集的性能最优作为特征评价的标准，那么使得最终的学习算法的性能最优就是最好的评估标准。因此，该方法选择特征子集的评价标准为选定学习器的性能。它的优点是可以直接针对选定的学习器进行优化，准确率高，缺点该方法需要多次训练学习器，开销较大，效率较低。典型的包裹式算法有 LVW (Las Vegas Wrapper)、

遗传算法等。所以针对该方法，提高评价的效率是一个热门的研究方向。加速决策树可以通过削减决策树分支数量来实现，提高特征选择的效率可以通过减少评估特征时分类器的训练样本数量来实现。该方法还有一个缺点是在训练数据规模较小的情况下，容易产生过适应问题^[144]。包裹式特征选择方法的示意图如图 6-4 所示。



图

6-4 包裹式特征选择过程

Fig 6-4 Process of wrapper feature selection

嵌入式特征选择是在特征选择过程中将算法本身嵌入到学习器中自动进行特征选择。典型的算法例如决策树算法，如 Breiman 的 CART 算法^[145]、Quinlan 的 ID3 和 C4.5^[146]等，该算法在每一个结点上，将与类别最相关的子特征挑选出来，然后根据选定的子特征对子空间进行分割，不断地重复这个过程，直到满足算法的终止条件。




图 6-5 基于特征选择算法的故障定位

Fig 6-5 Fault location based on feature selection

故障定位的算法流程图如图 6-5，首先，需要根据变量之间的相似性度量找到变量空间内的相关组，然后，分析每个相关组对故障的 0、1 分类的贡献程度，最后根据贡献的程度选择出对故障分类贡献度最大的特征子集。在一定的条件下，认为故障特征子集对故障发生贡献度最大，满足能量耗散系统的条件下，可以认为是这些变量是故障发生的根源变量，从而实现故障的定位。

上述结构的合理性通过解耦控制理论来进行^[147]。

系统具有变量组 $X=\{x_1, x_2, \dots, x_n\}$ ，利用状态空间来描述系统变量之间的关系如下：

$$\dot{X} = AX \quad (6.1)$$

其中， X 包括状态变量和控制变量，从而不需要单独列出输入状态 U 。由于状态空间的表达形式不唯一，可以表示为许多 X 变量的组合的形式，因此，状态空间的形式可以通过线性变换来实现变化。

如果系统可以完全解耦的，则可以通过特征值分解得到：

$$\dot{Z} = \begin{bmatrix} \lambda_1 & & & \\ 0 & \lambda_2 & & \\ \vdots & & \ddots & \\ 0 & & & \lambda_n \end{bmatrix} Z \quad (6.2)$$

变换矩阵为：

$$T = [P_1 \ P_2 \ \dots \ P_n] \quad (6.3)$$

其中，

$$\lambda_i P_i - A P_i = 0 \quad (6.4)$$

状态特征方程的特征值 $\lambda_i (i=1,2,\dots,n)$ 通常由下面的公式求得：

$$|\lambda I - A| = 0 \quad (6.5)$$

n 阶系统方程有 n 个特征值。如果 A 能够完整的表现为特征值沿着对角线的形式，说明系统变量之间没有耦合，通过线性变换可以实现完全解耦。但这种情况在现实中是非常罕见的，因为系统本身的变量之间会存在很多的耦合关系，更普遍的情况是，只能转换为约当标准型，如下：

$$\begin{bmatrix} \lambda_1 & 1 & & & \\ & \lambda_1 & 1 & & \\ & & \lambda_1 & & \\ & & & \lambda_2 & 1 \\ & & & & \lambda_2 \\ & & & & & \ddots \end{bmatrix} \quad (6.6)$$

公式 6.6 是约当标准型，如果线性定常系统的状态系数矩阵 A 具有重根，则可以通过奇异值变化为更普遍的约当标准型。很明显可以从公式中看出，同一个特征值对应的变量组直接无法完全解耦，也就是他们之间存在强烈的耦合关系，而不同组直接可以通过变化将变量

组直接的耦合关系完全解除。因此，可以通过分组的方式进行特征选择，选择合适的变量组每一个组内根据系统机理选择最佳的代表变量，组成的集合能够最大程度的重构原始空间，这些变量含有的故障信息也是最多的，完整的找到了这些故障特征的子集，在某些条件下可以实现了故障根源的定位。

6.2.3 相似性度量




图 6-6 相似性度量的分类图

Fig 6-6 Classification of similarity measure

相似性度量用于评价两事物间相近程度，二者越接近，它们的相似性度量越大，反之，二者越疏远，它们的相似性度量就越小。相似性度量的方法种类很多，常用的相似性度量有：相关系数（衡量特征之间接近程度）、相似系数（衡量样本之间接近程度）。相似性度量的分类如图 6-6 所示，公式如下：

$$Diff(X,Y) \quad (6.7)$$

相似系数一般用于衡量样本之间的接近程度，基本思想是：一个系统由一组具有 n 个特征属性的样本组成，每个对象由 n 维空间上的一个点来表征，该点第 i 维的坐标对应表示该对象的第 i 个特征属性的值，其中 $i=1,2,3,\dots,n$ 。空间上的两个点之间的距离越大，对应的两个对象之间的特征差异就越大，则两个对象的相似性就越小，反之，两点距离越小，对象特征差异越大，相似性就越大。下面简要介绍明考夫斯基（Minkowski）距离^[148]、Hausdorff 距离^[149]。

（1）Minkowski 距离

在 N 维样本空间 X 中，两个样本之间的 Minkowski 距离定义如下：

$$d_{ij}(q) = [\sum_{k=1}^n (x_i^{(k)} - x_j^{(k)})^q]^{\frac{1}{q}} \quad (6.8)$$

$$d_{ij}(q) = [\sum_{k=1}^n (x_i^{(k)} - x_j^{(k)})^q]^{\frac{1}{q}} \quad (6.9)$$

当 $q=1$ 时, $d_{ij}(1) = \sum_{k=1}^n (x_i^{(k)} - x_j^{(k)})$, 即为曼哈顿距离, 也称为 L_1 范数;

当 $q=2$ 时, $d_{ij}(2) = [\sum_{k=1}^n (x_i^{(k)} - x_j^{(k)})^2]^{\frac{1}{2}}$, 即为欧式距离, 也称为 L_2 范数。

以上公式均满足如下数学特性: (1) $d_{ij}(q) \geq 0$; (2) 若 $d_{ij}(q) = 0$, 则两个对象完全相似; (3) $d_{ij}(q) = d_{ji}(q)$; (4) $d_{ij}(q) \leq d_{ik}(q) + d_{kj}(q)$ 。

另外, 在某些情况下, 采用加权的欧式距离来突出某些重要的特征属性:

$$d_{ij}(q) = [\sum_{k=1}^n \omega_k (x_i^{(k)} - x_j^{(k)})^2]^{\frac{1}{2}} \quad (6.10)$$

(2) Hausdorff 距离

Hausdorff 距离采用集合中的 MAX-MIN 特性, 有效拓宽了该方法的适应领域和适用范围。设有对象集合 W 对象集合 C , 则 W 到 C 之间的 Hausdorff 距离定义为:

$$d_{WC} = \text{Max}\{\text{Min}\{w, C\}, w \in W\} \quad (6.11)$$

其中, Min 是求得两对象之间距离的最小值, Max 是求得集合中的最大值。

还有其他一些距离系数的计算方式如:

Chebyshev 距离:

$$d_{ij} = \sum_{k=1}^n |x_i^k - x_j^k| \quad (6.12)$$

Minkovski 距离:

$$d_{ij} = \left(\sum_{k=1}^n |x_i^k - x_j^k|^q \right)^{\frac{1}{q}} \quad (6.13)$$

Canberra 距离:

$$d_{ij} = \sum_{k=1}^n \frac{|x_i^k - x_j^k|}{|x_i^k| + |x_j^k|} \quad (6.14)$$

相关性系数用于衡量特征之间的接近程度。以下主要介绍皮尔森相关系数^[150]和互信息^[151]。

(1) 皮尔森相关系数

皮尔森相关系数的定义为两变量之间协方差和标准差的商, 商越大表示特征越相关。

$$\rho_{X,Y} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}} \quad (6.15)$$

(2) 互信息

在信息论中，互信息表示两个随机变量的相关性程度。

$$I(X;Y) = \sum_{x \in X, y \in Y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad (6.16)$$

$$I(X;Y) = H(X) - H(X|Y) \quad (6.17)$$

其中， $H(X)$ 为信息熵， $H(X|Y)$ 为条件熵。

6.3 Relief 型过滤式特征选择故障定位算法

6.3.1 Relief 算法

Kira 最早提出 Relief 算法，最初只用于两类数据的分类问题^[152]。Relief 算法的基本思想是由每个特征与样本类别的相关性的差异，给每个特征赋予不同的权重，若权重小于设定阈值，该特征就会被移除，因此它属于特征权重算法。Relief 算法是基于特征对样本类别的区分能力来确定特征和类别的相关性。算法基本思想：随机在训练集 D 中挑选一个样本 R ，再在和 R 同类的样本中找最近邻样本 H ，这个过程称为 Near Hit，从和 R 不同类的样本中同样找最近邻样本 M ，这个过程被称为 Near Miss。对每个特征分别计算 R 和 Near Hit 的距离以及 R 和 Near Miss 上的距离，若前者小于后者，则该特征有益于同类别和不同类别的最近邻样本的区分，应增大其权重；反之，若前者大于后者，说明该特征不利于区分同类别和不同类别的最近邻样本，应减小其权重。将以上过程重复进行 m 次，求均值，最后得到各个特征的权重。特征对样本进行分类的能力越强，则它的权重越大，反之，它的权重就越小。

Relief 算法运行高效，它的运行时间是随着进行次数 m 以及特征个数的增加而增加的。由于 Relief 算法的简单高效以及不错的效果，因此得到广泛应用。但是它的缺点是只能处理两类数据，于是在 1994 年，Kononeill 对 Relief 算法进行了扩展，得到可以处理多分类问题的 ReliefF 算法^[153]。ReliefF 算法每次在训练样本集中随机选取一个样本 R ，然后从每个和 R 同类别的样本集中挑选出 k 个近邻样本，从每个和 R 的不同类别的样本集中同样找出 k 个近邻样本，然后根据每个特征区分同类和不同类的能力来对每个特征的权重进行更新。ReliefF 算法具体描述如表 6-1 所示。

表 6-1 ReliefF 算法

Table 6-1 ReliefF

算法 6.1 ReliefF

输入：样本集 S 和类别 C

对特征 f_a , $a=1 \dots d$, 设置权重 $\omega(a)=0$, 特征选择阈值 δ ;

for $I=1$ to m do

 随机选取样本 x_i ;

 搜索同类 k 个最近邻样本 h_j ;

 在所有与样本 x_i 不同的类 c 中选择 k 非同类 $m_j(c)$ 个最近邻;

 for $a=1$ to d do

$$\omega(a) = \omega(a) - \sum_{j=1}^k \frac{\text{diff}(a, x_i, h_j)}{m-k} + \sum_{c \neq \text{class}(x_i)} \left\{ \frac{P(c)}{1 - P[\text{class}(x_i)]} \times \sum_{j=1}^k \{\text{diff}[a, x_i, m_j(c)]\} \right\} / (m-k)$$

 if $\omega(a) > \delta$ 将 f_a 加入到特征选择子集里

 end

end

$\text{diff}(a, X, Y)$: 样本 X 和样本 Y 关于特征 a 的距离;

$P(c)$: 第 c 类目标的概率, 由该类目标样本数比样本总数来确定;

$m_j(c)$: 第 c 类目标的第 j 个样本;

m : 迭代次数;

k : 最近邻样本个数

6.3.2 最大相关-最小相容 Relief 算法

Relief 算法是根据特征与类别的相关性来计算各个特征的权重, 由此可以选出与分类相关性高的最优特征。但是该算法并不考虑特征之间本来的相关性, 所以它选出的特征子集并不是最优的。mRMR 算法不仅考虑特征与分类的相关性, 也考虑特征之间的独立性, 所以它可以选出最优特征子集, 但是对分类器来说, mRMR 选择出的每个特征对分类的贡献度是相同的。由此, 本文采用 mRMR (最大相关最小冗余) 算法的思想对 ReliefF 算法进行优化。利用 ReliefF 算法计算各个特征的权重, 特征权重越大, 对于该分类集的支配权越大, 权重越小, 对于分类集的支配权越小, 然后利用 mRMR 算法的特性挑选出与目标类别相关性最大, 且特征相互之间的冗余性最小的特征子集。mRMR (最大相关最小冗余) 算法是典型特征降维算法, 它基于信息理论, 主要思想是从特征空间中寻找 m 个特征的特征子集, 且这些特征与目标类别有最大相关性, 同时相互之间具有

最小冗余性。

设有两个随机变量 x 和 y ，其概率密度函数为 $p(x)$ 、 $p(y)$ 和 $p(x, y)$ ，它们之间的互信息定义如下：

$$I(x; y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy \quad (6.18)$$

采用互信息来衡量特征子集当中的特征与类别之间以及特征相互之间的相关度：

$$D = \frac{1}{|S|} \sum_{x_i \in S} I(x_i; c) \quad (6.19)$$

$$R = \frac{1}{|S|^2} \sum_{x_i, x_j \in S} I(x_i; x_j) \quad (6.20)$$

其中， S 为特征集合， c 为目标类别， $I(x_i; c)$ 为特征 i 和目标类 c 之间的互信息， $I(x_i; x_j)$ 为特征 i 与特征 j 之间的互信息。对于特征子集 S ，最大化式 (6.19) 表示最大化特征与类别的相关度，最小化式 (6.20) 意味着最小化特征之间的互相关度。

将式 (6.19) 和式 (6.20) 进行组合，得到最小冗余最大相关的特征选择标准：

$$\max(D - R) \quad (6.21)$$

在这个选择标准下，为获得最优特征子集采用了序贯前向查找法，首先根据式 (6.19) 确定第一个与类别最为相关的特征，将其加入到特征子集 S_m 中，其他的特征也用这样的方法依次计算后加入。设在子集 S_m 中已有 m 个特征，在数据集 $\{S - S_m\}$ 中，根据式 (6.22) 选择一个特征：

$$\max_{x_i \in S - S_m} [I(x_i; c) - \frac{1}{m} \sum_{x_j \in S_m} I(x_i; x_j)] \quad (6.22)$$

ReliefF 算法的运行效率高，该算法会赋予分类能力强的特征较高的权重，但是该算法没有考虑特征之间的相关性，所以不能去除冗余特征；mRMR 算法可以得出与目标类别有最大相关性，且相互之间冗余性最小的特征子集，但是它没有考虑各个特征的权重系数，所以无法体现不同特征对于分类效果的差别。因此本文采用 mRMR 算法对 ReliefF 算法进行了优化，得出一种基于 mRMR 的 ReliefF 算法，它可以使得计算得出的特征子集是最优的。该算法的步骤如下。

算法名称：Algorithm 6.2 mRMR-ReliefF

输入： 有数据集 S ，设迭代次数为 m ，最近邻样本数目为 k 。

步骤 1： 对样本集 S 采用 ReliefF 算法计算样本集中的各个特征与目标类别的相关性，赋予特征相应的权重矩阵 ω 。去除权重最小的特征，得到特征子集 S_n 及相应的权重矩阵 ω_n ；

步骤 2： 将权重矩阵 ω_n 用于特征子集 S_n 加权，经过加权后的特征子集为 $S_m = S_n \cdot \omega_n$ ；

步骤 3： 设定目标维数 d ，解式 $R = \frac{1}{|S|^2} \sum_{x_i, x_j \in S} I(x_i; x_j)$ ，向特征子集 S_d 中加入第一个与

类别最相关的特征；

步骤 4: 依据 mRMR 特征选择法则，求解 $\max_{x_i \in S - S_m} [I(x_i; c) - \frac{1}{m} \sum_{x_j \in S_m} I(x_i; x_j)]$ ，依次选出符合要

求的特征加到特征子集 S_d 中，到选出 d 个特征时算法结束；

输出: 特征子集 S_d 。

6.3.3 实验结果与分析

本节对 SOFC 系统的故障数据集采用 mRMR-ReliefF 算法进行特征提取，根据提取出的变量特征在系统中的位置实现故障定位，同时单独采用 mRMR 以及 ReliefF 算法与之对比，验证了该方法的有效性。SOFC 系统的漏气位置如图 6-7。




图 6-7 用于特征选择的 SOFC 故障位置示意图

Fig 6-7 SOFC fault cases for feature selection

仿真实验采用 SOFC 系统的故障数据集（数据集的产生详见 2.3 节），分别选取 200 组故障 2、故障 6、故障 8 以及故障 10 的故障数据，加上标签为 1，同时在这 4 个故障数据集里加入 200 组正常数据样本，加上标签为 0，由此可得 4 个有 200 组故障数据以及 200 组正常数据的有标签样本集。对这 4 个样本分别采用 mRMR-ReliefF、ReliefF 以及 mRMR 进行特征选择，将挑选出的排名前 5 的特征列入表格，特征选择的结果分别在表 6-2、表 6-3、表 6-4 中显示。

故障 2 表示的是鼓风机后方、换热器之前空气端发生了漏气，mRMR-ReliefF 选择出的变量都分布在鼓风机和换热器 1 中，分布集中，其中没有其余管道漏气的可能，定位准确。而 ReliefF 选择的变量分布的比较分散，无法实现精确的定位，mRMR 选择出的变量与故障 2 的相关性不强，无法实现故障定位。

表 6-2 mRMR-ReliefF 特征选择结果

Table 6-2 Result of mRMR-ReliefF

故障 2		故障 6	
编号	变量名	编号	变量名
95	TempHEX1_T_node2_HEX1_T_fuel, K	149	TempNotes_Tnode1_Tair_out, (K)
101	TempHEX1_T_node3_HEX1_T_fuel, K	47	IniMassAndTemperature_T_air_1
107	TempHEX1_T_node4_HEX1_T_fuel, K	199	BurnerT
0	Air_Flow	71	NPNotes_NPnodeend_Nout_ca, (mol/s)
78	Pblower_P_blower	59	NPNotes_NPnode2_Nout_ca, (mol/s)

故障 8		故障 10	
编号	变量名	编号	变量名
94	TempHEX1_T_node1_HEX1_T_shell, K	192	XNotes_Xnodeend_X_H2_out
97	TempHEX1_T_node2_HEX1_T_hotgas, K	199	BurnerT
100	TempHEX1_T_node2_HEX1_T_shell, K	187	XNotes_Xnode4_X_H2O_out
21	ECNotes_ECnodeend_CD, (A/m2)	188	XNotes_Xnode4_X_H2_out
41	IniMassAndTemperature_T_tubeH2_HEX1	191	XNotes_Xnodeend_X_H2O_out

表 6-3 ReliefF 特征选择结果

Table 6-3 Result of ReliefF

故障 2		故障 6	
编号	变量名	编号	变量名
96	TempHEX1_T_node2_HEX1_T_air, K	129	TempHEX2_T_node2_HEX2_T_airtube, K
78	Pblower_P_blower	111	TempHEX1_T_node4_HEX1_T_airtube, K
129	TempHEX2_T_node2_HEX2_T_airtube, K	84	Stack_inlet_T
198	Stack_Outlet_T	199	BurnerT
34	IniMassAndTemperature_X_H2O_b	86	System_power

故障 8		故障 10	
编号	变量名	编号	变量名
112	TempHEX1_T_node4_HEX1_T_shell, K	150	TempNotes_Tnode1_Tfuel_out, (K)
158	TempNotes_Tnode3_Tfuel_out, (K)	152	TempNotes_Tnode1_TIC_out, (K)
85	Stack_Outlet_T	48	IniMassAndTemperature_T_IC_1

162	TempNotes_Tnode4_Tfuel_out, (K)	83	Stack_Ave
84	Stack_inlet_T	1	BunerH2

表 6-4 mRMR 特征选择结果

Table 6-4 Result of mRMR

故障 2		故障 6	
编号	变量名	编号	变量名
78	Pblower_P_blower	145	TempHEX2_T_nodeend_HEX2_T_hotgas, K
94	TempHEX1_T_node1_HEX1_T_shell, K	189	XNotes_Xnodeend_X_N2_out
133	TempHEX2_T_node3_HEX2_T_hotgas, K	36	IniMassAndTemperature_X_N2_b
35	IniMassAndTemperature_X_O2_b	190	XNotes_Xnodeend_X_O2_out
190	XNotes_Xnodeend_X_O2_out	1	BunerH2

故障 8		故障 10	
编号	变量名	编号	变量名
92	TempHEX1_T_node1_HEX1_T_H2tube, K	139	TempHEX2_T_node4_HEX2_T_hotgas, K
21	ECNotes_ECnodeend_CD, (A/m2)	192	XNotes_Xnodeend_X_H2_out
191	XNotes_Xnodeend_X_H2O_out	107	TempHEX1_T_node4_HEX1_T_fuel, K
198	Stack_Outlet_T	43	IniMassAndTemperature_T_wall
168	TempNotes_Tnodeend_TIC_out, (K)	1	BunerH2

故障 6 表示的位于电堆之后燃烧器之前的空气端发生了漏气, mRMR-ReliefF 选择出的变量都分布在电堆以及燃烧器内部以及进气出气口上, 分布集中, 可以实现准确定位。而 ReliefF 以及 mRMR 选择的变量有分布于换热器 1、换热器 2、电堆以及燃烧器, 涉及多个空气管道, 无法实现精确的定位。

故障 8 表示的燃料供应系统与热交换器之间的燃料连接发生故障, mRMR-ReliefF 选择出的变量都分布燃料进气管道以及换热器上, 可以定位到故障 8 的位置。而 ReliefF 选择的变量比较分散, 在换热器 1、换热器 2、电堆以及燃烧器上均有体现, 无法实现定位。mRMR 选择的变量有分布于换热器 1, 大多分布在电堆中, 和实际故障点不符。

故障 10 表示电堆出口与燃烧器入口之间的燃料连接故障, mRMR-ReliefF 选择出的变量都分布在电堆以及燃烧器上, 明显定位于故障 8。而 ReliefF 选择的变量虽然也比较集中, 但是可能与电堆入口的故障 9 相混淆, 无法精确定位。mRMR 选择的变量有分布非常分散, 在每个部件均有体现, 故无法定位。

6.4 基于 1-阶张量标签随机森林算法的包裹式特征选择

本节主要采用第五章提出的 1-阶张量标签并行随机森林算法，在训练过程中经过少量改进，就可以同时输出特征的度量。故障的识别与定位要同时采用 1-阶上一节提出的基于 ReliefF 的算法，需要对系统变量做冗余性分析，本节采用的向量标签-随机森林算法，可以直接利用变量子集在分类过程的重要性指标来进行特征选择，不需要分析变量冗余性，结合系统部分机理知识可以直接通过特征选择来实现故障的定位。这样做的好处是，在利用故障识别的过程中，就会自动的完成特征选择的过程，不需要额外的增加特征选择算法的成本。本节研究的创新之处在于，将工业系统的机理知识通过变量排序的方式加入到特征选择中，使定位的结果更合理。而且，与 Relief 型特征选择相比，本方法本身没有超参数，这会极大的增加算法的可行性。

6.4.1 Out-of-bag 随机特征挑选

当随机森林随机挑选特征进行决策树的建立过程中，有一些特征不会被选到，这些没有被选到的特征被称作袋外数据（Out-of-bag, Oob）。选择到这个特征与没有选择这个特征对分类的差别就成为了评价这个特征重要性的评估方法。

为了评估泛化误差，所有的特征全集被写作 D ，随机森林在建立决策树的过程中，每次只随机选择一部分特征，没有选择到的就被称作袋外特征。对于回归问题来说，泛化损失的均方误差（MSE）如下：

$$f_{oob}(x_i) = \arg \max_{j \in J} I(h_j(x_i) = y) \quad (6.23)$$

$$MSE_{oob} = \frac{1}{N} \sum_{i=1}^N (y_i - f_{oob}(x_i))^2 \quad (6.24)$$

$f_{oob}(x_i)$ 是对第 i 个变量的预测值。对于分类问题，采用 0-1 损失，均方误差损失如下：

$$E_{oob} = \frac{1}{N} \sum_{i=1}^N I(y_i \neq f_{oob}(x_i)) \quad (6.25)$$

6.4.2 重要性度量的特征选择算法

变量 k 的基于置换的重要性是当变量 k 的值在测试集中随机排列时，预测误差在测试集上增加的估计，如表 6-5。在这方面，这一过程类似于各种方法(如线性回归或 Logistic 回归)所使用的基于系数的重要度量；即，如果预测器的值增加一个单位，则预测值将发生多大的变化，而其他变量则保持不变。因此，随机森林置换的重要性往往会将所有相关的预测因子识别为重要的因素，而其中任何一个都是重要的。算法中显示了在算法描述中以 k 表示的特

定变量在对特定观测的预测上的重要性，该预测由 i 表示。这些值可以作为局部变量重要性的度量，也可以对所有观测值进行平均，以衡量变量的总体重要性。本算法的实质是，利用实际的标签对随机森林预测的标签进行了准确率的衡量，如果利用这个特征的分类效果非常好，那么它的重要性就大；采用这个特征分类效果不发生明显的变化，则这个特征的重要性就低。

表 6-5 变量重要性选择算法

Table 6-5 Variable importance algorithm

Algorithm 6.3. RF Variable importance	
Input: Train data set $R = \{x_1, x_2, \dots, x_{m_v}\}^T$ Label $Y_R = \{y_1, y_2, \dots, y_m\}^T$ Number of tree: J	
1. (Find $y_{i,j}$) For $i=1$ to M :	
a. Let $G_i = \{j : (x_i, y_i) \notin C_j\}$ and let J_i be the cardinality G_i (Running Algorithm 5.2)	
b. Let $y_{i,j} = h_j(x_i)$ for all $j \in G_i$	
2. (Find $y_{i,j}^*$) For $j=1$ to J :	
a. Let D_j be the j th bootstrap sample (Running Algorithm 5.2)	
b. Let $F_i = \{j : (x_i, y_i) \notin C_j\}$.	
c. Randomly permute the value of variable k for the data point $\{x_i = i \in F_j\}$ to give $P_j = \{x_i^* : i \in F_j\}$	
d. Let $y_{i,j}^* = h_j(x_i^*)$ for all $i \in F_j$	
Output: Importance of variable: For $i=1$ to M	
$\text{Imp}_i = \frac{1}{J_i} \sum_{j \in G_i} I(y_i \neq y_{i,j}^*) - \frac{1}{J_i} \sum_{j \in G_i} I(y_i \neq y_{i,j})$	

6.4.3 重要性度量实验结果


一旦检测到系统故障，就必须确定其根源。故障诊断是指对过程变量进行检索，找出故障的一个或多个根源的过程。本节描述了基于随机林算法提供的特征重要性度量的故障源发

现过程。

表 6-6 代表性故障

Table 6-6 Three representative faults

Fault name	Fault classes
Air leakage (A)	Air linkage 1
Burner exhausted leakage (B)	Air linkage 7
Fuel leakage (F)	Fuel linkage 8






图 6-8 不同故障的变量重要性排序与特征选择

Fig 6-8 Variable importance and feature space

表 6-7 特征选择空间与变量编号

Table 6-7 Feature selection space and corresponding number

Faults		Number and variables									
A		5	11	10	1	-	-	-	-	-	-
Selected Variable s		N_{Air_cont}									
		P_{blow}		$rol,$		$P_{system},$					
		$r, (W)$		(mod/s)		SE		(W)			
F		115	121	109	88	97	85	94	100	91	124
Selected		$T_{fuel_}$	T_{fuel_H}	T_{fuel_H}	T_{H2tube}	T_{fuel_H}	T_{fuel_H}	T_{H2tube}	T_{H2tube}	T_{fuel_H}	T_{H2tube}

Variables	HEX2_N1, (K)	EX2_N2, (K)	EX1_Nend, (K)	_HEX1_N1, (K)	EX1_N3, (K)	EX1_N1, (K)	_HEX1_N2, (K)	_HEX1_N3, (K)	EX1_N2, (K)	_HEX2_N2, (K)
B	144	140	6	143	57	142	141	165	18	51
Selected Variables	$T_{shell_HEX2_Nend}$	$T_{air_HEX2_Nend}$	N_{Air} (mol/s)	$T_{airtube_HEX2_Nend}$	$T_{air_Mix_er_out}$	$T_{H2tube_HEX2_Nend}$	$T_{hotgas_HEX2_N2}$	$T_{air_Stac_k_N1}$	CD_N2	$T_{exhaust}$

故障源定位结果与分析

本节根据上一节的结果进行分析。三种类型故障的特征重要性如图所示。图 6-8.a-c 显示了每个故障的特征重要性排序。图 6-8.d-e 显示了特征重要性比较高的变量以及对重要性的贡献程度。通过特征选择出来的特征空间，如表 6-7 所示。

对于故障 A，与正常状态相比，导致故障状态的最重要变量是鼓风机功率 (P_{blower})、控制器空气流量要求 ($N_{Air_control}$)、系统效率 (SE)和系统功率 (P_{system})。这些变量占了所有分类重要性的 98%，从而表明故障状态与正常状态之间的差异主要是由所选的四个特征引起的。也就是说，选取的四个特征是 A 故障的来源，即故障 A 的特征空间贡献。SOFC 系统机制表明随机森林重要性测度选择的故障源是非常合理的。在 SOFC 系统中，采用空气流量来控制电堆温度。当发生漏风故障时，进入电堆的空气减少会使电堆温度升高。然后，控制器将增加空气流量，使电堆温度保持在一个稳定的值。因此，故障 A 会增加鼓风机功率 (P_{blower}) 和控制器的空气流量要求($N_{Air_control}$)。随着寄生功率的增加 (P_{blower})，系统功率(P_{system})和系统效率 (SE) 将下降。所有变量的异常都可以通过随机森林特征重要性度量来发现，如图所示。8.a 和 8.d 和表 6。

对于故障 F，用于故障数据的重要变量如图所示。图 6-8.b 和图 6-8.e 及表 6-7。燃料温度 ($T_{fuel_HEX2_N1}$, $T_{fuel_HEX2_N2}$, $T_{fuel_HEX1_Nend}$, $T_{fuel_HEX1_N3}$, $T_{fuel_HEX1_N1}$, and $T_{fuel_HEX1_N2}$)和燃料管道温度 ($T_{H2tube_HEX1_N1}$, $T_{H2tube_HEX1_N2}$, $T_{H2tube_HEX1_N3}$, $T_{H2tube_HEX2_N2}$)与换热器的燃料温度有关。根本本研究的方法没有详细的机理，也可以推断出故障特征空间与换热器前的燃料供应有关。

对于故障 B，对故障数据作出贡献的重要变量如图所示。图 6-8.c 和 6-8.f 及表 6-7。选择的特征空间包括换热器 2 ($T_{shell_HEX2_Nend}$, $T_{air_HEX2_Nend}$, $T_{airtube_HEX2_Nend}$, $T_{H2tube_HEX2_Nend}$)的温

度、空气流量(N_{Air})、电堆电流密度 (CD_{N2})和燃烧器排气温度 ($T_{exhaust}$)。从故障特征空间可以推断,这种故障主要影响第二换热器的温度,特别是换热器的最后一个节点(Nend)。对电堆参数和燃烧器排气温度也有影响。从机理上看,燃烧器直接连接时,燃烧器排气泄漏必然会影响二次换热器温度。

6.4.4 实时监控系统

从前面的分析中,特征重要性度量可以发现每个故障的来源。然而,确定性推理仅仅是基于所选的故障变量空间,这就需要必要的理论基础。设计了一种利用故障源空间对重要变量进行快速高效故障诊断的故障监测系统,如图 6-9 所示。




图 6-9 重点变量实时监控系统

Fig 6-9 Important variable real-time monitoring system

基于故障特征空间的变量监控系统可以构建。可以监测风机功率 (P_{blower})、控制器空气流量要求($N_{Air_control}$)、系统效率 (SE)和系统功率 (P_{system})。如果这四个变量同时出现异常,则出现故障 A。同样,当燃料温度 ($T_{fuel_HEX2_N1}$, $T_{fuel_HEX2_N2}$, $T_{fuel_HEX1_Nend}$, $T_{fuel_HEX1_N3}$, $T_{fuel_HEX1_N1}$, $T_{fuel_HEX1_N2}$)和燃料管道温度 ($T_{H2tube_HEX1_N1}$, $T_{H2tube_HEX1_N2}$, $T_{H2tube_HEX1_N3}$, $T_{H2tube_HEX2_N2}$)出现异常状态时,应采取故障 F 的对策。B 故障的故障变量空间应与以下变量完全一致: 换热器 2 ($T_{shell_HEX2_Nend}$, $T_{air_HEX2_Nend}$, $T_{airtube_HEX2_Nend}$, $T_{H2tube_HEX2_Nend}$)、空气流量 (N_{Air})、电堆电流密度 (CD_{N2})和燃烧器排气温度 ($T_{exhaust}$)。由于冗余数据维度的存在,监控上述多变量过程具有挑战性。这样,SOFC 系统中的重要变量就可以被实时监控,从而增加了工业系统的安全性。

6.5 张量标签学习-随机森林算法的故障识别与定位

本节基于第五章的 1-阶张量标签-随机森林算法以及第六章的随机森林故障定位,介绍张量标签学习的随机森林故障识别与定位系统。采用同一套机器学习算法同时达到故障识别与

定位的目的。此过程也可以将识别与定位并行计算，然后统一采用张量标签学习来度量，具体情况可以根据需求来选择合适的机器学习算法。




图 6-10 张量标签学习-随机森林故障识别与定位流程图

Fig 6-10 Tensor label learning-random forests fault identification and location process

图 6-10 表示的是张量标签随机森林故障识别与定位算法的流程图，采用同一套算法就可以同时故障的识别与定位。流程如下：

步骤 1: 训练样本包括数据样本 X ，数据样本同时带有两类标签，故障的标签和故障位置标签，按照故障识别与定位矩阵型标签的格式进行编码，得到实际的识别与定位张量标签流 H_{dl} 。

步骤 2: 输入随机森林算法时，进行沿着定位方向切片与计算，得到故障的类别标签 (D)，然后将每个样本的数据 (X) 和类别标签 (D) 输入到随机森林分类器中进行训练，算法 5.2。

步骤 3: 训练的过程中，利用随机森林的特征重要性度量算法，得到故障的定位，算法 6.2。

步骤 4: 将带时间维度的故障类型标签流与故障定位流，按照 DL 形式组合成预测输出张量标签流 D_{dl} 。

步骤 5: 计算的 F1 评价指标，就是故障的识别与定位统一定量化定位指标。

采用 ReliefF 型特征选择算法（算法 6.1，算法 6.2）的故障识别与定位算法与图 6-10 类似，区别在于故障定位的环节与故障识别算法（算法 4.1）并行的进行，其他部分类似。表 6-8 表示了识别与算法的组合形式。




图 6-11 张量标签学习的识别与定位算法

Fig 6-11 Tensor label learning fault identification and location

对于随机森林算法，可以采用同一套算法同时得到故障的识别与定位，如图 6-10 所示。但是许多情况下可以根据具体算法的特点和需求选择合适的算法，张量标签学习的识别与定位算法流程如 6-11 所示，具体算法的选择如表 6-8。

表 6-8 识别与定位算法

Table 6-8 Fault identification and location algorithm

并发故障识别算法	故障定位算法
算法 4.1 Parallel SVM	算法 6.1 ReliefF
算法 5.1 Parallel random forests	算法 6.2 mRMR-ReliefF
	算法 6.3 RF variable importance

6.6 张量标签学习定量化定位结果

在故障定位中，利用特征选择算法可以得到一个特征变量的子集，这个子集也就是最能反映故障位置的信息。由于工业系统具有非常多的样本，这就需要解决的问题是特征在特征空间里的排序，不同的排列顺序可能会导致选择出的特征子集不同。

先采用相似性度量的方法，对系统的变量排序进行处理，处理步骤如下：

- 步骤 1：**根据工业系统机理，选择系统内部最重要的变量，编号为 x_1 ；
- 步骤 2：**根据 $Diff(A, B)$ 的计算格式，计算每一个变量与 x_1 的关系；
- 步骤 3：**按照与 x_1 相似性从大到小排列 $x_1 \dots x_{nv}$ 。

预测变量重要性的度量在变量选择和拟合森林解释中是有用的。从算法中直接获得变量的重要度，仅使用最重要的预测因子进行重构是较好的方法。

这种一维空间度量方式表达的是所有过程变量与系统最终输出的相似性关系的度量，按照相似性度量 $Diff(A, B)$ 来衡量。 $Diff(A, B)$ 表示的两个变量之间的相似性度量，采用的标准不同得到的结果也不同，可以根据需求来定义。

利用 3.3 节的定量化定量，公式 3.25-3.29 计算得到表 6-9。

表 6-9 一维定位与二维定位精度
Table 6-9 1-D fault location and 2-D fault location

故障类型	RF 一维定位精度 ($F1_{11}$)	RF 二维定位精度 ($F1_{12}$)	mRMR-ReliefF 一 维定位精度($F1_{11}$)	mRMR-ReliefF 二 维定位精度($F1_{12}$)
A	85%	86%	64%	62%
F	75%	78%	54%	55%
B	81%	83%	72%	76%

表 6-8 表示的是一维定位精度和二维定位精度，在实验中，采用第五章叙述的 SOFC 系统的三类故障：空气进气端漏气（A）、燃料漏气（F）和燃烧室尾气漏气（B），取 5 个变量作为定位变量数目，利用实际变量损坏矩阵 H_i 和定位矩阵 D_i 的关系来评价定位精度。表 6-8 反映的是故障定位系统的故障定位能力，与定性分析不同，基于张量标签学习可以定性的评价故障定位的精度，从表可以看出随机森林（RF）算法的定位精度要比 mRMR-Relief 算法精度高很多，后续的定位度量默认都采用 RF 算法。定量化定位对于系统的安全性、故障的处理能力具有很重要的意义。

利用 3.4 节叙述的识别与定位 2-阶张量标签流的评价，公式 3.34-3.37，计算得到表 6-10。

表 6-9 反映的是故障识别与定位评价指标，可以看出系统对故障 A 的识别和定位都具有比较好的效果，而故障 F 的识别难度较大，这是因为燃料环路的控制并不是作用在燃料气体的供应上，而是通过电流控制间接控制的，这就会使系统很多电特性的变量发生异常，造成了定位与识别的难度。故障 B 位于系统的最末端，与其他的变量在物理上和逻辑上都较远，变量特征非常明显，所以相对来说好识别与定位。

表 6-10 识别与定位评价体系
Table 6-10 Fault identification and location evaluation system

故障类型	故障识别 ($F1_d$)	1-D 定位 ($F1_{11}$)	2-D 定位 ($F1_{12}$)	1-D 定位与故障 识别 ($F1_{d11}$)	2-D 定位与故障识别 ($F1_{d12}$)
A	85%	85%	86%	75%	66%
F	75%	75%	78%	55%	58%
B	81%	81%	83%	61%	73%

表 6-10 反映的是故障识别与定位评价指标,可以看出系统对故障 A 的识别和定位都具有比较好的效果,而故障 F 的识别难度较大,这是因为燃料环路的控制并不是作用在燃料气体的供应上,而是通过电流控制间接控制的,这就会使系统很多电特性的变量发生异常,造成了定位与识别的难度。故障 B 位于系统的最末端,与其他的变量在物理上和逻辑上都较远,变量特征非常明显,所以相对来说好识别与定位。

6.7 本章小结

本章提出了一种基于特征选择的故障定位方法,用来实现基于数据模式的故障变量定位。首先,研究了特征选择唯一准确定位到故障源变量的条件,工业系统要满足是能量耗散网络;然后,根据系统变量相似性判断出特征相似组并给出了相应的证明。本研究采用优化的 ReliefF 特征选择算法挑选与故障类别最为相关的特征,结合模型特征采集的位置进行故障定位,并通过在 SOFC 系统上的实验仿真验证该方法的可行性。为采用同一套算法同时解决故障的识别与定位,本章采用随机森林的特征性度量来选择合适子集,从而确定故障发生的位置。通过张量标签学习的定量化评价,定量化评价了故障定位的精度。最后给出了故障识别与定位的张量化标签处理算法框架,可以采用同一套算法同时实现故障的识别与定位,也可以根据具体需要分别选择故障识别和故障定位算法。

第 7 章 基于张量标签学习的主动容错控制

7.1 引言

本章研究工业系统老化故障或是系统性能衰退故障下的容错控制。老化故障下的系统，是一种高复杂度、非线性的连续时变系统，传统的辨识方法无法得到高精度的模型，也就难以精确的控制。这类故障具有几个特点，第一，工业系统老化的参数是时变的；第二，参数的变化是连续的，但不一定是有规律的，难以用具体的数学模型表达的；第三，此类故障可以采用主动容错控制的方式进行恢复，这类故障不会对工业系统的控制系统造成极大的危害，不至于造成停机，但会使控制器性能下降甚至是失效，采用主动容错控制可以将此类故障的危害降低，可能系统效率会降低，但可以使控制系统至少维持稳定。

本章主要解决以下个问题：

(1) 工业系统的老化故障下，老化的状态在某一个时间节点是稳定的，但工况一直是变化的，如何通过采集自不同工况下的数据来进行故障的辨识，学习变工况情况下同一个故障类型的不变特征，是首先需要解决的问题。

(2) 在老化故障的情况下，系统的参数是时变的，而且这种时变参数无法用准确的数学表达式来描述，这就使通过设计传统观测器的方法来辨识当前的状态变为不可能，也无法根据输出反馈或者状态反馈的方法设计有效的控制器。如何能够设计一种在线的辨识系统的时变参数的算法，然后根据系统当前参数来设计控制器，就是容错控制器需要解决的难点。

大多数传统的控制技术，获取被控对象的精确的数学模型是设计控制律的前提条件，控制性能的获得很大程度上依赖于对象数学模型的精确与否。为了解决上述难题，本章首先采用无模型的 PID 控制与故障识别相结合的方法。采用张量标签学习对故障类型进行识别，针对这类故障的特性设计了一种决策树式的识别策略。通过故障识别的结果判断当前的故障状态，从而可以利用参数选择机制调整控制器的参数。为了应对连续的衰减的故障情况，本节对于 0-阶标签 SVM 算法进行了改进，针对连续的衰减故障的特征，本节采用决策树式的方式对 SVM 的多分类策略进行了改进，这种算法比 1-v-1 和 1-v-r 两种 SVM 集成策略更加适合识别工业系统老化故障。从识别与定位角度，本文的标量标签，可以看做是高维张量标签流在单故障维度的张量纤维。

为了解决工业系统老化故障系统系统参数时变而且无法用准确的数学方程来表达的难点，利用机器学习方法在线辨识时变系统参数，本章提出了一种基于 TS 型的贝叶斯学习机与 GPC 相结合的方式，在一定的时间窗内在线辨识缓慢变化故障下的系统参数，并将输入输出关系映射输入到 GPC 控制器中，实现了控制律在线重组型主动容错控制。

7.2 基于 0-阶张量标签学习的故障识别算法

基于 0-阶张量标签学习识别算法的故障识别，与传统监督学习算法在学习方法形式上相同，但 0-阶张量标签学习标签格式上，是更高阶张量标签的 0-阶空间的投影，高维信息仍然存在，只是根据当前的需求将暂时用不到的高维信息通过张量计算去除掉。本章研究的 SOFC 系统容错控制不需要故障位置信息，但有些情况下，故障的位置信息可以直接参与控制。

在 3.2 章介绍了 0-阶张量学习，可以认为是利用张量故障识别与定位矩阵沿着定位角度的切片，采用容错控制的方法，针对某些故障可能进需要知道故障的类型，但信息仍然存在标签中，采用 DL 矩阵的 2 次张量切片与计算后，可以得到 0-阶张量标签学习的标量编码方式。因为在控制的类型判别中，不需要进行 F1 标准的计算，因此将向量编码方式转化为自然数的形式，采用传统的准确率评价标准。




图 7-1 张量标签学习-主动容错控制流程图

Fig 7-1 Tensor label learning-fault tolerant control processing

前几章中研究的张量标签的故障识别与定位对故障的类型与位置给出了认知和量化的描述，与容错控制结合时，由于故障的原因复杂多样无法统一的进行描述，本文仅研究故障的类型对系统参数产生的影响，因此，故障的位置因素可以作为控制器设计的参考因素，并不直接参与控制过程。容错控制的参数调整仅采用控制类型，直接参与控制器的参数选择。具体步骤如图 7-1。

步骤 1: 根据正常状态的控制关系，得到控制有向拓扑矩阵，并得到控制有向拓扑矩阵标签流 (H_c)；

步骤 2: 利用张量标签学习故障识别与定位算法，得到当前故障的识别与定位标签流 (D_{dl})， D_{dl} 包含故障的类型信息与位置信息，可以利用这两类信息对控制律进行重组或者

重构;

步骤 3: 在老化故障的主动容错控制中, 将 D_{dl} 进行切片有向与计算, 得到 0-阶张量型标签流, 也就是每个时刻的故障类型;

步骤 4: 根据当前故障的类型, 选择整定好的控制参数, 从而实现主动容错控制;

步骤 5: 重新评估控制有向拓扑矩阵 (D_c), 计算 $comp(H_c, D_c)$ 得到在故障状态下控制系统维持律。

7.2.1 决策树式多分类

本文提出一种决策树式的多分类方法来应对故障类型连续且具有一定顺序的情况。通过决策树式的 SVM 多分类算法, 首先, 层级决策树法把所有类分为两个子类, 然后将每个子类再细分为两个更小子类, 以此类推, 直到所有类别被分开, 如图 7-1 所示。




图 7-2 决策树式多分类示意图

Fig 7-2 Hierarchical classification

不同多分类策略所需 SVM 的个数, 如表 7-1 所示。考虑到本文研究的是识别 SOFC 电堆故障, 不同故障的区别是电堆的衰减程度不一样 (2%、4%、6%、8%、10%), 因此不同故障之间是存在一定层次性的。同时, 真实的 SOFC 系统故障诊断对速度要求很高, 需要达到实时诊断。鉴于以上原因, 本文采用决策树层级法构造多分类 SVM (Decision Tree SVM, DT-SVM)。

表 7-1 不同多分类的分类器

Table 7-1 Classifier number in different multi-class method

多分类策略	分类器个数
一对一法	$k(k-1)/2$
层级法	$k-1$

7.2.2 基于 0-阶张量标签的多工况故障识别

通过采集 SOFC 的数据建立故障的模式 X ，然后通过 PCA 特征提取方法进行降维，再利用低维空间的数据进行 SVM 分类。本研究利用的工业数据是不同工况的数据，同一种类型的故障下采集不同工况的数据，这样就采集了这种类型的故障的完整的信息，利用这些不同工况下的故障模式进行学习，学习器学习到的是这个故障类型最本质的特征，在预测环节，就算这个故障的工况之前没有采集过，也可以实现故障的变工况预测。本研究的方法，将不同工况下的故障识别问题转化为故障模式的识别问题，利用 0-阶张量标签学习解决了变工况故障的判别。




图 7-3 变工况模式识别方法

Fig 7-3 Fault class identification in different working conditions

在数据驱动的故障分类过程中，如图 7-3，首先要准备两种数据集：训练数据集和测试数据集。训练数据集应该被标记，这意味着应该知道数据的故障类型，然后数据可以用来训练分类器。高维数据应该降低维，这对于数据处理来说要快得多。由于数据是冗余的，PCA 提取的特征不会失去其主要特征。采用低维训练多类支持向量机，然后利用训练 SVM 对测试数据进行故障类型分类。

表 7-2 PCA-DT-SVM 决策树式故障识别算法

Table 7-2 PCA-DT-SVM fault identification algorithm

Training period	Input: Training data set: $D = \{x_1, x_2, \dots, x_m\}^T$, Label $Y_D = \{y_1, y_2, \dots, y_m\}^T$ Testing data set: $T = \{t_1, t_2, \dots, t_m\}^T$ Low dimensional space dimension: N
	PCA Normalizing: For each variable $\bar{x}_i = x_i - \frac{1}{n} \sum_{i=1}^n x_i$ End for $X = \{\bar{x}_1, \bar{x}_2, \dots, \bar{x}_m\}^T$
	Covariance matrix: $C_x = XX^T$
	Eigenvalue decomposition: $C_x = W^T \Lambda W$, $\Lambda = \text{diag}[\lambda_1, \dots, \lambda_n]$
	Principle analysis: Selecting top N largest λ and the corresponding eigenvector $w_1, w_2, \dots, w_N$
	PCA Output: Projection matrix: $W_p = (w_1, w_2, \dots, w_N)$
	SVM training input: Low dimensional space: $D_L = W_p^T D$
	SVM Training: Train the multi-class SVM by D_L and Y_D
	Output: Trained multi-class SVM
	SVM testing input: Low dimensional space: $T_L = W_p^T T$
Testing period	Testing: T_L input the trained multi-class SVM Output: T_L corresponding classes Y_L T corresponding classes is also Y_L
	Output: T corresponding classes Y_L

7.2.3 实验结果

在 MATLAB 2017a 软件的 Simulink 环境下, 给出了 SOFC 系统数据驱动的故障诊断-容错控制集成技术策略。数据驱动的 PCA 和 SVM 在 Python2.7 中运行, 然后.py 文档也可以在 MATLAB 软件中运行, 并将分类结果传递给 SOFC 控制器。

数据预处理

上述 SOFC 装置的参考工况包括正常运行状态和故障状态两个阶段。正常运行条件为：系统功率约 5000 W，电堆温度约 960 K，燃烧器温度约 1140 K。故障状态：由于电堆功率退化约为 2%、4%、6%、8%、10%，因此采用功率下降来设置误差。由于控制目标是通过增加燃料来恢复退化，保持燃烧器温度的稳定，所以堆积物的退化程度不应设定过高。设置误差幅度后，由 201 个变量创建数据集，每个变量收集 4000 点。各工况的训练数据为 201×4000 矩阵。

表 7-3 故障类型

Table 7-3 Fault type

Stack degradation	Fault type
Normal	Mode 0
2%	Mode 1
4%	Mode 2
6%	Mode 3
8%	Mode 4
10%	Mode 5

PCA-SVM 故障识别




图 7-4 PCA 主元贡献图

Fig 7-4 Principle Component Analysis

在应用 SVM 之前，减少数据维数是非常重要的。避免具有更大的数值范围的属性支配具有较小数值范围的那些属性是缩放的主要优点。在计算过程中避免数值困难是另一个优点。因此，具有较大值的属性可能导致数值问题。应用 PCA 方法将数据的维数从 201×4000 降为 8×4000。解释的主成分方差百分比在图 7-4 中示出。本研究选择了 8 个最大主成分，保留方差比为 99.10%。训练数据集的第 1、第 2 和第 3 个尺度数据。图 7-5 示出了 PCA 之后的三个最大尺寸数据。图 7-5 示出了 PCA 之后的数据更易于分类。




图 7-5 变工况故障的模式可视化

Fig 7-5 Fault raw data pattern and PCA

表 7-4 程序运行时间

Table 7-4 Running time

Process	Running average time	Running average time
	(PCA-SVM)	(DT-SVM)
Normalizing	0.070467 s	0.070467 s
Training SVM	86.840932 s	7.329922 s
Testing (Training Data)	28.485807 s	1.379304 s
Testing (Training Data)	10.236343 s	0.502901 s
(one calculation cycle)	0.001329 s	0.000065 s

图 7-6 显示了训练数据的测试结果。对于前 2434 点，SOFC 在正常运行状态下运行，然后分别采集故障 1，2，3，4 数据约 1784 点。从图可以看出，多类 SVM 可以对故障类型进行分类。但从分类结果中可以看出一个明显的现象，即从一开始就会发现故障是以前的故障。例如，故障模式 5 在开始阶段被划分为模式 1、模式 2、模式 3、模式 4。这是因为 10%左右的电堆故障不会突然发生，实际上 10%的电堆衰退应该从 2%、4%、6%、8%缓慢发生，最终达到 10%。




图 7-6 故障类型识别

Fig 7-6 Fault classification results

表 7-5 识别精度

Table 7-5 Fault diagnosis accuracy

Stack Fault	Fault class	DT-SVM Classification accuracy without PCA	DT-SVM Classification accuracy with PCA
Normal	Mode 0	99.9%	99.9%
2%	Mode 1	96%	96%
4%	Mode 2	90%	92%
6%	Mode 3	85%	91%
8%	Mode 4	79%	91%
10%	Mode 5	75%	88%

故障诊断的准确性见表 7-5。结果表明，PCA 分类效果优于不使用 PCA 的分类方法。究其原因，主要有三个方面。

- 1) 首先，在减少维数后，减少特征数，有效地避免过拟合；
- 2) 对扰动变量进行 PCA 去噪，得到最有价值的特征。
- 3) 提取的特征可以大大提高分类器的训练和测试速度。

利用主成分分析方法（PCA），提高了多类 DT-SVM 的精度和快速性。故障分类结果将在下一节中使用，以决定选择哪个故障恢复控制器。

7.3 控制律重新调度的主动容错控制

本节研究的是主动容错控制的控制律重新调度的方法。本节的控制系统，在现实中的 SOFC 系统中应用成功。控制律重新调度提前已知常见的故障类型，针对每个故障的类型提前整定几套应对这些故障类型的控制参数，利用设计好的 FDD 单元在线的判断故障的类型，再从整定好的控制参数库中选择相应的控制器参数，从而实现容错控制的过程。利用上一节节设计的故障识别系统作为 FDD 环节，根据故障识别的结果选择控制器增益参数。本节提出的方法，具有几个优势：第一，控制律重新调度类方法是最普遍的最有效的主动容错控制方法，避免了被动容错控制的被动型容错的缺点，主动的对故障进行干预；第二，本节提出的主动容错控制是不依赖与模型的控制系统，全部控制系统采用传统的 PID 控制与数据驱动的机器学习方法相结合，不需要知道系统详细的机理，可以处理非线性系统。第三，训练得到本控制系统之后，控制系统的运行非常快速，可以实现工程化实践。

7.3.1 燃料电池系统的控制系统

在容错控制器之前，首先要设计系统的控制系统。固体氧化物燃料电池 (SOFC) 与传统发电系统相比，具有发电效率高、温室气体排放低、运行安静等优点，可以直接利用氢气或者碳氢化合物进行发电。SOFC 系统由于能高效的发电效率，特别适合用于分布式替代电站的建设。而且，其低污染排放特性以及安静运行特性，使得 SOFC 适合于安放在市区和人口稠密地区，以满足居民用电负荷和商业用电负荷的需要。虽然 SOFC 系统具有许多优点，但由于系统的耐久性和可靠性问题，SOFC 系统还没有达到商业化的程度。因此，必须开发一种既能保证系统安全又能使系统高效运行的有效控制方法。在系统存在常见故障的时候，能够有一定的容错能力。

近些年，许多文献研究了 SOFC 系统的控制问题，总体来说，这些文献主要解决了三个控制目标：（1）控制 SOFC 系统的功率输出，让发电系统能够快速的满足功率负载的需要 [154-161]；（2）将 SOFC 关键部件，如电堆、燃烧器和交换器的温度保持在安全运行极限以下，并保持在一个最优的范围内 [162-168]；（3）保证较高的燃料利用率 (FU) 和系统效率 (SE) [169-174]。为了实现 SOFC 系统的最优运行状态，必须设计一种快速、高效、易于应用、鲁棒性强的整体控制方案来解决上述的控制目标。然而，燃料电池系统的强耦合特性导致了控制设计的困难，SOFC 系统的变量耦合情况如图 7-7 所示。SOFC 作为一个多变量系统，具有多个相互耦合或相互作用的输入和输出变量。一个输入的变化往往会影响多个输出变量，这就使控制设计者很难采用输入-输出配对的方式设计控制回路，调节一个控制器参数会影响另一个控制器的性能，并有可能会破坏整个系统的稳定性。

通过设计一种解耦控制方案，可以将多变量 SOFC 系统简化为几个不存在交叉耦合或变

量间相互作用的单变量系统，这对 SOFC 的控制至关重要。通过解耦控制的应用，每个 SOFC 输出变量只受一个参考输入变量的影响，每个输入-输出对都可以由单输入-单输出 (SISO) 控制器控制，与多变量控制相比这对于控制工程实践来说更加容易，硬件成本更低。在文献^[175]中采用自校正比例积分微分(PID) 设计了 SOFC-MGT 混合系统的功率解耦控制器，用以独立控制 SOFC 功率和 MGT 功率。文献^[176]针对 SOFC-GT 联合系统，提出了一种基于动态扰动解耦控制的控制方案，用于向燃料电池提供压缩空气以控制质量流量和压力。然而，据笔者所知，目前还没有对 SOFC 的热-电特性进行解耦控制的研究，从而给实现系统的高效运行和保证安全带来了方便。




图 7-7 SOFC 系统耦合关系

Fig 7-7 Decoupling relationship in SOFC




图 7-8 结构性冗余 AOR 装置的 SOFC 系统

Fig 7-8 SOFC system with redundancy AOR structure

阳极未利用燃料回收 (AOR) 是将阳极尾气部分回收阳极入口的一种新方法，已被广泛应用于提高 SOFC 系统效率的研究中。用于氢燃料 SOFC 系统 (图 7-8)。解耦控制器的设计，由于缺乏建立输入-输出对所需的控制输入，使得被控对象的输出变量难以独立管理。因

此,为了缓解变量间相互作用的解耦问题,本研究将 AOR 作为一个独立的操作变量来设计解耦控制结构。AOR 适用于氢燃料 SOFC 的系统级解耦控制,因为无改造反应的氢燃料 SOFC 系统自给热需要较少的燃烧器产生的热量,而 AOR 可以防止废气中的过量氢进入燃烧器产生无用的热量。虽然以往的许多工作都使用了 AOR 来提高系统的效率^[177-180],本文首次利用 AOR 在系统级控制中的作用进行了研究,结合 AOR 系统来实现系统的解耦控制。

本节研究的目的是通过 AOR 结构冗余系统,来控制电堆的输出,减少电堆故障对整个系统的影响。方法采用的是解耦控制的方法,将基于动态 SOFC 模型的氢燃料电池系统中的热和电参数之间的相互作用解耦起来,将多输入多输出 (MIMO) 控制系统简化为多个单输入单输出控制系统,适用于控制器的开发和实现。通过利用 AOR 方法,我们设计的解耦控制器解决以下问题:

(1) 容错控制的问题。电堆的故障会造成电堆发电能力不足,燃料无法消耗。从电堆中输出过多的燃料会输入到燃烧室,由于燃烧室是唯一的热源会造成整个系统的温度升高。这会造成 SOFC 系统的温度出现非常大的波动。

(2) 热-电解耦。燃烧器的温度可以独立控制,通过 AOR 的作用,消除由于负载功率改变而造成的燃料流量增加。这样,电堆温度可以独立进行控制,而不受电特性波动的显著影响,从而实现热-电解耦。

(3) 快速负荷跟踪和避免燃料亏空。对于发电系统来说,系统的功率快速跟踪性能是非常重要的,但由燃料供应时间延迟引起的功率跟踪能力不足,可以通过适当处理的 AOR 比率得到提高。由于 AOR 结构提供了一部分燃料供应,也就使燃料消耗时间的增加,从而增加了功率负载跟踪能力和燃料亏空的应对能力。

为了有效地管理系统级参数,应在本节中定义一些运行参数,包括燃料利用率 (FU)、旁路比 (BP)和系统效率 (SE)^[170, 171, 173, 174]。特别是要有效地管理 SOFC 的热电参数,必须定义阳极废气循环比 (AORR)。系统级操作参数定义如下:

$$FU = \frac{\text{fuel consumed in stack}}{\text{fuel entering the stack}} = \frac{nI}{2F(dN_{H_2}/dt)} \quad (7.1)$$

$$SE = \frac{\text{SOFC power}}{\text{stack power}} = \frac{P_{\text{stack}} - P_{\text{blower}} - P_{\text{offgas,blower}}}{P_{\text{stack}}} \quad (7.2)$$

$$BP = \frac{\text{air through bypass manifold}}{\text{air through main manifold}} = \frac{d(N_{\text{air,bypass EX}})/dt}{d(N_{\text{air}})/dt} \quad (7.3)$$

在 AOR 系统中尾气回收率 (AORR) 是最重要的指标,它表示电堆尾气的回收比例,如下所示:

$$AORR = \frac{\text{fuel recycling rate}}{\text{anode offgas rate}} = \frac{d(N_{\text{recycle}})/dt}{d(N_{\text{offgas}})/dt} \quad (7.4)$$

7.3.2 结构冗余装置




图 7-9 结构性冗余装置

Fig 7-9 The structural redundancy

从容错控制的角度，AOR 结构需要三个参数来实现解耦控制和负载跟踪问题：

- (1) 控制进入燃烧器的燃料量；
- (2) 将过量的废气燃料安全有效地回收到电堆（Stack）中；
- (3) 在燃料消耗和燃料供应之间起到缓冲作用，在 AOR 结构中存储一些燃料，以便在需要时为电堆提供燃料。

从容错的角度来讲，发电系统发生损坏最大的可能是发电能力的下降，从而造成系统中的燃料过量问题，采用冗余的结构合理的处理这些过量的燃料，要也就是增加了一个结构冗余的容错系统。

近年来，为提高功率输出和系统效率，许多文献^[177-180]采用了气体再循环喷射器和鼓风机等不同的循环结构。重整装置不存在于氢燃料 SOFC 系统中，因此，需要冷凝才能将水气从尾气中除去，如图 7-9 所示。AOR 结构由分离器、冷凝器、AOR 鼓风机和混合器组成。冷凝器是 AOR 中的关键部件，阳极尾气通过 AOR 鼓风机收集、浓缩、储存和输送到电堆。分离器迫使部分废气进入再循环管道。在此期间，废气中含有氢气和水蒸汽。利用冷凝来去除尾气中的水，并将多余的氢气储存在 AOR 结构中。冷凝的作用是通过冷却水将水气降至 333 K (60°C)。废气只保留氢气，而氢气储存在凝结物中。该混合器用于混合回收的低温度氢气和高温氢气，也用于控制阳极压力。

7.3.3 解析冗余控制系统与控制律重新调度

在这一部分中，我们提出了基于 AOR 的 SOFC 系统解耦控制方案，将多变量系统简化为多个单变量系统，尽量多的解除系统变量之间的耦合关系。在每个单变量系统中，输出变量

由一个操作变量控制。考虑到单变量控制比多变量控制容易得多,解耦控制特别适合于 SOFC 控制工程实践。本章采用解耦的方式,将重要控制变量以及增广的变量(AOR)都采用操作变量进行控制,从而实现了解析冗余。

控制指标与控制变量选择

在设计和实现解耦控制器之前,必须选择合适的 MIMO 系统、SOFC 系统的控制变量配对。选择合适的控制变量配对将决定输入-输出 (Input and Output) 对,通过 SISO 控制器的实现,输出变量可以由输入参考变量控制。在解耦控制方案中,所有的 SISO 控制器都是基于 PID 的控制器。PID 控制器结构简单,工程实际性能好,适用于处理鲁棒性和稳定性较好的复杂 SOFC 系统^[167, 168]。

在本研究中,将电压保持在恒定的范围内,通过控制燃料流量和电流来控制功率。在电气参数方面,通过实现 DC/DC(DC/AC)变换器等电子器件的实现,可以独立地控制电流。

(1) 通过对电流的控制,系统电源可以满足要求^[158-160];

(2) 调节燃料流量,维持一定的燃料流量,供应负载电流^[95, 160];

(3) 限制电流,以确保电压保持在安全值,以防止燃料在电堆亏空造成阳极氧化^[160, 161]。在电参数上,可独立控制电堆入口温度、电堆出口温度和燃烧器温度。

(4) 可以通过调节空气流量和 BP 值来维持电堆正常的工作温度^[162, 163];

(5) 作为操作变量的 AOR 是热电参数相互作用解耦的关键。AORR 用于独立控制燃烧器温度,不受功率波动的影响。所有控制变量都可以在表 3-8 中找到。

表 7-6 控制配对

Table 7-6 Control variable pairing

Manipulate variables (MV)	Control variables (CV)
Current	Power
Air flow	Stack inlet T
Air bypass ratio (BP)	Stack outlet T
AORR	Burner T

以下各节讨论了所选控制变量配对的实现和解耦设计。

电堆控制器

由于 SOFC 的目的是通过电堆内的电化学反应来提供电能,所以应将电堆温度的控制保持在最高优先级。因此,在燃料电池的运行中,堆的安全是至关重要的。SOFC 要快速、高

效地提供电流，必须将其电堆温度保持在恒定的水平，这将有助于严格控制堆的温度梯度和瞬态。然而，电化学反应热振荡和换热器预热波动等干扰影响了电堆温度的稳定性。




图 7-10 电堆控制回路

Fig 7-10 Stack temperature controller

在这一部分中，设计了电堆温度控制器。文中讨论了热响应时间。[9]其中，通过控制空气流量，热响应比电堆固有热响应更快，因此控制器能够有效、快速地管理电堆的进出口温度。考虑到鼓风机的响应速度明显快于电堆的热响应，气流可以有效地控制电堆温度。根据安全要求，在瞬态运行期间，电堆进出口温度应分别保持在最优值 (960 K 和 1050 K) 附近。在最优值 (OV) 附近，电堆温度波动幅度应保持在 10 K 以下。

一个反馈控制系统是基于选定的控制变量配对设计的，如图 7-10 所示。采用两个独立的反馈回路来实现快速的温度管理。只有对电堆温度进行良好的管理，才能有效地提供电能。考虑到热、电参数的耦合关系，在不影响系统功率的情况下，电堆入口温度的管理是很困难的。因此，电堆温度控制器不仅要与其他控制器配合，以保持系统的温度，而且还要有效地提供电能。

燃烧室控制器

本节讨论了在不受电参数影响的情况下实现燃烧器温度控制的方法。燃烧器温度，特别是气相温度，应该保持不变，因为排出的气体进入换热器可能会对燃烧器的温度稳定和材料耐久性产生不利影响。




图 7-11 解析冗余控制器

Fig 7-11 Burner temperature controller

基于 AOR 的控制器包括两个部分，即燃烧器控制器和燃料亏空补偿控制器，如图 7-11 所示。本部分只介绍了燃烧器的温度控制部分。为了保持燃烧器温度 (y_{BurnerT})，AOR 控制燃料进入燃烧器，多余的燃料被回收到电堆入口。进入电堆的燃料流量必须减少，因为需要保持一个安全的电堆压力水平。下一节将研究功率级控制中的 AOR 控制部分。

功率控制器

对于功率控制，电压保持在一个恒定的最优值，通过使用 DC/DC 或 DC/AC 变换器等电力电子器件来控制电堆电流，从而满足功率需求。同时，作为操纵变量，电流应由燃料提供。必须将足够的燃料输送到电堆中，以避免燃料耗尽和阳极再氧化。燃料耗尽问题应该避免，因为它会氧化阳极材料，并在很大程度上损害产生燃料电池电力的能力。




图 7-12 电特性控制器：燃料亏空补偿控制和功率控制

Fig 7-12 Electrical parameter controller

燃料供应的延迟导致燃料耗尽问题，导致负荷跟踪能力的限制。由于燃料供应的延迟，负荷突然增加会导致电堆燃料短缺。阳极空间中所含的燃料将在此期间消耗。为了避免燃料消耗，必须在电堆中保留足够的氢。如上节所分析的，储存在 AOR 冷凝中的燃料通过 AOR 鼓风机的驱动将燃料短缺期供应给电堆。因此，AOR 结构可以看作是电堆的扩展。基于文献中的分析。增加电堆的尺寸，使电堆对突然电负荷变化不太敏感。当负荷减少时，凝结水中所含的燃料可以补充。先前进入燃烧器的过量燃料随后被 AOR 回收到冷凝中，作为燃料供应缓冲，以应对负荷的突然变化。

功率控制方案由四个控制器组成：燃料亏空补偿控制器、AOR 控制器功率控制器部分 (P_AOR 控制器)、功率控制器和燃料流控制器。对于耗尽控制器，为了确保氢不会在电堆中耗尽，电流应该被限制，以防止电压下降。燃料耗尽控制器如图 7-12 所示。AOR 控制器功率部分 (P_AOR 控制器) 用于将包含在 AOR 结构中的燃料吹入电堆。电压的降低表明，堆内的

燃料浓度降低了。对于功率控制器来说，电流被用来控制功率需求，而燃料流应该由燃料流控制器提供足够的能量。

如图 7-12 所示，燃料耗尽控制通过反馈（燃料亏空补偿控制器）操纵电流来管理电压。当电压(y_v)降低且小于参考电压(r_v)时， I 值应降低，以降低油耗。同时，提高了 AOR 率(P_{AOR} 控制器)，使 AOR 冷凝箱中的燃料迅速吹至满足燃料需求和负荷跟踪要求的堆中。功率由功率反馈（功率控制器）和前馈控制器（FFP）通过对电流 (I) 的操纵来控制。AOR 前馈控制器 (K_{AOR}) 通过略微降低燃料流量来帮助维持电堆燃料压力。AOR 有助于防止燃料电池电压下降到一个较低的水平，这确保了足够的燃料在阳极室通过增加电堆燃料消耗时间。除第二燃料供应元件外，AOR 结构中的燃料箱可视为电堆的一部分。




图 7-13 完整的控制系统

Fig 7-13 Integrate control system for SOFC

为了展示控制输入和输出之间的关系，综合解耦控制方案如图 7-13 所示。该控制器由 6 个部分组成，即：电堆控制器、燃烧器温度控制器、 P_{AOR} 控制器、功率控制器、燃料亏空控制器和燃料流量控制器。所有控制输入和输出应保证在操作范围内。

电堆控制器分别管理 BP 比和空气流量，控制电堆进出口温度。燃烧器温度由 AORR 通过控制进入燃烧器的燃料来管理。 P_{AOR} 控制器还管理 AORR，以便在电压降低时将燃料添加到电堆中。燃料耗尽控制器减少电流，以防止电压显著下降。功率控制器通过操纵燃料流量来快速管理系统的功率跟随需求。电气特性控制器同时处理快速负荷跟踪和燃料消耗。此

外，系统级热参数，如电堆温度和燃烧器温度，不受功率变化的影响。因此，在解耦控制器的控制下，热、电特性之间的相互作用可以进行单独的控制。

控制律重新调度




图 7-14 控制律重新调度的主动容错控制

Fig 7-14 Integrate Fault diagnosis-tolerant control

根据叙述的容错控制框图如图 7-14，基于 7.2 节故障识别的结果，选择解耦控制系统的参数，上一节采用的解耦控制器，本质上就存在结构性冗余和解析冗余，根据 FDD 单元判断的当前系统的故障状态进行合适的控制参数选择，从而实现了控制率重新调度的主动容错控制。

7.3.4 实验结果与分析

解耦控制结果

本部分研究 AOR-SOFC，并对解耦控制的性能进行分析，本节的控制系统在现实中的 SOFC 系统里运行成功。解耦控制方案中的单输入输出控制器结构简单，在工程实践中性能良好，具有鲁棒性和稳定性，是基于 PID 的控制器。解耦控制系统的控制参数如表 7-7 所示，采用 Ziegler-Nichols 整定方法进行调整，适合工程实践。为了评估解耦控制器的性能，特别是负载跟踪能力和系统温度无关控制，本文设置了一个变功率情况。在此情况下，假设功率需求从 3500 W 迅速变化到 4500 W，然后在常规控制器和解耦控制器控制下的系统功率响应

下降到 4000 W。从功率跟踪特性、燃烧器温度、电堆温度和系统级运行参数 (燃料利用率和系统效率) 四个方面对解耦性能进行了评价。在本研究中, 传统的控制是无 AOR 控制驱动的系统级控制, 它由电堆控制器、功率控制器、燃料流量控制器和燃料亏空补偿控制器组成。常规控制和解耦控制参数相同, 如表 7-7 所示。

表 7-7 控制器参数

Table 7-7 Control parameters

(1)Stack inlet T control				
K_p	2.1	K_i	0.61	
(2)Stack outlet T control				
K_p	0.3	K_i	0.001	
(3)Burner T control				
K_p	0.8	K_i	0	K_d 0.3
(4)Power control				
K_p	0.000016	K_i	0.000002	K_d 0.000005 K_{AOR} 0.12 FF_p 0.00002
(5)Depletion control				
K_p	1.2	K_i	0.01	FF_i 0.024
(6) Fuel flow control				
K_p	0.21	K_i	0.012	

功率跟踪

图 7-15 中示出了功率负载跟踪特性。当 $0 < t < 1000s$ 时, 功率波动, 因为 SOFC 需要时间从 0 开始增加到 3500W。当 $t=1000s$ 时, 功率突然从 3500W 上升到 4500W。常规和解耦控制器都操纵系统来跟随需求。图 7-15.a-b 示出了负载跟随增加的局部信息。图 7-16 示出了功率控制器的控制动作。如图 7-15 所示, AOR 将冷凝中的燃料吹到电堆中以供应突然负载增加。然而, 当 $t=1020s$ 时, 系统功率停滞, 因为耗尽控制器降低了电流以避免堆燃料耗尽。在数秒之后, 来自燃料源的燃料到达堆以向电流供应充足的燃料, 从而导致功率再次增加。传统的控制使得过量的燃料流率在功率增加时增加, 这可能导致无用的燃料进入燃烧器。图 7-15.c 示出当 $t=2000s$ 时, 功率需求从 4500W 减少到 4000W。过量的燃料被 AOR 鼓风机从电堆出口吹到 AOR 中以填充冷凝器。最终, 系统功率在解耦控制系统的控制下的功率迅速降低到参考功率。




图 7-15 功率负载特性

Fig 7-15 Power load following characters




图 7-16 解耦的控制作用

Fig 7-16 Control actuation of the decoupling power controller

解耦控制器在功率负荷跟踪和避免燃料耗尽方面优于常规控制器, 因为 AOR 减少了燃料短缺周期, 使燃料供应对功率变化不那么敏感。AOR 控制器的收敛速度比图中所示的无 AOR

控制器快。图 7-15.b 和图 7-15.c。在功率波动时，AOR 控制器需要 50s 左右才能达到需求值，而无 AOR 控制器则需花费大约 300s。这是因为当电力需求增加时，AOR 结构将电堆尾气中的燃料回收到电堆入口，而最初包含在 AOR 结构中的燃料也规定了燃料供应延迟期。因此，AOR 控制器的功率响应速度将高于不带 AOR 的控制器。在降低功率的情况下，AOR 循环鼓风机有助于降低堆内过量的燃料气体的浓度，因此功率下降速度高于传统控制器。

燃烧室温度




图 7-17 进入燃烧室的燃料流量

Fig 7-17 Fuel flow rate to burner




图 7-18 热交换器温度

Fig 7-18 Heat exchangers temperature

燃烧器温度在系统功率变化期间的动态响应如图所示。图 7-17 传统的控制器会引起较大的温度波动、破坏燃烧器，引起换热器和电堆温度的振荡。基于 AOR 的燃烧器温度控制器通过限制燃料流入燃烧器来维持燃烧器温度，如图 7-18 所示，虽然功率和燃料流量发生变化，但解耦控制器使燃烧器燃料几乎保持在一个稳定的值，而常规控制则将过量的燃料送入燃烧器。

AOR 控制器下的温度动态温度响应如图 7-19 所示。当功率增加时，燃料在电堆中消耗更多的燃料产生电流，产生的热量增加，燃烧器产生的热量减少。因此，换热器的传热量将减少。当功率增加时，进入电堆的过量燃料将被循环利用，因此燃烧器和交换器的温度不会发生很大的变化。

电堆温度




图 7-19 电堆温度

Fig 7-19 Stack temperature under conventional and decoupling controller.





图 7-20 空气流量与冷空气开度

Fig 7-20 Stack temperature control actuation

图 7-19 显示了两个控制器下的电堆入口和出口温度。对于电堆入口温度，电堆出口温度保持在 10K 以内，解耦控制器由于 AOR 将冷 (333 K) 燃料送至电堆入口而降低 10K。虽然电堆入口温度波动，如图 7-20 所示，空气流量是 AORR 的 20 倍以上，使入口温度再次达到控制目标。图 7-19、图 7-20 表明，由于燃烧器温度的稳定，使得电堆温度控制器不必采用过大的控制驱动，使得解耦控制的空气流量和 BP 速率明显降低。降低 BP 率会降低旁路换热器的冷风流量，对系统效率有积极的影响，AOR 控制器下的温度动态温度响应如图 7-20 所示。当功率增加时，燃料在电堆中消耗更多的燃料产生电流，产生的热量增加，燃烧器产生的热量减少。因此，换热器的传热量将减少。当功率增加时，进入电堆的过量燃料将被循环利用，因此燃烧器和交换器的温度不会发生很大的变化。






图 7-21 电堆温度动态

Fig 7-21 Stack temperatures

图 7-21 显示了电堆的温度分布、电堆内的空气温度响应、堆内的燃料温度响应、IC 温度响应和笔式温度响应。所有的温度都可以维持在 15K 以内，尽管系统功率增加和下降。由于电堆的入口温度和出口温度可以保持在稳定的水平。

电堆温度主要受空气温度的影响，因为进入电堆的空气是电堆运行温度的主要热源，空气流量是燃料流量的几倍。电堆温度分布近似于沿气流方向的线性增长。结果表明，当电堆入口温度和电堆出口温度控制在稳定值时，整个电堆温度可以在一定程度上保持在一定的恒定值。

AOR 控制器下的电堆温度动态响应如图 7-21 所示。当功率增加时，燃料在电堆中消耗更多的燃料产生电流，产生的热量增加，燃烧器产生的热量减少。因此，换热器的传热量将减少。当功率增加时，进入电堆的过量燃料将被循环利用，因此燃烧器和交换器的温度不会发生很大的变化。

系统效率控制

FU 和 SE 是表征固体氧化物燃料电池系统最佳工作条件的两个系统重要参数。在图 7-22 中，由常规控制器控制的 FU 受功率变化的影响。换言之，功率和燃料流量之间的相互作用防止了 SOFC 高效率地工作。因此，在常规方案的控制下，FU、SE 不能保持稳定。然而，解耦控制器独立地管理电特性，而不受燃料流量的影响。结果如图 7-23 所示，即使在功率变化时，FU 和 SE 几乎保持在高电平。




图 7-22 燃料利用率和系统效率

Fig 7-22 Fuel utilization and system efficiency under two controller




图 7-23 AOR 鼓风机和系统鼓风机功率

Fig 7-23 The power of AOR blower and the air blower.

温度动态响应的 AOR 控制器下，当功率增加时，电堆内消耗更多的燃料产生电流，电堆内产生的热量增加，燃烧器内产生的热量也随之减少。因此，换热器的热输运将减少。当功率增加时，进入电堆的多余燃料将被循环利用，因此燃烧器和换热器的温度不会大大地改变。

图 7-23 展示出了 AOR 风机与系统鼓风机功率相比，AOR 鼓风机的功率非常小，所以在 SE 中没有发挥重要的作用。FU 表示电堆中使用的燃料消耗速率，如果在电堆中消耗更多的燃料，则意味着电化学反应比率处于高水平。SE 表示系统输出的有效功率与总功率的比值。图 7-22 示出了即使在功率改变条件下，AOR 控制器也可以在高电平保持 FU 和 SE，而没有 AOR 的控制器也不能很好保持较高的 FU 和 SE。FU 首先在功率增加时减小，因为当功率需求增加时，将增加更多的燃料到电堆中，这将导致 FU 减少。对于 SE，当系统功率需求增加时，电堆中消耗的燃料将增加，以及电堆中产生的热量，因此更多的空气应该被添加到电堆中以冷却温度下降和寄生功率增加，然后 SE 将降低。

因此，AOR 控制器不仅有助于控制系统温度，而且还能控制堆内的燃料利用率（FU）和系统效率（SE）。利用冗余结构与解析冗余相结合，从而为故障的主动容错控制提供基础。

容错控制结果




图 7-24 SOFC 正常故障状态

Fig 7-24 SOFC normal state

该部分根据第一部分的故障诊断结果进行容错控制。解耦控制方案中的单输入输出控制器结构简单，在工程实践中性能良好，具有鲁棒性和稳定性，是基于 PID 的控制器。采用 Ziegler-Nichols 整定方法对解耦控制系统的控制参数进行了整定，使其更适合工程实际应用。为了验证所提出的控制策略在正常情况下的有效性，功率负荷在 0~4950 W 之间变化，并由标称控制维持 400 s。燃烧器温度保持在 1141 K 左右，电堆温度保持在 1075 K 左右。控制驱动，如空气流量，燃料流量和燃烧器的燃料率保持在恒定值，如图 7-24 所示。




图 7-25 电堆故障与诊断结果

Fig 7-25 Stack fault and PCA-DT-SVM diagnosis results




图 7-26 容错控制与无容错控制对比

Fig 7-26 SOFC response with and without fault diagnosis and fault tolerant control

为了研究数据驱动故障诊断和容错控制技术的性能,对电堆故障进行了 10%欧姆电阻增加的仿真,如图 7-25。在第一个 2000 s, SOFC 处于正常运行状态,然后在 $t=20000$ s 发生电堆故障。欧姆电阻倍数在 200 s 左右变化在 1 到 1.1 之间。数据驱动的故障诊断部分检测故障,并将故障类型分别从 0 到 1、2、3、4、5 进行分类,并随着图 7-25 所示的电堆故障加深,重构算法决策激活相应的恢复策略。

图 7-26.a-c 显示了 SOFC 功率、燃烧器温度和电堆温度在容错控制和不容错控制下的比较。这两种控制方法的差异表明,当发生故障时,名义控制会引起功率的下降和温度的不稳定,从而导致寿命和耐久性的降低。通过图 7-26.d-f 中所示的控制激励,容错控制可以减弱故障的影响,使燃烧器和堆温保持在期望值。通过控制驱动,功率可恢复到 4950 W 左右,约为初始值。图 7-26.d-f 分别给出燃烧器的空气流量、燃料流量和燃料流量。容错控制器需要流量的突然变化来弥补电堆故障。

7.4 控制律在线重组的主动容错控制

老化故障使工业系统的参数随时间变化,而且原因众多无法采用准确的数学模型去描述,因此无法采用设计观测器的方法来观测当前的状态,也无法根据输出反馈或者状态反馈的方法设计有效的控制器。但是这类故障变化一般是非常缓慢的,本章的思路是通过机器学习的方法进行系统故障参数的在线估计,然后基于估计的结果赋值到基于模型的控制器中,从而实现故障的控制律在线重组的主动容错控制。

本节主要研究的是,利用老化故障的在线估计故障程度,并结合控制器参数主动调整来实现故障的主动容错控制。控制器在线重构是指, FDD 单元确诊故障后,在线重组或重构控制律。控制律重构设计方法严格依赖 FDD 单元,通过 FDD 确定所发生的故障时间,发生的位置,和相应的故障严重程度或故障大小,在得出故障信息后,利用这些信息对控制器进行重构设计。本节研究的是故障程度的评估与控制器在线参数调整的问题,采用主动容错控制的控制律在线重组的方法。上一节采用故障识别的方式来解决故障类型的判定,然后根据类型切换控制器的参数,控制器的参数是属于离线确定的。

本节研究的是系统本身发生故障的情况,当系统本身发生故障系统本身的输入输出关系是发生变化的,这就使传统的控制器无法正常工作。本文采用在线故障评估-控制律实时调整的方式实现了系统的主动容错。采用的方法是: 1) 利用 TS 型贝叶斯学习机 (TS-BL) 根据系统的输入输出数据学习输入输出之间的关系,并根据受控自回归积分滑动平均模型 (Controlled Auto-Regressive Integrated Moving Average, CARIMA) 的特性学习到输入 (X) 与输出 (Y) 之间的函数关系; 2) 利用广义预测控制 (GPC) 基于 CARIMA 模型进行控制关系计算的特性,通过 TS-BL 学习到的 CARIMA 模型计算控制参数。

本节研究主动容错控制的优势是,克服了之前研究中 FDD 的设计方法研究都是离线设计

的，利用机器学习方法学习系统自身故障下的输入输出映射关系函数，并将学习到的系统参数直接给控制系统赋值，从而实现了在线的主动容错控制功能。本类型的主动容错控制适合处理故障变化缓慢的一类连续故障，例如石油化工系统的缓慢变化故障，工业系统老化的故障。

7.4.1 TS 模型的特点与规则

TS 模糊模型是一种本质非线性模型，它能够以任意精度逼近一个复杂的非线性系统。其方法是根据输入输出的局部关系将输入空间模糊划分为光滑过度的子空间，然后对每一个子空间建立局部线性化模型，模型的总输出则为局部模型的线性加权组合^[181-184]。因此，TS 模糊模型具有以如下优点：能以很少的规则数目表达高度非线性的复杂系统、易于调节结构及参数、易于系统分析和设计传统控制器设计。其中，较少的规则数又使得其具有模型结构简单，运算速度快的特点。

相比于使用常规的分段线性化方法建立的模型，TS 模糊模型能够以更少的规则数逼近非线性系统。这是因为 TS 模糊模型机构建输入输出数据关系规则的方法要比常规的分段非线性方法有优势。TS 型分段线性化的描述方法能够显著地减少规则数量，极大地简化了模型，减少运算时间^[185-188]。




图 7-27 TS 模糊规则与分段线性化规则的比较

Fig 7-27 TS fuzzy rule and piecewise linearization

第 i 条 TS 模糊规则对系统输出的贡献分量 $y^i(k+1)$ 可以用 “If...Then” 语句表示如下^[183]:

$$\begin{aligned} R^i : & \text{If } x_1(k) \text{ is } A_1^i \text{ and } x_2(k) \text{ is } A_2^i \text{ and } \cdots \text{ and } x_n(k) \text{ is } A_n^i \\ & \text{Then } y^i(k+1) = p_0^i + p_1^i x_1 + \cdots + p_n^i x_n; \quad i = 1, 2, \dots, c \end{aligned} \quad (7.5)$$

其中，

c 为模糊规则数目,

n 为 TS 模糊模型的输入变量数目,

$x_1(k), x_2(k), \dots, x_n(k)$ 为第 k 时刻及以前的输入输出数据的回归变量,

$x(k) = [x_1(k), x_2(k), \dots, x_n(k)]$ 为模糊模型的输入向量,

$A_1^i, A_2^i, \dots, A_n^i$ 为代表各模糊子空间的具有线性隶属度函数的模糊集, 可以用来进行第 i 条规则的模糊推理,

$p_0^i, p_1^i, \dots, p_n^i$ 为第 i 条模糊规则的后件参数。

定义 β_i 为模糊规则 i 的适应度, 那么模型在第 $(k+1)$ 时刻的输出 $y(k+1)$ 可以通过下面的公式计算:

$$\begin{aligned} y(k+1) &= \sum_{i=1}^c \beta_i y^i(k+1) = \sum_{i=1}^c \beta_i (p_0^i + p_1^i x_1(k) + \dots + p_n^i x_n(k)) \\ &= \sum_{i=1}^c (p_0^i + p_1^i + \dots + p_n^i) (\beta_i + \beta_i x_1(k) + \dots + \beta_i x_n(k))^T \end{aligned} \quad (7.6)$$

定义

$$\begin{cases} \Theta(k) = [\theta_1, \theta_2, \dots, \theta_r]^T = [p_{10}, p_{20}, \dots, p_{c0}, p_{11}, p_{21}, \dots, p_{c1}, \dots, p_{cn}]^T; \\ \Phi(k) = [\beta_1, \dots, \beta_c, \beta_1 x_1(k), \dots, \beta_c x_1(k), \dots, \beta_1 x_n(k), \dots, \beta_c x_n(k)]^T; \end{cases} \quad (7.7)$$

其中 $r = c(n+1)$, 我们可以得到:

$$y(k+1) = \Phi(k)^T \Theta(k) \quad (7.8)$$

一般而言, 前件参数使用基于模糊 C 均值算法的模糊聚类方法进行辨识获得, 后件参数通过最小二乘法辨识获得。

7.4.2 TS 型贝叶斯学习(TS-BL)

本节基于 TS 模糊模型, 提出了一种 TS 型二级贝叶斯学习器, 采集当前工业系统的数据, 对系统的损坏程度进行估计, 在线调节控制器参数, 从而实现系统的容错控制。但本方法的应用范围是: 系统的结构不能发生重大的变化, 系统发生某一类型的故障, 且损坏程度需要在可控范围内。TS 型贝叶斯学习可以通过离线辨识和在线辨识两种方法建立。离线辨识是利用充足的离线数据进行一次性辨识, 获取模型前件结构以及后件参数。模型由固定的控制规则组成, 它的性能受到离线数据范围大小及完整性的严格限制, 因此离线 TS 型贝叶斯学习机所产生的开环数据可能不会满足闭环控制的需求。相反的, 在线 TS 型贝叶斯学习机的前件结构及后件参数会根据系统实时产生的数据进行修正和更新, 所以它可以在系统的所有操作范围内进行准确的输出预测。对于非线性、参数时变的复杂系统, 在线 TS 型贝叶斯学习机是一

种描述其输入输出特性的强大工具^[189, 190]。

文献^[191]介绍了一种进化 TS 型贝叶斯学习机的建立方法，当新的数据产生之后，该模型能够通过实时修正现存和增加新的规则和参数来继承并更新规则的结构。尽管其仿真结果证明了它对非线性模型估计的准确性，但这种方法比较耗费时间。为了 TS 模型的平衡计算量与估计精度的关系，我们使用加权回归最小二乘法来更新聚类中心和后件参数。

为了获得快速准确的在线 TS 型贝叶斯学习机，本文采用以下方法来建立规则及辨识参数：

1) **步骤 1:** 初始化模型参数。模型参数包括聚类中心数量 $c (c > 1)$ ，模糊规则学习率 $\lambda (0 < \lambda < 1)$ ，模糊因子 $m (m > 1)$ ，权重回归最小二乘法协方差矩阵 $\Gamma(1) = \Omega I$ （其中 Ω 为一个较大的正实数， I 为 $[c(n+1) \times c(n+1)]$ 维的单位矩阵）以及后件参数 $\Theta(1) = 0$ 。特别的，聚类中心向量 $V(1) = [v_1(1), v_2(1), \dots, v_c(1)]$ 的初始值可以用实验数据的离线辨识获得，也可以直接给定 $V(1) = 0$ 。然而，在仿真测试过程中，这两种方法使得模型具有相似的性能，因此 $V(1) = 0$ 可以作为首选初始值。

2) **步骤 2:** 用下面的方程计算输入 $x(k)$ 与每一个第 $(k-1)$ 时刻的聚类中心向量的距离：

$$d'_i = \sqrt{\sum_{j=1}^n [x_j(k) - v_{ij}(k-1)]^2}; i = 1, 2, \dots, c \quad (7.9)$$

3) **步骤 3:** 根据贝叶斯理论评价输入 $x(k)$ 对每一个聚类中心 $v_i(k-1)$ 的隶属度：

$$u'_i = \left[\sum_{j=1}^c \left(\frac{d'_i(k)}{d'_j(k)} \right) \right]^{\frac{(m-1)}{2}}, i = 1, 2, \dots, c \quad (7.10)$$

4) **步骤 4:** 基于第 $(k-1)$ 时刻 $x(k)$ 的隶属度和模糊规则学习率，利用如下公式修正聚类中心向量 $V(k-1)$ ：

$$v_i(k) = v_i(k-1) + \lambda u'_i(k)^2 [x(k) - v_i(k-1)] \quad (7.11)$$

5) **步骤 5:** 根据新获得的聚类中心向量 $V(k)$ 更新输入 $x(k)$ 与中心点的距离与隶属度：

$$d_i = \sqrt{\sum_{j=1}^n [x_j(k) - v_{ij}(k)]^2}, i = 1, 2, \dots, c \quad (7.12)$$

$$u_i = \left[\sum_{j=1}^c \left(\frac{d_i(k)}{d_j(k)} \right) \right]^{\frac{(m-1)}{2}}, i = 1, 2, \dots, c \quad (7.13)$$

6) **步骤 6:** 计算当输入为 $x(k)$ 时，第二次使用贝叶斯理论，第 i 条规则对系统

输出的适应度:

$$\beta_i = \sum_{j=1}^c \left(\frac{u_i}{u_j} \right), \quad i = 1, 2, \dots, c \quad (7.14)$$

然后可以求得向量:

$$\Phi(k) = [\beta_1, \dots, \beta_c, \beta_1 x_1(k), \dots, \beta_c x_1(k), \dots, \beta_1 x_n(k), \dots, \beta_c x_n(k)]^T. \quad (7.15)$$

7) **步骤 7:** 为了使得 TS 模型输出与原系统输出的均方根误差之和最小, 利用加权回归递推型最小二乘法确定关于输入 $x(k)$ 的后件参数 $\Theta(k)$:

$$K = \frac{\Gamma(k-1)\Phi(k)}{[1 + \Phi(k)^T \Gamma(k-1)\Phi(k)]} \quad (7.16)$$

$$\Theta(k) = \Theta(k-1) + K[y(k) - \Phi(k)^T \Theta(k-1)] \quad (7.17)$$

$$\Gamma(k) = [I - K\Phi(k)^T] \Gamma(k-1) \quad (7.18)$$

8) **步骤 8:** 最后, 根据公式 3.53~3.55 可以求得 TS 模型的预测输出:

$$y(k+1) = \Phi(k)^T \Theta(k) \quad (7.19)$$

9) **步骤 9:** 让 $k = k + 1$ 并返回步骤 2, 直到系统的控制过程结束。

按照上述过程可以建立一个准确的在线 TS 型贝叶斯学习机。

7.4.3 广义预测控制 (GPC)

预测模型

受控自回归积分滑动平均模型 (Controlled Auto-Regressive Integrated Moving Average, CARIMA) 是适用范围非常广的模型, 不仅可以描述非平稳随机过程, 也能描述阻尼和欠阻尼特性的系统, 由于其能够包含工业中的过程知识信息并能够消除系统稳态静差, 因此, GPC 控制器一般都会以 CARIMA 模型来描述控制对象^[190]。

CARIMA 模型的一般形式为:

$$A(z^{-1})y(k) = B(z^{-1})U(k-1) + C(z^{-1})\delta(k) / \Delta \quad (7.20)$$

其中 Δ 是微分算子 $1 - z^{-1}$, $y(k)$, $U(k-1)$ 和 $\delta(k)$ 分别表示模型的输出、输入和不相干随机序列。并且,

$$U(k-1) = [u_1(k-1), u_2(k-1), \dots, u_p(k-1)]^T \quad (7.21)$$

式 7.20 中 $A(z^{-1})$, $B(z^{-1})$, $C(z^{-1})$ 分别为后向移位算子 z^{-1} 的多项式, 多项式的系数可以通过 TS 型贝叶斯学习机的后件参数的在线辨识计算求得, 可表示为^[94]:

$$A(z^{-1}) = 1 + a_1 z^{-1} + \dots + a_{na} z^{-na} \quad (7.22)$$

$$B(z^{-1}) = B_0 + B_1 z^{-1} + \dots + B_{nb} z^{-nb} \quad (7.23)$$

$$C(z^{-1}) = 1 + c_1 z^{-1} + \dots + c_{nc} z^{-nc} \quad (7.24)$$

其中, na, nb, nc 分别为三个多项式的阶次, $B_i = [b_{1i}, b_{2i}, \dots, b_{pi}]^T$, $i = 0, 1, \dots, nb$, $C(z^{-1})$ 一般取值为 1。

根据 GPC 算法, 定义时间长度 $[k + N_1, k + N_2]$ 为预测时域, 进行输出预测, 其中 N_1 为最小预测时域, N_2 为最大预测时域。在本文中, 我们取输入延迟时间 $d = 0$, 最小预测时域 $N_1 = 1$ 。为了获得系统在 $(k + j)th, j = 1, 2, \dots, N_2$ 时刻的预测输出, 可以引入丢番图方程组 (Diophantine Equations), 并且可以获得未来的输出为:

$$\hat{y}(k + j) = G_j(z^{-1})\Delta U(k + j - 1) + F_j(z^{-1})y(k) + H_j(z^{-1})\Delta U(k - 1) \quad (7.25)$$

式中 $G_j(z^{-1})\Delta U(k + j - 1)$, $F_j(z^{-1})y(k)$ 和 $H_j(z^{-1})\Delta U(k - 1)$ 可以分别通过预测控制增量序列、已知输出序列和已知的输入增量序列来求得。因此, 对于给定的预测控制增量序列, 并将两个已知项 $F_j(z^{-1})y(k)$ 和 $H_j(z^{-1})\Delta U(k - 1)$ 表示为 $f(k + j)$, 可以获得系统的预测输出 $\hat{y}(k + j)$ 为:

$$\hat{y}(k + j) = G_j(z^{-1})\Delta U(k + j - 1) + f(k + j) \quad (7.26)$$

滚动优化

在 GPC 控制中, 控制器并不是直接跟踪系统设定的目标输出, 而是以一个精心的设计参考轨迹为跟踪目标。这个参考轨通过迹柔和地连接系统的当前输出值和目标输出值来提高提高系统的动态控制性能^[190, 192]。一个设计良好的参考轨迹能够驱使系统的输出值能够快速、平滑地跟踪到目标轨迹。在本文, GPC 控制中使用的参考轨迹为:

$$\begin{cases} y_r(k) = y(k) \\ y_r(k + j) = \alpha^j y(k) + (1 - \alpha^j)s \end{cases} \quad (7.27)$$

其中, $s, y(k)$ 分别为设定值和系统在第 k 时刻的输出值, α 为平滑因子。为了使得系统的输出值能够完美地趋近参考轨迹, 系统的最优控制增量序列可以通过最小化如下的多级目标函数来获得:

$$J = E\left\{\sum_{j=1}^{N_y} [\hat{y}(k + j) - y_r(k + j)]^2 + \sum_{j=1}^{N_u} \eta_j [\Delta U(k + j - 1)]^2\right\} \quad (7.28)$$

其中,

$E\{*\}$ 为数学期望算子,

η_j 是用来限制控制序列能量的控制权重序列,

N_2 为最大预测时域,

Nu 为控制时域,

$\hat{y}(k+j)$ 为系统在 $(k+j)th$ 时刻的预测输出,

$y_r(k+j)$ 为 $(k+j)th$ 时刻的参考轨迹值。

从多级目标函数公式 (7.28) 可以看出, GPC 控制算法的一个重要目标是极小化系统输出和参考轨迹之间的误差, 因此也可以说明, GPC 控制器的性能在很大程度上可以收到参考轨迹的影响。

将公式 (7.27) 中的 $\hat{y}(k+j)$ 代入公式 (7.28), 并改写成向量形式, 那么可以获得:

$$J = [GU + f - Y_r]^T [GU + f - Y_r] + \lambda U^T U \quad (7.29)$$

其中

$$\tilde{U} = [\Delta U(k), \Delta U(k+1), \dots, \Delta U(k+Nu-1)]^T \quad (7.30)$$

$$Y_r = [y_r(k+1), y_r(k+2), \dots, y_r(k+N_2)]^T \quad (7.31)$$

$$f = [f(k+1), f(k+2), \dots, f(k+N_2)]^T \quad (7.32)$$

$$G = \begin{bmatrix} G_0 & 0 & \dots & 0 \\ G_1 & G_0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ G_{N_2-1} & G_{N_2-2} & \dots & G_{N_2-Nu} \end{bmatrix} \quad (7.33)$$

将目标函数 (7.28) 进行最小化 $\frac{\partial J}{\partial \tilde{U}} = 0$ 操作就可以获得无约束控制增量序列:

$$\tilde{U} = (G^T G - \lambda I)^{-1} G^T (Y_r - f) \quad (7.34)$$

最后可以得到当前时刻应用到系统的控制输入向量 $U(k)$:

$$U(k) = U(k-1) + \Delta U(k) \quad (7.35)$$

其中 $\Delta U(k)$ 为 $\tilde{U}$ 的第一列向量。

反馈校正

从上一节可知, 系统最优控制增量序列的求解过程需要用到由预测模型提供的系统预测输出, 因此要保证 GPC 控制器具有良好的工作性能, 一个准确的预测模型是不可缺少的基础。然而, 大多数工业过程中的强非线性与时变特性, 具有固定结构与参数的预测模型难免会存在模型失配的现象, 导致控制器性能变差。为了克服这种现象, 那么预测模型的模型就需要

在每一个工作周期进行参数校正，以实时跟踪系统的工作特性。本章前面给出的在线 TS 型贝叶斯学习机就具有实时校正的能力，其后件参数在每一个工作周期都通过最小二乘法进行校正，并且 GPC 算法使用的 CARIMA 模型多项式 $A(z^{-1})$ ， $B(z^{-1})$ 的系数可以通过 TS 型贝叶斯学习机的后件参数求得，因此，GPC 的预测模型也就能够在每一个周期获得了更新校正，确保了预测输出的准确性与控制的精度。CARIMA 模型多项式的系数与 TS 型贝叶斯学习机后件参数的计算关系如下^[188]：

$$\begin{cases} a_i = -\sum_{s=1}^c \theta_{ci+s} \beta_s; & i = 1, 2, \dots, na \\ b_{jw} = -\sum_{s=1}^c \theta_{c(na+(w+1)+(j-1)(nb+1)+s} \beta_s; & \begin{cases} j = 1, \dots, p; \\ w = 0, \dots, nb; \end{cases} \end{cases} \quad (7.36)$$

在线 TS 型贝叶斯学习机根据系统实时输出的反馈值，用最小二乘法校正后件参数，然后通过式（7.36）来校正 CARIMA 模型的过程就实现了 GPC 算法的反馈校正。

7.4.4 TS-BL-GPC 控制律在线重组

如图 7-28 所示，在 Matlab/Simulink 平台下搭建的水蒸气重整器 SOFC 并应用到了前面辨识的动态模型上，本文提出的 TS-CGPC 控制算法将以此为基础进行研究。为了更清楚地展示控制系统的结构，控制框图如图 7-29 所示，控制系统包括了水蒸气重整器动态模型，一个在线 TS 型贝叶斯学习机和一个约束 GPC 控制器。控制器通过调节燃烧甲烷流量 BCH_4 和重整甲烷流量 RCH_4 来控制重整温度 Tr 。控制过程如下：TS 型贝叶斯学习机利用水蒸气重整器 $(k-1)th$ 时刻的输入输出数据来校正其后件参数并预测重整器在 kth 时刻的输出 y_m ；然后基于已知输入 $BCH_4(k-1)$ 和 $BCH_4(k-1)$ ，预测输出 y_m ，模型参数 Φ/ϕ ，预测误差 e 以及设定值 y_{set} ，约束 GPC 控制器计算最优控制序列；最后，获得 kth 时刻的系统输入并应用到水蒸气重整器上，等待进入下一周期。




图 7-28 Matlab/Simulink 平台下搭建的 SOFC 重整器模型与控制器

Fig 7-28 SOFC reformer model in Matlab/Simulink platform




图 7-29 TS-BL-GPC 容错控制的结构框图

Fig 7-29 TS-BL-GPC fault tolerant control

下面将从三个方面对控制器进行测试：

- 1) 重整甲烷流量 RCH4 恒定，调节燃烧甲烷流量 BCH4 来跟踪实验数据的重整温度。
- 2) 在 RCH4 恒定的情况下分析控制系统的阶跃响应情况。
- 3) 当重整甲烷流量 RCH4 发生波动时，研究控制系统的抗扰动能力。

执行程序的个人电脑配置为：CPU: 3.40GHz; RAM: 16G, 1666MHz; Hard Disk: 128G。


7.4.5 实验结果与分析

正常系统的动态跟踪特性


为了验证系统控制器在正常系统下的动态特性，有必要让控制器在大范围内去跟踪实验数据的变化趋势。我们选择了 780K~1000K 范围内的 30000 个重整温度数据作为设定值来测试本文提出的 TS-GPC 控制器。作为基于模型的控制器，TS-GPC 基于预测模型的输出来计算控制输入序列，因此，控制器的性能在很大程度上由在线 TS 模糊模型的准确性来决定。T-S 模糊模型的预测输出能够准确地吻合物理模型的输出，并且 TS 模型的稳态预测误差曲线趋近与 0，在动态过程最大误差也不超过 4K，如图 7-30.b-c 所示。

TS-GPC 控制方法在重整器系统上的应用效果可以发现该控制方法的有效性，不仅能够快速、平滑地跟踪系统设定值，并且对约束的处理也十分简单有效。PID 控制作为经典控制方法中的代表，是工业控制中经常用到的一种控制方法。为了分析 TS-GPC 控制方法的优越性，本节将 PID 控制方法应用到重整器温度控制中，并与 TS-GPC 控制方法进行比较。


当给定阶跃设定信号时，TS-CGPC 控制器与 PID 控制器的对重整器的温度控制如图 7-30.a 所示，其中绿色为 TS-GPC 控制效果，黑色为 PID 控制效果。从图中可以看到，PID 控制器虽然能够比较快速地控制重整器温度跟踪设定值，但存在较大的温度超调。并且温度阶跃越大，超调也越大，如图 7-30.a 中的小图所示，当设定值从 840K 到 870K 阶跃上升 30K，超调为 6K 左右。而当使用 TS-GPC 控制器进行控制时，重整温度的响应速度不仅更快（跟踪时间约为 PID 的一半），而且超调几乎不到 1K，比 PID 控制器要小很多。由此可以发现，相比于传统 PID 控制器，TS-GPC 在控制性能上存在着显著的优势，能够快速、平滑地跟踪目标值。同时，由于 TS-GPC 控制的速度快、超调小，使得重整器给 SOFC 发电系统带来的负面扰动也更小。由此可以证明 TS-GPC 控制方法的有效性。



a. Controllers comparison



b. Control system follow ability



c. Error

图 7-30 TS-BL-GPC 动态跟踪特性

Fig 7-30 TS-BL-GPC dynamic tracking characteristics

功率连续衰减故障

本节主要研究在老化故障下，系统的稳定性能保持状况。本节研究了电堆的衰减故障机理以及主动容错控制，本节采用了上一节叙述的解耦控制系统，通过解耦的方式来精确控制每一个重要的系统变量从而使故障状态下的系统能够安全的运行，并利用结构冗余配合解析冗余来实习系统的控制律在线重组主动容错控制。

根据参考文献^[193, 194]，所有的极化损失都可以通过叠加电阻来定义。根据文献^[195]，将

SOFC 电堆的退化表示为欧姆电阻的增量，并利用实验数据拟合的方法建立了 SOFC 的衰减方程。受此方法的启发，我们利用传递函数定义了电堆电特性衰退方程，它与 Zaccaria 的工作^[195]具有相同的退化趋势。电堆输出电压可由公式 7.37 计算，其中 r 表示阻碍电流的所有电阻因素。对于电堆电气故障特性分析，目的是一步改变系统的 U_{OCV} 和 r 值，以分析系统中的电流密度响应和相应的变量。阶跃响应是最严格的变量转换。在 SOFC 电气故障特性建模中，考虑了阶跃响应对故障动态响应边界的影响。所有其他类型的故障都比阶跃响应更为温和。

$$U_{cell} = U_{OCV} - ir \quad (7.37)$$

但是，由于电极结构特殊，含有多个储能元件，即使电压或电阻突变，电流变化缓慢，其电容功能也是如此。这种现象在电阻-电容电路响应中很常见。对于电压退化情况， U_{cell} ， r 是固定的，当 U_{OCV} 突变时， i 变化缓慢。这是因为电容器提供了部分电压，因此等效的 U_{OCV} 也在缓慢变化。

故障方程被描述为 U_{OCV} 和 r 的关系：

$$G(s) = \frac{K}{Ts + 1} e^{-\tau s} \quad (7.38)$$

$$r_{degradation} = (1 + g(1 - e^{-\frac{t-\tau}{T}})) \cdot r, \quad g > 0 \quad (7.39)$$




图 7-31 欧姆电阻增长

Fig 7-31 Ohmic resistance raising degradation

表 7-8 训练时间与控制模式

Table 7-8 Running state and Control type

Time span	0-10000s	10000s-20000s	20000s-40000s
Running state	Full power (5kW)	Stack 20% degradation	
Control type	Conventional Controller		Fault tolerant Controller

公式 7.38 和 7.39 可用于分析整个电堆退化情况，结果如图 7-31 所示。为了比较传统控制器和主动容错控制器的系统控制能力，在表 7-8 中设置了一个正常状态转故障状态情况。考虑到 SOFC 电堆面临 20% 的劣化，这意味着 20% 的电堆失效。首先，系统在前 10000s 内，是正常工作的。公式 7.38 中的时间参数 T 为 5000。在第一个 20000s (从 0 到 20000s)，SOFC

系统由无主动容错功能的控制系统来控制，在第二个 20000s (20000s 到 40000s)，系统由控制器转换为 TS-BL-GPC 主动容错控制器。整个系统额定输出功率为 5kW。仿真案例研究中存在两个对比：

第一，是常规控制器在正常状态 (0-10000s) 和故障状态 (10000-20000s)下的性能。

第二，比较了传统的(10000 s~20000 s)和容错控制器(20000s~ 40000 s)在故障状态下，当电堆电流抽取能力下降时的故障状态。

由于电堆的性能是恢复的，电堆故障衰退达到一定的阶段之后，就会达到一个稳定的阶段。所以，可以采用同一次实验的不同阶段作为对比，这样由于处于同样的实验环境，更能对比出不同控制器的控制作用^[94-96]。

在线容错控制

分析了电堆温度、气体流量和系统级参数，包括燃烧器温度、系统功率、燃料利用率、系统效率等。





图 7-32 电堆温度控制

Fig 7-32 Stack temperature parameters

电堆温度如图 7-32 所示。仿真结果表明，不管是普通的控制系统还是容错控制系统都可以把温度控制在设定值的 5K 范围内，电堆的进出口电温度均保持在 5K 以内。燃料电池的热响应可以通过操纵旁路率（BP）和空气流量来得到充分的控制。这是非常重要的，因为只有将电堆温度保持在安全限和高效率工作的温度下，才能保证 SOFC 系统提供高的燃料利用率和系统效率，从而保证电堆的发电功能。图 7-32 还表明电堆温度控制器不受电堆故障的影响，堆的温度控制环路自身就具有一定的容错功能。






图 7-33 系统流量特性

Fig 7-33 Gas flow parameters

SOFC 系统的气体动态响应如图 7-33 所示。从 0 到 10000s，所有的气体参数，包括燃料进入燃烧器、电堆燃料流量和空气流量，都由常规控制器控制在一个恒定值。在 10000s 时，电堆面临 20%的电堆退化，退化动态在公式 7.38 中显示，这意味着 20%的电堆发电功能失效。




图 7-34 系统级变量

Fig 7-34 System level parameters

随着电堆衰退的加深 (10000-20000s)，电堆发出的电流会比以前少，从而导致系统功率下降 (图 7-34)。然后，系统功率输出小于额定功率 (5kW)，功率控制器会增加电堆燃料流量。但是，由于电堆的电流抽取能力降低，基于电流的常规控制器不能通过增加电流来消耗更多的燃料，过量的燃料将进入燃烧器，这种故障会导致燃烧器温度不断升高。最后，燃烧器温度最终达到燃烧器所能承受的极限 (1260 K)，会造成极大的破坏，甚至发生爆炸等危险。此外，系统功率、燃料利用率 (FU) 和系统效率 (SE) 也在下降。空气流量的下降是由于在电堆中产生的反应热较少，温度控制器的控制作用不需要太多的空气流量来带走多余的热量。在发生上述情况后，必须关闭 SOFC 以避免危险的发生。

10000~20000s 的所有现象都表明，当系统出现故障时，传统控制器无法对系统参数进行有效的控制，反而使系统的性能恶化。从 20000s 开始，容错控制器就开始工作了。首先，AOR

回收 40% 的阳极尾气中的氢气 (图 7-33), 并减少反馈控制驱动, 使情况恶化 (燃烧器温度升高) 得到了有效的缓解。控制器使用于进入燃烧器的多余燃料回流到电堆入口, 最后, 燃烧器温度下降到正常水平。为了平衡电堆气体的压力, 前馈控制作用 K_{AOR} 降低了燃料到电堆的流量, 使氢气流速从 0.066mol/s (正常状态) 降至 0.06mol/s (容错控制状态)。由于的电堆退化不能使系统功率恢复到正常的全功率 (5kW), 导致系统所需燃料比正常状态少。但电堆中储存的燃料比第二个 10000s ($10000\text{-}20000\text{ s}$) 更多, 使系统功率从 4100 W 提高到 4500 W , 比传统控制器增加 10%。

总体结果表明, 当发生故障的容错控制器保持系统参数如温度 (图 7-33), 电堆的温度, 燃料利用率 (FU) 和系统效率 (SE) (图 7-34) 安全操作范围内。但由于堆压承载能力的限制, 燃料不能增加过多直到恢复功率正常状态。电堆可以在降性能 (低于额定功率) 但安全的状态下运行。

7.5 张量标签学习评价结果

表 7-9 故障评价体系

Table 7-9 Fault evaluation system

故障类型 (Fault class)	故障识别 ($F1_d$)	1-D 定位精 度 ($F1_{11}$)	控制系统维持率 ($F1_c$)	1-D 定位、故障识别、容错控制 维持率综合评价 ($F1_{dt1c}$)
A	85%	85%	100%	75%
F	75%	75%	61%	55%
B	71%	51%	88%	37%

采用 3.5 章叙述的基于张量标签学习的故障识别、定位与容错控制评价体系对故障的系统进行量化度量。本指标评价的是故障诊断系统对这个故障的综合认知与治理的能力, 本故障诊断系统对不同故障的处理能力。从表 7-9 可以看出, 系统对故障 A 的识别率、定位精度、控制系统维持率以及综合指标都高于另外两个故障类型, 从机理分析故障 A 并不是致命性故障, 只是会造成系统的效率降低但并没有对系统的安全性产生重大影响, 而且控制系统本身具有处理故障 A 的容错能力, 所以控制系统并不会因为故障 A 的改变而改变。另外两个故障 F 和 B 都在一定程度上增加了系统处理的难度, 所以故障的综合治理能力比较低。

7.6 本章小结

为了解决工业系统老化故障系统参数难以准确表达的难题, 利用故障识别定位算法得到的结果, 本文利用 0-阶张量标签学习的故障识别的结果, 设计了一种基于故障识别结果的控

制律重新调度型主动容错控制器，来应对工业系统老化的故障，但控制系统仍然可以正常调控的故障恢复问题。为了解决工业系统老化故障系统系统参数时变而且无法用准确的数学方程来表达的难点，本章提出了一种基于 TS 型的贝叶斯学习机与 GPC 相结合的方式，在一定的时间窗内在线辨识缓慢变化故障下的系统参数，并将输入输出关系映射输入到 GPC 控制器中，实现了控制律在线重组型主动容错控制。最后，本节将容错控制和故障识别与定位统一到一个评价框架中，定量的评价故障诊断系统对故障的认知和处理能力。

第 8 章 总结与展望

本文在深入了解生产过程中的过程特性、数据特性以及基于机器学习故障诊断方法的基础上，解决了故障信息表示不充分问题以及故障诊断各环节无法统一度量的问题。利用张量标签学习的方法研究故障的识别、定位与控制问题，将这三个故障诊断的主要环节输出的异构信息数据统一到张量学习的框架中，将异构的故障信息融合到故障诊断张量中，综合评价故障诊断系统对故障的处理能力。本研究提出的张量标签学习，将数据的信息表示在高维的张量数据结构中，能够更本质的保持和反映数据信息的结构、数据的时序关系和不同数据模式之间的本质联系。

本文采用模式识别的方法来解决变工况条件下的工业故障识别、定位与容错控制的问题。采用了标量标签学习的方法解决了工业过程的故障识别的问题，然后利用识别的结果进行了容错控制的研究；研究了并发故障的情况，分别利用向量标签学习的方法研究了海量数据样本下的并发故障识别，利用向量标签-迁移学习的策略研究了稀疏样本条件下的并发故障问题；针对故障定位的问题，本文采用了两种类型的特征选择方法对故障源变量进行了定位，并将工业系统的部分知识加入到故障定位中，可以快速准确的定位到故障的位置。

本文的主要创新如下：

第一，本文研究了故障的识别、定位与控制问题，并将这三个故障诊断的主要环节输出的异构信息数据统一到张量学习的框架中，将异构的故障信息融合到故障诊断张量中，综合评价故障诊断系统对故障的处理能力。本研究为了解决故障信息表示不充分问题以及故障诊断各环节无法统一度量的问题，本研究提出的张量标签学习，将数据的信息表示在高维的张量数据结构中，能够更本质的保持和反映数据信息的结构、数据的时序关系和不同数据模式之间的本质联系。将故障的识别、定位与容错控制的异构信息进行信息融合，对工业系统和控制系统的故障进行精确的状态、位置以及类别的判定，进行快速完整的态势和威胁估计，对工业系统安全的威胁进行高效、精确的进行处理。

第二，本文实现了两个层次的信息融合。一是多传感器信息融合，利用工业系统多种类型的传感器来获得系统的数据，利用不同来源的传感器的数据进行检测、关联、相关、识别，将多源数据的信息综合的利用，实现了两套数据挖掘系统：故障识别和故障定位。二是利用故障识别与故障定位两套数据挖掘系统的信息，按照张量信息表示融合到定位与识别张量中，从而对故障精确的位置和类型进行判别，利用张量标签学习综合判断、评价数据挖掘的知识，从而可以对工况和故障威胁及其重要程度进行全面及时的进行信息处理，对故障进行精确、完整、高效的进行消除。

第三，本研究对不同特性数据利用相应的机器学习的方法提取隐藏其内部的可用信息，

对建立的有效机器学习模型将基于数据驱动的变工况故障识别问题转化为模式识别问题来进行分析从而实施故障类型的识别，这具有一定的理论意义和实际应用价值。本研究提出了基于张量标签学习的故障识别方法处理的结果可应用于设备故障识别中，可以提高状态监测和故障识别智能化的程度。

第四，本研究将监督学习、多标签问题统一到张量标签学习的框架中，作为 0-阶张量、1-阶张量学习的特殊情况。将现有的多标签学习拓展到了高维的张量形式，并在故障诊断与容错控制领域赋予了实际的含义。

第五，本文设计的 TS 型贝叶斯学习机与广义预测控制相结合的主动容错控制方案，将机器学习方法与控制理论相结合，利用机器学习来辨识当前的系统参数，并将状态参数与控制参数的关系相映射，实现了控制律在线重组的主动型容错控制与机器学习的有机结合。

第六，拓展了机器学习在工业故障识别领域应用的方法。之前的工业故障识别极大的依赖监督学习，本文将迁移学习应用到并发故障识别中，主要解决并发数据域数据量稀少的问题，工业领域或者其他领域类似的问题，都可以采用本文提出的 ML-Transfer learning 的方法进行数据域的转换，训练得到预测模型。现阶段机器学习模式识别领域的仅采用监督学习，迁移学习的应用拓展了机器学习在工业模式识别中的范围，放松了监督学习对数据要满足独立同分布的假设和训练数据要足够的假设。

基于本文的研究，后续可以开展的工作：

(1) 本文研究的是标签的张量化，后续可以开展工业数据 X 的张量化研究，利用张量型结构的数据，可以保存更多的数据特性以及数据之间的联系，通过分析张量数据的结构，张量型降维以及张量型数据的分解，例如张量的 CP 分解和 Tucker 分解，可以挖掘出更多的数据信息。

(2) 异常检测与识别的研究。本文研究的内容虽然是工业数据的故障识别与定位问题，但是本质上，是一种异常状态与正常状态的检测与识别的问题，这是一个在非常多的领域都具有普遍意义的问题。例如，网络安全领域，检测网络的安全运行与攻击，识别网络攻击的位置；金融领域的反洗钱与反不正当交易等。都可以借用本文提出的方法与问题与方法进行研究。

(3) 迁移学习与生成式对抗网络 (GAN, Generative Adversarial Networks) 的结合。迁移学习主要是为了解决某些工业状态数据缺少的问题，而 GAN 的出发点就是为了通过生成与对抗的方式训练得到一个可以生成数据的深度学习网络，因此，如果将迁移学习与 GAN 合理的结合，可以在一定程度上解决缺少训练数据的问题，这在许多领域都会有非常广泛的应用。

参 考 文 献

- [1] Puggini L, McLoone S. An enhanced variable selection and Isolation Forest based methodology for anomaly detection with OES data [J]. ENGINEERING APPLICATIONS OF ARTIFICIAL INTELLIGENCE, 2018, 67: 126-135.
- [2] van Horssen L J, de Visser C C, Pool D M. Aerodynamic Stall and Buffet Modeling for the Cessna Citation II Based on Flight Test Data 2018:1-28.
- [3] Slimane A, Kebdani S, Bouchouicha B, et al. An interactive method for predicting industrial equipment defects [J]. INTERNATIONAL JOURNAL OF ADVANCED MANUFACTURING TECHNOLOGY, 2018, 95 (9-12): 4341-4351.
- [4] Precup R, Angelov P, Jales Costa B S, et al. An overview on fault diagnosis and nature-inspired optimal control of industrial process applications [J]. COMPUTERS IN INDUSTRY, 2015, 74 (SI): 75-94.
- [5] Liu R, Yang B, Zio E, et al. Artificial intelligence for fault diagnosis of rotating machinery: A review [J]. MECHANICAL SYSTEMS AND SIGNAL PROCESSING, 2018, 108: 33-47.
- [6] Maitre J, Bouchard B, Bouzouane A, et al. Classification Algorithms Comparison for Interturn Short-Circuit Recognition in Induction Machines Using Best-Fit 3-D-Ellipse Method [J]. CANADIAN JOURNAL OF ELECTRICAL AND COMPUTER ENGINEERING-REVUE CANADIENNE DE GENIE ELECTRIQUE ET INFORMATIQUE, 2018, 40 (4): 255-265.
- [7] Bindu S, Thomas V V. Detection of Static Air-Gap Eccentricity in Three-Phase Squirrel Cage Induction Motor Through Stator Current and Vibration Analysis [M]//GARG A, KUMAR BHOI A, SANJEEVIKUMAR P, et al. 2018:511-518.
- [8] Zhong J, Wong P K, Yang Z. Fault diagnosis of rotating machinery based on multiple probabilistic classifiers [J]. MECHANICAL SYSTEMS AND SIGNAL PROCESSING, 2018, 108: 99-114.
- [9] Nadeer E P, Patra A, Mukhopadhyay S. Hybrid State Space Modeling of a Spark Ignition Engine for Online Fault Diagnosis [J]. JOURNAL OF DYNAMIC SYSTEMS MEASUREMENT AND CONTROL-TRANSACTIONS OF THE ASME, 2018, 140 (0410104).
- [10] Zhou L, Chen J, Hou B, et al. Multi-grade principal component analysis for fault detection with multiple production grades [J]. CHEMOMETRICS AND INTELLIGENT LABORATORY SYSTEMS, 2018, 175: 20-29.
- [11] Zhaojun C. New train of thought in troubleshooting of modern automobiles [J]. AIP Conference Proceedings, 2018, 1944: 20042-20043.
- [12] Huang Q, Hui R, Wang B, et al. A review of AC impedance modeling and validation in SOFC diagnosis [J]. ELECTROCHIMICA ACTA, 2007, 52 (28): 8144-8164.
- [13] Arafat A K M, Choi S. Optimal Phase Advance Under Fault-Tolerant Control of a Five-Phase Permanent Magnet Assisted Synchronous Reluctance Motor [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2018, 65 (4): 2915-2924.
- [14] Prasad A, Belwin Edward J. Wavelet Technique-Based Fault Classification in Transmission Lines [M]//GARG A, KUMAR BHOI A, SANJEEVIKUMAR P, et al. 2018:403-410.
- [15] 张可, 周东华, 柴毅. 复合故障诊断技术综述 [J]. 控制理论与应用, 2015, (9): 1143-1157.
- [16] A. N, J. D, A. C, et al. Intelligent process monitoring by interfacing knowledge-based systems and multivariate statistical monitoring [J]. 2000, 10 (4): 341-350.
- [17] Fatima S, Mohanty A R, Naikan V N A. A misalignment detection methodology by measuring rate of temperature rise of shaft coupling using thermal imaging [J]. PROCEEDINGS OF THE INSTITUTION OF MECHANICAL ENGINEERS PART O-JOURNAL OF RISK AND RELIABILITY, 2015, 229 (3): 209-219.
- [18] El-Thalji I, Jantunen E. A summary of fault modelling and predictive health monitoring of rolling element bearings [J]. MECHANICAL SYSTEMS AND SIGNAL PROCESSING,

- 2015, 60-61: 252-272.
- [19] Caesarendra W, Kosasih B, Tieu A K, et al. Acoustic emission-based condition monitoring methods: Review and application for low speed slew bearing [J]. MECHANICAL SYSTEMS AND SIGNAL PROCESSING, 2016, 72-73: 134-159.
 - [20] Raza S, Mokhlis H, Arof H, et al. Application of signal processing techniques for islanding detection of distributed generation in distribution network: A review [J]. ENERGY CONVERSION AND MANAGEMENT, 2015, 96: 613-624.
 - [21] Zhenyu Z, Juan W, Xinli M, et al. Reviews of recent progress on low-complexity linear detection via iterative algorithms for massive MIMO systems [J]. 2016 IEEE/CIC International Conference on Communications in China (ICCC): Workshops, 2016: 6.
 - [22] Li S, Gong L, Yang Y. Fault Tolerant Control of an Anode Offgas Recycle Based SOFC System. American Control Conference (ACC 2017). 2017:4117-4122.
 - [23] Wang D, Larder B, Revell A, et al. A comparison of three computational modelling methods for the prediction of virological response to combination HIV therapy [J]. ARTIFICIAL INTELLIGENCE IN MEDICINE, 2009, 47 (1): 63-74.
 - [24] Allahbakhshi M, Akbari A. An improved computational approach for thermal modeling of power transformers [J]. INTERNATIONAL TRANSACTIONS ON ELECTRICAL ENERGY SYSTEMS, 2015, 25 (7): 1319-1332.
 - [25] Patel J, Parekh K, Upadhyay R V. Prevention of hot spot temperature in a distribution transformer using magnetic fluid as a coolant [J]. INTERNATIONAL JOURNAL OF THERMAL SCIENCES, 2016, 103: 35-40.
 - [26] Pylvanainen J K, Nousiainen K, Verho P. Studies to utilize loading guides and ANN for oil-immersed distribution transformer condition monitoring [J]. IEEE TRANSACTIONS ON POWER DELIVERY, 2007, 22 (1): 201-207.
 - [27] Isermann R, Balle P. Trends in the application of model based fault detection and diagnosis of technical processes [M]//GERTLER J J, CRUZ J B, PESHKIN M, et al. 1997:1-12.
 - [28] Jiang B, Staroswiecki M. Fault diagnosis for nonlinear uncertain systems using robust/sliding mode observers [J]. Control and Intelligent Systems, 2005, 33 (3): 151-157.
 - [29] O'Neill Z, Narayanan S. Model-based estimation of cold room temperatures in a supermarket refrigeration system [J]. APPLIED THERMAL ENGINEERING, 2014, 73 (1): 819-830.
 - [30] Zhang P, Ding S X. Disturbance decoupling in fault detection of linear periodic systems [J]. AUTOMATICA, 2007, 43 (8): 1410-1417.
 - [31] Costamagna P, De Giorgi A, Magistri L, et al. A Classification Approach for Model-Based Fault Diagnosis in Power Generation Systems Based on Solid Oxide Fuel Cells [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2016, 31 (2): 683-694.
 - [32] Steiner N Y, Hissel D, Mocoteguy P, et al. Application of Fault Tree Analysis to Fuel Cell diagnosis [J]. FUEL CELLS, 2012, 12 (2S1): 302-309.
 - [33] Wu X, Ye Q. Fault diagnosis and prognostic of solid oxide fuel cells [J]. JOURNAL OF POWER SOURCES, 2016, 321: 47-56.
 - [34] Polverino P, Pianese C, Sorrentino M, et al. Model-based development of a fault signature matrix to improve solid oxide fuel cell systems on-site diagnosis [J]. JOURNAL OF POWER SOURCES, 2015, 280: 320-338.
 - [35] Murshed A K M M, Huang B, Nandakumar K. Monitoring of solid oxide fuel cell systems [J]. ASIA-PACIFIC JOURNAL OF CHEMICAL ENGINEERING, 2011, 6 (2): 204-219.
 - [36] Sorrentino M, Marra D, Pianese C, et al. On the Use of Neural Networks and Statistical Tools for Nonlinear Modeling and On-Field Diagnosis of Solid Oxide Fuel Cell Stacks [M]//MORINI G L, BIANCHI M, SACCANI C, et al. Energy Procedia. 2014:298-307.
 - [37] Liu T Y, Lin K J, Wu H. ECG Data Encryption Then Compression Using Singular Value Decomposition. [J]. IEEE journal of biomedical and health informatics, 2017.
 - [38] Kumar R, Kumar A, Singh G K, et al. Efficient compression technique based on temporal modelling of ECG signal using principle component analysis [J]. IET SCIENCE MEASUREMENT & TECHNOLOGY, 2017, 11 (3): 346-353.
 - [39] Kumar R, Kumar A, Singh G K. Electrocardiogram signal compression using singular

- coefficient truncation and wavelet coefficient coding [J]. IET SCIENCE MEASUREMENT & TECHNOLOGY, 2016, 10 (4): 266-274.
- [40] Kumar R, Kumar A, Singh G K. Hybrid method based on singular value decomposition and embedded zero tree wavelet technique for ECG signal compression [J]. COMPUTER METHODS AND PROGRAMS IN BIOMEDICINE, 2016, 129: 135-148.
- [41] Padhy S, Sharma L N, Dandapat S. Multilead ECG data compression using SVD in multiresolution domain [J]. BIOMEDICAL SIGNAL PROCESSING AND CONTROL, 2016, 23: 10-18.
- [42] Zhang L, Yang Y, Yu M. Study on Compression Algorithm for Long-term Continuous Driving Behavior Data Based on Fractal Interpolation 2016:115-120.
- [43] Huang Y C. A new data mining approach to dissolved gas analysis of oil-insulated power apparatus [J]. IEEE TRANSACTIONS ON POWER DELIVERY, 2003, 18 (4): 1257-1261.
- [44] He D, Li R, Zhu J. Plastic Bearing Fault Diagnosis Based on a Two-Step Data Mining Approach [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2013, 60 (8): 3429-3440.
- [45] Zhou J, Yang Y, Ding S X, et al. A Fault Detection and Health Monitoring Scheme for Ship Propulsion Systems Using SVM Technique [J]. IEEE ACCESS, 2018, 6: 16207-16215.
- [46] Dong J, Wang Q, Wang M, et al. Data-Driven Quality Monitoring Techniques for Distributed Parameter Systems With Application to Hot-Rolled Strip Laminar Cooling Process [J]. IEEE ACCESS, 2018, 6.
- [47] Ragab A, El-Koujok M, Poulin B, et al. Fault diagnosis in industrial chemical processes using interpretable patterns based on Logical Analysis of Data [J]. EXPERT SYSTEMS WITH APPLICATIONS, 2018, 95: 368-383.
- [48] Ma L, Dong J, Peng K. Root cause diagnosis of quality-related faults in industrial multimode processes using robust Gaussian mixture model and transfer entropy [J]. NEUROCOMPUTING, 2018, 285: 60-73.
- [49] Yu W, Zhao C. Sparse Exponential Discriminant Analysis and Its Application to Fault Diagnosis [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2018, 65 (7): 5931-5940.
- [50] Keay K, Simmonds I. The association of rainfall and other weather variables with road traffic volume in Melbourne, Australia [J]. ACCIDENT ANALYSIS AND PREVENTION, 2005, 37 (1): 109-124.
- [51] Wei Y, Chaudhary V. Fast Quantitative Analysis of Stock Trading Points in Dual Period of DMAC 2015:34-43.
- [52] Sartori I, Sandberg N H, Brattebo H. Dynamic building stock modelling: General algorithm and exemplification for Norway [J]. ENERGY AND BUILDINGS, 2016, 132 (SI): 13-25.
- [53] Yongmei L, Guangeng L, Wanxing S, et al. An electric shock impedance modeling method of living organisms in low-voltage distribution network [J]. 2016 China International Conference on Electricity Distribution (CICED), 2016: 5.
- [54] Yang T, Pen H, Wang Z, et al. Feature Knowledge Based Fault Detection of Induction Motors Through the Analysis of Stator Current Data [J]. IEEE TRANSACTIONS ON INSTRUMENTATION AND MEASUREMENT, 2016, 65 (3): 549-558.
- [55] Lau E C C, Ngan H W. Detection of Motor Bearing Outer Raceway Defect by Wavelet Packet Transformed Motor Current Signature Analysis [J]. IEEE TRANSACTIONS ON INSTRUMENTATION AND MEASUREMENT, 2010, 59 (10): 2683-2690.
- [56] Lei Y, Jia F, Lin J, et al. An Intelligent Fault Diagnosis Method Using Unsupervised Feature Learning Towards Mechanical Big Data [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2016, 63 (5): 3137-3147.
- [57] Li B, Chow M Y, Tipsuwan Y, et al. Neural-network-based motor rolling bearing fault diagnosis [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2000, 47 (5): 1060-1069.
- [58] 江道灼, 张锋, 张怡. 基于配电监控终端的配网故障区域判断和隔离 [J]. 继电器, 2002, (9): 21-24, 57.

- [59] 陈清川, 王成楷, 杨振中. 一种基于网形结构矩阵的配电网故障定位改进算法研究 [J]. 电气技术, 2010, (12): 31-34, 38.
- [60] 谢艳菲. 基于改进矩阵算法的配电网故障定位研究 [J]. 电力学报, 2011, (3): 199-201.
- [61] 许琪, 刘维亭, 戴星明. 基于多支配电网的新型矩阵故障定位算法 [J]. 科学技术与工程, 2011, (29): 7097-7100.
- [62] 庄进发. 基于模式识别的流程工业生产在线故障诊断若干问题研究 [D]. 厦门大学控制理论与控制工程, 2009.
- [63] 张小易, 徐兵, 张岩, 等. 利用气象等影响要素的电力系统故障元件识别与故障原因分析 [J]. 华北电力大学学报 (自然科学版), 2014, (6): 14-21.
- [64] 张可, 周东华, 柴毅. 复合故障诊断技术综述 [J]. 控制理论与应用, 2015, (9): 1143-1157.
- [65] 苗启, 张端金. 容错控制理论的新进展 [J]. 电气自动化, 2007, (6): 3-6.
- [66] 周振超, 张健, 王立红, 等. 容错控制理论综述与展望 [J]. 自动化博览, 2008, (7): 77-79.
- [67] Wu H, Lin X, Liu X, et al. Application-Level Scheduling With Probabilistic Deadline Constraints [J]. IEEE-ACM TRANSACTIONS ON NETWORKING, 2016, 24 (3): 1504-1517.
- [68] Javier Lopez-Martinez F, Kurniawan E, Islam R, et al. Average Fade Duration for Amplify-and-Forward Relay Networks in Fading Channels [J]. IEEE TRANSACTIONS ON WIRELESS COMMUNICATIONS, 2015, 14 (10): 5454-5467.
- [69] Amerimehr M H, Ashtiani F, Valaee S. Maximum Stable Throughput of Network-Coded Multiple Broadcast Sessions for Wireless Tandem Random Access Networks [J]. IEEE TRANSACTIONS ON MOBILE COMPUTING, 2014, 13 (6): 1256-1267.
- [70] Hashmi U S, Zaidi S A R, Imran A. User-Centric Cloud RAN: An Analytical Framework for Optimizing Area Spectral and Energy Efficiency [J]. IEEE ACCESS, 2018, 6: 19859-19875.
- [71] Huang C Y, Stengel R F. Restructurable control using proportional-integral implicit model following [J]. Journal of Guidance, Control, and Dynamics, 1990, 13 (2): 303-309.
- [72] Gheorghe A. Restructurable control using proportional-integral implicit model following (vol 13, pg 303, 1990) [J]. IEEE CONTROL SYSTEMS MAGAZINE, 2013, 33 (5): 71.
- [73] Garcia-Alvarez D, Fuente M J. A UPCA-based monitoring and fault detection approach for reverse osmosis desalination plants [J]. DESALINATION AND WATER TREATMENT, 2014, 52 (7-9): 1272-1286.
- [74] Monroy I, Villegas K, Graells M, et al. Fault diagnosis of a benchmark fermentation process: a comparative study of feature extraction and classification techniques [J]. BIOPROCESS AND BIOSYSTEMS ENGINEERING, 2012, 35 (5): 689-704.
- [75] Sales R F, Vitale R, de Lima S M, et al. Multivariate statistical process control charts for batch monitoring of transesterification reactions for biodiesel production based on near-infrared spectroscopy [J]. COMPUTERS & CHEMICAL ENGINEERING, 2016, 94: 343-353.
- [76] Kharbach M, Cherrah Y, Vander Heyden Y, et al. Multivariate statistical process control in product quality review assessment - A case study [J]. Annales Pharmaceutiques Francaises, 2017, 75 (6).
- [77] Kharbach M, Cherrah Y, Vander Heyden Y, et al. Multivariate statistical process control in product quality review assessment-A case study. [J]. Annales pharmaceutiques francaises, 2017, 75 (6): 446-454.
- [78] Chakraborty S, Mandal P K. SPC based on growth models for monitoring the process of hydrogenation of edible oil [J]. JOURNAL OF FOOD ENGINEERING, 2015, 146: 192-203.
- [79] 赵旭. 基于统计学方法的过程监控与质量控制研究 [D]. 上海交通大学控制理论与控制工程, 2007.
- [80] 马玉鑫. 流程工业过程故障检测的特征提取方法研究 [D]. 华东理工大学控制科学与工程, 2015.
- [81] 蒋雷海, 万芳茹, 徐泰山. 电力系统故障恢复方法简述 [J]. 电力自动化设备, 2002, (5): 70-73.
- [82] 徐兵. 利用多源信息的电力系统故障诊断方法与应用 [D]. 浙江大学电气工程, 2017.

-
- [83] Dai C, Liu Z, Hu K, et al. Fault diagnosis approach of traction transformers in high-speed railway combining kernel principal component analysis with random forest [J]. IET ELECTRICAL SYSTEMS IN TRANSPORTATION, 2016, 6 (3): 202-206.
 - [84] Shekhawat H S, Weiland S. A locally convergent Jacobi iteration for the tensor singular value problem [J]. MULTIDIMENSIONAL SYSTEMS AND SIGNAL PROCESSING, 2018, 29 (3): 1075-1094.
 - [85] Kim J. A new numerically stable sequential algorithm for coupled finite-strain elastoplastic geomechanics and flow [J]. COMPUTER METHODS IN APPLIED MECHANICS AND ENGINEERING, 2018, 335: 538-562.
 - [86] 王飞. 基于众包的张量模乘计算 [D].华中科技大学计算机技术, 2015.
 - [87] Zhu Q, Liu Y, Lu J, et al. Observability of Boolean control networks [J]. SCIENCE CHINA-INFORMATION SCIENCES, 2018, 61 (0922019).
 - [88] 匡立伟. 基于张量的大数据统一表示及降维方法研究 [D].华中科技大学计算机系统结构, 2016.
 - [89] Zamkovoy S, Nakova G. The decomposition of almost paracontact metric manifolds in eleven classes revisited [J]. JOURNAL OF GEOMETRY, 2018, 109 (UNSP 181).
 - [90] Syrakos A, Dimakopoulos Y, Tsamopoulos J. Theoretical study of the flow in a fluid damper containing high viscosity silicone oil: Effects of shear-thinning and viscoelasticity [J]. PHYSICS OF FLUIDS, 2018, 30 (0307083).
 - [91] Jordan M I, Mitchell T M. Machine learning: Trends, perspectives, and prospects [J]. SCIENCE, 2015, 349 (6245SI): 255-260.
 - [92] Cao H, Li X, Deng Z, et al. Dynamic modeling and experimental validation for the electrical coupling in a 5-cell solid oxide fuel cell stack in the perspective of thermal coupling [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2011, 36 (7SI): 4409-4418.
 - [93] Zhang L, Li X, Jiang J, et al. Dynamic modeling and analysis of a 5-kW solid oxide fuel cell system from the perspectives of cooperative control of thermal safety and high efficiency [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2015, 40 (1): 456-476.
 - [94] Jiang J, Li X, Deng Z, et al. Thermal management of an independent steam reformer for a solid oxide fuel cell with constrained generalized predictive control [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2012, 37 (17): 12317-12331.
 - [95] Cao H, Li X, Deng Z, et al. Thermal management oriented steady state analysis and optimization of a kW scale solid oxide fuel cell stand-alone system for maximum system efficiency [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2013, 38 (28): 12404-12417.
 - [96] Cao H, Li X. Thermal Management-Oriented Multivariable Robust Control of a kW-Scale Solid Oxide Fuel Cell Stand-Alone System [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2016, 31 (2): 603-612.
 - [97] 廖思威. 并行高阶SVD及其增量计算的研究 [D].华中科技大学系统结构, 2015.
 - [98] 程媛. 多关系数据聚类算法及其应用研究 [D].哈尔滨工程大学计算机应用技术, 2014.
 - [99] Kuang L, Hao F, Yang L T, et al. A Tensor-Based Approach for Big Data Representation and Dimensionality Reduction [J]. IEEE TRANSACTIONS ON EMERGING TOPICS IN COMPUTING, 2014, 2 (3): 280-291.
 - [100] Kuang L, Yang L T, Wang X, et al. A Tensor-Based Big Data Model for QoS Improvement in Software Defined Networks [J]. IEEE NETWORK, 2016, 30 (1): 30-35.
 - [101] Kuang L, Zulkernine M. An intrusion-tolerant mechanism for intrusion detection systems [M]//JAKOUBI S, TJOA S, WEIPPL E R. 2008:319.
 - [102] Kuang L, Yang L T, Qiu K. TENSOR-BASED SOFTWARE-DEFINED INTERNET OF THINGS [J]. IEEE WIRELESS COMMUNICATIONS, 2016, 23 (5): 84-89.
 - [103] Li S, Cao H, Yang Y. Data-driven simultaneous fault diagnosis for solid oxide fuel cell system using multi-label pattern identification [J]. Journal of Power Sources, 2018, 378: 646-659.
 - [104] Wong P K, Zhong J, Yang Z, et al. A new framework for intelligent simultaneous-fault diagnosis of rotating machinery using pairwise-coupled sparse Bayesian extreme learning committee machine [J]. PROCEEDINGS OF THE INSTITUTION OF MECHANICAL

-
- ENGINEERS PART C-JOURNAL OF MECHANICAL ENGINEERING SCIENCE, 2017, 231 (6): 1146-1161.
- [105] Vong C, Wong P, Ip W. A New Framework of Simultaneous-Fault Diagnosis Using Pairwise Probabilistic Multi-Label Classification for Time-Dependent Patterns [J]. IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS, 2013, 60 (8): 3372-3385.
- [106] Monroy I, Benitez R, Escudero G, et al. A semi-supervised approach to fault diagnosis for chemical processes [J]. COMPUTERS & CHEMICAL ENGINEERING, 2010, 34 (5SI): 631-642.
- [107] Yelamos I, Escudero G, Graells M, et al. Performance assessment of a novel fault diagnosis system based on support vector machines [J]. COMPUTERS & CHEMICAL ENGINEERING, 2009, 33 (1): 244-255.
- [108] Yelamos I, Graells M, Puigjaner L, et al. Simultaneous fault diagnosis in chemical plants using a multilabel approach [J]. AIChE JOURNAL, 2007, 53 (11): 2871-2884.
- [109] Pooyan N, Shahbazian M, Salahshoor K, et al. Simultaneous Fault Diagnosis using multi class support vector machine in a Dew Point process [J]. JOURNAL OF NATURAL GAS SCIENCE AND ENGINEERING, 2015, 23: 373-379.
- [110] 李红丽, 许春香, 马耀锋. 基于多核学习SVM的图像分类识别算法 [J]. 现代电子技术, 2018, (6): 50-52, 56.
- [111] 吕飞, 韩敏. 基于深度极限学习机的高光谱遥感影像分类研究 [J]. 大连理工大学学报, 2018, (2): 166-173.
- [112] 周华兵, 朱国家, 张彦铎, 等. 基于兴趣域检测的空间金字塔匹配图像分类 [J]. 计算机工程与应用, 2018, (3): 206-211.
- [113] 刘国锋, Chen W. U. 基于支持向量机和稀疏表示的文本分类研究 [J]. 计算机与数字工程, 2017, (12): 2479-2481, 2497.
- [114] Barelli L, Barluzzi E, Bidini G. Diagnosis methodology and technique for solid oxide fuel cells: A review [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2013, 38 (12): 5060-5074.
- [115] Sorce A, Greco A, Magistri L, et al. FDI oriented modeling of an experimental SOFC system, model validation and simulation of faulty states [J]. APPLIED ENERGY, 2014, 136: 894-908.
- [116] Wen L, Gao L, Li X. A New Deep Transfer Learning Based on Sparse Auto-Encoder for Fault Diagnosis [J]. IEEE T. Syst. Man Cy-S., 2017, PP (99): 1-9.
- [117] Pan S J, Yang Q. A Survey on Transfer Learning [J]. IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING, 2010, 22 (10): 1345-1359.
- [118] Salaken S M, Khosravi A, Thanh N, et al. Extreme learning machine based transfer learning algorithms: A survey [J]. NEUROCOMPUTING, 2017, 267: 516-524.
- [119] Min A T W, Sagarna R, Gupta A, et al. Knowledge Transfer Through Machine Learning in Aircraft Design [J]. IEEE COMPUTATIONAL INTELLIGENCE MAGAZINE, 2017, 12 (4): 48-60.
- [120] Aerts G, Doooms M, Haezendonck E. Knowledge transfers and project-based learning in large scale infrastructure development projects: an exploratory and comparative ex-post analysis [J]. INTERNATIONAL JOURNAL OF PROJECT MANAGEMENT, 2017, 35 (3): 224-240.
- [121] Wang Y, Song J, Marquez-Lago T T, et al. Knowledge-transfer learning for prediction of matrix metalloprotease substrate-cleavage sites [J]. SCIENTIFIC REPORTS, 2017, 7 (5755).
- [122] Pun M, Mutibwa D, Li R. Land Use Classification: A Surface Energy Balance and Vegetation Index Application to Map and Monitor Irrigated Lands [J]. REMOTE SENSING, 2017, 9 (125612).
- [123] Shao L, Zhu F, Li X. Transfer Learning for Visual Categorization: A Survey [J]. IEEE TRANSACTIONS ON NEURAL NETWORKS AND LEARNING SYSTEMS, 2015, 26 (5): 1019-1034.
- [124] Lu J, Behbood V, Hao P, et al. Transfer learning using computational intelligence: A survey [J]. KNOWLEDGE-BASED SYSTEMS, 2015, 80 (SI): 14-23.
- [125] Zhang R, Tao H, Wu L, et al. Transfer Learning With Neural Networks for Bearing Fault Diagnosis in Changing Working Conditions [J]. IEEE Access, 2017, 5; 5: 14347-14357.

-
- [126] Zhuang F, Luo P, Du C, et al. Triplex Transfer Learning: Exploiting Both Shared and Distinct Concepts for Text Classification [J]. IEEE TRANSACTIONS ON CYBERNETICS, 2014, 44 (7): 1191-1203.
 - [127] Das S, Chakraborty R, Maitra A. A random forest algorithm for nowcasting of intense precipitation events [J]. ADVANCES IN SPACE RESEARCH, 2017, 60 (6): 1271-1282.
 - [128] Abellan J, Mantas C J, Castellano J G. A Random Forest approach using imprecise probabilities [J]. KNOWLEDGE-BASED SYSTEMS, 2017, 134: 72-84.
 - [129] Dai C, Liu Z, Hu K, et al. Fault diagnosis approach of traction transformers in high-speed railway combining kernel principal component analysis with random forest [J]. IET ELECTRICAL SYSTEMS IN TRANSPORTATION, 2016, 6 (3): 202-206.
 - [130] Wang Z, Zhang Q, Xiong J, et al. Fault Diagnosis of a Rolling Bearing Using Wavelet Packet Denoising and Random Forests [J]. IEEE SENSORS JOURNAL, 2017, 17 (17): 5581-5588.
 - [131] Wang H, Zhou L. Random survival forest with space extensions for censored data [J]. ARTIFICIAL INTELLIGENCE IN MEDICINE, 2017, 79: 52-61.
 - [132] Uriarte R B, Tiezzi F, Tsafaris S A. Supporting Autonomic Management of Clouds: Service Clustering With Random Forest [J]. IEEE TRANSACTIONS ON NETWORK AND SERVICE MANAGEMENT, 2016, 13 (3SI): 595-607.
 - [133] 罗晓伟. 探究智能配网故障快速定位方法的研究与实现 [J]. 大科技, 2014, (31): 159, 160.
 - [134] 冯伟杰. 智能配网故障快速定位方法的研究与实现 [D]. 华南理工大学电气工程, 2011.
 - [135] 陈栩秋, 赵晓坤, 张宁. 智能配网故障快速定位方法的研究与实现 [J]. 信息通信, 2016, (9): 262, 263.
 - [136] 刘嘉伟. 智能配网故障快速定位方法研究 [J]. 中国科技投资, 2016, (33): 103.
 - [137] 陈炳灿. 智能配网故障快速定位方法研究 [J]. 中国高新技术企业 (中旬刊), 2016, (12): 1-2.
 - [138] Demetgul M, Yildiz K, Taskin S, et al. Fault diagnosis on material handling system using feature selection and data mining techniques [J]. MEASUREMENT, 2014, 55: 15-24.
 - [139] Liang L, Liu F, Li M, et al. Feature selection for machine fault diagnosis using clustering of non-negation matrix factorization [J]. MEASUREMENT, 2016, 94: 295-305.
 - [140] 史东锋, 屈梁生. 遗传算法在故障特征选择中的应用研究 [J]. 振动.测试与诊断, 2000, (03): 19-24.
 - [141] Singh D A A G, Balamurugan S A A, Leavline E J. A novel filter based feature selection for image and signal classification [J]. JOURNAL OF OPTOELECTRONICS AND ADVANCED MATERIALS, 2016, 18 (7-8): 645-653.
 - [142] Wang W, Liu C, Zhao Q, et al. An Improved Wrapper Method for Feature Selection [J]. Journal of University of Electronic Science and Technology of China, 2016, 45 (4): 607-615.
 - [143] Zhang D, Zhou Z. A Novel Spectral Clustering Based on Nonlinear Low Dimensional Embedding Feature Selection [J]. INTERNATIONAL JOURNAL OF GRID AND DISTRIBUTED COMPUTING, 2016, 9 (8): 171-180.
 - [144] 张丽新. 高维数据的特征选择及基于特征选择的集成学习研究 [D]. 北京: 清华大学, 2004.
 - [145] Grajski K A, Breiman L, Viana Di Prisco G, et al. Classification of EEG spatial patterns with a tree-structured methodology: CART. [J]. IEEE transactions on bio-medical engineering, 1986, 33 (12): 1076-1086.
 - [146] Mu Y, Liu X, Yang Z, et al. A parallel C4.5 decision tree algorithm based on MapReduce [J]. CONCURRENCY AND COMPUTATION-PRACTICE & EXPERIENCE, 2017, 29 (e40158).
 - [147] 许峰. 解耦控制在酸气压缩机性能控制中的应用 [J]. 自动化仪表, 2018, (1): 6-11.
 - [148] Xu D, Xu X, Chen X, et al. Research on improved consensus clustering algorithm based on Minkowski distance and its application [J]. Journal of Hunan University (Natural Sciences), 2016, 43 (4): 133-140.
 - [149] Ushakov V N, Lakhtin A S, Lebedev P D. Optimization of the Hausdorff distance between sets in Euclidean space [J]. PROCEEDINGS OF THE STEKLOV INSTITUTE OF

-
- MATHEMATICS, 2015, 2911: S222-S238.
- [150] Liu H, Zhang Y, Su X, et al. Mobile Localization Based on Received Signal Strength and Pearson's Correlation Coefficient [J]. INTERNATIONAL JOURNAL OF DISTRIBUTED SENSOR NETWORKS, 2015, (157046).
 - [151] Huang W, Zhang J, Sun H, et al. An Anomaly Detection Method Based on Normalized Mutual Information Feature Selection and Quantum Wavelet Neural Network [J]. WIRELESS PERSONAL COMMUNICATIONS, 2017, 96 (2): 2693-2713.
 - [152] Kira K, Rendell L A. The feature selection problem: traditional methods and a new algorithm [J]. AAAI-92. Proceedings Tenth National Conference on Artificial Intelligence, 1992: 129-134.
 - [153] Kononenko I. Estimating attributes: analysis and extensions of RELIEF [M]//BERGADANO F, DE RAEDT L. 1994:171-182.
 - [154] Lee J, Jo J, Choi S W, et al. A 10-kW SOFC low-voltage battery hybrid power conditioning system, for residential use [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2006, 21 (2): 575-585.
 - [155] Sedghisigarchi K, Feliachi A. Dynamic and transient analysis of power distribution systems with fuel cells - Part I: Fuel-cell dynamic model [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2004, 19 (2): 423-428.
 - [156] Colson C M, Nehrir M H. Evaluating the Benefits of a Hybrid Solid Oxide Fuel Cell Combined Heat and Power Plant for Energy Sustainability and Emissions Avoidance [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2011, 26 (1): 140-148.
 - [157] Fardadi M, Mueller F, Jabbari F. Feedback control of solid oxide fuel cell spatial temperature variation [J]. JOURNAL OF POWER SOURCES, 2010, 195 (13SI): 4222-4233.
 - [158] Wang C, Nehrir M H. Load transient mitigation for stand-alone fuel cell power generation systems [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2007, 22 (4): 864-872.
 - [159] Wang L, Lee D. Load-Tracking Performance of an Autonomous SOFC-Based Hybrid Power Generation/Energy Storage System [J]. IEEE TRANSACTIONS ON ENERGY CONVERSION, 2010, 25 (1): 128-139.
 - [160] Mueller F, Jabbari F, Gaynor R, et al. Novel solid oxide fuel cell system controller for rapid load following [J]. JOURNAL OF POWER SOURCES, 2007, 172 (1SI): 308-323.
 - [161] Allag T, Das T. Robust Control of Solid Oxide Fuel Cell Ultracapacitor Hybrid System [J]. IEEE TRANSACTIONS ON CONTROL SYSTEMS TECHNOLOGY, 2012, 20 (1): 1-10.
 - [162] Inui Y, Ito N, Nakajima T, et al. Analytical investigation on cell temperature control method of planar solid oxide fuel cell [J]. ENERGY CONVERSION AND MANAGEMENT, 2006, 47 (15-16): 2319-2328.
 - [163] Stiller C, Thorud B, Bolland O, et al. Control strategy for a solid oxide fuel cell and gas turbine hybrid system [J]. JOURNAL OF POWER SOURCES, 2006, 158 (1): 303-315.
 - [164] Murshed A K M M, Huang B, Nandakumar K. Estimation and control of solid oxide fuel cell system [J]. COMPUTERS & CHEMICAL ENGINEERING, 2010, 34 (1): 96-111.
 - [165] Pohjoranta A, Halinen M, Pennanen J, et al. Model predictive control of the solid oxide fuel cell stack temperature with models based on experimental data [J]. JOURNAL OF POWER SOURCES, 2015, 277: 239-250.
 - [166] Sorrentino M, Pianese C. Model-based development of low-level control strategies for transient operation of solid oxide fuel cell systems [J]. JOURNAL OF POWER SOURCES, 2011, 196 (21SI): 9036-9045.
 - [167] Mueller F, Jabbari F, Gaynor R, et al. Novel solid oxide fuel cell system controller for rapid load following [J]. JOURNAL OF POWER SOURCES, 2007, 172 (1SI): 308-323.
 - [168] Cao H, Li X, Deng Z, et al. Thermal management oriented steady state analysis and optimization of a kW scale solid oxide fuel cell stand-alone system for maximum system efficiency [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2013, 38 (28): 12404-12417.
 - [169] Inui Y, Ito N, Nakajima T, et al. Analytical investigation on cell temperature control method of planar solid oxide fuel cell [J]. ENERGY CONVERSION AND MANAGEMENT, 2006,

- 47 (15-16): 2319-2328.
- [170] Murshed A K M M, Huang B, Nandakumar K. Estimation and control of solid oxide fuel cell system [J]. *COMPUTERS & CHEMICAL ENGINEERING*, 2010, 34 (1): 96-111.
 - [171] Fardadi M, Mueller F, Jabbari F. Feedback control of solid oxide fuel cell spatial temperature variation [J]. *JOURNAL OF POWER SOURCES*, 2010, 195 (13SI): 4222-4233.
 - [172] Zhang X W, Chan S H, Ho H K, et al. Nonlinear model predictive control based on the moving horizon state estimation for the solid oxide fuel cell [J]. *INTERNATIONAL JOURNAL OF HYDROGEN ENERGY*, 2008, 33 (9): 2355-2366.
 - [173] Cao H, Li X, Deng Z, et al. Thermal management oriented steady state analysis and optimization of a kW scale solid oxide fuel cell stand-alone system for maximum system efficiency [J]. *INTERNATIONAL JOURNAL OF HYDROGEN ENERGY*, 2013, 38 (28): 12404-12417.
 - [174] Cao H, Li X. Thermal Management-Oriented Multivariable Robust Control of a kW-Scale Solid Oxide Fuel Cell Stand-Alone System [J]. *IEEE TRANSACTIONS ON ENERGY CONVERSION*, 2016, 31 (2): 603-612.
 - [175] Wu X, Huang Q, Zhu X. Power decoupling control of a solid oxide fuel cell and micro gas turbine hybrid power system [J]. *JOURNAL OF POWER SOURCES*, 2011, 196 (3SI): 1295-1302.
 - [176] Zhao D, Zheng Q, Gao F, et al. Disturbance decoupling control of an ultra-high speed centrifugal compressor for the air management of fuel cell systems [J]. *INTERNATIONAL JOURNAL OF HYDROGEN ENERGY*, 2014, 39 (4): 1788-1798.
 - [177] Torii R, Tachikawa Y, Sasaki K, et al. Anode gas recirculation for improving the performance and cost of a 5-kW solid oxide fuel cell system [J]. *JOURNAL OF POWER SOURCES*, 2016, 325: 229-237.
 - [178] Engelbracht M, Peters R, Blum L, et al. Comparison of a fuel-driven and steam-driven ejector in solid oxide fuel cell systems with anode off-gas recirculation: Part-load behavior [J]. *JOURNAL OF POWER SOURCES*, 2015, 277: 251-260.
 - [179] Peters R, Deja R, Engelbracht M, et al. Efficiency analysis of a hydrogen-fueled solid oxide fuel cell system with anode off-gas recirculation [J]. *JOURNAL OF POWER SOURCES*, 2016, 328: 105-113.
 - [180] Carre M, Brandenburger R, Friede W, et al. Feed-forward control of a solid oxide fuel cell system with anode offgas recycle [J]. *JOURNAL OF POWER SOURCES*, 2015, 282: 498-510.
 - [181] Branco P, Dente J A. A fuzzy relational identification algorithm and its application to predict the behaviour of a motor drive system [J]. *FUZZY SETS AND SYSTEMS*, 2000, 109 (3): 343-354.
 - [182] Sung K O, Young H J, Eui S N, et al. Fuzzy identification by means of fuzzy inference method and its application to waste water treatment system [J]. *Journal of the Korean Institute of Telematics and Electronics*, 1994, 31B (6): 43-52.
 - [183] Takagi T, Sugeno M. Fuzzy identification of systems and its applications to modelling and control [J]. *IEEE Transactions on Systems, Man and Cybernetics*, 1985, SMC-15 (1): 116-132.
 - [184] Sugeno M, Tanaka K. Successive identification of a fuzzy model and its applications to prediction of a complex system [J]. *Fuzzy Sets and Systems*, 1991, 42 (3): 315-334.
 - [185] Wu X, Zhu X, Cao G, et al. Dynamic modeling of SOFC based on a T-S fuzzy model [J]. *SIMULATION MODELLING PRACTICE AND THEORY*, 2008, 16 (5): 494-504.
 - [186] Yang J, Li X, Mou H, et al. Predictive control of solid oxide fuel cell based on an improved Takagi-Sugeno fuzzy model [J]. *JOURNAL OF POWER SOURCES*, 2009, 193 (2): 699-705.
 - [187] Jiang J, Li X, Deng Z, et al. Thermal management of an independent steam reformer for a solid oxide fuel cell with constrained generalized predictive control [J]. *INTERNATIONAL JOURNAL OF HYDROGEN ENERGY*, 2012, 37 (17): 12317-12331.
 - [188] 苏佰丽. 非线性系统的有约束模糊预测控制研究 [D]. 南开大学运筹学与控制论, 2006.
 - [189] Wang B, Shi K, Yang L, et al. Fuzzy generalised predictive control for a class of fractional-order non-linear systems [J]. *IET CONTROL THEORY AND APPLICATIONS*,

-
- 2018, 12 (1): 87-96.
- [190] Deng Z, Cao H, Li X, et al. Generalized predictive control for fractional order dynamic model of solid oxide fuel cell output power [J]. JOURNAL OF POWER SOURCES, 2010, 195 (24SI): 8097-8103.
- [191] Angelov P P, Filev D P. An approach to Online identification of Takagi-Suigeno fuzzy models [J]. IEEE TRANSACTIONS ON SYSTEMS MAN AND CYBERNETICS PART B-CYBERNETICS, 2004, 34 (1): 484-498.
- [192] Jiang J, Li X, Deng Z, et al. Thermal management of an independent steam reformer for a solid oxide fuel cell with constrained generalized predictive control [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2012, 37 (17): 12317-12331.
- [193] Cao H, Li X, Deng Z, et al. Thermal management oriented steady state analysis and optimization of a kW scale solid oxide fuel cell stand-alone system for maximum system efficiency [J]. INTERNATIONAL JOURNAL OF HYDROGEN ENERGY, 2013, 38 (28): 12404-12417.
- [194] Zaccaria V, Tucker D, Traverso A. Transfer function development for SOFC/GT hybrid systems control using cold air bypass [J]. APPLIED ENERGY, 2016, 165: 695-706.
- [195] Zaccaria V, Tucker D, Traverso A. A distributed real-time model of degradation in a solid oxide fuel cell, part II: Analysis of fuel cell performance and potential failures [J]. JOURNAL OF POWER SOURCES, 2016, 327: 736-742.

致 谢

在此论文结束之际，三年的博士生涯也将画上圆满的句号。在此首先要特别感谢我的导师杨煜普教授，杨老师为人和蔼，在项目中给予我充分的信任，培养了我独立完成项目的能力，这将会对我的未来产生深远影响；在科研遇到困难时，杨老师的指点迷津总能够让我有新的思路，一种从高维空间看低维投影的豁然开朗。感谢杨老师在生活和工作上的帮助，杨老师严谨的治学态度和对问题的分析能力将是我以后处理事情的楷模。以后不管走在哪里，在上海交通大学 512 实验室的做事方式和处理问题的能力积累都将一直伴随我成长。杨老师孜孜探索、刻苦求真的学术精神，以及豁达乐观的生活态度深深的影响了我，也改变了我，他的谆谆教诲会永远是我人生道路上的一笔宝贵财富。

感谢实验室的兄弟姐妹们宫亮老师、傅春江、李楠、姜腾、张泽瀚、钟纯、詹承俊、郭文博、宋新建、秦超、王一琳、苏梦珂、崔平、许朝雄、曾萧、汪旭鸿，感谢你们的指导、帮助和鼓励，每次交流都受益良多，实验室的组会与大家讨论问题让我收获了许多灵感；特别感谢感谢傅春江、冉永清、宋新建等师兄在我找工作过程中给与的帮助。感谢张泽瀚在机器学习和 Python 方面的指导和帮助，我们一起合作完成了许多有贡献度的学术成果。感谢周远强、向国菲、邓闯、张彪、王鸿源、朱孝刚，在这段难忘的时光里，我们能互相学习，互相交流，共同进步。

衷心感谢 A1503291 班的每一位同学，感谢你们对我学习和生活的帮助，送给我最真诚的友谊。

感谢我的父母的养育之恩，感谢我的家人对我学习和生活的支持。

最后，感谢所有曾经给过我帮助和关心的人，愿你们永远幸福平安。

李双宏

2018 年 6 月

于上海交通大学电信群楼 2-512

附录 1 攻读博士学位期间已发表或录用的论文

一、录用和发表论文

1. 第一作者, Data-driven simultaneous fault diagnosis for solid oxide fuel cell system using multi-label pattern identification, Journal of Power Sources 378, 646-659 (SCI 检索, JCR 一区 IF 6.395)
2. 第一作者, Control System Based on Anode Offgas Recycle for Solid Oxide Fuel Cell System, Mathematical Problems in Engineering 2018:1-16 (SCI 检索, JCR 三区)
3. 第一作者, Intelligent Model Building and GPC-PID Based Temperature Curve Control Strategy for Metallurgical Industry, Mathematical Problems in Engineering 2016 (5):1-16 (SCI 检索 JCR 三区)
4. 第一作者, Fault Tolerant Control of an Anode Offgas Recycle Based SOFC System, 2017 American Control Conference, Publisher: IEEE , Seattle, WA, USA (EI 检索)
5. 第一作者, Distributed fault diagnosis of plantwide process for fuel cell power system, Journal of Computational and Theoretical Nanoscience Volume 14, Issue 4, April 2017, Pages 1876-1885, (EI 检索)
6. 第二作者, Enhanced Fault Detection Based on Ensemble Global-Local Preserving Projections with Quantitative Global-Local Structure Analysis, Industrial & Engineering Chemistry Research 56 (38) (SCI 检索, JCR 二区)
7. 第一作者, Knowledge-transfer learning with multi-label random forests for SOFC simultaneous fault diagnosis, (Submitted to Journal of Power Sources, JCR 一区)
8. 第一作者, Decoupling control of thermal and electrical characteristics for hydrogen-fueled SOFC: An Anode Offgas Recycle Method, (Submitted to Renewable energy, JCR 二区)
9. 通讯作者, Fault Diagnosis and Prognostic of PEM Fuel Cell using Random Forest Feature Extraction, (Submitted to IEEE Transactions on Industrial Electronics,

JCR 一区)

10. 通讯作者, Intelligent Simultaneous Fault Diagnosis for Solid Oxide Fuel Cell System based on Deep Learning, (Submitted to Journal of Power Sources, JCR 一区)

二、专利

1. 第一作者, 基于多源信息融合和深度学习网络的 GIS 故障检测系统及方法, 公开号: CN 106597231

2. 第一作者, 基于机器学习和专家推理系统的金融资本市场计算机仿真系统, 专利号: 201710121362.X

3. 第二作者, 航天器故障快速检测系统, CN 106844775

三、软件著作权

1. 第一作者, 无人机快速故障诊断软件

四、读博期间受到的奖励

1. 上海交通大学光华奖学金 2017

附录 2 攻读博士学位期间参与的科研项目

1. 非完整数据过程的鲁棒故障检测与故障认知方法（国家自然科学基金项目：61273161）
2. 导弹快速故障诊断系统（中国航天科技集团上海航天技术研究院科研项目）
3. 基于多源参量关联分析的 GIS 开关设备动作状态监测和故障诊断（南方电网科技项

